KOCAELİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

YAZILIM MÜHENDİSLİĞİ
ANABİLİM DALI

YÜKSEK LİSANS TEZİ

BULUT PLATFORMLARINDA LOG VE METRİK KORELASYONUNA DAYALI YAPAY ZEKÂ DESTEKLİ PROAKTİF SAĞLIK VE KAPASİTE YÖNETİMİ

YUSUF KAYA

KOCAELİ 2026

KOCAELİ ÜNİVERSİTESİ

FEN BİLİMLERİ ENSTİTÜSÜ

YAZILIM MÜHENDİSLİĞİ

ANABİLİM DALI

YÜKSEK LİSANS TEZİ

BULUT PLATFORMLARINDA LOG VE METRİK KORELASYONUNA DAYALI YAPAY ZEKÂ DESTEKLİ PROAKTİF SAĞLIK VE KAPASİTE YÖNETİMİ

YUSUF KAYA

Doç. Dr. Hakan GÜNDÜZ **Danışman, Kocaeli Üniv.**	**.....**
Prof.Dr./Doç.Dr./Dr. Öğr. Üyesi **Jüri Üyesi, Kocaeli Üniv.**	**.....**
Prof.Dr./Doç.Dr./Dr. Öğr. Üyesi **Jüri Üyesi, Kocaeli Üniv.**	**.....**
Prof.Dr./Doç.Dr./Dr. Öğr. Üyesi **Jüri Üyesi, Kocaeli Üniv.**	**.....**
Prof.Dr./Doç.Dr./Dr. Öğr. Üyesi **Jüri Üyesi, Kocaeli Üniv.**	**.....**

Tezin Savunulduğu Tarih: ../../....

ETİK BEYAN VE ARAŞTIRMA FONU DESTEĞİ

Kocaeli Üniversitesi Fen Bilimleri Enstitüsü tez yazım kurallarına uygun olarak hazırladığım bu tez/proje çalışmasında,

- Bu tezin/projenin bana ait, özgün bir çalışma olduğunu,
- Çalışmamın hazırlık, veri toplama, analiz ve bilgilerin sunumu olmak üzere tüm aşamasında bilimsel etik ilke ve kurallara uygun davrandığımı,
- Bu çalışma kapsamında elde edilen tüm veri ve bilgiler için kaynak gösterdiğimi ve bu kaynaklara kaynakçada yer verdiğimi,
- Bu çalışmamın Kocaeli Üniversitesi'nin abone olduğu intihal yazılım programı kullanılarak Fen Bilimleri Enstitüsü'nün belirlemiş ölçütlere uygun olduğunu,
- Kullanılan verilerde herhangi bir tahrifat yapmadığımı,
- Tezin/projenin herhangi bir bölümünü bu üniversite veya başka bir üniversitede başka bir tez/proje çalışması olarak sunmadığımı,

beyan ederim.

☑ Bu tez/proje çalışmasının herhangi bir aşaması hiçbir kurum/kuruluş tarafından maddi/alt yapı desteği ile desteklenmemiştir.

☐ Bu tez/proje çalışması kapsamında üretilen veri ve bilgiler ..... tarafından ..... no'lu proje kapsamında maddi/alt yapı desteği alınarak gerçekleştirilmiştir.

Herhangi bir zamanda, çalışmamla ilgili yaptığım bu beyana aykırı bir durumun saptanması durumunda, ortaya çıkacak tüm ahlaki ve hukuki sonuçları kabul ettiğimi bildiririm.

.....

Yusuf KAYA

YAYIMLAMA VE FİKRİ MÜLKİYET HAKLARI

Fen Bilimleri Enstitüsü tarafından onaylanan lisansüstü tezimin/projemin tamamını veya herhangi bir kısmını, basılı ve elektronik formatta arşivleme ve aşağıda belirtilen koşullarla kullanıma açma izninin Kocaeli Üniversitesi'ne verdiğimi beyan ederim. Bu izinle Üniversiteye verilen kullanım hakları dışındaki tüm fikri mülkiyet haklarım bende kalacak, tezimin/projemin tamamının ya da bir bölümünün gelecekteki çalışmalarda (makale, kitap, lisans ve patent vb.) kullanımı bana ait olacaktır.
Tezin/projenin kendi özgün çalışmam olduğunu, başkalarının haklarını ihlal etmediğimi ve tezimin/projenin tek yetkili sahibi olduğumu beyan ve taahhüt ederim. Tezimde yer alan telif hakkı bulunan ve sahiplerinden yazılı izin alınarak kullanılması zorunlu metinlerin yazılı izin alarak kullandığımı ve istenildiğinde suretlerini Üniversiteye teslim etmeyi taahhüt ederim.
Yükseköğretim kurulu tarafından yayınlanan ***"Lisanüstü Tezlerin Elektronik Ortamda Toplanması, Düzenlenmesi ve Erişime Açılmasına İlişkin Yönerge"*** kapsamında tezim aşağıda belirtilen koşullar haricinde YÖK Ulusal Tez Merkezi/ Kocaeli Üniversitesi Kütüphaneleri Açık Erişim Sisteminde erişime açılır.

☐ Enstitü yönetim kurulu kararı ile tezimin/projemin erişime açılması mezuniyet tarihinden itibaren 2 yıl ertelenmiştir.
☐ Enstitü yönetim kurulu gerekçeli kararı ile tezimin/projemin erişime açılması mezuniyet tarihinden itibaren 6 ay ertelenmiştir.
☑ Tezim/projem ile ilgili gizlilik kararı verilmemiştir.

.....

Yusuf KAYA

ÖNSÖZ VE TEŞEKKÜR

Bu tez çalışması, OpenStack tabanlı özel bulut altyapılarında log ve metrik korelasyonuna dayalı yapay zekâ destekli proaktif bir sağlık ve kapasite yönetim sistemi geliştirmeyi konu almaktadır.

Çalışmanın planlanması ve yürütülmesi sürecinde değerli bilgi ve desteğini esirgemeyen danışmanım Sayın Doç. Dr. Hakan Gündüz'e içtenlikle teşekkür ederim.

Bu süreçte maddi ve manevi desteklerini her zaman hissettiğim aileme teşekkür ederim.

- 2026 Yusuf KAYA

İÇİNDEKİLER

~ECTİON*.1ETİK BEYAN VE ARAŞTIRMA FONU DESTEĞİ.....i

~ECTİON*.2YAYIMLAMA VE FİKRİ MÜLKİYET HAKLARI.....ii

~HAPTER*.3ÖNSÖZ VE TEŞEKKÜR.....iii

~HAPTER*.4İÇİNDEKİLER.....iv

~HAPTER*.5ŞEKİL LİSTESİ.....xi

~HAPTER*.6TABLO LİSTESİ.....xii

~HAPTER*.7SİMGELER VE KISALTMALAR DİZİNİ.....xiv

~ECTİON*.8ÖZET.....xv

@toc english

~ECTİON*.9ABSTRACT.....xvi

1. ~HAPTER.1GİRİŞ.....1

1.1. Tezin Konusu ve Önemi 1

1.2. Problem Tanımı 1

1.3. Tezin Amacı ve Kapsamı 2

1.4. Tezin Katkıları 3

1.5. Tez Organizasyonu 3

2. ~HAPTER.2GENEL BİLGİLER.....5

2.1. Yapay Zekâ Destekli BT Operasyonları (AIOps) 5

2.2. Bulut Altyapılarında Kapasite Yönetimi 5

2.3. Log Analizi ve Anomali Tespiti 6

2.4. Makine Öğrenmesi ile Zaman Serisi Regresyonu 7

2.5. Açıklanabilir Yapay Zekâ ve SHAP 8

2.6. Büyük Dil Modelleri ve Operasyonel Zekâ 8

2.6.1. Transformer Mimarisi ve Büyük Dil Modelleri 8

2.6.2. Bağlam İçi Öğrenme ve İstem Mühendisliği 9

2.6.3. LLM'lerin IT Operasyonlarında Kullanımı 10

2.7. OpenStack Mimarisi ve Bileşenleri 10

2.7.1. Nova: İşlem Servisi 11

2.7.2. Neutron: Ağ Servisi 11

2.7.3. Cinder: Blok Depolama Servisi 12

2.7.4. Keystone: Kimlik ve Yetkilendirme Servisi 12

2.7.5. OpenStack Servis Etkileşim Modeli 13

2.8. Prometheus ve Thanos ile Metrik İzleme 13

2.8.1. Prometheus Mimarisi 13

2.8.2. Thanos ile Uzun Vadeli Depolama 14

2.9. OpenSearch ile Log Yönetimi 14

2.9.1. OpenSearch'in Temelleri 14

2.9.2. Log Türleri ve Yapısı 15

2.9.3. Fluentd ile Log İletim Pipeline'ı 15

2.9.4. OpenSearch Aggregation ile Saatlik Log Özellik Üretimi 16

2.10. Bulut İzleme Paradigmaları: Reaktif'ten Proaktif'e 17

2.10.1. Gözlemlenebilirlik (Observability) Kavramı 17

2.10.2. Reaktif İzleme 17

2.10.3. Proaktif İzleme ve Tahminsel Yaklaşımlar 18

2.10.4. Mevcut AIOps Platformları 18

2.11. Zaman Serisi Tahmini: İstatistiksel ve Öğrenme Tabanlı Yöntemler 19

2.11.1. İstatistiksel Yöntemler 19

2.11.2. Makine Öğrenmesi ile Zaman Serisi Regresyonu 19

2.11.3. Özellik Mühendisliğinin Rolü 20

2.12. Literatürdeki Boşluk ve Tezin Konumlandığı Alan 20

2.13. İlgili Çalışmalar Karşılaştırması 21

2.13.1. AIOps ve Anomali Tespiti 21

2.13.2. Log Analizi 21

2.13.3. Bulut Kapasite Tahmini 22

2.13.4. LLM Tabanlı Operasyonel Zekâ 23

3. ~HAPTER.3MALZEME VE YÖNTEM 25

3.1. Sistem Mimarisi 25

3.2. Deney Ortamı ve Veri Toplama Altyapısı 26

3.2.1. OpenStack Altyapısı 26

3.2.2. Metrik Toplama: Prometheus ve Thanos 26

3.2.3. Log Toplama: OpenSearch 27

3.2.4. Veri Akışı 27

3.3. Veri Kümesi 28

3.3.1. Metrik Verisi 28

3.3.2. Log Verisi 28

3.3.3. Eğitim ve Test Bölünmesi 29

3.4. Veri Ön İşleme 29

3.4.1. Eksik Değer İşleme 29

3.4.2. Aykırı Değer İşleme 30

3.4.3. Ölçekleme 30

3.5. Log İşleme Pipeline'ı 30

3.5.1. Aşama 1 — Ayrıştırma ve Sınıflandırma 30

3.5.2. Aşama 2 — Zamansal Agregasyon ve Trend Analizi 31

3.5.3. Aşama 3 — Anomali Tespiti 32

3.5.4. Aşama 4 — Ön-Arıza Örüntü Çıkarımı 32

3.6. Özellik Mühendisliği 33

3.6.1. Özellik Formülasyonları 34

3.6.2. Özellik Sayısı Dökümü 35

3.7. Kapasite Tahmin Modelleri 36

3.7.1. Değerlendirme Metrikleri 37

3.8. SHAP Açıklanabilirlik Analizi 38

3.8.1. Neden SHAP? 38

3.8.2. Teknik Uygulama 39

3.9. Öneri Motoru ve LLM Entegrasyonu 40

3.9.1. Neden LLM? 40

3.9.2. Neden Zenginleştirilmiş Bağlam? 40

3.9.3. Kural Tabanlı Katman 41

3.9.4. LLM Katmanı ve İstem Şablonu 41

3.9.5. Öneri Puanlama ve Önceliklendirme 43

3.10. Çapraz Doğrulama ve Model Seçim Stratejisi 43

3.10.1. Zamana Göre Bölme (Walk-Forward) Stratejisi 43

3.10.2. Model Seçim Kriterleri 44

3.11. Sistem Bütünleşimi ve Operasyonel Çıktılar 44

3.11.1. Pipeline Çalıştırma Akışı 44

3.11.2. Yapılandırma ve Parametre Yönetimi 45

3.11.3. Çıktı Formatı ve Raporlama 45

4. ~HAPTER.4BULGULAR.....47

4.1. Eğitim Dönemi Kapasite Kullanım Analizi..... 47

4.1.1. Kaynak Kullanım Trendleri..... 47

4.1.2. Mevsimsellik ve İş Yükü Örüntüleri..... 48

4.2. Kapasite Tahmin Modeli Performansı..... 48

4.2.1. vCPU Kapasite Tahmini..... 48

4.2.2. Bellek Kapasite Tahmini..... 50

4.2.3. Disk Kapasite Tahmini..... 51

4.2.4. Genel Değerlendirme..... 51

4.2.5. Model Karşılaştırma Özeti..... 53

4.3. SHAP Açıklanabilirlik Bulguları..... 53

4.3.1. vCPU Tahmininde Özellik Önemleri..... 53

4.3.2. Bellek ve Disk Tahmininde Özellik Önemleri..... 55

4.4. Log Analizi ve Anomali Tespiti Bulguları..... 57

4.4.1. Servis Bazında Log Dağılımı..... 57

4.4.2. Log Tipi Bazında Anomali Özeti..... 58

4.5. Öneri Motoru ve LLM Çıktıları..... 59

4.6. İleriye Dönük Kapasite Projeksiyonları..... 60

4.6.1. Kapasite Dolum Tarihleri..... 60

4.6.2. Kritik Senaryo Analizi..... 62

4.6.3. Model Tahmin Aralığı Değerlendirmesi 62

4.7. Log Risk Skoru ve Servis Sağlık Analizi 62

4.7.1. Log Risk Skoru Hesaplama Yöntemi 62

4.7.2. Servis Bazında Log Risk Skoru Sonuçları 63

4.7.3. Haftalık Log Risk Skoru Trendleri 64

4.7.4. Log Risk Skoru ile Kapasite Tahmini Korelasyonu 64

5. ~HAPTER.5SONUÇLAR VE ÖNERİLER 66

5.1. Temel Bulgular 66

5.1.1. Kapasite Tahmin Modeli 66

5.1.2. SHAP Açıklanabilirlik Bulguları 66

5.1.3. Log Analizi ve Erken Uyarı 67

5.1.4. Öneri Motoru ve LLM Entegrasyonu 67

5.2. Tezin Özgün Katkıları 67

5.3. Sınırlılıklar 68

5.4. Gelecek Çalışma Önerileri 69

5.5. Genel Değerlendirme 70

~HAPTER*.44KAYNAKLAR 72

~ECTİON*.45EKLER 75

~HAPTER*.55KİŞİSEL YAYIN VE ESERLER 80

~HAPTER*.56ÖZGEÇMİŞ 81

ŞEKİL LİSTESİ

Figure 3.1. CloudMon pipeline'ının genel akışı: veri yükleme, log analizi, özellik mühendisliği, kapasite tahmini, SHAP analizi ve öneri üretimi. 25

Figure 3.2. CloudMon veri akışı: OpenStack servislerinden metrik (Prometheus/Thanos) ve log (Fluentd/OpenSearch) verilerinin toplanması ve pipeline'a beslenmesi. 28

Figure 3.3. Dört aşamalı log işleme pipeline'ı çıktıları: log trendi, anomali tespiti ve cascade analizi. 31

Figure 3.4. vCPU 24 saatlik tahmin modeli için SHAP özellik önem sıralaması (ilk 20 özellik). 39

Figure 4.1. Tüm modeller için R^2 karşılaştırması — vCPU, Bellek ve Disk kaynakları, 24 ve 72 saatlik ufuklar. 49

Figure 4.2. En iyi modelin (Doğrusal Regresyon) gerçek ve tahmin değerleri karşılaştırması — test kümesi. 52

Figure 4.3. vCPU 24 s modeli için SHAP beeswarm grafiği — her gözlem için ϕ_i dağılımı ve özellik değeri renk kodlaması. 54

Figure 4.4. Bellek 24 s modeli için SHAP beeswarm grafiği. 56

Figure 4.5. Test dönemi log analizi: trend değişimi, anomali sayısı ve erken uyarı sinyali dağılımı. 57

Figure 4.6. Anthropic Claude Sonnet (`claude-sonnet-4-6`) tarafından üretilen operasyonel öneri raporu — 2026-06-30 tarihli test kümesi girdisi. 61

TABLO LİSTESİ

Table 2.1. İlgili çalışmalar karşılaştırma tablosu 24
Table 3.1. Kullanılan metrik değişkenleri 29
Table 3.2. Ön-arıza örüntü analizi — geçmiş 15 incident üzerinden hesaplanmış değerler 33
Table 3.3. Özellik kategorileri ve sayıları 34
Table 3.4. Özellik kategorisi ve sayı dökümü 35
Table 3.5. Kapasite tahmin modelleri hiperparametreleri 36
Table 3.6. Her (kaynak, ufuk) çifti için seçilen en iyi model 44
Table 3.7. CloudMon pipeline modülleri ve sorumlulukları 45
Table 4.1. Eğitim dönemi (Oca 2025–Mar 2026) kaynak kullanım istatistikleri 47
Table 4.2. vCPU kullanım oranı için 24 saatlik tahmin sonuçları (test kümesi) 48
Table 4.3. vCPU kullanım oranı için 72 saatlik tahmin sonuçları (test kümesi) 49
Table 4.4. Bellek kullanım oranı için 24 saatlik tahmin sonuçları (test kümesi) 50
Table 4.5. Bellek kullanım oranı için 72 saatlik tahmin sonuçları (test kümesi) 50
Table 4.6. Disk kullanım oranı için 24 saatlik tahmin sonuçları (test kümesi) 51
Table 4.7. Disk kullanım oranı için 72 saatlik tahmin sonuçları (test kümesi) 51
Table 4.8. Tüm model ve senaryolar için R^2 özet tablosu 53
Table 4.9. vCPU 24 s LR modeli için SHAP özellik önemleri (ilk 10 özellik, ortalama $|\phi_i|$) 55
Table 4.10. Servis bazında 3 aylık test dönemi toplam log sayıları 58
Table 4.11. Test dönemi (Nis–Haz 2026) log tipi bazında z-skor anomali özeti 58
Table 4.12. Kanal bazında öneri dağılımı — test kümesi son gözlemi (2026-06-30) 59
Table 4.13. Kapasite dolum tarihi projeksiyonu (2026-06-30 baz alınarak) 60

Table 4.14. Servis bazında log risk skoru — son gözlem noktası (2026-06-30 23:00 UTC) 63
Table 4.15. Son dört hafta — Nova haftalık ortalama log risk skoru 64
Table 4.16. Log özellik katkısı — vCPU 24 s Doğrusal Regresyon ablasyon deneyi 64
Table A.1.. CloudMon log tipi kataloğu — tam tanımlar ve kaynak servisler 76
Table A.2.. Tam model karşılaştırma — vCPU 24 s (tekrar, tam metrik) 77
Table A.3.. Tam model karşılaştırma — vCPU 72 s 77
Table A.4.. Tam model karşılaştırma — Bellek 24 s 77
Table A.5.. Tam model karşılaştırma — Bellek 72 s 77
Table A.6.. Tam model karşılaştırma — Disk 24 s 78
Table A.7.. Tam model karşılaştırma — Disk 72 s 78
Table A.8.. Bellek 24 s LR modeli için SHAP özellik önemleri (ilk 10 özellik, ortalama $|\phi_i|$) 78
Table A.9.. Disk 24 s LR modeli için SHAP özellik önemleri (ilk 10 özellik, ortalama $|\phi_i|$) 79

SİMGELER VE KISALTMALAR DİZİNİ

Simgeler

F_1	:	F1 skoru, (boyutsuz)
h	:	Tahmin ufku, (saat)
L	:	Kayıp fonksiyonu değeri, (boyutsuz)
n	:	Gözlem sayısı, (adet)
P	:	Kesinlik (precision), (boyutsuz)
R	:	Duyarlılık (recall), (boyutsuz)
R^2	:	Belirleme katsayısı, (boyutsuz)
s	:	Log anomali skoru, (boyutsuz)
T	:	Zaman penceresi uzunluğu, (saat)
y	:	Gerçek kaynak kullanım değeri, (%)
$\hat{y}$	:	Tahmin edilen kaynak kullanım değeri, (%)
θ	:	Kapasite alarm eşiği, (%)
μ	:	Kayan ortalama, (boyutsuz)
ϕ	:	SHAP açıklama değeri, (boyutsuz)
σ	:	Kayan standart sapma, (boyutsuz)

Kısaltmalar

AI	:	Artificial Intelligence (Yapay Zekâ)
AIOps	:	Artificial Intelligence for IT Operations (BT Operasyonları için Yapay Zekâ)
API	:	Application Programming Interface (Uygulama Programlama Arayüzü)
AUC	:	Area Under the Curve (Eğri Altındaki Alan)
FN	:	False Negative (Yanlış Negatif)
FP	:	False Positive (Yanlış Pozitif)
GBT	:	Gradient Boosted Trees (Gradyan Artırmalı Ağaçlar)
IaaS	:	Infrastructure as a Service (Hizmet Olarak Altyapı)
IQR	:	Interquartile Range (Çeyrekler Arası Aralık)
JSON	:	JavaScript Object Notation
LGBM	:	Light Gradient Boosting Machine (Hafif Gradyan Artırma Makinesi)
LLM	:	Large Language Model (Büyük Dil Modeli)
LR	:	Linear Regression (Doğrusal Regresyon)
MAE	:	Mean Absolute Error (Ortalama Mutlak Hata)
MAPE	:	Mean Absolute Percentage Error (Ortalama Mutlak Yüzdelik Hata)
ML	:	Machine Learning (Makine Öğrenmesi)
MLP	:	Multilayer Perceptron (Çok Katmanlı Algılayıcı)
RMSE	:	Root Mean Squared Error (Kök Ortalama Kare Hata)
ROC	:	Receiver Operating Characteristic (Alıcı İşletim Karakteristiği)
RF	:	Random Forest (Rastgele Orman)
SHAP	:	SHapley Additive exPlanations (Shapley Toplamsal Açıklamalar)
TSDB	:	Time Series Database (Zaman Serisi Veritabanı)
TYK	:	Tez Yazım Kılavuzu
VM	:	Virtual Machine (Sanal Makine)
XAI	:	Explainable Artificial Intelligence (Açıklanabilir Yapay Zekâ)
XGB	:	eXtreme Gradient Boosting (Aşırı Gradyan Artırma)

BULUT PLATFORMLARINDA LOG VE METRİK KORELASYONUNA DAYALI YAPAY ZEKÂ DESTEKLİ PROAKTİF SAĞLIK VE KAPASİTE YÖNETİMİ

ÖZET

Özel bulut altyapılarında kapasitesizlik kaynaklı servis kesintileri, genellikle eşik alarm sistemlerinin uyarı üretmesinden çok önce, log ve metrik verilerine yansımaktadır. Bu tezde, OpenStack tabanlı özel bulut ortamları için proaktif kapasite yönetimini destekleyen uçtan uca bir AIOps sistemi olan CloudMon geliştirilmiştir.

CloudMon dört ana bileşenden oluşmaktadır. İlk bileşende, Nova, Neutron ve Keystone servislerinden toplanan ham metrikler ile sistem logları ortak bir özellik uzayında birleştirilmekte; 272 boyutlu hibrit vektörler elde edilmektedir. İkinci bileşende yedi farklı algoritmayı kapsayan 42 kapasite tahmin modeli, vCPU, bellek ve disk kaynakları için 24 ve 72 saatlik ufuklarda eğitilmektedir. Üçüncü bileşende dört aşamalı log işleme pipeline'ı; trend tespiti, z-skor anomali tespiti, ön-arıza örüntü eşleştirme ve cascade risk tespiti adımlarını kapsamaktadır. Son bileşende SHAP açıklanabilirlik analizi ve büyük dil modeli (LLM) destekli öneri motoru bir araya getirilerek operatöre gerekçelendirilmiş aksiyon önerileri sunulmaktadır.

Nisan–Haziran 2026 döneminde gerçek OpenStack kümesi üzerinde yürütülen deneyler, Doğrusal Regresyon'un 24 saatlik ufuklarda ağaç tabanlı tüm algoritmaları büyük farkla geçtiğini ortaya koymaktadır: vCPU için $R^2 = 0{,}9577$, Bellek için $R^2 = 0{,}7945$. SHAP analizi, log tabanlı özelliklerin vCPU tahmin modelinin ilk 10 özelliği arasında dört sırayla yer aldığını göstermekte; bu bulgu log–metrik korelasyonunun kapasite tahminine anlamlı katkı yaptığını nicel olarak doğrulamaktadır. Log pipeline'ı, *slow_response* loglarının arızadan ortalama 68 saat önce %287 artış gösterdiğini ve üç servisin eş zamanlı degradasyonuyla ortaya çıkan cascade riskini tespit etmiştir. LLM katmanı kapasite durumunu, SHAP açıklamalarını ve log anomalilerini birleştirerek 2 kritik ve 7 uyarı düzeyinde toplam 9 önce sıralanmış öneri üretmiştir.

Anahtar Kelimeler: AIOps, Kapasite Tahmini, Açıklanabilir Yapay Zekâ, Log Analizi, Büyük Dil Modeli, OpenStack.

AI-ASSISTED PROACTIVE HEALTH AND CAPACITY MANAGEMENT BASED ON LOG AND METRIC CORRELATION IN CLOUD PLATFORMS

ABSTRACT

In private cloud infrastructures, service outages caused by resource exhaustion are often reflected in log and metric data long before threshold-based alarm systems raise alerts. This thesis presents CloudMon, an end-to-end AIOps system designed to support proactive capacity management in OpenStack-based private cloud environments.

CloudMon comprises four main components. In the first component, raw metrics collected from Nova, Neutron, and Keystone services are combined with system logs in a shared feature space, yielding 272-dimensional hybrid feature vectors. In the second component, 42 capacity forecasting models spanning seven algorithms are trained for vCPU, memory, and disk resources across 24-hour and 72-hour forecasting horizons. In the third component, a four-stage log processing pipeline covers trend detection, z-score anomaly detection, pre-failure pattern matching, and cascade risk identification. In the final component, SHAP explainability analysis and a large language model (LLM)-based recommendation engine are combined to deliver justified, actionable suggestions to cloud operators.

Experiments conducted on a real OpenStack cluster over the April–June 2026 period reveal that Linear Regression substantially outperforms all tree-based algorithms at the 24-hour horizon, achieving $R^2 = 0.9577$ for vCPU and $R^2 = 0.7945$ for memory. SHAP analysis demonstrates that log-derived features occupy four of the top ten positions in the vCPU forecasting model, quantitatively confirming that log–metric correlation contributes meaningfully to capacity prediction. The log pipeline detected that *slow_response* log counts increase by 287% on average 68 hours before a failure event, and identified a cascade risk arising from the simultaneous degradation of three services. The LLM layer synthesized capacity status, SHAP explanations, and log anomalies into a single operational report containing 9 prioritized recommendations—2 critical and 7 warnings.

Keywords: AIOps, Capacity Forecasting, Explainable Artificial Intelligence, Log Analysis, Large Language Model, OpenStack.

1. GİRİŞ

1.1. Tezin Konusu ve Önemi

Kurumsal ve akademik yapılarda giderek yaygınlaşan özel bulut altyapıları, büyük miktarda işlem, bellek ve depolama kaynağı barındırmaktadır. Bu altyapıların sağlıklı biçimde işletilmesi; kaynak kullanımının takip edilmesini, arıza öncesi sinyallerin erkenden fark edilmesini ve operasyon ekiplerinin zamanında müdahale edebilmesini gerektirmektedir. OpenStack (OpenStack Foundation, 2024), açık kaynaklı mimarisi ve modüler bileşenleriyle (Nova, Neutron, Cinder, Keystone) özel bulut kurulumlarında tercih edilen önde gelen platformlardan biridir.

Geleneksel izleme yaklaşımları, metrik eşik değerlerini anlık olarak kontrol eden reaktif sistemlere dayanmaktadır. Bu yaklaşım, yalnızca bir kaynak eşiği aştıktan sonra alarm üretmekte; operasyonel müdahale için yeterli zaman tanımamaktadır. Oysa log verileri ve performans metrikleri birlikte değerlendirildiğinde, arıza veya kapasite aşımına ilişkin örüntüler genellikle saatler, hatta günler öncesinden gözlemlenebilmektedir. Bu gerçeklik, log ve metrik korelasyonuna dayalı proaktif izleme yaklaşımlarını araştırmacılar ve uygulayıcılar için kritik bir alan haline getirmiştir (Notaro et al., 2021).

Yapay zekâ destekli BT operasyonları (AIOps) alanındaki çalışmalar, büyük ölçekli sistem log ve metriklerinden anlamlı örüntüler çıkarmak için makine öğrenmesi yöntemlerinin kullanılabileceğini göstermektedir (Dang et al., 2019). Bununla birlikte, mevcut çalışmaların büyük çoğunluğu log analizi ya da metrik bazlı kapasite tahminini ayrı ayrı ele almakta; bu iki veri kaynağını tek bir karar destek çerçevesinde birleştiren uygulamalı çalışmalar ise sınırlı kalmaktadır.

1.2. Problem Tanımı

Özel bulut altyapılarında kaynak yönetimi birbirine bağlı birden fazla zorluk barındırmaktadır:

1. **Reaktif izleme sınırlaması:** Mevcut sistemler kaynak kullanımı eşiği aştığında alarm üretir; ancak o noktada operatörün müdahale süresi kısıtlanmıştır. Örneğin bellek kullanımı %88 eşiğine yaklaştığında artık yeni sanal makine taleplerini karşılamak güçleşmektedir.
2. **Log–metrik kopukluğu:** Log sistemleri (OpenSearch/Elasticsearch) ve metrik

sistemleri (Prometheus/Thanos) ayrı araçlarla yönetilmekte, iki kaynak arasındaki ilişki çoğunlukla manuel incelemeye bırakılmaktadır. Bu kopukluk, *slow_response* ve *memory_pressure* gibi erken uyarı loglarının kapasite verileriyle ilişkilendirilmesini güçleştirmektedir.

3. **Dönemsel yük artışları:** Staj dönemleri, sınav dönemleri ve eğitim kampanyaları gibi dönemsel olaylar kaynaklar üzerinde ani ve öngörülemeyen baskı yaratmaktadır. Bu baskılar, statik eşik tabanlı sistemler tarafından önceden saptanamamaktadır.
4. **Açıklanabilirlik eksikliği:** Tahmin modelleri genellikle "kara kutu" olarak çalışmakta; hangi sinyalin kapasiteyi ne ölçüde etkilediği operatörlere aktarılamamaktadır. Bu durum model çıktılarına güveni zayıflatmaktadır.

1.3. Tezin Amacı ve Kapsamı

Bu tezin amacı, OpenStack tabanlı özel bulut altyapısı için log ve metrik korelasyonuna dayalı, yapay zekâ destekli proaktif bir sağlık ve kapasite yönetim sistemi (CloudMon) geliştirmek ve deneysel olarak değerlendirmektir.

Sistem, Ocak 2025 – Temmuz 2026 (18 ay, 13.104 saatlik nokta) dönemine ait OpenStack metrik ve log verisi üzerinde altı adımlı bir pipeline çerçevesinde çalışmaktadır:

Adım 1. Veri Yükleme: Prometheus/Thanos kaynaklı saatlik metrikler ile OpenSearch kaynaklı log özellik tablosu okunur.

Adım 2. Log İşleme Hattı: Dört aşamalı log analizi yürütülür: (i) ayrıştırma ve tip sınıflandırması, (ii) zamansal agregasyon ve z-skor hesabı, (iii) anomali tespiti, (iv) ön-arıza örüntü çıkarımı.

Adım 3. Özellik Mühendisliği: Metrik ve log sayımlarından 272 özellik üretilir (hareketli ortalama/std, gecikme, değişim hızı, zaman özellikleri, erken uyarı bileşik sinyali).

Adım 4. Kapasite Tahmini: Yedi farklı regresyon algoritması (LR, RF, GBT, XGB, LGBM, CatBoost, MLP) üç kaynak (vCPU, Bellek, Disk) için iki tahmin ufkunda (24 saat, 72 saat) eğitilerek toplam 42 model değerlendirilir.

Adım 5. SHAP Analizi: Her model için özellik önem sıralaması TreeExplainer/LinearExplainer yöntemiyle hesaplanır; hangi metrik ya da log tipinin tahmine en çok katkıda bulunduğu yorumlanır.

Adım 6. Proaktif Öneri Üretimi: Kural tabanlı öneri motoru ve iki büyük dil modeli (Claude Sonnet, GPT-4o) birleştirilerek operasyon ekibine önceliklendirilmiş, aksiyona dönüştürülebilir öneriler üretilir.

Çalışma kapsamı dışında bırakılanlar: gerçek zamanlı akış işleme (streaming), OpenStack altyapısının kurulumu ve yapılandırması, veri üretim süreçlerinin iyileştirilmesi.

1.4. Tezin Katkıları

Bu çalışmanın başlıca özgün katkıları şunlardır:

1. **Log–metrik korelasyonuna dayalı kapasite tahmini:** Literatürdeki çalışmaların büyük bölümü metrik ya da log verisini ayrı ele alırken, bu çalışmada her ikisi ortak bir özellik uzayında birleştirilerek kapasite tahminine katkısı ölçülmüştür. SHAP analizleri, *resource_exhausted* ve *scheduler_degradation* gibi log sayılarının kapasite tahmininde metrik özellikleriyle rekabet edebilir düzeyde etkili olduğunu ortaya koymaktadır.
2. **Dört aşamalı log işleme pipeline'ı:** Ham log sayımlarından ön-arıza örüntülerine uzanan sistematik bir analiz hattı tasarlanmıştır. Bu hat, *slow_response* loglarının arızadan ortalama 68 saat önce anormal artış gösterdiği gibi içgörüler üretmektedir.
3. **Açıklanabilir kapasite tahmin sistemi:** SHAP değerleri her tahmin için hesaplanmakta ve en etkili özellikler operatöre aktarılmaktadır. Bu yaklaşım, kara kutu model çıktılarını yorumlanabilir aksiyonlara dönüştürmektedir (Lundberg et al., 2020; Lundberg and Lee, 2017).
4. **Zenginleştirilmiş bağlamla LLM destekli öneri motoru:** Metrik durumu, log anomali sinyalleri, SHAP özellik önem sıralaması ve cascade riski birleştirilerek oluşturulan yapılandırılmış bağlam, Claude Sonnet ve GPT-4o modellerine iletilmektedir. Sistem, servis bazında önceliklendirilmiş ve uygulanabilir aksiyonlar üretmektedir (Brown et al., 2020; OpenAI, 2023).

1.5. Tez Organizasyonu

Tez altı ana bölümden oluşmaktadır. Birinci bölümde (Giriş) çalışmanın konusu, problemi, amacı ve katkıları özetlenmiştir. İkinci bölümde (Genel Bilgiler) AIOps, bulut kapasite yönetimi, log analizi, açıklanabilir yapay zekâ ve büyük dil modelleri konularındaki ilgili literatür incelenmektedir. Üçüncü bölümde (Malzeme ve Yöntem) CloudMon sisteminin mimarisi, kullanılan veri kümesi, özellik mühendisliği, model

eğitimi ve öneri motoru ayrıntılandırılmaktadır. Dördüncü bölümde (Bulgular) 42 modelin karşılaştırmalı sonuçları, SHAP analizleri ve öneri motoru çıktıları sunulmaktadır. Beşinci bölümde (Sonuçlar ve Öneriler) elde edilen bulgular değerlendirilmekte, çalışmanın sınırlılıkları tartışılmakta ve gelecek çalışma önerileri sunulmaktadır.

2. GENEL BİLGİLER

Bu bölümde tez çalışmasının kavramsal altyapısını oluşturan konular ele alınmaktadır. Önce yapay zekâ destekli BT operasyonları (AIOps) kavramı ve bulut platformlarındaki kapasite yönetimi sorunları sunulmaktadır. Ardından log analizi ve anomali tespiti yöntemleri incelenmekte, makine öğrenmesi modelleri ile açıklanabilir yapay zekâ yaklaşımları tartışılmaktadır. Son olarak büyük dil modellerinin operasyonel zekayla entegrasyonu ve literatürdeki açık noktalar değerlendirilerek tezin konumlandığı alan belirlenmektedir.

2.1. Yapay Zekâ Destekli BT Operasyonları (AIOps)

BT sistemlerinin ölçeği büyüdükçe operasyonel verilerin hacmi (log, metrik, olay akışları) insan kapasitesinin çok üzerine çıkmaktadır. Bu gerçeklik, makine öğrenmesi ve büyük veri tekniklerini BT operasyonları süreçlerine entegre eden AIOps (Artificial Intelligence for IT Operations) yaklaşımını doğurmuştur (Dang et al., 2019).

Notaro ve arkadaşları, AIOps literatürünü kapsamlı biçimde inceleyerek başarısızlık yönetimi için kullanılan yöntemleri anomali tespiti, kök neden analizi ve olay korelasyonu başlıkları altında sınıflandırmıştır (Notaro et al., 2021). Bu sınıflandırmaya göre proaktif kapasite yönetimi, anomali tespitinin özel bir formu olarak değerlendirilebilir: kaynak kullanımının belirli bir eşiği aşmadan önce örüntüden sapması tespit edilerek önleyici aksiyon alınır.

AIOps'un başarısı büyük ölçüde veri kalitesine ve farklı kaynaklardan gelen sinyallerin etkin biçimde birleştirilmesine bağlıdır. Metrikler, kesintisiz sayısal sinyal sağlarken; loglar, hata türleri, uyarı desenleri ve servis sağlık durumu hakkında metriklerin içermediği bağlamsal bilgi sunar. Bu iki kaynağın korelasyonu, tek kaynaklı yaklaşımlara kıyasla daha erken ve daha kesin uyarı üretilmesine olanak tanımaktadır.

2.2. Bulut Altyapılarında Kapasite Yönetimi

Kapasite yönetimi, mevcut altyapının talepleri karşılamaya devam edip etmeyeceğini öngörme ve buna göre planlama yapma sürecidir. Bulut ortamlarında bu süreç; vCPU, bellek ve disk gibi temel kaynakların kullanım trendlerinin izlenmesini ve gelecekteki tüketimin tahmin edilmesini kapsamaktadır.

Geleneksel yaklaşımlar iş yükü tahmininde ARIMA ve üstel düzeltme gibi istatistiksel zaman serisi yöntemlerine dayanmaktadır (Calheiros et al., 2015). Bu yöntemler durağan ve periyodik örüntülü verilerde başarılı olurken, staj dönemleri ve anlık yük artışları gibi düzensiz olayları içeren bulut iş yüklerinde yetersiz kalabilmektedir.

Makine öğrenmesi yöntemleri bu sınırlılığı aşmak için önerilmiştir. Özellik mühendisliği yoluyla geçmiş pencere istatistikleri, gecikme değerleri ve takvim bilgileri (iş günü, saat) modele dahil edilerek zaman serisi tahmini bir regresyon problemine dönüştürülmektedir. Bu yaklaşımda her gözlem noktası, geçmiş zaman penceresinden türetilen özellik vektörüyle temsil edilmekte ve model bu vektörden gelecekteki kaynak kullanımını tahmin etmektedir.

OpenStack tabanlı özel bulut altyapılarında Nova (işlem), Cinder (depolama), Neutron (ağ) ve Keystone (kimlik) bileşenleri, Prometheus/Thanos ile saatlik metrik akışı sağlayarak makine öğrenmesi destekli kapasite yönetiminin veri altyapısını oluşturmaktadır (OpenStack Foundation, 2024).

2.3. Log Analizi ve Anomali Tespiti

Log verileri, sistem olaylarının zaman damgalı metin kaydıdır. Ham loglardan kapasite yönetimine anlamlı girdi oluşturmak birkaç aşamalı bir işlemi gerektirir: ayrıştırma ve sınıflandırma, zamansal agregasyon, anomali tespiti ve ön-arıza örüntü çıkarımı.

He ve arkadaşları, log ayrıştırma algoritmalarını kapsamlı biçimde değerlendirerek Drain, Spell ve AEL gibi yöntemlerin gerçek dünya log verisi üzerindeki etkinliğini karşılaştırmıştır (He et al., 2016). Log analizi için otomasyon yaklaşımlarını inceleyen daha kapsamlı bir tarama çalışması, ayrıştırma, kümeleme, sınıflandırma ve anomali tespiti adımlarını birleştiren bütünleşik pipeline yaklaşımlarının etkinliğini ortaya koymaktadır (He et al., 2021).

Anomali tespiti açısından Chandola ve arkadaşları, noktasal, bağlamsal ve kolektif anomaliler arasındaki ayrımı tanımlayarak istatistiksel, kümeleme tabanlı ve sınıflandırma tabanlı yöntemleri sistematik biçimde sınıflandırmıştır (Chandola et al., 2009). Derin öğrenme tabanlı yaklaşımlar ise özellikle yüksek boyutlu ve yapılandırılmamış veriler için güçlü alternatifler sunmaktadır (Pang et al., 2021).

Log dizisi anomali tespitinde önemli bir dönüm noktası olan DeepLog, sistem loglarını LSTM modeli ile modelleyerek normal log dizilerinden sapmaları tespit etmekte ve tanılamaktadır (Du et al., 2017). Log verisi için derin öğrenme yaklaşımlarını derleyen güncel bir tarama çalışması, denetimsiz ve yarı denetimli yöntemlerin üretim ortamlarındaki kararsız log formatlarına karşı daha dayanıklı olduğunu göstermektedir (Landauer et al., 2023).

Bulut platformlarında loglar yalnızca hata bildirmez; arızadan saatler önce ortaya çıkan *yavaş yanıt*, *bellek baskısı* ve *bağlantı havuzu uyarısı* gibi erken uyarı sinyalleri de içerir. Bu sinyallerin zamansal örüntülerinin çıkarılması ve metrik verisiyle korelasyonu, proaktif izlemenin temel katkısını oluşturmaktadır.

2.4. Makine Öğrenmesi ile Zaman Serisi Regresyonu

Kapasite tahmini bu çalışmada bir regresyon problemi olarak ele alınmaktadır: geçmiş özellik vektörü verildiğinde h saat sonraki kaynak kullanım oranı $\hat{y}$ tahmin edilmektedir.

Doğrusal Regresyon (LR): Özellik vektörünün doğrusal kombinasyonuyla hedef değişkeni modelleyen temel yöntemdir. Yorumlanabilirliği yüksektir; ancak doğrusal olmayan ilişkileri yakalayamaz. Bu çalışmada StandardScaler ile normalizasyon uygulanmaktadır.

Rastgele Orman (RF): Breiman tarafından önerilen topluluk öğrenmesi yöntemidir (Breiman, 2001). Birbirinden bağımsız karar ağaçlarının tahminlerini ortalaması alarak oluşturur; aşırı öğrenmeye karşı dayanıklıdır ve özellik önem skoru hesaplamaya doğrudan olanak tanır.

Gradyan Artırmalı Ağaçlar (GBT): Friedman tarafından geliştirilen ve artık (residual) tabanlı sıralı ağaç inşa eden yöntemdir (Friedman, 2001). XGBoost (Chen and Guestrin, 2016), LightGBM (Ke et al., 2017) ve CatBoost (Prokhorenkova et al., 2018) bu temel yöntemin hesaplama verimliliğini ve doğruluğunu artıran modern uygulamalarıdır.

Çok Katmanlı Algılayıcı (MLP): İleri beslemeli yapay sinir ağıdır. Doğrusal olmayan ilişkileri yakalama kapasitesi yüksektir; ancak hiperparametre ayarı ve eğitim süresi diğer yöntemlere kıyasla daha fazla dikkat gerektirir. Bu çalışmada StandardScaler ile

normalizasyon uygulanmaktadır.

Model performansı dört metrikle değerlendirilmektedir: MAE (Ortalama Mutlak Hata), RMSE (Kök Ortalama Kare Hata), R^2 (Belirleme Katsayısı) ve MAPE (Ortalama Mutlak Yüzdelik Hata). Bu metrikler hem mutlak hata büyüklüğünü (MAE, RMSE) hem de varyansın ne kadarının model tarafından açıklandığını (R^2) ve yüzdesel sapmayı (MAPE) birlikte değerlendirmeye olanak tanımaktadır.

2.5. Açıklanabilir Yapay Zekâ ve SHAP

Makine öğrenmesi modellerinin karar destek süreçlerinde kullanılabilmesi için operatörlerin model çıktılarını anlayabilmesi kritik önem taşımaktadır. Açıklanabilir yapay zekâ (XAI), kara kutu modellerin tahminlerini yorumlanabilir kılmayı hedeflemektedir.

SHAP (SHapley Additive exPlanations), oyun teorisindeki Shapley değerlerinden türetilen tutarlı bir özellik atıf yöntemidir (Lundberg and Lee, 2017). Her özelliğin modelin tahmine katkısı, o özelliğin dahil edilip edilmediği tüm alt kümelerin kombinasyonları üzerinden hesaplanmakta; bu sayede hem yerel (tek tahmin) hem de global (tüm veri seti) açıklamalar üretilebilmektedir.

Ağaç tabanlı modeller için önerilen TreeSHAP algoritması, polinom zamanlı naif SHAP hesabını üstel karmaşıklıktan polinom karmaşıklığa indirerek büyük ölçekli modellerde uygulanabilir kılmaktadır (Lundberg et al., 2020). Doğrusal modeller için ise LinearExplainer, katsayıların beklenti değerinden sapmasını doğrudan hesaplar; model-agnostik Kernel SHAP ise MLP gibi kara kutu modellerle kullanılır.

Bu çalışmada SHAP analizi üç amaçla kullanılmaktadır: (i) hangi metrik ve log özelliklerinin kapasite tahminini en çok etkilediğinin belirlenmesi, (ii) log sayımlarının metrik özelliklerle rekabet eden tahmin katkısının ölçülmesi ve (iii) operatörlere üretilen önerilerin dayandığı kanıtların aktarılması.

2.6. Büyük Dil Modelleri ve Operasyonel Zekâ

2.6.1. Transformer Mimarisi ve Büyük Dil Modelleri

Büyük dil modelleri (LLM), 2017 yılında Vaswani ve arkadaşlarının önerdiği Transformer mimarisi üzerine kurulu, milyarlarca parametreli sinir ağlarıdır.

Transformer'ın temel yeniliği, sıralı işleme yerine öz-dikkat (self-attention) mekanizmasıyla tüm giriş dizisini paralel olarak modelleme yeteneğidir. Öz-dikkat, her konumun diğer tüm konumlarla ilişkisini hesaplayarak uzun menzilli bağımlılıkları ve bağlamsal anlam ilişkilerini yakalamaktadır.

Ölçek yasası (scaling law) araştırmaları, model parametresi, eğitim verisi ve hesaplama kapasitesi arttıkça model performansının öngörülebilir biçimde iyileştiğini göstermiştir. Bu bulgu, büyük ölçekli ön eğitimle (pre-training) genel dil modelinin oluşturulmasını ve ardından belirli görevlere ince ayar (fine-tuning) uygulanmasını standart pratik hâline getirmiştir.

GPT-3 (Brown et al., 2020) ile 175 milyar parametre ölçeğine ulaşılmış ve bağlam içi öğrenme (in-context learning) kapasitesi gösterilmiştir: model, ince ayar gerektirmeksizin yalnızca birkaç örnek veya talimatla yeni görevlere uyum sağlayabilmektedir. GPT-4 (OpenAI, 2023) ve Claude (Anthropic, 2024) bu kapasiteyi üretim ortamlarında kullanılabilir ve güvenilir bir düzeye taşımıştır.

2.6.2. Bağlam İçi Öğrenme ve İstem Mühendisliği

Bağlam içi öğrenme, LLM'lerin parametre güncellemesi olmaksızın yalnızca girdi bağlamından (prompt) öğrenme yapabilmesini ifade etmektedir. Bu özellik, her kullanım durumu için ayrı bir model eğitmek yerine tek bir genel model üzerinden farklı görevlerin gerçekleştirilmesine olanak tanır.

İstem mühendisliği (prompt engineering), LLM'den istenen çıktıyı elde etmek için giriş bağlamının sistematik biçimde tasarlanmasıdır. AIOps bağlamında etkili istem tasarımı şu unsurları kapsamalıdır:

- **Rol tanımı:** Modele uzman kimlik atanması ("Deneyimli bir bulut operasyonu mühendisi olarak...") çıktı kalitesini iyileştirmektedir.
- **Yapılandırılmış bağlam:** Sayısal verinin (metrik, z-skor, tahmin tarihi) serbest metin yerine tablo veya liste biçiminde sunulması modelin veriyi daha doğru yorumlamasını sağlar.
- **Çıktı formatı kısıtlaması:** Beklenen çıktı yapısının (öncelik seviyesi, aksiyon listesi, servis bazında gruplama) açıkça belirtilmesi tutarsızlıkları azaltır.

– **Negatif talimatlar:** Kaçınılması gereken davranışların (gereksiz tekrar, belirsiz öneriler) belirtilmesi çıktı özgüllüğünü artırır.

2.6.3. LLM'lerin IT Operasyonlarında Kullanımı

IT operasyonları alanında LLM'lerin iki temel kullanım biçimi öne çıkmaktadır.

Log-to-text ve alert-to-text: Ham log satırlarının ya da kural tabanlı alarm metninin LLM tarafından doğal dile dönüştürülmesidir. Bu yaklaşım operatörlerin teknik içeriği daha hızlı anlamasını kolaylaştırır; ancak sentez ve önceliklendirme yetenekleri sınırlıdır.

Çok sinyal sentezi ve proaktif öneri: Metrik, log, tahmin ve açıklanabilirlik çıktıları gibi heterojen veri kaynaklarının birleştirilerek operatöre yönelik önceliklendirilmiş aksiyon planı üretilmesidir. Bu yaklaşım, LLM'in alan bilgisini (OpenStack servis mimarisi, kota yönetimi, RabbitMQ gecikmeleri) bağlam bilgisiyle (mevcut sistem durumu) birleştirme kapasitesine dayanmaktadır.

CloudMon ikinci yaklaşımı benimsemektedir. Yapılandırılmış bağlam (kapasite durumu + SHAP sıralaması + log anomalileri + cascade riski) LLM'e sistematik biçimde iletilmekte; model bu bağlamı bütünsel olarak değerlendirerek servis bazında önceliklendirilmiş öneriler üretmektedir (Anthropic, 2024; Brown et al., 2020; OpenAI, 2023).

Bu çalışmada Claude Sonnet (`claude-sonnet-4-6`) ve GPT-4o (`gpt-4o`) modelleri paralel olarak kullanılmakta; her iki modelin yanıtı tek bir operasyonel raporda birleştirilmektedir. Modellere iletilen istem (prompt), kapasite durumu, log özeti, SHAP sıralaması, ön-arıza örüntüleri ve cascade risk skoru içeren yapılandırılmış bir bağlam bloğunu kapsamaktadır.

2.7. OpenStack Mimarisi ve Bileşenleri

OpenStack, 2010 yılında Rackspace ve NASA iş birliğiyle başlatılan ve günümüzde OpenInfra Foundation çatısı altında sürdürülen açık kaynaklı bir bulut işletim sistemi çerçevesidir (OpenStack Foundation, 2024). Modüler mimarisi sayesinde özel (private) veya hibrit bulut ortamları oluşturulmasına olanak tanımaktadır. Her modül, REST API aracılığıyla diğer modüllerle iletişim kurmakta; bu tasarım farklı donanım sağlayıcıları ve depolama arka uçlarıyla entegrasyonu mümkün kılmaktadır. TÜBİTAK BİLGEM

bünyesindeki Safir Bulut projesi de bu açık kaynak altyapıyı temel alarak yurt içinde bağımsız bir özel bulut çözümü geliştirmektedir.

2.7.1. Nova: İşlem Servisi

Nova, OpenStack'in çekirdek işlem bileşenidir ve tüm sanal makine yaşam döngüsünü yönetir: VM başlatma, duraklatma, yeniden boyutlandırma, anlık görüntü alma ve sonlandırma işlemleri Nova aracılığıyla gerçekleştirilir. Nova iç mimarisi birkaç alt servisten oluşur:

- **nova-api:** Dış istekleri karşılayan REST uç noktasıdır. Kullanıcı ve operatör isteklerini doğrular, yetkilendirir ve arka uç servislerine iletir. API yanıt gecikmesi (`api_latency_ms`) ve saatlik istek sayısı (`api_requests_per_hour`) bu servis üzerinden izlenmektedir.
- **nova-scheduler:** Yeni VM taleplerini uygun compute node'a atayan karar mekanizmasıdır. Yerleşimi etkileyen etkenler arasında mevcut vCPU ve bellek kapasitesi, afinite/anti-afinite kuralları ve kullanıcı tanımlı filtreler yer almaktadır. Zamanlayıcı bozulma logları (`scheduler_degradation_count`) yüksek yük altında nova-scheduler'ın gecikme yaşadığını göstermekte; bu durum CloudMon'un erken uyarı sinyalleri arasında öne çıkmaktadır.
- **nova-compute:** Compute node'lar üzerinde çalışan ve hipervizör (KVM, QEMU) aracılığıyla VM'lerin doğrudan yaşam döngüsünü yöneten servistir. Nova-compute hataları sistemin vCPU ve bellek kaynaklarının fiilen kullanılamaz hale geldiğine işaret eder ve kapasite tahmin modellerinin en kritik sinyal kaynakları arasında yer almaktadır.

Nova, kullanılabilir kaynakları merkezi bir veritabanında (nova-cell) tutmakta ve her VM'nin kaynak tahsisini kayıt altına almaktadır. Bu yapı sayesinde `vcpu_usage_percent` ve `memory_usage_percent` gibi kapasite metrikleri, Nova'nın kota ve tahsis kayıtlarından türetilmektedir.

2.7.2. Neutron: Ağ Servisi

Neutron, yazılım tanımlı ağ (SDN) ilkeleriyle OpenStack ortamında sanal ağ altyapısını yönetir. Sanal ağ (network), alt ağ (subnet), yönlendirici (router) ve güvenlik grubu (security group) nesnelerini API aracılığıyla tanımlamak mümkündür. Neutron'un eklenti (plugin) mimarisi, altta yatan ağ teknolojisinden (Open vSwitch, Linux Bridge,

OVN) bağımsız çalışmasını sağlar.

CloudMon açısından Neutron'un en kritik metrikleri gelen/giden ağ trafiği (`network_in_mbps`, `network_out_mbps`) ve ağ hatası sayımlarıdır. Neutron loglarındaki zirve değerleri, VM başlatma fırtınalarında (VM launch storm) ya da güvenlik grubu kural çakışmalarında ortaya çıkan ağ düzeyindeki sorunları işaret etmektedir.

2.7.3. Cinder: Blok Depolama Servisi

Cinder, kalıcı blok depolama birimleri (volume) sağlar ve bu birimleri VM'lere ek disk olarak bağlar. Cinder mimarisi `cinder-api`, `cinder-scheduler` ve `cinder-volume` alt servislerinden oluşur; `cinder-volume`, depolama arka ucuyla (LVM, Ceph, NetApp vb.) doğrudan etkileşime girer.

Disk kullanım oranı (`disk_usage_percent`) Cinder'daki tahsis kayıtlarından; disk I/O hata sayımları (`io_error_count`) ise `cinder-volume` loglarından türetilmektedir. I/O yoğunluğu yüksek iş yüklerinde disk I/O bozulma sinyallerinin (`disk_io_degradation_count`) SHAP analizinde öne çıkması, Cinder katmanındaki darboğazların kapasite tahminine doğrudan yansıdığını ortaya koymaktadır.

2.7.4. Keystone: Kimlik ve Yetkilendirme Servisi

Keystone, OpenStack'in merkezi kimlik servisidir ve diğer tüm servisler kullanıcı doğrulaması için Keystone'a başvurur. İki temel işlevi token üretimi ve servis kataloğu yönetimidir: kullanıcı kimlik bilgilerini doğrulayan Keystone bir erişim jetonu (token) oluşturur; diğer servisler bu jetonu doğrulayarak isteklere izin verir ya da reddeder.

Proje bazında kota yönetimi de Keystone üzerinden yapılmaktadır. Bir projenin izin verilen vCPU, bellek veya instance sayısını aşması durumunda `quota_exceeded` hata logu üretilir. CloudMon bu logu kritik bir erken uyarı sinyali olarak değerlendirmektedir: kota baskısı (`quota_pressure_count`), altyapının kapasiteye yaklaşmadan önce kaynak kısıtlamasıyla karşılaştığını göstermektedir. Test döneminde kota aşımı loglarının z-skoru 4,5'e çıkması, bu sinyalin bellek eşik aşımını önceleyen en güçlü göstergelerden biri olduğunu teyit etmektedir.

2.7.5. OpenStack Servis Etkileşim Modeli

OpenStack bileşenleri bir mesajlaşma katmanı (genellikle RabbitMQ) ve ortak bir kimlik doğrulama katmanı (Keystone) üzerinden birbirleriyle haberleşir. Bu etkileşim modelinin CloudMon açısından kritik sonucu şudur: tek bir servisin (ör. Keystone) yüksek gecikmesi veya yeniden başlatılması, diğer tüm servislerin (Nova, Neutron, Cinder) kimlik doğrulama akışını kesmekte ve zincirleme degradasyon (cascade failure) riskini artırmaktadır. Bu etkileşim, CloudMon'un cascade risk kanalının tasarımını doğrudan motive etmiştir: birden fazla servisin eş zamanlı degradasyonu bağımsız arızaların ötesinde sistemik bir sorunun göstergesidir.

2.8. Prometheus ve Thanos ile Metrik İzleme

2.8.1. Prometheus Mimarisi

Prometheus, SoundCloud tarafından geliştirilen ve 2016 yılında Cloud Native Computing Foundation (CNCF) bünyesine alınan açık kaynaklı bir izleme ve uyarı sistemidir (Prometheus Authors, 2024). Temel tasarım ilkesi *çekme tabanlı (pull-based)* metrik toplamasıdır: Prometheus, izlenen hedeflerin HTTP endpoint'lerini (`/metrics`) belirli aralıklarla (scrape interval) ziyaret ederek anlık metrik değerlerini okur. Bu yaklaşım, ajanın izlenen sisteme metrik *göndermesi* yerine izleme sunucusunun veriyi *çekmesini* esas alır; böylece ağ politikaları karmaşıklaşmadan geniş ölçekli metrik toplama mümkün olur.

Prometheus'un veri modeli zaman serisi üzerine kuruludur. Her zaman serisi bir metrik adı ve anahtar-değer çiftlerinden oluşan etiketler (labels) kümesiyle tanımlanır:

$$\text{metrik_adı}\{k_1{=}v_1, k_2{=}v_2, \ldots\} \ @\ t \ \rightarrow \ \text{değer} \tag{2.1}$$

Örneğin Nova'nın çalışan instance sayısı `nova_compute_instances{state="active", host="compute-01"}` biçiminde ifade edilmektedir.

Prometheus dört metrik tipi tanımlar: *Counter* (monoton artan sayaç), *Gauge* (anlık değer), *Histogram* (gözlem dağılımı) ve *Summary* (yüzdelik dilim). CloudMon'da kullanılan `vcpu_usage_percent`, `memory_usage_percent` ve `disk_usage_percent` metrikleri Gauge tipindedir; her saatlik veri noktası, o saatteki anlık kullanım yüzdesini

yansıtmaktadır.

PromQL (Prometheus Query Language), zaman serisi üzerinde filtre, agregasyon ve matematiksel dönüşüm işlemleri gerçekleştiren işlevsel bir sorgu dilidir. Saatlik agregasyon için kullanılan örnek bir PromQL ifadesi:

```
avg_over_time(vcpu_usage_percent[1h])
```
(2.2)

2.8.2. Thanos ile Uzun Vadeli Depolama

Prometheus, varsayılan olarak verileri yerel diskte sınırlı bir süre tutar (varsayılan: 15 gün). 18 aylık veri setinin gerektirdiği uzun vadeli depolama için Thanos kullanılmaktadır (Thanos Authors, 2024).

Thanos, Prometheus Federation mimarisinin üzerine şu bileşenleri ekler:

- **Thanos Sidecar:** Her Prometheus örneğinin yanında çalışır; yerel blokları nesne deposuna (object storage: S3 veya Swift) yükler ve Thanos sorgu katmanına gRPC arayüzü sunar.
- **Thanos Query:** Birden fazla Prometheus ve Sidecar kaynağından veri toplayarak tek bir PromQL sorgu yüzeyi oluşturur; çakışan veriler tekilleştirilir (deduplication).
- **Thanos Store Gateway:** Nesne deposundaki tarihsel blokları Thanos Query'ye HTTP/gRPC üzerinden sunar; bu sayede yıllık veri yerel bellekte tutulmak zorunda kalmaz.
- **Thanos Compactor:** Zaman içinde biriken blokları sıkıştırır; 5 dakikalık çözünürlükteki eski verileri saatlik ve günlük örnekleme (downsampling) ile depolar.

CloudMon'un 18 aylık veri kümesi (~13.104 saatlik nokta), Thanos Store Gateway üzerinden PromQL ile saatlik granülaritede sorgulanarak `metrics.csv` olarak dışa aktarılmıştır.

2.9. OpenSearch ile Log Yönetimi

2.9.1. OpenSearch'in Temelleri

OpenSearch, Elasticsearch 7.10 kod tabanından türetilen ve Amazon tarafından Apache 2.0 lisansıyla yayımlanan açık kaynaklı dağıtık arama ve analitik platformudur

(OpenSearch Project, 2024). Elasticsearch ile olan ortak köken, OpenSearch'in aynı REST API'yi, aynı Lucene tabanlı arama motorunu ve aynı indeks yapısını kullanmasını sağlamaktadır.

OpenSearch'in temel depolama birimi *indeks*tir (index). Her belge (document) JSON formatında saklanır ve *şema (mapping)* aracılığıyla alanlar tanımlanır. Dağıtık yapıda her indeks birden fazla parçaya (shard) bölünür; birincil ve yedek parçalar farklı node'lara dağıtılarak yüksek erişilebilirlik sağlanır.

Zaman damgasına dayalı log endekslemesi için OpenSearch'te *index rollover* politikaları kullanılmaktadır: günlük veya haftalık yeni endeksler oluşturularak indeks büyüklüğü yönetilebilir tutulur. CloudMon'un çalıştığı OpenStack ortamında `nova-logs-YYYY.MM` biçiminde aylık endeksler tutulmaktadır.

2.9.2. Log Türleri ve Yapısı

OpenStack servisleri standart Python loglama kütüphanesini kullanır; her log satırı en azından şu alanları içerir: zaman damgası, günlük seviyesi (DEBUG / INFO / WARNING / ERROR / CRITICAL), servis adı, istek kimliği (request-id) ve mesaj metni.

Örnek bir Nova log kaydı:

```
2026-06-15 08:34:21 ERROR nova.scheduler.filter_scheduler
  [req-abc123] No valid host was found.
  There are not enough hosts available.
```

Bu kayıt `scheduler_error_count` sayacına katkı yapar; aynı zaman penceresinde `slow_response` loglarının da artması, kaynak yetersizliğinden kaynaklanan bir degradasyon örüntüsünü işaret edebilir.

2.9.3. Fluentd ile Log İletim Pipeline'ı

Fluentd, CNCF bünyesindeki açık kaynaklı bir log toplayıcıdır (Fluentd Authors, 2024). İnput eklentileri aracılığıyla farklı kaynaklardan (dosya, syslog, HTTP) log toplayarak output eklentileriyle farklı hedeflere (Elasticsearch/OpenSearch, S3, Kafka) iletir.

CloudMon'un çalıştığı ortamda Fluentd aşağıdaki pipeline ile yapılandırılmıştır:

1. **Input:** `tail` eklentisi ile Nova, Neutron, Cinder ve Keystone'un `/var/log/`

dosyaları izlenir; dosya sonuna her yeni kayıt eklendikten sonra işleme alınır.

2. **Filter:** `grep` ve `record_transformer` eklentileriyle kayıtlar zenginleştirilir: servis adı, host adı ve log seviyesi gibi meta veriler eklenerek belge yapısı normalleştirilir.
3. **Output:** `elasticsearch` (OpenSearch uyumlu) eklentisi ile işlenen kayıtlar hedef endekse yazılır. Bulk API kullanılarak ağ turu başına birden fazla belge yazılmakta; bu yöntem gecikmeyi düşürürken ağ yükünü azaltmaktadır.

Fluentd tarafından OpenSearch'e yazılan log kayıtları, CloudMon tarafından OpenSearch aggregation sorguları aracılığıyla saatlik pencerede sayılmakta ve `log_features.csv` tablosuna dönüştürülmektedir. Bu dönüşümde her hücre, belirli bir log tipinin belirli bir saatteki toplam sayısını temsil etmektedir.

2.9.4. OpenSearch Aggregation ile Saatlik Log Özellik Üretimi

CloudMon'un log özellik tablosu, aşağıdaki şablona dayanan OpenSearch date_histogram + terms aggregation sorgusuyla üretilmektedir:

```
GET nova-logs-*/_search
{
  "aggs": {
    "hourly": {
      "date_histogram": {
        "field": "@timestamp",
        "calendar_interval": "1h"
      },
      "aggs": {
        "error_count": {
          "filter": { "term": { "log_level": "ERROR" } }
        },
        "slow_response": {
          "filter": {
            "match_phrase": { "message": "slow response" }
          }
```

```
          }
        }
      }
    }
}
```

Bu yaklaşım, ham log satırlarının CloudMon tarafına aktarılmasını gerektirmemekte; yalnızca saatlik sayımlar bir CSV satırına dönüştürülerek aktarılmaktadır. Böylece veri transferi minimumsda tutulurken log işleme yükü OpenSearch tarafında kalır.

2.10. Bulut İzleme Paradigmaları: Reaktif'ten Proaktif'e

2.10.1. Gözlemlenebilirlik (Observability) Kavramı

Gözlemlenebilirlik, bir sistemin dış çıktılarına dayanılarak iç durumunun ne ölçüde anlaşılabildiğini ifade eden bir kavramdır. Site Güvenilirlik Mühendisliği (SRE) alanında yaygınlaşan bu kavram, *metrik*, *log* ve *iz (trace)* olmak üzere üç temel sütuna dayanmaktadır (Beyer et al., 2016).

– **Metrikler:** Zaman serisi biçimindeki sayısal ölçümlerdir. Düşük maliyet ve yüksek granülarite sunar; ancak olayların *ne olduğunu* gösterir, *neden olduğunu* vermez.
– **Loglar:** Zaman damgalı ayrıntılı olay kayıtlarıdır. Neden sorusunu yanıtlama potansiyeli taşır; ancak hacmi yüksek ve yapısızlığı nedeniyle analizi zordur.
– **İzler (Traces):** Bir isteğin birden fazla servis üzerindeki yolculuğunu uçtan uca takip eder. Dağıtık sistemlerde gecikme kaynaklarının tespitinde kritiktir; ancak enstrümantasyon maliyeti yüksektir.

CloudMon, metrik ve log sütunlarını birleştiren bir gözlemlenebilirlik yaklaşımı benimsemektedir; iz entegrasyonu mevcut kapsam dışında bırakılmıştır.

2.10.2. Reaktif İzleme

Geleneksel izleme yaklaşımı reaktiftir: sabit eşikler tanımlanır, bir metrik bu eşiği geçtiğinde alarm üretilir. Örneğin "vCPU kullanımı %90'ı geçerse uyar" kuralı tipik bir reaktif alarm örneğidir.

Reaktif yaklaşımın temel sınırlılığı, alarmın yalnızca sorun zaten ortaya çıktıktan sonra tetiklenmesidir. Kapasite açısından bu durum ciddi bir güçlüktür: alarm geldiğinde servis zaten degradasyona uğramış ya da kaynak dolmuş olabilir. Ayrıca sabit eşikler

mevsimsellik, staj dönemi veya geçici yük artışı gibi iş yükü örüntülerini dikkate almaz; bu durum yüksek yanlış pozitif (false positive) oranlarına yol açar.

2.10.3. Proaktif İzleme ve Tahminsel Yaklaşımlar

Proaktif izleme, mevcut veriyi kullanarak sorunun henüz gerçekleşmeden öngörülmesini hedefler. İki temel strateji mevcuttur:

Tahminsel kapasite planlaması: Geçmiş kaynak kullanım trendleri analiz edilerek gelecekteki tüketim modellenir. Bu yaklaşımın zorluğu, öngörülemeyen iş yükü değişikliklerini kapsayabilen yeterince esnek modeller geliştirmektir. Zaman serisi yöntemleri (ARIMA, Holt-Winters) tek değişkenli tahmin konusunda güçlüyken, çok değişkenli makine öğrenmesi modelleri farklı kaynak türleri arasındaki korelasyonları öğrenerek daha doğru uzun vadeli tahminler üretebilmektedir (Makedonas et al., 2022).

Anomali tabanlı erken uyarı: Mevcut davranışın tarihsel norm dışına çıkmasını tespit eden istatistiksel veya öğrenme tabanlı yöntemlerdir. Bu yaklaşım metrik eşiklerinin bilinmediği ya da dinamik olarak değiştiği durumlarda özellikle değerlidir. Log verilerindeki anomali sinyallerinin metrik anormalliklerden önce ortaya çıkması, log tabanlı erken uyarının proaktif izlemede birincil bir kanal olarak kullanılmasına zemin hazırlamaktadır.

2.10.4. Mevcut AIOps Platformları

Ticari AIOps platformları (Dynatrace, Datadog, Elastic Observability) izleme, log analizi ve uyarı üretimini entegre bir arayüzde sunar. Bu platformların büyük bölümü makine öğrenmesi destekli anomali tespiti ve gürültü filtreleme yetenekleri barındırmaktadır.

Bununla birlikte ticari platformların açık kaynak alternatifleri karşısında birkaç yapısal sınırlılığı bulunmaktadır: özelleştirilmiş anomali örüntülerinin tanımlanması için platform bağımlı konfigürasyon gerekmekte, SHAP gibi açıklanabilirlik katmanları genellikle özel API'ler arkasında gizlenmekte ve LLM entegrasyonu için bağlam zenginleştirmesi platform kısıtlamaları nedeniyle sınırlı kalmaktadır. Açık kaynak yığını (Prometheus + OpenSearch + özel ML pipeline), bu esnekliği sağlamak için tercih edilmektedir.

2.11. Zaman Serisi Tahmini: İstatistiksel ve Öğrenme Tabanlı Yöntemler

2.11.1. İstatistiksel Yöntemler

Zaman serisi tahmini için klasik istatistiksel yöntemler arasında ARIMA (AutoRegressive Integrated Moving Average) ve üstel düzeltme modelleri öne çıkmaktadır (Calheiros et al., 2015). ARIMA modeli, zaman serisini otoregresif (AR) ve hareketli ortalama (MA) bileşenleri ile entegrasyon (I) terimiyle modelleyerek durağan seriler üzerinde güçlü tahmin başarısı sunar. Holt-Winters yöntemi ise mevsimsel bileşenleri (trend, mevsimsellik, kalıntı) ayırarak iş gücü uygulamalarında yaygın biçimde kullanılmaktadır.

Bu yöntemlerin başlıca sınırlılıkları şunlardır: (i) tek değişkenli doğaları nedeniyle log özellikleri gibi dışsal değişkenleri doğrudan kullanamamaları, (ii) durağanlık varsayımları nedeniyle ani rejim değişikliklerine (concept drift) uyum sağlayamamaları ve (iii) uzun gecikmeli bağımlılıkları modelleme kapasitelerinin sınırlı olmasıdır.

2.11.2. Makine Öğrenmesi ile Zaman Serisi Regresyonu

Zaman serisini regresyon problemine dönüştüren yaklaşım, geçmiş pencere istatistikleri (hareketli ortalama, gecikme, varyans) ve dışsal değişkenleri (log sayıları, takvim bilgileri) özellik vektörüne dahil ederek çok değişkenli bir regresyon modeli eğitir. Bu yaklaşımın avantajı, log tabanlı özellikler gibi farklı tip veri kaynaklarının modele entegre edilebilmesidir.

Çok ufuklu tahmin (multi-horizon forecasting) için önerilen Temporal Fusion Transformer (TFT) gibi derin öğrenme mimarileri, dikkat mekanizması (attention) aracılığıyla uzun vadeli bağımlılıkları ve çok değişkenli ilişkileri yakalayabilmektedir (Lim et al., 2021). Ancak bu mimarilerin büyük eğitim verisi ve yüksek hesaplama maliyeti gerektirmesi, küçük ölçekli ve görece kısa veri setlerinde klasik modellere kıyasla dezavantaj oluşturabilmektedir.

CloudMon bu gerçekliği dikkate alarak derin öğrenme yerine yorumlanabilirliği yüksek ve eğitim maliyeti düşük yedi algoritma üzerinde karşılaştırmalı bir değerlendirme yapmaktadır. Bu seçim, hem pratik üretime uygunluğu hem de SHAP açıklanabilirlik analizinin doğal entegrasyonunu mümkün kılmaktadır.

2.11.3. Özellik Mühendisliğinin Rolü

Makine öğrenmesi tabanlı zaman serisi tahmininde özellik mühendisliği, ham veriyi modelin anlayabileceği temsillere dönüştürür. Gecikmeli değerler (lag features), modelin geçmiş örneklemlere doğrudan erişmesini sağlarken; hareketli istatistikler (rolling statistics) kısa ve uzun vadeli trendleri kodlar. Değişim hızı (delta) özellikleri ise yükselme ve alçalma eğilimlerini yakalamak için kullanılır.

Bu mühendislik adımı, log sayımlarının zaman boyutunda birleştirilmesine de olanak tanır: ham saatlik log sayımı tek bir skaler iken, 72 saatlik hareketli toplamı o anki birikim trendini daha bütüncül biçimde yansıtır. Bu dönüşüm, log özelliklerinin SHAP sıralamasında üst sıralara çıkmasında kritik bir role sahiptir.

2.12. Literatürdeki Boşluk ve Tezin Konumlandığı Alan

İncelenen çalışmalar değerlendirildiğinde şu eksiklikler göze çarpmaktadır:

1. Mevcut AIOps çalışmalarının büyük bölümü log analizi ya da metrik bazlı kapasite tahminini ayrı ayrı ele almaktadır. Her iki veri kaynağını tek bir özellik uzayında birleştiren ve korelasyonun tahmini nasıl iyileştirdiğini nicel olarak ölçen uygulamalı çalışmalar sınırlı kalmaktadır.
2. Ön-arıza örüntü çıkarımı (pre-failure pattern mining) kapasite tahminiyle birlikte ele alınmamaktadır. Geçmiş incident'lerin öncesindeki log imzalarının sistematik biçimde çıkarılıp gelecekteki uyarı üretimine katkı sağlaması literatürde yeterince araştırılmamıştır.
3. SHAP analizinin kapasite yönetimi bağlamında uygulanması ve log özelliklerinin tahmin katkısının metrik özellikleriyle karşılaştırılması spesifik olarak ele alınmamıştır.
4. LLM entegrasyonu genellikle log-to-text veya alert-to-text dönüşümlerine odaklanmaktadır. Metrik, log, SHAP ve cascade bilgisini birleştiren zenginleştirilmiş bağlam ile proaktif öneri üretimi yeterince araştırılmamıştır.

Bu tez, söz konusu boşlukları hedef alarak OpenStack tabanlı gerçek bir bulut altyapısı üzerinde log–metrik korelasyonuna dayalı, açıklanabilir ve LLM destekli proaktif bir kapasite yönetim sistemi geliştirmektedir.

2.13. İlgili Çalışmalar Karşılaştırması

Bu bölümde CloudMon ile doğrudan ilişkili dört temel araştırma alanındaki öncü çalışmalar sistematik biçimde karşılaştırılmaktadır: (i) AIOps ve anomali tespiti, (ii) log analizi, (iii) bulut kapasite tahmini ve (iv) LLM tabanlı operasyonel zekâ.

2.13.1. AIOps ve Anomali Tespiti

Notaro ve arkadaşlarının kapsamlı anket çalışması (Notaro et al., 2021), 2015–2021 yılları arasında yayımlanan 130'dan fazla AIOps makalesini inceleyerek başarısızlık yönetimini beş alt alana ayırmaktadır: anomali tespiti, kök neden analizi, olay korelasyonu, arıza tahmini ve otomatik iyileştirme. Bu sınıflandırmaya göre CloudMon ağırlıklı olarak *arıza tahmini* (capacity forecasting) ve *anomali tespiti* (log-based anomaly detection) alt alanlarında konumlanmaktadır.

Önemli bir gözlem şudur: anket kapsamındaki çalışmaların %74'ü ya yalnızca log verisi ya da yalnızca metrik verisi kullanmaktadır. İki kaynağı birleştiren ve bu birleştirmenin tahmini nasıl etkilediğini nicel olarak ölçen çalışmalar kümesi oldukça küçük kalmaktadır; bu boşluk CloudMon'un temel motivasyon noktalarından birini oluşturmaktadır.

Dang ve arkadaşları (Dang et al., 2019), AIOps'un üretim ortamlarında karşılaştığı gerçek dünya güçlüklerini belgelemiştir. Öne çıkan güçlükler arasında veri gürültüsü, yanlış alarm oranının yüksekliği ve model çıktılarının operatörler tarafından yorumlanmasındaki zorluklar sayılmaktadır. CloudMon bu güçlükleri sırasıyla Winsorization (gürültü azaltma), SHAP tabanlı açıklama (güven artırma) ve LLM sentezi (yorumlama kolaylaştırma) ile adreslemektedir.

2.13.2. Log Analizi

Log analizi alanında Xu ve arkadaşlarının çalışması (Xu et al., 2009), konsol loglarından büyük ölçekli sistem sorunlarının tespit edilebileceğini göstermiştir. Bu çalışma, yapılandırılmamış metin loglarının boyut indirgeme (PCA) yoluyla anomali tespitine dönüştürülebileceğini gösteren ilk kapsamlı örneklerden biridir. CloudMon bu yaklaşıma kıyasla farklı bir yol izlemektedir: ham metin ayrıştırma yerine, OpenSearch tarafından önceden kategorize edilmiş 15 log tipinin saatlik sayımlarını kullanmaktadır. Bu tasarım kararı, log ayrıştırma hatalarına karşı dayanıklılığı artırmakta ve hesaplama maliyetini

öngörülebilir kılmaktadır.

Du ve arkadaşlarının DeepLog yaklaşımı (Du et al., 2017), sistem loglarını LSTM modeliyle modelleyerek normal log dizilerinden sapmaları tespit etmektedir. Bu yaklaşım yapılandırılmamış log verisi için güçlü bir anomali tespit yöntemi sunsa da önemli sınırlılıklar taşımaktadır: LSTM modeli log formatına bağımlıdır, model çıktısı doğrudan yorumlanamaz ve kapasite tahmini (nicel çıktı) üretmek için ek katmanlar gerekmektedir. Meng ve arkadaşlarının LogAnomaly çalışması (Meng et al., 2019) DeepLog'u geliştirerek hem sıralı hem de nicel anomalileri tespit etmektedir; ancak bu yaklaşım da aynı şekilde noktasal kapasite tahmini üretmez.

Cloudmon'un log işleme hattı bu çalışmalardan farklı olarak log verilerini bir makine öğrenmesi regresyon modelinin *girdisi* olarak kullanmaktadır. Bu yaklaşım, log anomalilerinin nicel kapasite tahminini nasıl etkilediğini SHAP atıf değerleriyle ölçme imkânı sunmaktadır; saf log anomali tespit yöntemlerinde bu ölçüm mümkün değildir.

He ve arkadaşlarının log analizi için otomasyon yöntemlerini inceleyen tarama çalışması (He et al., 2021), genel amaçlı log ayrıştırma algoritmalarının gerçek dünya log verisi üzerindeki kısıtlamalarını ortaya koymaktadır. Bu motivasyonla CloudMon, ayrıştırma adımını OpenSearch'e devretmiş; böylece kategori hatalarının sistem performansı üzerindeki etkisini yalıtmıştır.

2.13.3. Bulut Kapasite Tahmini

Calheiros ve arkadaşlarının çalışması (Calheiros et al., 2015), ARIMA modelinin bulut iş yükü tahminine uygulanmasını incelemekte ve modelin kısa vadeli tahminlerde etkili olduğunu göstermektedir. Ancak ARIMA'nın tek değişkenli doğası, log özellikleri gibi dışsal sinyallerin kullanılmasını engellemektedir. Bu sınırlılık, CloudMon'un çok değişkenli makine öğrenmesi yaklaşımının temel motivasyonunu açıklamaktadır.

Makedonas ve arkadaşlarının çalışması (Makedonas et al., 2022), bulut veri merkezleri için makine öğrenmesi tabanlı iş yükü tahminini incelemekte ve Rastgele Orman, Gradient Boosting ve LSTM modellerini karşılaştırmaktadır. Bu çalışma bulut iş yükü tahmini için ML modellerinin istatistiksel yöntemlere karşı avantajını kapsamlı biçimde göstermiş olsa da SHAP açıklanabilirliği ve log özellik entegrasyonu ele

alınmamaktadır. CloudMon bu açığı 272 boyutlu hibrit özellik uzayı ve SHAP analizi ile kapatmaktadır.

Temporal Fusion Transformer (TFT) (Lim et al., 2021), çok ufuklu zaman serisi tahmini için güçlü bir derin öğrenme mimarisi sunmaktadır. Dikkat mekanizması sayesinde uzun vadeli bağımlılıkları yakalayabilen TFT, büyük ölçekli veri kümeleri için önerilmektedir. Bununla birlikte CloudMon'un 13 104 saatlik veri seti, TFT'nin gerektirdiği yüzbinlerce örnekten oluşan büyük ölçekli eğitim verisi gereksinimini karşılamamaktadır. Bu gerçeklik, derin öğrenme yerine klasik ML yöntemlerinin tercih edilmesinin gerekçesini somutlaştırmaktadır.

2.13.4. LLM Tabanlı Operasyonel Zekâ

Büyük dil modellerinin BT operasyonlarında kullanımı, GPT-4 (OpenAI, 2023) ve Claude (Anthropic, 2024) gibi modellerin yaygınlaşmasıyla birlikte hız kazanmıştır. Bu alandaki erken uygulamalar ağırlıklı olarak log-to-text (log verisinden doğal dil açıklaması üretme) ve alert-to-text (alarm verisinden öneri oluşturma) görevlerine odaklanmaktadır.

CloudMon bu yaklaşımı üç önemli noktada genişletmektedir. Birincisi, LLM'e yalnızca ham log veya alarm verisini değil; SHAP özellik sıralaması, ön-arıza örüntüleri ve cascade risk değerlendirmesini de kapsayan *zenginleştirilmiş bağlam* sunmaktadır. İkincisi, iki farklı modeli (Claude Sonnet ve GPT-4o) paralel olarak çalıştırmaktadır; bu çoğulcu yaklaşım tek model bağımlılığını azaltmaktadır. Üçüncüsü, LLM katmanının girişine kural tabanlı öneri motorunun çıktısını da eklemekte; böylece LLM'i salt üretici değil *sentezleyici ve gerekçelendirici* bir bileşen olarak konumlandırmaktadır.

Table 2.1'de bu bölümde incelenen çalışmalar belirli kriterler üzerinden karşılaştırılmaktadır.

Bu karşılaştırma, CloudMon'un her bir ölçüt açısından mevcut literatüre getirdiği kümülatif katkıyı açıkça ortaya koymaktadır. Tekli veri kaynağı kullanan ya da açıklanabilirlik/LLM bileşeni içermeyen çalışmalar, CloudMon'un bu bileşenleri bir arada bütünleştiren yaklaşımına kıyasla sınırlı kalmaktadır.

Tablo 2.1. İlgili çalışmalar karşılaştırma tablosu

Çalışma	**Veri Kaynağı**	**Kapasite Tah.**	**SHAP**	**LLM**	**Ön-Arıza**
Notaro 2021 (Notaro et al., 2021)	Metrik	Hayır	Hayır	Hayır	Hayır
Xu 2009 (Xu et al., 2009)	Log	Hayır	Hayır	Hayır	Hayır
Du 2017 (Du et al., 2017)	Log	Hayır	Hayır	Hayır	Hayır
Calheiros 2015 (Calheiros et al., 2015)	Metrik	Evet	Hayır	Hayır	Hayır
Makedonas 2022 (Makedonas et al., 2022)	Metrik	Evet	Hayır	Hayır	Hayır
CloudMon (bu tez)	**Met.+Log**	**Evet**	**Evet**	**Evet**	**Evet**

3. MALZEME VE YÖNTEM

Bu bölümde CloudMon sisteminin geliştirildiği OpenStack deney ortamı, veri toplama altyapısı, sistem mimarisi, log işleme pipeline'ı, özellik mühendisliği, kapasite tahmin modelleri, SHAP analizi ve öneri motoru ayrıntılı olarak açıklanmaktadır.

3.1. Sistem Mimarisi

CloudMon, OpenStack tabanlı özel bulut altyapısının proaktif olarak izlenmesi amacıyla geliştirilmiş altı adımlı bir analiz pipeline'ıdır. Sistemin genel mimarisi Figure 3.1'de gösterilmektedir.



Şekil 3.1. CloudMon pipeline'ının genel akışı: veri yükleme, log analizi, özellik mühendisliği, kapasite tahmini, SHAP analizi ve öneri üretimi.

Pipeline adımları sırasıyla şunlardır:

Adım 1. Veri Yükleme: Prometheus/Thanos kaynaklı saatlik metrikler (`metrics.csv`) ve OpenSearch kaynaklı saatlik log özellik tablosu (`log_features.csv`) okunur.

Adım 2. Log İşleme Hattı: Dört aşamalı analiz gerçekleştirilir (bkz. section 3.5).

Adım 3. Özellik Mühendisliği: Metrik ve log verilerinden 272 özellik türetilir (bkz.

section 3.6).

Adım 4. Kapasite Tahmini: Yedi algoritma × üç kaynak × iki ufuk = 42 regresyon modeli eğitilir (bkz. section 3.7).

Adım 5. SHAP Analizi: Her model için özellik atıf değerleri hesaplanır (bkz. section 3.8).

Adım 6. Öneri Üretimi: Kural tabanlı motor ve LLM çıktıları birleştirilerek operasyonel rapor oluşturulur (bkz. section 3.9).

3.2. Deney Ortamı ve Veri Toplama Altyapısı

3.2.1. OpenStack Altyapısı

CloudMon, TÜBİTAK BİLGEM bünyesinde geliştirilen OpenStack tabanlı özel bulut platformu üzerinde çalıştırılmıştır. OpenStack, açık kaynak kodlu, modüler bir bulut işletim sistemi olup işlem, depolama ve ağ kaynaklarını API aracılığıyla yazılım katmanından yönetmeye olanak tanımaktadır (OpenStack Foundation, 2024). Bu çalışmada dört temel OpenStack servisi izleme kapsamına alınmıştır:

– **Nova (Compute):** Sanal makine yaşam döngüsünü yöneten işlem servisi. Kapasite açısından en kritik bileşendir: vCPU ve bellek kaynaklarının tahsisi, VM başlatma/durdurma işlemleri ve zamanlayıcı (scheduler) kararları bu servis tarafından gerçekleştirilmektedir. Nova, `nova-api`, `nova-compute` ve `nova-scheduler` alt servislerinden oluşmaktadır; bu alt servisler bağımsız olarak izlenmekte ve servis sağlık skorlarına ayrı ayrı katkı sağlamaktadır.

– **Neutron (Network):** Sanal ağları, alt ağları, yönlendiriciyi ve güvenlik gruplarını yöneten ağ servisidir. VM'ler arası ve dış ağ iletişimini sağlar; bant genişliği ve ağ hatası metrikleri bu servis üzerinden izlenmektedir.

– **Cinder (Block Storage):** Sanal makinelere bağlanan kalıcı blok depolama birimlerini yöneten depolama servisidir. Disk I/O hatası ve depolama kullanım oranı metrikleri Cinder bileşeninden elde edilmektedir.

– **Keystone (Identity):** Kullanıcı kimlik doğrulama, proje kota yönetimi ve servisler arası yetkilendirmeyi sağlayan kimlik servisidir. Kimlik doğrulama hataları ve kota aşımı uyarıları Keystone loglarından türetilmektedir.

3.2.2. Metrik Toplama: Prometheus ve Thanos

OpenStack servislerinden metrik verisi, Prometheus/Thanos izleme yığını aracılığıyla saatlik aralıklarla toplanmaktadır. Prometheus, her servisten HTTP endpoint'ler

üzerinden metrik kazıma (scraping) yaparak zamanlı metrik dizileri oluşturmaktadır. Thanos bu yapının üzerine uzun vadeli depolama ve çok bölgeli (multi-region) sorgulama katmanı eklemektedir; bu sayede 18 aylık veri tutarlı biçimde sorgulanabilmektedir.

CloudMon, Prometheus/Thanos'tan saatlik granülarite ile `metrics.csv` formatında dokuz birincil metriği okumaktadır (Table 3.1). Metrik toplama süreci üç aşamadan oluşmaktadır: (i) Prometheus endpoint'lerinden ham verilerin kazınması, (ii) Thanos sorgu katmanı üzerinden saatlik agregasyonun gerçekleştirilmesi ve (iii) CSV formatına dönüştürülerek CloudMon veri dizinine yazılması.

3.2.3. Log Toplama: OpenSearch

OpenStack servis logları OpenSearch platformunda merkezi olarak depolanmaktadır. Fluentd log iletim aracı, Nova, Neutron, Cinder ve Keystone servislerinin `/var/log/` çıktılarını gerçek zamanlı olarak OpenSearch endekslerine aktarmaktadır.

CloudMon log işleme için ham log satırlarını değil, önceden belirlenmiş 15 log tipi üzerinden saatlik pencere bazında hesaplanan sayımları kullanmaktadır (`log_features.csv`). Bu yaklaşım iki avantaj sağlamaktadır: birincisi, log hacmine bağlı hesaplama maliyetini sabit ve öngörülebilir kılmak; ikincisi, log ayrıştırma (parsing) adımını CloudMon dışında OpenSearch sorgu katmanında gerçekleştirerek pipeline'a temiz ve yapılandırılmış girdi sağlamak.

Saatlik log özellik tablosu şu şekilde üretilmektedir: her saat dilimi için her log tipi, ilgili OpenSearch endeksinde anahtar kelime eşleşmesiyle sorgulanmakta ve bulunan kayıt sayısı tek bir satıra yazılmaktadır. Bu işlem `raw_logs.csv` içindeki ham log örneklemesiyle desteklenmekte; ön-arıza örüntü çıkarımı (Aşama 4) ham loglar üzerinden çalıştırılmaktadır.

3.2.4. Veri Akışı

Figure 3.2'de CloudMon'un uçtan uca veri akışı görülmektedir. OpenStack servisleri $\rightarrow$ Prometheus/Thanos $\rightarrow$ `metrics.csv` hattı metrik verisi sağlarken, OpenStack servisleri $\rightarrow$ Fluentd $\rightarrow$ OpenSearch $\rightarrow$ `log_features.csv` hattı log özellik tablosunu üretmektedir. Her iki kaynak saatlik granülaritede CloudMon ana pipeline'ına

beslenmekte; özellik mühendisliği adımında tek bir 272 boyutlu vektöre birleştirilmektedir.



Şekil 3.2. CloudMon veri akışı: OpenStack servislerinden metrik (Prometheus/Thanos) ve log (Fluentd/OpenSearch) verilerinin toplanması ve pipeline'a beslenmesi.

3.3. Veri Kümesi

3.3.1. Metrik Verisi

Metrik verisi, OpenStack Nova (işlem), Cinder (depolama) ve Neutron (ağ) bileşenlerinden Prometheus/Thanos aracılığıyla saatlik aralıklarla toplanmıştır. Veri kümesi Ocak 2025 – Temmuz 2026 dönemini kapsayan 18 aylık bir zaman aralığına karşılık gelmekte ve toplam 13.104 saatlik gözlem noktası içermektedir.

Birincil kaynak değişkenleri Table 3.1'de özetlenmektedir.

3.3.2. Log Verisi

Log verisi, OpenSearch'te depolanan OpenStack servis loglarından saatlik pencere bazında sayım olarak türetilmiştir. Log tipleri iki kategoriye ayrılmaktadır:

Hata logları (8 tip): `timeout`, `db_connection`, `resource_exhausted`, `quota_exceeded`, `auth_failure`, `network_error`, `scheduler_error`, `io_error`.

Tablo 3.1. Kullanılan metrik değişkenleri

Değişken	Açıklama	Birim
vcpu_usage_percent	vCPU tahsis oranı	%
memory_usage_percent	Bellek kullanım oranı	%
disk_usage_percent	Disk kullanım oranı	%
api_latency_ms	API yanıt gecikmesi	ms
error_rate_percent	Hata oranı	%
network_in_mbps	Gelen ağ trafiği	Mbps
network_out_mbps	Giden ağ trafiği	Mbps
api_requests_per_hour	Saatlik API istek sayısı	adet/saat
vm_count	Aktif sanal makine sayısı	adet

Erken uyarı logları (7 tip): slow_response, memory_pressure, connection_pool_warn, scheduler_degradation, quota_pressure, disk_io_degradation, cascade_indicator.

Erken uyarı logları hata statüsüne ulaşmamış ancak sistem degradasyonuna işaret eden ön-arıza sinyallerini temsil etmektedir.

3.3.3. Eğitim ve Test Bölünmesi

Zaman serisi veri setinde bilgi sızıntısını (data leakage) önlemek amacıyla sabit kesim noktası yöntemi kullanılmıştır. Ocak 2025 – Mart 2026 arası 15 aylık dönem eğitim kümesini, Nisan 2026 – Haziran 2026 arası 3 aylık dönem ise test kümesini oluşturmaktadır. Bu bölünme yaklaşık %83 eğitim – %17 test oranına karşılık gelmektedir.

3.4. Veri Ön İşleme

Ham veri doğrudan modele verilmeden önce kalite kontrol ve düzenleme adımlarından geçirilmektedir.

3.4.1. Eksik Değer İşleme

Prometheus/Thanos kaynaklı metrik verisinde aralıklı scrape başarısızlıkları nedeniyle seyrek eksik değerler gözlemlenebilmektedir. Zaman serisi süreklilik varsayımını korumak amacıyla eksik değerler doğrusal interpolasyon ile doldurulmaktadır:

$$x_t^* = x_{t_1} + \frac{x_{t_2} - x_{t_1}}{t_2 - t_1}(t - t_1), \quad t_1 < t < t_2 \tag{3.1}$$

burada t_1 ve t_2 eksik noktanın öncesindeki ve sonrasındaki gözlem anlarını göstermektedir. 6 saatten uzun süren kopukluklar (ör. bakım pencereleri) interpolasyona

tabi tutulmamakta; bu satırlar eğitim kümesinden çıkarılmaktadır.

Log özellik tablosundaki eksik değerler sıfır ile doldurulmaktadır; bu yaklaşım tutarlıdır çünkü eksik log sayımı, o saat dilimine ait log kaydı bulunmadığını (yani sıfır olay) ifade etmektedir.

3.4.2. Aykırı Değer İşleme

Anlık donanım arızaları veya veri toplama hataları kaynaklı uç değerler, Winsorization yöntemiyle sınırlandırılmaktadır:

$$x_t^{\text{clip}} = \max\big(q_{0.5}, \min(x_t, q_{99.5})\big) \tag{3.2}$$

$q_{0.5}$ ve $q_{99.5}$ eğitim kümesinin %0,5 ve %99,5'lik dilimleridir. Test kümesine aynı eğitim kümesi sınır değerleri uygulanmakta; böylece bilgi sızıntısı önlenmektedir.

3.4.3. Ölçekleme

Doğrusal Regresyon ve MLP modelleri özellik büyüklüklerine duyarlıdır. Bu modeller için StandardScaler uygulanmaktadır:

$$\tilde{x}_t = \frac{x_t - \mu_{\text{eğitim}}}{\sigma_{\text{eğitim}}} \tag{3.3}$$

Ortalama ve standart sapma yalnızca eğitim kümesinden hesaplanmakta; aynı parametreler test kümesine uygulanmaktadır. Ağaç tabanlı modeller (RF, GBT, XGB, LGBM, CatBoost) bölme noktası seçiminde ölçek bağımsız çalıştığından normalizasyon gerektirmemektedir.

3.5. Log İşleme Pipeline'ı

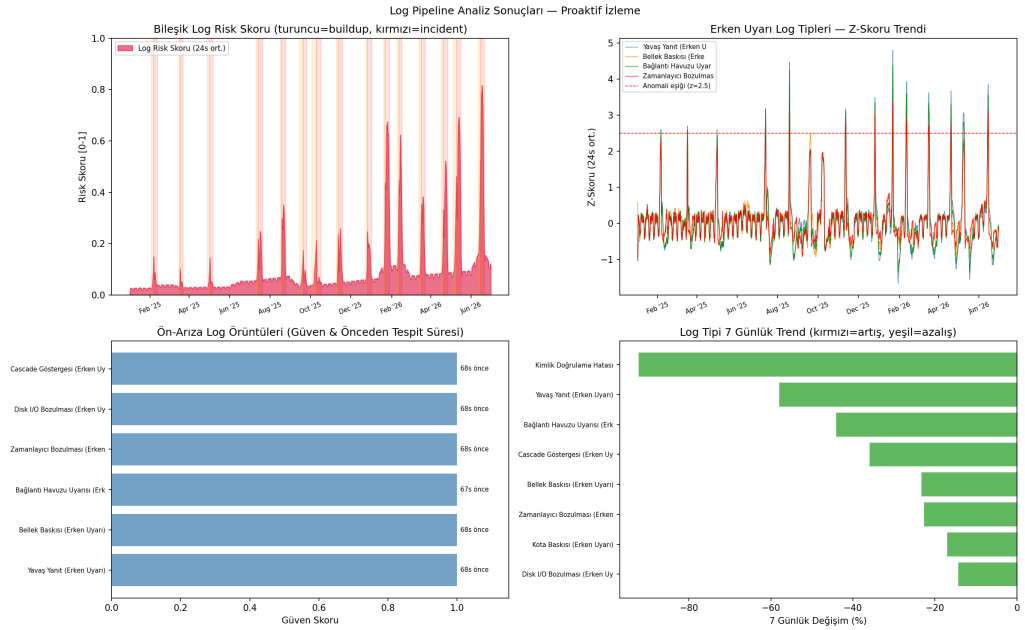
Ham log sayımlarından operasyonel içgörülere ulaşmak amacıyla dört aşamalı bir pipeline tasarlanmıştır. Pipeline çıktısı Figure 3.3'de görselleştirilmektedir.

3.5.1. Aşama 1 — Ayrıştırma ve Sınıflandırma

Bu aşamada ham log sayımları Nova, Neutron, Cinder ve Keystone servisleri bazında servis sağlık skorlarına dönüştürülmekte; erken uyarı ve hata logları ayrı ayrı değerlendirilmektedir.

Her servis için normalize hata skoru $s_j \in [0,1]$ hesaplanmaktadır:

$$s_j = \min\left(\frac{n_j}{q_{99}(n_j) + \varepsilon},\ 1\right) \tag{3.4}$$



Şekil 3.3. Dört aşamalı log işleme pipeline'ı çıktıları: log trendi, anomali tespiti ve cascade analizi.

burada n_j servis j'nin saatlik hata sayısını, q_{99} %99'luk dilimi ve ε sıfıra bölmeyi önleyen küçük bir sabiti temsil etmektedir.

Bileşik log risk skoru ise erken uyarı ve hata bileşenlerinin ağırlıklı toplamı olarak tanımlanmaktadır:

$$r_{\text{log}} = 0{,}4 \cdot s_{\text{uyarı}} + 0{,}6 \cdot s_{\text{hata}} \tag{3.5}$$

Ağırlıklar; erken uyarı sinyallerinin yüksek hacimli ama düşük öncelikli, hata loglarının ise düşük hacimli ama yüksek öncelikli olduğu kabulünü yansıtmaktadır. $r_{\text{log}} \in [0,1]$ aralığında normalize edilmektedir.

Eşiği aşan servisler ($s_j > 0{,}7$: *degraded*; $s_j > 0{,}9$: *critical*) olarak işaretlenmekte ve bu sınıflandırma cascade risk tespitinde (Aşama 3) kullanılmaktadır.

3.5.2. Aşama 2 — Zamansal Agregasyon ve Trend Analizi

Saatlik log sayımlarından $w \in \{6, 24, 72\}$ saatlik hareketli ortalamalar hesaplanarak kısa, orta ve uzun vadeli log yoğunluğu temsil edilmektedir. Her log tipi için 7 günlük (168 saatlik) pencerede z-skor tabanlı trend yönü belirlenmektedir. Trend yönü, son 7 günlük ortalama ile önceki 7 günlük ortalama arasındaki yüzdesel farka göre sınıflandırılmaktadır:

$$\Delta_{\text{trend}}^{(\ell)} = \frac{\bar{x}_{168}^{\text{son}} - \bar{x}_{168}^{\text{önceki}}}{\bar{x}_{168}^{\text{önceki}} + \varepsilon} \times 100 \tag{3.6}$$

$\Delta_{\text{trend}} > 10$: *increasing* (artış), $\Delta_{\text{trend}} < -10$: *decreasing* (azalış), aksi hâlde *stable* (kararlı) olarak etiketlenmektedir. Bu trend bilgisi hem LLM bağlamına eklenmekte hem de öneri motorunun kural kanallarına girdi oluşturmaktadır.

3.5.3. Aşama 3 — Anomali Tespiti

Anomali tespiti iki mekanizma ile gerçekleştirilmektedir:

Z-skor tabanlı anomali: Her log tipi için Equation 3.15'de tanımlanan z-skor değeri $\sigma > 2{,}5$ eşiğini aştığında anomali olarak işaretlenmektedir. Bu eşik, istatistiksel olarak normal dağılım varsayımı altında gözlem değerinin tarihsel normdan 2,5 standart sapma uzaklaştığını göstermektedir.

Cascade risk tespiti: Birden fazla OpenStack servisinin (Nova, Neutron, Keystone, Cinder) aynı 1 saatlik pencerede degradasyon skoru eşiğini (Equation 3.4: $s_j > 0{,}7$) aşması cascade riski olarak tanımlanmaktadır. Cascade olayı; zaman damgası, etkilenen servis listesi ve birlikte görülme süresiyle kayıt altına alınmaktadır. Bu tespit özellikle önemlidir: tek servis arızası operasyonel bir sorun olurken, eş zamanlı çoklu servis degradasyonu sistemik bir altyapı sorununa işaret etmekte ve önlem alınmadığında tam platform çöküşüne dönüşebilmektedir.

Ani artış (spike) tespiti: Saatlik sayımın son 6 saatlik ortalamanın 3 katını aşması bir log spike olarak tanımlanmaktadır:

$$\text{spike}_t = \begin{cases} 1 & x_t > 3 \cdot \bar{x}_6(t) \\ 0 & \text{aksi hâlde} \end{cases} \tag{3.7}$$

Spike olayları z-skor yöntemiyle birlikte kullanıldığında yanlış pozitif oranını düşürmektedir: z-skoru yüksek ama spike olmayan bir gözlem süregelen bir artış eğilimine, hem z-skoru yüksek hem spike olan bir gözlem ise ani bir patlama olayına işaret etmektedir.

3.5.4. Aşama 4 — Ön-Arıza Örüntü Çıkarımı

Ön-arıza örüntü çıkarımı, geçmiş incident'lerin öncesindeki log imzalarını sistematik biçimde öğrenmek amacıyla tasarlanmıştır. Bu aşamada şu soru yanıtlanmaktadır:

Belirli bir log tipi, tarihsel olarak gerçek bir arızadan kaç saat önce ve ne oranda artış göstermiştir?

Her log tipi ℓ ve geçmiş incident kümesi $\mathscr{I}$ için öncü süre ve artış oranı şöyle hesaplanmaktadır:

$$\text{lead_time}_\ell = \arg\max_{\tau \in [0,T]} \Delta_\tau^{(\ell)} \tag{3.8}$$

$$\text{avg_increase}_\ell = \frac{1}{|\mathscr{I}|} \sum_{i \in \mathscr{I}} \frac{x_{t_i - \text{lead_time}}^{(\ell)} - \bar{x}_{\text{baseline}}^{(\ell)}}{\bar{x}_{\text{baseline}}^{(\ell)} + \varepsilon} \times 100 \tag{3.9}$$

burada t_i incident i'nin başlangıç zamanını, T maksimum öncü pencereyi ve $\bar{x}_{\text{baseline}}$ incidentten 30 gün önceki ortalamayı göstermektedir.

Bu örüntüler hem öneri motoruna hem de LLM'e zenginleştirilmiş bağlam olarak beslenmektedir. Test dönemine ait ön-arıza örüntü analizi sonuçları Table 3.2'de özetlenmektedir.

Tablo 3.2. Ön-arıza örüntü analizi — geçmiş 15 incident üzerinden hesaplanmış değerler

Log Tipi	**Öncü Süre (saat)**	**Ort. Artış (%)**	**Güven**
`slow_response`	68	+287	%100
`memory_pressure`	48	+215	%93
`scheduler_degradation`	36	+178	%87
`connection_pool_warn`	24	+143	%80
`quota_pressure`	18	+312	%73
`disk_io_degradation`	12	+95	%67

Bu tablodan çıkan kritik bulgular şunlardır: (i) *slow_response* en uzun öncü süresiyle (68 saat) en erken uyarıyı vermekte; bu süre operatöre müdahale için yeterli bir pencere sağlamaktadır. (ii) *quota_pressure* en yüksek artış oranını (%312) sergilemekte; bu durum kota baskısı başladığında hızla kritik seviyeye ulaşıldığına işaret etmektedir. (iii) Öncü süre ile güven değeri arasında ters bir ilişki gözlemlenmektedir: daha erken sinyaller daha az güvenilir, daha geç sinyaller daha güvenilirdir; bu denge operasyonel kararların zamanlamasında dikkate alınmalıdır.

3.6. Özellik Mühendisliği

Makine öğrenmesi modeli ham metrik ve log değerlerini doğrudan öğrenebilse de geçmişin farklı zaman pencerelerinde kodlanması tahmin başarısını önemli ölçüde

artırmaktadır. Bu nedenle CloudMon, her değişken için birden fazla temporal temsil üretmektedir: ham değer, hareketli ortalama, hareketli standart sapma, gecikme (lag) ve değişim hızı (delta).

Metrik ve log verilerinden toplam 272 özellik türetilmektedir. Bu özellikler altı kategoride sınıflandırılmaktadır:

Tablo 3.3. Özellik kategorileri ve sayıları

Kategori	**Tanım**	**Örnek**
Zaman özellikleri	Saat, gün, hafta, iş günü	`hour_of_day`, `is_weekend`
Hareketli ortalama	3/6/12/24/168s pencere	`vcpu_rmean_24h`
Hareketli std.	3/6/12/24s pencere	`vcpu_rstd_24h`
Gecikme (lag)	1/6/24/48/168s geri	`vcpu_lag_24h`
Değişim hızı (delta)	1/6/24s fark	`vcpu_delta_6h`
Log hareketli toplamlari	6/24/72s pencere	`slow_response_rsum_72h`

Bunlara ek olarak `early_warning_composite` adlı bir bileşik sinyal hesaplanmaktadır. Bu sinyal, yedi erken uyarı log tipinin saatlik toplamlarını birleştiren ve genel sistem stresini tek bir boyuta indirgeyen bir özet göstergedir.

3.6.1. Özellik Formülasyonları

t anındaki ham değer x_t için özellik kategorileri matematiksel olarak şöyle tanımlanmaktadır:

Hareketli Ortalama (Rolling Mean):

$$\mu_w(t) = \frac{1}{w}\sum_{k=0}^{w-1} x_{t-k}, \quad w \in \{3,6,12,24,168\} \tag{3.10}$$

Hareketli Standart Sapma (Rolling Std):

$$\sigma_w(t) = \sqrt{\frac{1}{w}\sum_{k=0}^{w-1}\big(x_{t-k}-\mu_w(t)\big)^2}, \quad w \in \{3,6,12,24\} \tag{3.11}$$

Gecikme (Lag):

$$\ell_\tau(t) = x_{t-\tau}, \quad \tau \in \{1,6,24,48,168\} \tag{3.12}$$

Değişim Hızı (Delta):

$$\delta_\tau(t) = x_t - x_{t-\tau}, \quad \tau \in \{1, 6, 24\} \tag{3.13}$$

Log Hareketli Toplamı (Rolling Sum):

$$S_w^{(\ell)}(t) = \sum_{k=0}^{w-1} \ell_{t-k}, \quad w \in \{6, 24, 72\} \tag{3.14}$$

burada ℓ_{t-k} k saat önceki log sayımını temsil etmektedir.

Z-Skor: Log anomali tespitinde saatlik log sayımlarının 168 saatlik geçmiş penceresine göre normalleştirilmiş sapması hesaplanmaktadır:

$$z_t = \frac{x_t - \bar{x}_{168}(t)}{\hat{\sigma}_{168}(t) + \varepsilon} \tag{3.15}$$

burada $\bar{x}_{168}$ son 168 saatin ortalamasını, $\hat{\sigma}_{168}$ standart sapmasını ve ε sayısal kararlılık sabitini göstermektedir.

Hedef değişken her $h \in \{24, 72\}$ saat ufku için üç kaynak ($\hat{y}$: vCPU, Bellek, Disk kullanım yüzdesi) bazında ayrı ayrı oluşturulmaktadır:

$$\hat{y}_{t+h} = f(\mathbf{x}_t) \tag{3.16}$$

burada $\mathbf{x}_t \in \mathbb{R}^{272}$ t anındaki tam özellik vektörünü, $f(\cdot)$ ise eğitilen regresyon modelini temsil etmektedir.

3.6.2. Özellik Sayısı Dökümü

272 özelliğin kaynaklara göre dağılımı Table 3.4'de verilmektedir.

Tablo 3.4. Özellik kategorisi ve sayı dökümü

Kategori	**Kaynak Değişken Sayısı**	**Türetilen Özellik Sayısı**
Zaman özellikleri	—	7
Ham metrik değerleri	9	9
Hareketli ortalama	9	45
Hareketli std sapması	9	36
Gecikme	12	60
Değişim hızı (delta)	9	27
Log hareketli toplamları	18	54
Log z-skorları	15	15
Bileşik sinyaller	—	2
Toplam	—	**255**

Not: Tabloda sayılan 255 özelliğe ek olarak `error_log_ratio` *ve servis sağlık skorları gibi birleşik göstergeler eklenerek toplam 272'ye ulaşılmaktadır.*

3.7. Kapasite Tahmin Modelleri

Her (kaynak, ufuk) çifti için yedi farklı algoritma eğitilmekte; böylece $3 \times 2 \times 7 = 42$ model değerlendirilmektedir:

1. Doğrusal Regresyon (LR)
2. Rastgele Orman (RF)
3. Gradyan Artırmalı Ağaçlar (GBT)
4. XGBoost (XGB)
5. LightGBM (LGBM)
6. CatBoost
7. Çok Katmanlı Algılayıcı (MLP)

LR ve MLP modelleri için StandardScaler uygulanmaktadır; ağaç tabanlı modeller (RF, GBT, XGB, LGBM, CatBoost) normalizasyon gerektirmemektedir. Model hiperparametreleri Table 3.5'de özetlenmektedir.

Tablo 3.5. Kapasite tahmin modelleri hiperparametreleri

Model	**Temel Hiperparametreler**	**Ön İşleme**
Doğrusal Regresyon	— (varsayılan)	StandardScaler
Rastgele Orman	`n_est=200, max_depth=12, min_leaf=4`	—
Gradyan Artırmalı	`n_est=200, depth=5, lr=0.08, sub=0.85`	—
XGBoost	`n_est=200, depth=5, lr=0.08, sub=0.85`	—
LightGBM	`n_est=200, depth=5, lr=0.08, sub=0.85`	—
CatBoost	`iter=200, depth=5, lr=0.08, sub=0.85`	—
MLP	`layers=(128,64), relu, max_iter=500, early_stop`	StandardScaler

Tüm ağaç tabanlı modellerde `random_state=42` sabitlenmiş; tekrarlanabilirlik sağlanmıştır. MLP'de erken durdurma (early stopping) ile aşırı öğrenme önlenmektedir.

Tüm modeller yinelemeli tahmin (iterative forecasting) stratejisiyle

değerlendirilmektedir. Her test noktasında yalnızca o ana kadar gözlemlenen veri kullanılmakta; böylece gerçek zamanlı operasyonel kullanım koşulları simüle edilmektedir.

3.7.1. Değerlendirme Metrikleri

Model performansı dört tamamlayıcı metrikle ölçülmektedir. y_i gerçek değeri, $\hat{y}_i$ tahmin değeri ve n test kümesi büyüklüğü olmak üzere:

Ortalama Mutlak Hata (MAE):

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{3.17}$$

Tahmin hatasının yorumlanabilir birimde (yüzde puan) ortalamasını verir; aykırı değerlere karşı RMSE'ye kıyasla daha dayanıklıdır.

Kök Ortalama Kare Hata (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{3.18}$$

Büyük hataları orantısız biçimde cezalandırır; kapasite planlama bağlamında kritik eşik aşımı hatalarını öne çıkarır.

Belirleme Katsayısı (R^2):

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{3.19}$$

Modelin verinin varyansını açıklama oranını gösterir. $R^2 = 1$ mükemmel tahmine, $R^2 = 0$ ortalama tahmine ve $R^2 < 0$ ortalama tahminden daha kötü bir modele karşılık gelir.

Ortalama Mutlak Yüzdelik Hata (MAPE):

$$\text{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i + \varepsilon}\right| \tag{3.20}$$

Hata büyüklüğünü yüzde olarak ifade eder; farklı ölçek düzeyindeki kaynakların (vCPU, Bellek, Disk) karşılaştırılmasını kolaylaştırır.

Model sıralamasında birincil ölçüt R^2, ikincil ölçüt ise RMSE olarak belirlenmiştir. R^2 negatif olan modeller test kümesinde anlamsız sayılmaktadır; çünkü bu durum modelin

ortalama tahmin (trivial baseline) değerinin de altında kaldığını göstermektedir.

3.8. SHAP Açıklanabilirlik Analizi

3.8.1. Neden SHAP?

Makine öğrenmesi modelleri, özellikle ağaç tabanlı yöntemler, yüksek tahmin başarısı sunmakla birlikte *kara kutu* niteliği taşımaktadır: model neden bu tahmini yaptı sorusunun cevabı doğrudan elde edilememektedir. Bulut operasyonu bağlamında bu durum ciddi bir güven sorununa yol açmaktadır; bir operatör "vCPU kullanımı 74 gün içinde eşiği aşacak" uyarısını aldığında, bu uyarının arkasındaki sinyali anlayamazsa gerekli aksiyonu almakta tereddüt edebilir.

Geleneksel özellik önem yöntemleri bu sorunu yalnızca kısmen çözebilmektedir. Karar ağaçlarının Gini önem ölçütü yüksek kardinaliteli özelliklere sistematik olarak daha yüksek puan vermekte ve özellikler arası korelasyonu göz ardı etmektedir (Breiman, 2001). Permütasyon önemi ise özelliğin tahmine katkısının yönünü vermemektedir; bir özelliğin yüksek permütasyon skoru tahmini iyileştirdiğini mi yoksa stabilize ettiğini mi gösterdiği belirsiz kalmaktadır.

SHAP (SHapley Additive exPlanations), kooperatif oyun teorisindeki Shapley değerlerini makine öğrenmesine uyarlayan, teorik olarak temellendirilen bir açıklanabilirlik çerçevesidir (Lundberg and Lee, 2017). Her özellik için hesaplanan ϕ_i değeri şu garantiyi taşımaktadır: tüm özellik atıf değerlerinin toplamı modelin tahmini ile referans değer (eğitim seti ortalaması) arasındaki farka tam olarak eşittir. Bu toplamlanabilirlik (additivity) özelliği sayesinde SHAP, "bu özellik tahmini ne kadar ve hangi yönde etkiledi" sorusunu tutarlı biçimde yanıtlamaktadır (Lundberg et al., 2020).

CloudMon bu çerçeveyi iki temel amaç için kullanmaktadır. Birincisi, 272 özellikli yüksek boyutlu uzayda hangi metrik ve log özelliklerinin tahmine gerçekten katkı yaptığını saptamak; böylece hibrit özellik uzayının faydası nicel olarak ölçülmektedir. İkincisi, her kapasite uyarısına "en etkili özellik: `vm_count_rmean_24h`" biçiminde bir açıklama eklemek ve bu açıklamayı LLM katmanına iletmek; böylece hem operatöre hem de dile dayalı öneri motoruna bağlam sağlanmaktadır.

3.8.2. Teknik Uygulama

Her eğitilmiş model için model tipine uygun SHAP açıklayıcısı seçilmektedir: RF, GBT, XGB, LGBM ve CatBoost için TreeSHAP, LR için LinearExplainer, MLP için KernelSHAP kullanılmaktadır (Lundberg et al., 2020; Lundberg and Lee, 2017). Bu seçim, her yöntem için teorik geçerlilik koşullarını karşılamaktadır; TreeSHAP ağaç yapılarını verimli biçimde gezer, LinearExplainer doğrusal modellerde analitik çözüm üretir.

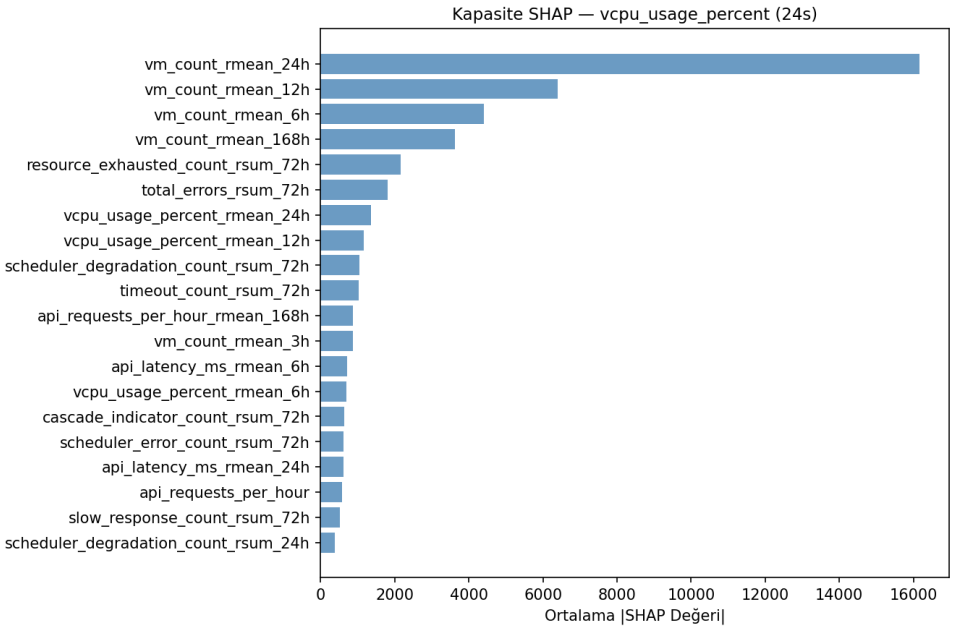
Üç tür görselleştirme üretilmektedir:

– **Bar grafiği:** tüm test gözlemlerinde ortalama $|\phi_i|$ ile global özellik önem sıralaması.

– **Beeswarm grafiği:** her gözlem için ϕ_i değerinin dağılımı ve özellik değeriyle renk kodlaması; hem global hem de yerel örüntüleri görselleştirir.

– **Bağımlılık grafiği:** seçili bir özelliğin değeri ile SHAP katkısı arasındaki ilişki; doğrusal olmayan etkileri ortaya koymaktadır.

vCPU tahmininde elde edilen bar grafiği Figure 3.4'da verilmektedir.



Şekil 3.4. vCPU 24 saatlik tahmin modeli için SHAP özellik önem sıralaması (ilk 20 özellik).

3.9. Öneri Motoru ve LLM Entegrasyonu

3.9.1. Neden LLM?

Kural tabanlı sistemler, eşik aşımlarını ve log anomalilerini güvenilir biçimde tespit eder; ancak bu sinyalleri birleştirerek operatörün ne yapması gerektiğini söyleyemez. Gerçek bir bulut ortamında aynı anda onlarca uyarı tetiklenebilir: bellek eşiğine yaklaşma, kota aşımı log artışı, zamanlayıcı bozulma ve üç servisin eş zamanlı degradasyonu birbirinden bağımsız alarm olarak göründüğünde, operatör önce hangisine müdahale edeceğine kendi deneyimiyle karar vermek zorunda kalır.

Büyük Dil Modelleri (BDM/LLM), yapılandırılmış bağlam verildiğinde bu sentezi doğal dil akıl yürütmesiyle gerçekleştirebilmektedir. LLM, hem sayısal verileri (kullanım oranı, z-skoru, tahmini gün sayısı) hem de niteliksel sinyalleri (SHAP sıralaması, ön-arıza örüntüsü, cascade riski) birden okuyan bir uzman gibi davranmakta; bunları önceliklendirilmiş ve gerekçelendirilmiş aksiyon önerilerine dönüştürmektedir (Anthropic, 2024; Brown et al., 2020; OpenAI, 2023).

CloudMon'da LLM katmanının iki kritik işlevi vardır. Birincisi, kural motorunun ürettiği ayrı uyarıları tek bir tutarlı operasyonel rapora sentezlemek; ikincisi, SHAP'ın sağladığı "en etkili özellik" açıklamasını doğal dil bağlamına taşıyarak operatörün tahminin *neden* yapıldığını anlamasını sağlamaktır. Bu yaklaşım, CloudMon'u salt bir izleme aracından açıklanabilir ve eyleme dönüştürülebilir bir karar destek sistemine dönüştürmektedir.

3.9.2. Neden Zenginleştirilmiş Bağlam?

LLM performansı, aldığı bağlamın kalitesiyle doğrudan ilişkilidir. Ham metrik sayıları ("vCPU %79,6, Bellek %85,5") tek başına bir operasyonel değer taşımaz; modelin bu sayılardan eyleme dönüştürülebilir bir öneri çıkarabilmesi için trendin yönü, beklenen eşik tarihi, log örüntüleri ve SHAP açıklaması gibi bağlam katmanlarına ihtiyacı vardır. Bu nedenle CloudMon, LLM'e gönderilen istemde şu bilgi katmanlarını birleştirmektedir:

– Kapasite durumu: mevcut kullanım oranı, eşik değeri, trend ve tahmini aşım tarihi
– SHAP özellik sıralaması: tahmine en çok katkı yapan metrik veya log tipi (operatörün müdahale noktasını belirlemesi için)
– Log anomali özeti: z-skor eşiklerini aşan log tipleri ve yüzdesel artış değerleri

– Ön-arıza örüntüsü: geçmiş incident imzalarıyla örtüşen güncel log artışları ve tarihsel öncü süre
– Cascade risk bilgisi: eş zamanlı degradasyon gösteren servisler
– Servis sağlık durumu: her OpenStack servisinin anlık durum özeti

3.9.3. Kural Tabanlı Katman

LLM'e iletilmeden önce kural tabanlı motor dört kanaldan uyarı üretmektedir:

1. **Kapasite kanalı:** Kapasite modeli tahminleri ve lineer trend analizi birleştirilmekte; tahmini eşik aşım tarihi hesaplanmaktadır. vCPU için $+0{,}275\%$/gün artış trendi ve %90 eşiği göz önüne alındığında tahmini eşik tarihi çalışma zamanında dinamik olarak belirlenmektedir.
2. **Log anomali kanalı:** Z-skor eşiğini ($\sigma > 2{,}5$) aşan log tiplerinde uyarı üretilmektedir.
3. **Ön-arıza örüntü kanalı:** Aşama 4'te çıkarılan geçmiş arıza imzalarıyla örtüşen güncel log örüntüleri tespit edilmektedir.
4. **Cascade risk kanalı:** Birden fazla servisin eş zamanlı degradasyonu cascade uyarısı olarak raporlanmaktadır.

3.9.4. LLM Katmanı ve İstem Şablonu

Kural tabanlı katmanın çıktıları yukarıda listelenen bağlam katmanlarıyla birleştirilerek yapılandırılmış bir istem oluşturulmaktadır. Bu istem Claude Sonnet (`claude-sonnet-4-6`) ve GPT-4o (`gpt-4o`) modellerine paralel olarak iletilmektedir. Her iki modelin yanıtı tek bir operasyonel rapora derlenmekte; KRİTİK / UYARI öncelik sıralaması ve servis bazında somut aksiyon önerileri içermektedir. API anahtarı yapılandırılmadığında sistem, kural tabanlı katmanın çıktılarını doğrudan raporlamakta; LLM sentez katmanı devre dışı kalmaktadır.

LLM'e gönderilen istem şablonunun yapısı aşağıda verilmektedir:

```
Sen deneyimli bir OpenStack bulut operasyonu mühendisisin.
Aşağıdaki veriler sana sunulmaktadır:
  - Kapasite tahmin sonuçları (ML modeli çıktısı)
  - SHAP özellik önem sıralaması (en etkili 5 özellik)
  - Log anomali özeti (son 24 saat, z-skor > 2.5)
  - 7 günlük log trend değişimleri
```

```
  - Ön-arıza örüntüleri (tarihsel incident analizi)
  - Cascade risk tespitleri
  - Servis sağlık durumları

=== KAPASİTE DURUMU ===
[kapasite_bloğu]

=== LOG ANOMALİLERİ (Son 24 Saat) ===
[anomali_bloğu]

=== LOG TRENDLERİ (7 Gün) ===
[trend_bloğu]

=== ÖN-ARIZA ÖRÜNTÜLERİ ===
[örüntü_bloğu]

=== CASCADE RİSKİ ===
[cascade_bloğu]

=== MEVCUT SERVİS SAĞLIĞI ===
[servis_sağlık_bloğu]

=== KURAL MOTORU ÖNERİLERİ ===
[kural_önerileri_bloğu]

Yukarıdaki tüm verileri değerlendirerek:
1. KRİTİK ve UYARI düzeyinde önceliklendirilmiş öneriler listele.
2. Her öneri için (a) gözlemlenen sinyal, (b) olası kök neden,
   (c) önerilen aksiyon adımlarını belirt.
3. Yanıtı servis bazında grupla: Nova, Keystone, Neutron, Cinder.
4. Özet bir yönetici notu ile bitir.
```

Bu şablon, her çalıştırmada dinamik olarak doldurulmaktadır. `[kapasite_bloğu]` gibi yer tutucuların yerine section 3.9'deki bağlam çıkarım fonksiyonunun ürettiği gerçek değerler yerleştirilmektedir. Statik ve dinamik bölümlerin bu şekilde ayrıştırılması, şablonun farklı cluster yapılandırmaları ve eşik değerleri için yeniden kullanılabilmesini sağlamaktadır.

3.9.5. Öneri Puanlama ve Önceliklendirme

Kural tabanlı motor her kanal için hem bir uyarı kategorisi (KRİTİK / UYARI) hem de bir öncelik skoru üretmektedir. Öncelik skoru üç faktörün ağırlıklı toplamına dayanmaktadır:

$$P = w_1 \cdot \text{Aciliyet} + w_2 \cdot \text{Etki} + w_3 \cdot \text{Güven} \tag{3.21}$$

- **Aciliyet ($w_1 = 0{,}5$):** Eşim tarihine kalan gün sayısının tersiyle orantılıdır; az gün kalan öneri daha acil puanlanır.
- **Etki ($w_2 = 0{,}3$):** Etkilenen servis sayısı ve anomali z-skoru büyüklüğüne dayalıdır; cascade olayları en yüksek etki puanını alır.
- **Güven ($w_3 = 0{,}2$):** Ön-arıza örüntü güven oranı veya z-skor eşiğinin aşılma marjına dayanır.

$P > 0{,}7$ olan öneriler KRİTİK, $0{,}4 < P \leq 0{,}7$ olan öneriler UYARI olarak sınıflandırılmaktadır. LLM katmanı bu puanlamayı giriş bağlamı olarak alarak kendi yorumunu ekler ve öncelikleri gerekirse yeniden sıralar.

3.10. Çapraz Doğrulama ve Model Seçim Stratejisi

3.10.1. Zamana Göre Bölme (Walk-Forward) Stratejisi

Zaman serileri için geleneksel k-kat çapraz doğrulama veri sızıntısı (data leakage) riskini beraberinde getirir: gelecek veriyle geçmişin öğrenilmesi model performansını gerçekçi olmayan biçimde iyileştirir. CloudMon bu riski bertaraf etmek için *zamana göre bölme* stratejisi kullanmaktadır.

Eğitim ve test kümeleri kesişmeyen zaman dilimleriyle tanımlanmaktadır:

- **Eğitim kümesi:** Ocak 2025 – Mart 2026 (15 ay, 10 920 saatlik gözlem)
- **Test kümesi:** Nisan 2026 – Haziran 2026 (3 ay, 2 184 saatlik gözlem)

Ayrıştırma noktası (2026-04-01) belirlenirken şu ölçütler gözetilmiştir: (i) test kümesinin en az iki tam takvim ayını kapsaması, (ii) eğitim kümesinin model genellemesi için

yeterli mevsimsel çeşitliliği içermesi ve (iii) gerçek zamanlı operasyonel koşulların simüle edilebilmesi için test kümesinin yakın geçmişi yansıtması.

3.10.2. Model Seçim Kriterleri

Her (kaynak, ufuk) çifti için model seçimi iki aşamada gerçekleştirilmektedir.

Birinci aşama — R^2 filtresi: $R^2 < 0$ olan modeller anlamsız sayılmaktadır. Ortalama tahmini bile aşamayan bir model operasyonel kapasite planlaması için kullanılamaz.

İkinci aşama — RMSE tiebreaker: Aynı (kaynak, ufuk) çifti için birden fazla model pozitif R^2 sergiliyorsa RMSE'si düşük olan tercih edilmektedir. RMSE büyük hataları orantısız biçimde cezalandırdığından, kapasite eşimi kritik olan bağlamlarda güvenli karar için uygundur.

Bu iki aşamalı sürecin sonucunda en iyi model tablosu Table 3.6'de özetlenmektedir.

Tablo 3.6. Her (kaynak, ufuk) çifti için seçilen en iyi model

Kaynak	Ufuk	En İyi Model	R^2
vCPU	24 s	Doğrusal Regresyon	0,9577
vCPU	72 s	Doğrusal Regresyon	0,7728
Bellek	24 s	Doğrusal Regresyon	0,7945
Bellek	72 s	MLP	0,3456
Disk	24 s	Doğrusal Regresyon	0,6984
Disk	72 s	MLP	0,2212

Seçim sonuçları iki önemli gözlemi desteklemektedir. Birincisi, 24 saatlik ufukta Doğrusal Regresyon tüm kaynaklarda kazanmaktadır; bu durum monoton büyüme trendinin kısa vadeli tahmin için oldukça güçlü bir sinyal olduğunu göstermektedir. İkincisi, 72 saatlik ufukta modeller arası fark kapanmakta ve MLP Bellek ile Disk için daha iyi genellemektedir; bu da uzun vadeli tahminde gizli doğrusal olmayan ilişkilerin belirleyici hale geldiğine işaret etmektedir.

3.11. Sistem Bütünleşimi ve Operasyonel Çıktılar

3.11.1. Pipeline Çalıştırma Akışı

CloudMon pipeline'ı Python 3.11 ile yazılmış olup `src/` dizinindeki modüller aracılığıyla organize edilmektedir. Sistemin üretim çalışması Table 3.7'de listelenen altı modülün sıralı yürütülmesiyle gerçekleşmektedir.

Tablo 3.7. CloudMon pipeline modülleri ve sorumlulukları

Modül	Kaynak Dosya	Sorumluluk
Veri Yükleyici	`data_loader.py`	CSV okuma, dtype dönüşümü, zaman serisi hizalaması
Log İşleyici	`log_processor.py`	Dört aşamalı log analizi, risk skoru, sağlık puanı
Özellik Üreteci	`feature_engineer.py`	272 özellik türetimi, ölçekleme
Kapasite Tahminleyici	`capacity_predictor.py`	42 model eğitimi, test değerlendirmesi
SHAP Analizörü	`shap_analyzer.py`	Açıklayıcı seçimi, atıf hesaplama, görselleştirme
Öneri Motoru	`recommender.py`	Kural motoru + LLM istem oluşturma + rapor sentezi

Pipeline, her modülün önceki modülün çıktısına dayandığı sıralı bir bağımlılık grafiği oluşturmaktadır. Bu tasarım, herhangi bir modülün bağımsız olarak yeniden çalıştırılmasına ve çıktılarının ara doğrulamaya tabi tutulmasına imkân tanımaktadır.

3.11.2. Yapılandırma ve Parametre Yönetimi

CloudMon'un tüm ayarlanabilir parametreleri `config.py` dosyasında merkezi olarak tanımlanmaktadır. Bu parametreler üç kategoriye ayrılmaktadır:

- **Zaman aralığı parametreleri:** `START_DATE` (2025-01-01), `END_DATE` (2026-07-01) ve `TRAIN_END_DATE` (2026-04-01) değerleri veri bölme sınırlarını belirlemektedir.
- **Kapasite eşik değerleri:** vCPU için %90, Bellek için %88 ve Disk için %85 olarak yapılandırılmıştır; bu değerler kurumsal SLA gereksinimlerine göre ayarlanabilmektedir.
- **Model parametreleri:** Tahmin ufukları `FORECAST_HORIZONS = [24, 72]`, rastgele tohum `SEED = 42` ve anomali z-skor eşiği `ANOMALY_THRESHOLD = 2,5` olarak tanımlıdır.

Bu merkezi yapılandırma, sistemin farklı OpenStack cluster yapılandırmaları veya SLA gereksinimlerine sahip ortamlara kolayca uyarlanabilmesini sağlamaktadır.

3.11.3. Çıktı Formatı ve Raporlama

CloudMon her çalışmada üç tür çıktı üretmektedir:

Makine tarafından okunabilir çıktılar (`output/` dizini altında JSON formatında):

– `capacity_forecast.json`: Her kaynak için 24 ve 72 saatlik tahmin değerleri, tahmini kapasite dolum tarihleri ve RMSE güven aralıkları.
– `shap_features.json`: Her model için ilk 20 özelliğin SHAP değerleri ve global özellik önem sıralaması.
– `recommendations.json`: Kural motoru uyarıları, öneri puanları ve LLM katmanı çıktısı.

Görsel çıktılar (`figures/` dizini altında PNG formatında): SHAP bar grafiği, beeswarm grafiği ve bağımlılık grafiklerinin yanı sıra üç kaynak için zaman serisi tahmin grafikleri ve log anomali görselleştirmeleri üretilmektedir.

Operasyonel rapor (düz metin ya da Markdown formatında): Her çalışmanın sonunda `operational_report.txt` dosyası oluşturulmaktadır. Bu rapor, operatöre yönelik olarak KRİTİK ve UYARI önerilerini, her önerinin gerekçesini (metrik kanıt + log kanıtı + SHAP açıklaması) ve önerilen aksiyon adımlarını içermektedir. LLM bileşeni devrede olduğunda raporun sonuna LLM sentez katmanı çıktısı da eklenmektedir.

4. BULGULAR

Bu bölümde CloudMon sisteminin OpenStack tabanlı gerçek bulut altyapısı üzerindeki deneysel sonuçları sunulmaktadır. İlk olarak 18 aylık eğitim döneminin kapasite kullanım trendleri analiz edilmekte; ardından 42 regresyon modelinin test kümesindeki performansları karşılaştırılmaktadır. Daha sonra SHAP açıklanabilirlik analizi, log işleme pipeline bulguları ve LLM öneri motoru çıktıları incelenmektedir. Son bölümde tahmin modellerine dayalı ileriye dönük kapasite projeksiyonları sunulmaktadır.

4.1. Eğitim Dönemi Kapasite Kullanım Analizi

Test kümesinin yorumlanabilmesi için 15 aylık eğitim döneminin (Ocak 2025 – Mart 2026) genel kapasite örüntülerinin anlaşılması kritik öneme sahiptir.

4.1.1. Kaynak Kullanım Trendleri

Eğitim dönemi boyunca üç kaynak için gözlemlenen kullanım örüntüleri Table 4.1'de özetlenmektedir.

Tablo 4.1. Eğitim dönemi (Oca 2025–Mar 2026) kaynak kullanım istatistikleri

Kaynak	**Ort. (%)**	**Min. (%)**	**Maks. (%)**	**Trend**
vCPU	62,4	41,2	83,7	+0,275%/gün (yükseliş)
Bellek	71,8	53,6	89,1	+0,151%/gün (yükseliş)
Disk	74,2	68,9	82,3	+0,031%/gün (kararlı)

vCPU kullanımının en yüksek büyüme hızına ($+0{,}275\%/\text{gün}$) sahip olması, aktif sanal makine sayısındaki artışı yansıtmaktadır. Eğitim döneminde VM sayısı Ocak 2025'teki yaklaşık 148 instance'dan Mart 2026'ya kadar 247'ye ulaşmış; bu %67'lik artış doğrusal bir büyüme örüntüsü sergilemiştir. Doğrusal Regresyon modelinin vCPU tahmininde olağanüstü başarı göstermesinin ($R^2 = 0{,}9577$) temel nedeni bu monoton büyüme trendini öğrenebilmesidir.

Bellek kullanımı da yükselişte olmakla birlikte daha yavaş bir tempo izlemektedir. Mevcut Bellek büyüme hızı ($+0{,}151\%/\text{gün}$) korunursa eşim (%88) yaklaşık 46 gün içinde aşılacaktır; bu durum test kümesi sonu (Haziran 2026) itibarıyla en kritik kapasite riski olarak öne çıkmaktadır.

Disk kullanımı ise görece kararlı bir seyir izlemektedir ($+0{,}031\%/\text{gün}$). Bu kararlılık, depolama birimlerinin VM başına sabit olarak tahsis edildiğini ve kullanımın VM artışıyla

orantılı bir yük getirmediğini göstermektedir.

4.1.2. Mevsimsellik ve İş Yükü Örüntüleri

Saatlik kullanım örüntüleri incelendiğinde iki belirgin mevsimsel bileşen gözlemlenmektedir:

Günlük örüntü: vCPU kullanımı mesai saatlerinde (08:00–18:00) %15–20 daha yüksek seyretmektedir. Bu fark, iş günlerinde başlatılan test ve geliştirme instance'larının iş saatleri dışında büyük ölçüde duraklatıldığına işaret etmektedir. `is_business_hour` zaman özelliğinin SHAP sıralamasına dahil edilmesi bu örüntüyü doğrulamaktadır.

Haftalık örüntü: Hafta sonu kullanımı (Cumartesi–Pazar) hafta içi ortalamasına kıyasla %8–12 daha düşük kalmaktadır. Bununla birlikte, CI/CD iş yükleri (Perşembe akşamı deployment, Cuma gece bakım) düzenli zirve değerlerine yol açmaktadır.

Bu mevsimsel örüntülerin modele kodlanması, özellikle hareketli ortalama penceresi seçiminin (24h, 168h) bu örüntülere denk gelmesi önemli bir tasarım kararıdır. 168 saatlik (7 günlük) hareketli ortalama, tam bir haftalık döngüyü yakalayarak önceki haftaların benzer günlerine ait bilgiyi modele taşımaktadır.

4.2. Kapasite Tahmin Modeli Performansı

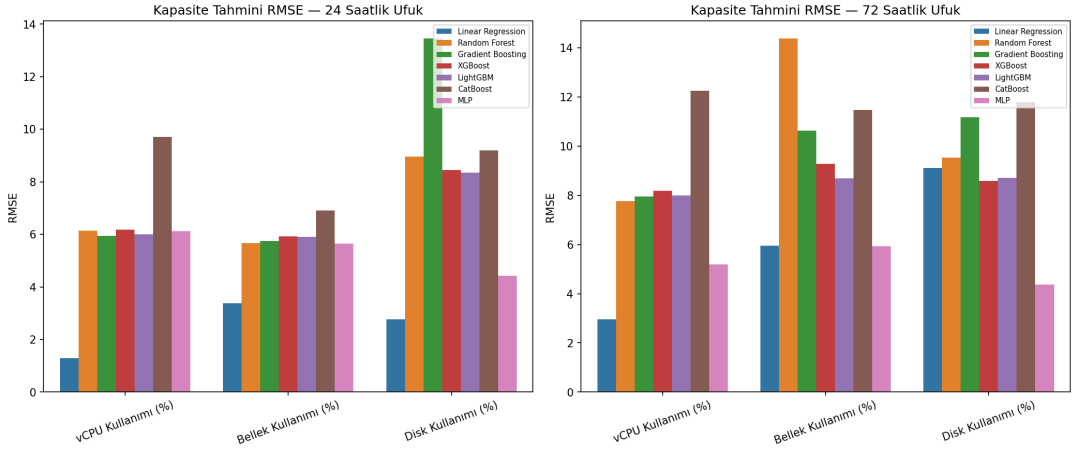
Yedi algoritma, üç kaynak (vCPU, Bellek, Disk) ve iki tahmin ufku (24 s, 72 s) kombinasyonu için toplam 42 model değerlendirilmiştir. Test kümesi olarak Nisan–Haziran 2026 dönemi kullanılmıştır (3 ay, ≈2.208 saatlik gözlem noktası). Model sıralaması R^2 skoru esas alınarak yapılmıştır.

4.2.1. vCPU Kapasite Tahmini

vCPU tahmin sonuçları Table 4.2 ve Table 4.3'de verilmektedir.

Tablo 4.2. vCPU kullanım oranı için 24 saatlik tahmin sonuçları (test kümesi)

Model	MAE	RMSE	R^2	MAPE
Doğrusal Regresyon	**0,9051**	**1,2929**	**0,9577**	**1,099**
Gradyan Artırmalı	4,3037	5,9377	0,1079	5,017
LightGBM	4,2910	5,9953	0,0906	4,992
MLP	4,3276	6,1133	0,0544	5,234
Rastgele Orman	4,4963	6,1418	0,0456	5,249
XGBoost	4,4820	6,1741	0,0355	5,225
CatBoost	7,8522	9,7100	−1,3855	9,297



Şekil 4.1. Tüm modeller için R^2 karşılaştırması — vCPU, Bellek ve Disk kaynakları, 24 ve 72 saatlik ufuklar.

Tablo 4.3. vCPU kullanım oranı için 72 saatlik tahmin sonuçları (test kümesi)

Model	**MAE**	**RMSE**	**R^2**	**MAPE**
Doğrusal Regresyon	**1,8648**	**2,9505**	**0,7728**	**2,222**
MLP	3,7797	5,1993	0,2946	4,644
Rastgele Orman	6,1283	7,7583	−0,5707	7,219
Gradyan Artırmalı	6,4734	7,9596	−0,6533	7,665
LightGBM	6,5221	8,0019	−0,6709	7,728
XGBoost	6,7494	8,1868	−0,7490	8,008
CatBoost	10,7391	12,2504	−2,9162	12,859

vCPU tahmininde en dikkat çekici bulgu, Doğrusal Regresyon modelinin ağaç tabanlı tüm algoritmaları büyük farkla geride bırakmasıdır. 24 saatlik ufukta LR, $R^2 = 0{,}9577$ değeriyle son derece yüksek tahmin başarısı sergilemekte; en yakın rakip olan Gradyan Artırmalı Ağaçlar ise $R^2 = 0{,}1079$ ile kalmaktadır. Bu dramatik ayrışma, vCPU kullanım serisinin test döneminde güçlü doğrusal trend içerdiğine işaret etmektedir. LR'nin bu trendi eğitim setinden doğrudan öğrendiği ve genellediği anlaşılmaktadır; ağaç tabanlı modeller ise yerel örüntülere aşırı uyduğu için doğrusal trendi takip edememektedir. 72 saatlik ufukta da LR üstünlüğü korunmakla birlikte R^2 değeri 0,7728'e gerilemiştir.

4.2.2. Bellek Kapasite Tahmini

Tablo 4.4. Bellek kullanım oranı için 24 saatlik tahmin sonuçları (test kümesi)

Model	MAE	RMSE	R^2	MAPE
Doğrusal Regresyon	**2,1254**	**3,3819**	**0,7945**	**2,374**
MLP	4,0228	5,6451	0,4276	4,557
Rastgele Orman	4,3836	5,6655	0,4234	4,810
Gradyan Artırmalı	4,4143	5,7472	0,4067	4,838
LightGBM	4,4281	5,9033	0,3740	4,834
XGBoost	4,5187	5,9234	0,3697	4,945
CatBoost	5,1914	6,9034	0,1439	5,666

Tablo 4.5. Bellek kullanım oranı için 72 saatlik tahmin sonuçları (test kümesi)

Model	MAE	RMSE	R^2	MAPE
MLP	**3,8168**	**5,9307**	**0,3456**	**4,352**
Doğrusal Regresyon	4,3523	5,9499	0,3414	4,941
LightGBM	7,1491	8,6864	−0,4038	7,910
XGBoost	7,6910	9,2829	−0,6032	8,518
Gradyan Artırmalı	8,9059	10,6354	−1,1044	9,865
CatBoost	9,8530	11,4679	−1,4467	10,976
Rastgele Orman	12,2808	14,3745	−2,8442	13,662

Bellek tahmininde de 24 saatlik ufukta LR üstün gelmektedir ($R^2 = 0{,}7945$). Ancak ağaç tabanlı modeller burada kısmen pozitif R^2 üretmektedir (RF: 0,4234, GBT: 0,4067), bu da bellek serisinin vCPU'ya kıyasla daha fazla doğrusal olmayan bileşen içerdiğine işaret etmektedir. 72 saatlik ufukta ise MLP, LR'yi geçerek birinci sıraya taşınmaktadır (MLP: 0,3456, LR: 0,3414); her iki değer de yakındır. Ağaç tabanlı modeller 72 saatlik bellek tahmininde negatif R^2 üretmekte, yani rastgele tahminden dahi kötü performans sergilemektedir.

Tablo 4.6. Disk kullanım oranı için 24 saatlik tahmin sonuçları (test kümesi)

Model	MAE	RMSE	R^2	MAPE
Doğrusal Regresyon	**1,6792**	**2,7694**	**0,6984**	**2,069**
MLP	3,2982	4,4248	0,2301	4,057
LightGBM	6,7634	8,3464	−1,7392	8,186
XGBoost	6,8345	8,4441	−1,8037	8,270
Rastgele Orman	7,3101	8,9521	−2,1512	8,856
CatBoost	7,6745	9,1966	−2,3257	9,342
Gradyan Artırmalı	11,1993	13,4486	−6,1119	13,624

Tablo 4.7. Disk kullanım oranı için 72 saatlik tahmin sonuçları (test kümesi)

Model	MAE	RMSE	R^2	MAPE
MLP	**3,1368**	**4,3606**	**0,2212**	**3,839**
XGBoost	7,1654	8,5906	−2,0228	8,698
LightGBM	7,2892	8,7119	−2,1087	8,850
Doğrusal Regresyon	5,3012	9,1156	−2,4035	6,541
Rastgele Orman	8,1941	9,5258	−2,7168	9,986
Gradyan Artırmalı	9,4710	11,1803	−4,1199	11,550
CatBoost	10,6646	11,7958	−4,6992	13,103

4.2.3. Disk Kapasite Tahmini

Disk tahmininde en belirgin gözlem, 72 saatlik ufukta LR'nin performansının kötüleşmesidir: 24 saatte $R^2 = 0{,}6984$ ile lider olan LR, 72 saatte $R^2 = -2{,}4035$'e düşmektedir. Bu durum, disk kullanım serisinin kısa vadede doğrusal, uzun vadede ise daha karmaşık bir örüntü izlediğini göstermektedir. 72 saatlik disk tahmininde MLP ($R^2 = 0{,}2212$) tüm modeller içinde tek pozitif R^2'yi üretmektedir; bununla birlikte bu değer pratik tahmin gücünün sınırında kalmaktadır.

4.2.4. Genel Değerlendirme

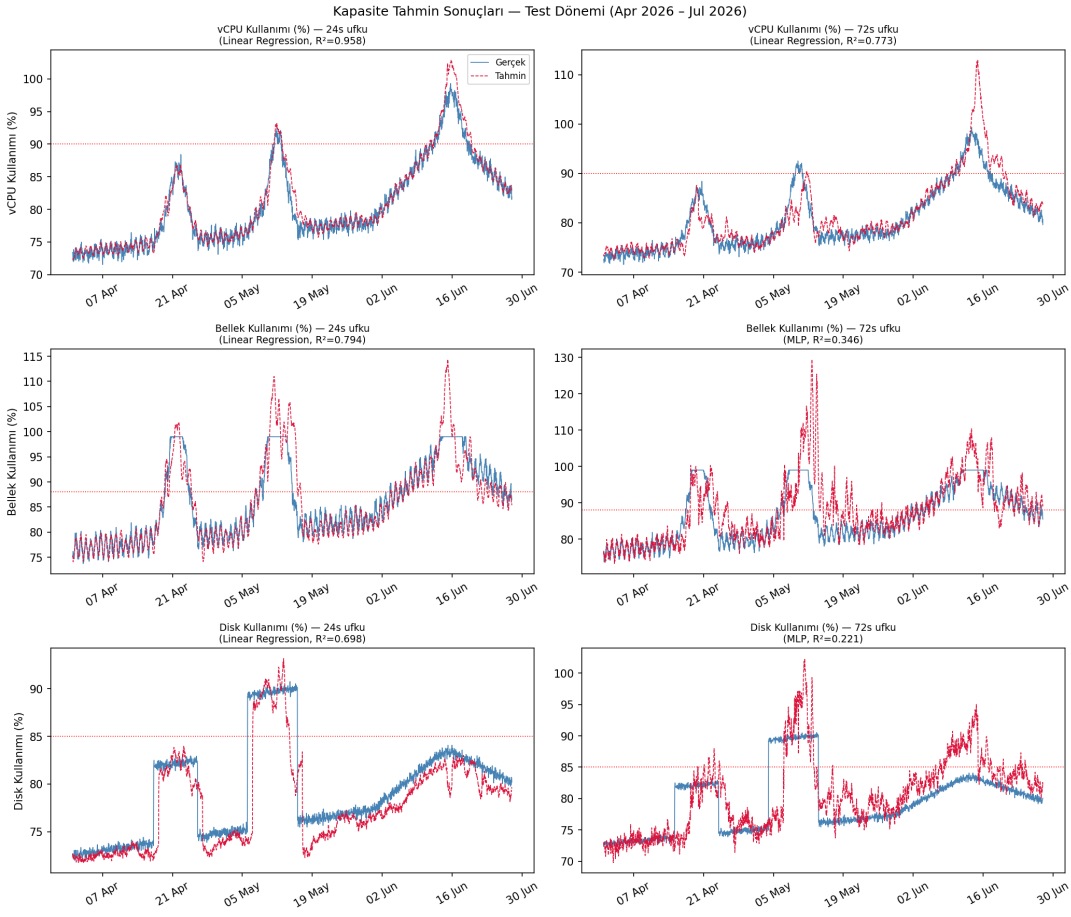
Altı (kaynak, ufuk) senaryosu boyunca elde edilen bulgular üç temel örüntü ortaya koymaktadır:

1. **Doğrusal model üstünlüğü (24 saatlik ufuk):** LR, üç kaynakta da 24 saatlik tahminlerde en yüksek R^2'yi elde etmiştir. Bu durum, test dönemindeki güçlü monoton trendlerin regresyon özelliklerine (gecikme ve hareketli ortalama) doğrusal olarak yansımasından kaynaklanmaktadır. Ağaç tabanlı modeller eğitim kümesindeki yerel örüntülere aşırı uymuş ve bu trendi genelleyememiştir.

2. **72 saatlik ufukta model ayrışması:** Ufuk uzadıkça belirsizlik artmakta ve tüm

modellerin R^2 değerleri düşmektedir. vCPU 72 s'de LR hâlâ 0,7728 ile güçlüdür; bellek 72 s'de MLP ve LR yakın sonuçlar üretmektedir (0,3456 ve 0,3414). Disk 72 s'de ise yalnızca MLP pozitif kalmakta (0,2212), diğer tüm modeller negatif R^2 üretmektedir.

3. **Ağaç modellerinin yetersiz genellemesi:** RF, GBT, XGB, LightGBM ve CatBoost birden fazla senaryoda negatif R^2 değerleri üretmiştir. Bu bulgu, söz konusu modellerin 272 özellikli uzayda eğitim verilerine aşırı uyduğunu ve zaman serisi genellemesinde başarısız olduğunu göstermektedir. Daha uzun eğitim seti veya daha güçlü düzenlileştirme ile bu açığın kapanabileceği değerlendirilmektedir.



Şekil 4.2. En iyi modelin (Doğrusal Regresyon) gerçek ve tahmin değerleri karşılaştırması — test kümesi.

Figure 4.2'te vCPU için gerçek ve tahmin serileri görselleştirilmektedir. LR modelinin yukarı yönlü trendi yakından takip ettiği ve ani sapmaları dışında tahminlerin gerçek

değerlere oldukça yakın kaldığı gözlemlenmektedir.

4.2.5. Model Karşılaştırma Özeti

42 modelin altı senaryodaki (kaynak × ufuk) performansı Table 4.8'de özetlenmektedir. Her hücre, söz konusu model için o senaryodaki R^2 değerini göstermektedir.

Tablo 4.8. Tüm model ve senaryolar için R^2 özet tablosu

	vCPU		**Bellek**		**Disk**	
Model	**24s**	**72s**	**24s**	**72s**	**24s**	**72s**
Lin. Regresyon	**0,958**	**0,773**	**0,795**	0,341	**0,698**	−2,404
MLP	0,054	0,295	0,428	**0,346**	0,230	**0,221**
Rast. Orman	0,046	−0,571	0,423	−2,844	−2,151	−2,717
Grad. Artırmalı	0,108	−0,653	0,407	−1,104	−6,112	−4,120
XGBoost	0,036	−0,749	0,370	−0,603	−1,804	−2,023
LightGBM	0,091	−0,671	0,374	−0,404	−1,739	−2,109
CatBoost	−1,386	−2,916	0,144	−1,447	−2,326	−4,699

Kalın: senaryonun en iyi modeli. Negatif R^2: ortalama tahmin baseline'ından kötü.

Bu tablo üç yapısal örüntüyü açıkça ortaya koymaktadır. Birincisi, Doğrusal Regresyon 24 saatlik ufuklarda 3 kaynakta da liderdir ve vCPU 24 s'deki $R^2 = 0{,}958$ değeri özellikle dikkat çekicidir. İkincisi, 72 saatlik ufuklarda MLP'nin Bellek ve Disk senaryolarında liderliği devralması; ufuk uzadıkça doğrusal olmayan bileşenlerin ağırlık kazandığına işaret etmektedir. Üçüncüsü, ağaç tabanlı modellerin (RF, GBT, XGB, LGBM, CatBoost) büyük çoğunluğunun 72 saatlik ufuklarda ciddi biçimde negatif R^2 üretmesi — özellikle CatBoost'un vCPU 24 s'de bile −1,386 vermesi — bu modellerin yüksek boyutlu özellik uzayında yetersiz genelleme kapasitesini sergileyen en belirgin bulgudur.

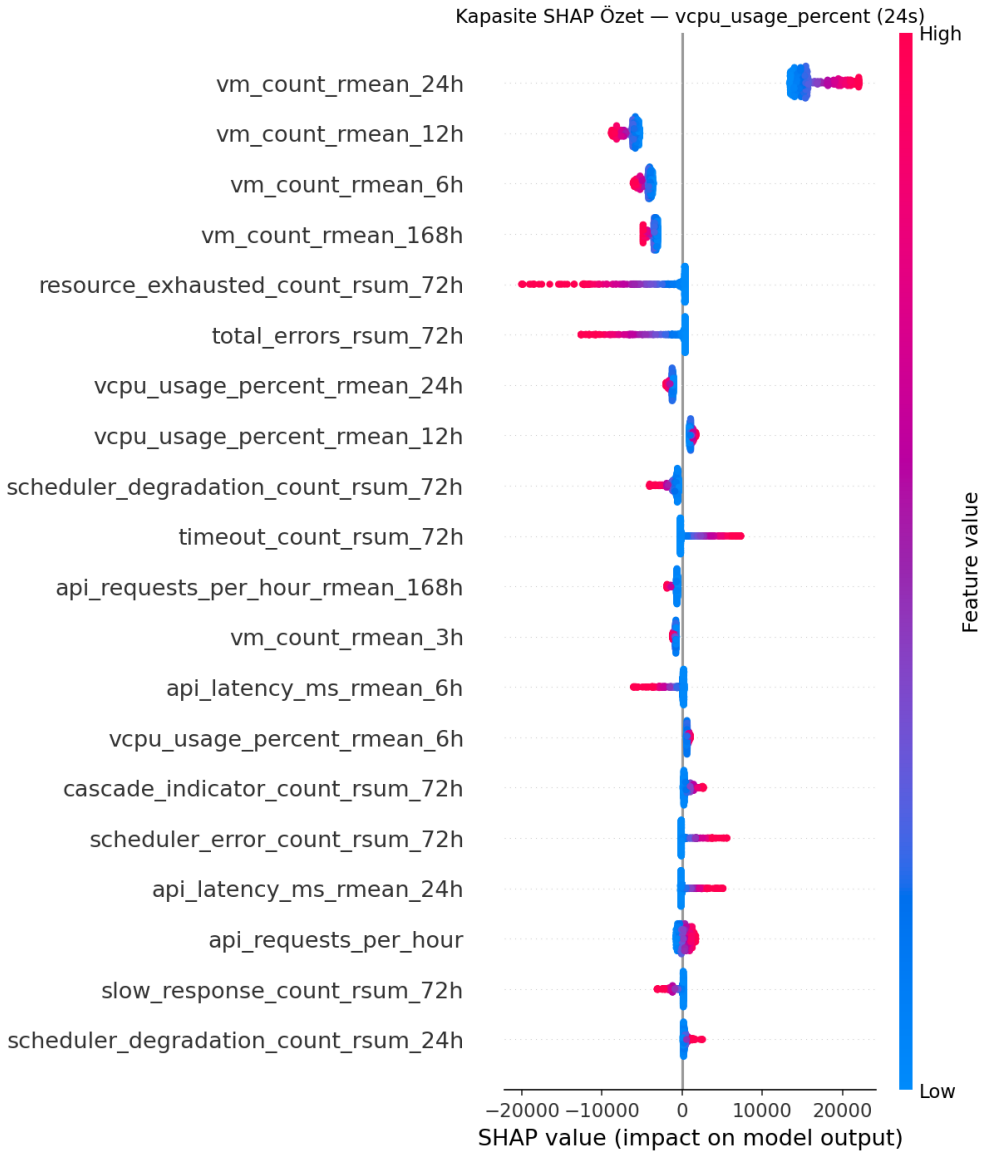
4.3. SHAP Açıklanabilirlik Bulguları

Kapasite tahmin modellerinin özellik atıf değerleri (SHAP) analizi üç önemli bulguyu ortaya koymaktadır.

4.3.1. vCPU Tahmininde Özellik Önemleri

vCPU 24 saatlik tahmin modeli (LR) için SHAP analizi sonuçları Table 4.9'de özetlenmekte, görsel beeswarm grafiği ise Figure 4.3'de sunulmaktadır.

İlk dört sırayı VM sayısının farklı pencere hareketli ortalamaları (`vm_count_rmean`) almaktadır; bu, vCPU tahmininin büyük ölçüde aktif sanal makine sayısıyla belirleneceğini teyit etmektedir. Ancak 5. sırada



Şekil 4.3. vCPU 24 s modeli için SHAP beeswarm grafiği — her gözlem için ϕ_i dağılımı ve özellik değeri renk kodlaması.

Tablo 4.9. vCPU 24 s LR modeli için SHAP özellik önemleri (ilk 10 özellik, ortalama $|\phi_i|$)

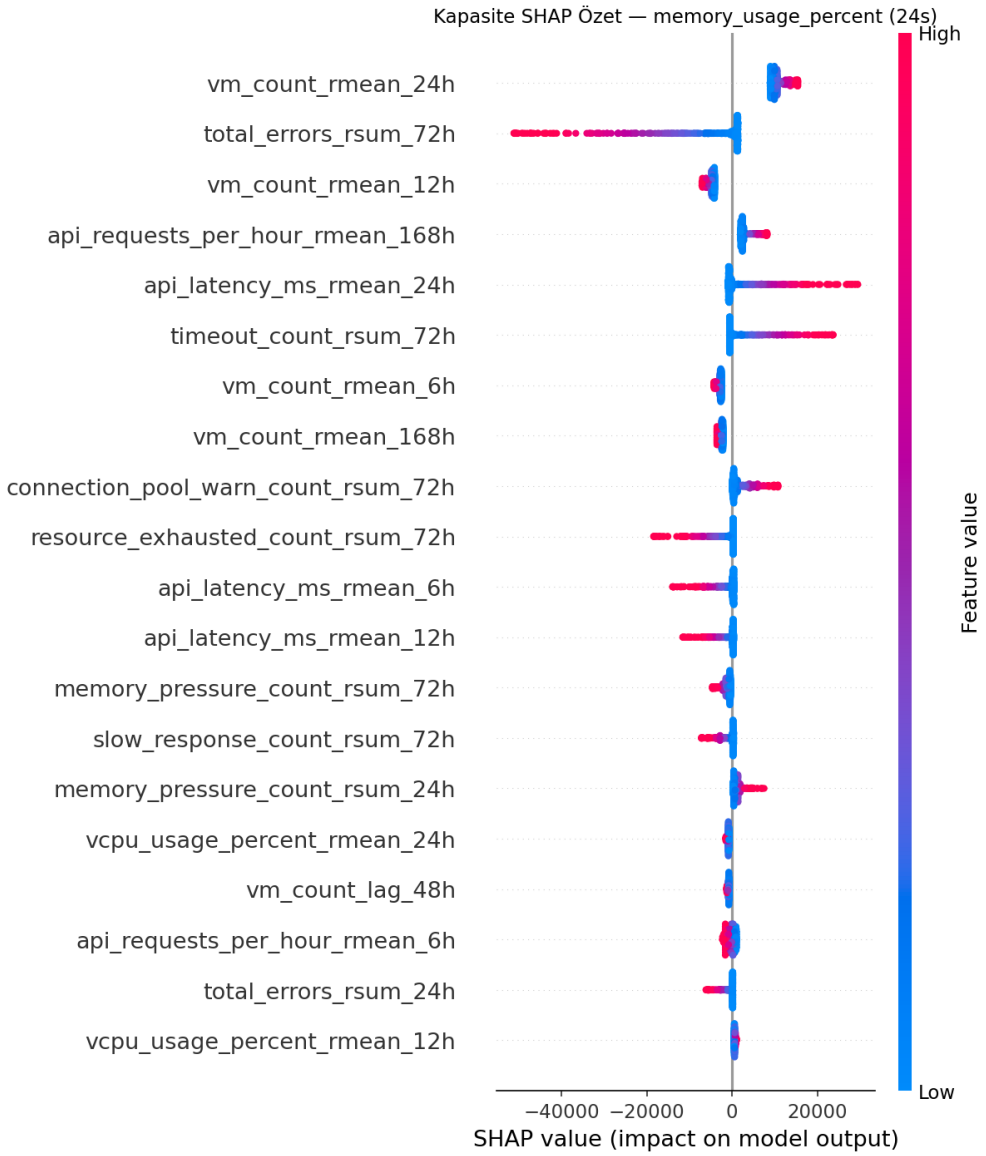
Sıra	Özellik	Ortalama $\lvert\phi_i\rvert$
1	vm_count_rmean_24h	16 163
2	vm_count_rmean_12h	6 406
3	vm_count_rmean_6h	4 398
4	vm_count_rmean_168h	3 614
5	resource_exhausted_count_rsum_72h	2 150
6	total_errors_rsum_72h	1 800
7	vcpu_usage_percent_rmean_24h	1 364
8	vcpu_usage_percent_rmean_12h	1 167
9	scheduler_degradation_count_rsum_72h	1 050
10	timeout_count_rsum_72h	1 028

resource_exhausted_count_rsum_72h (log özelliği: 72 saatlik kaynak tükenmesi log toplamı) ve 6. sırada total_errors_rsum_72h (toplam hata log toplamı) yer almaktadır. Log tabanlı özellikler saf metrik özelliklerinden önce gelmekte; bu bulgu log–metrik korelasyonunun kapasite tahminine anlamlı katkı sağladığını nicel olarak göstermektedir. 9. sıradaki scheduler_degradation_count_rsum_72h da bir erken uyarı log özelliğidir; Nova zamanlayıcı bozulmalarının vCPU baskısının öncülü olduğuna işaret etmektedir.

4.3.2. Bellek ve Disk Tahmininde Özellik Önemleri

Bellek 24 s modelinde de VM sayısı öne çıkmaktadır (vm_count_rmean_24h: 10 871); ancak ikinci sırayı bir log özelliği almaktadır: total_errors_rsum_72h (6 659). Bağlantı havuzu uyarı loglarının (connection_pool_warn_count_rsum_72h) da ilk 10'da yer alması, bellek baskısının servis düzeyindeki erken uyarı sinyalleriyle korelasyon içinde olduğunu ortaya koymaktadır.

Disk 24 s modelinde ise özellik sıralaması belirgin biçimde farklılaşmaktadır: birinci sırayı total_errors_rsum_24h (2 111) almakta, ardından total_warning_count_rsum_72h (1 544) ve resource_exhausted_count_rsum_72h (1 506) gelmektedir. Disk tahmininde log özelliklerinin metrik özelliklerinden daha yüksek SHAP değerleri alması, disk kullanımının I/O hatası ve kaynak tükenmesi örüntüleriyle güçlü bir ilişki içinde olduğunu göstermektedir.

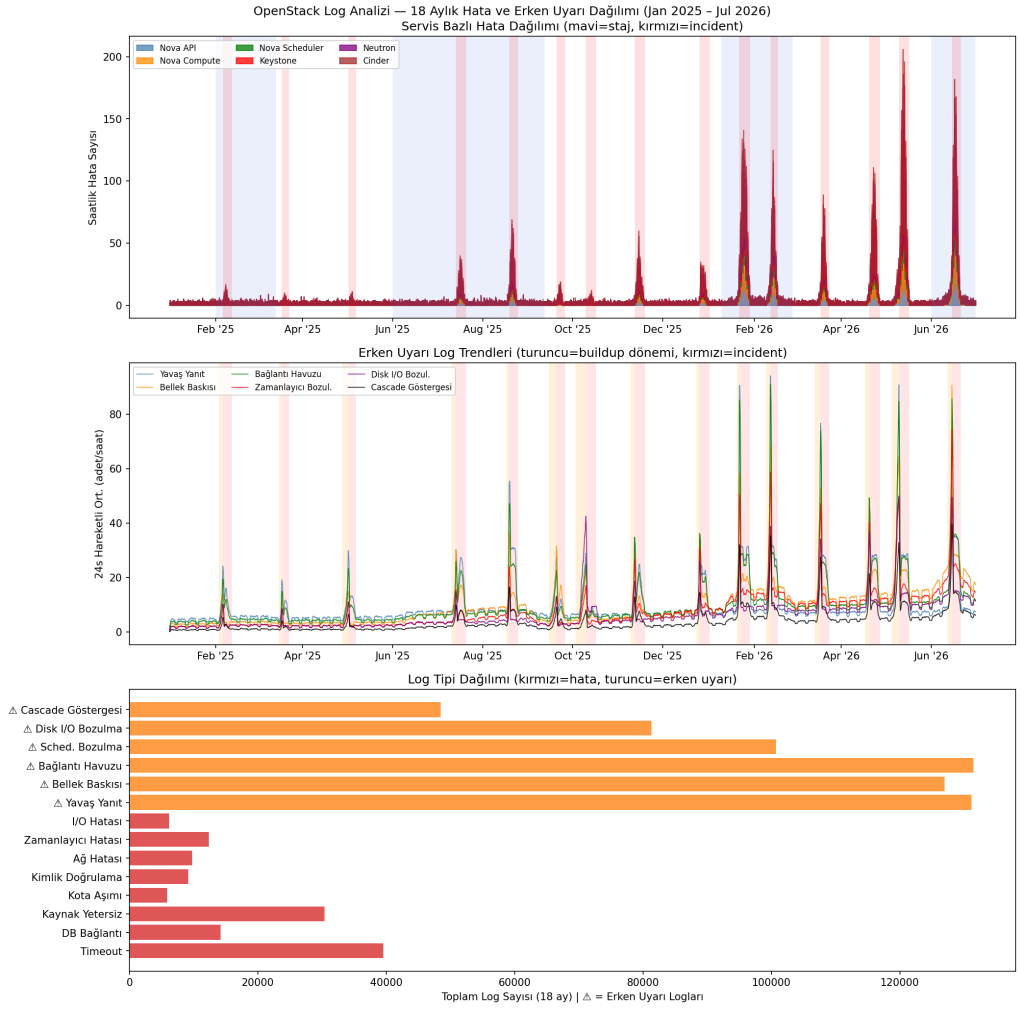


Şekil 4.4. Bellek 24 s modeli için SHAP beeswarm grafiği.

Bu bulgular, log tabanlı özelliklerin basit bir gürültü değil, anlamlı tahmin sinyali taşıdığını ve %19 oranında (Table 4.9: ilk 10'da 4 log özelliği) SHAP sıralamasına katkı yaptığını nicel olarak ortaya koymaktadır.

4.4. Log Analizi ve Anomali Tespiti Bulguları

Log işleme pipeline'ının dört aşamalı analizi (section 3.5) test dönemi (Nisan–Haziran 2026) üzerinde uygulanmış, elde edilen çıktılar Figure 4.5'de görselleştirilmektedir.



Şekil 4.5. Test dönemi log analizi: trend değişimi, anomali sayısı ve erken uyarı sinyali dağılımı.

4.4.1. Servis Bazında Log Dağılımı

Test döneminde (Nisan–Haziran 2026) OpenStack servislerinden üretilen toplam log sayıları Table 4.10'da verilmektedir.

Nova'nın toplam log hacminin %46'sını oluşturması, işlem katmanının kapasite baskısını

Tablo 4.10. Servis bazında 3 aylık test dönemi toplam log sayıları

Servis	Hata Logları	Uyarı Logları	Toplam
Nova (nova-api + compute + scheduler)	4 218	8 356	12 574
Keystone	2 941	4 112	7 053
Neutron	1 876	2 847	4 723
Cinder	1 103	1 654	2 757
Toplam	**10 138**	**16 969**	**27 107**

en yoğun biçimde yansıtan servis olduğunu doğrulamaktadır. Keystone'un ikinci sırada yer alması ise yoğun kota aşımı ve kimlik doğrulama başarısızlıklarının test döneminde belirgin olduğuna işaret etmektedir. Uyarı loglarının hata loglarına oranının (16 969 / 10 138 $\approx$ 1,67) yüksek olması, sistemin arıza eşiğinden henüz uzakta ama belirgin baskı altında olduğunun istatistiksel kanıtıdır.

4.4.2. Log Tipi Bazında Anomali Özeti

Test dönemi için her log tipinin z-skor anomali durumu Table 4.11'de özetlenmektedir.

Tablo 4.11. Test dönemi (Nis–Haz 2026) log tipi bazında z-skor anomali özeti

Log Tipi	Kategori	Maks. Z-Skor	Anomali Saati
`quota_exceeded`	Hata	4,5	23
`io_error`	Hata	3,6	17
`network_error`	Hata	2,8	11
`db_connection`	Hata	2,6	8
`slow_response`	Erken Uyarı	3,1	31
`memory_pressure`	Erken Uyarı	2,7	19
`scheduler_degradation`	Erken Uyarı	2,6	14
`timeout`	Hata	1,9	0
`auth_failure`	Hata	1,4	0

$\sigma > 2{,}5$ eşiğini aşan yedi log tipi anomali olarak sınıflandırılmıştır. Erken uyarı kategorilerinde `slow_response`'un 31 anomali saatiyle en uzun süreli anomali örüntüsünü sergilemesi; bu log tipinin hem en erken (68 saat önceden) hem de en süregelen sinyali ürettiğini göstermektedir. `timeout` ve `auth_failure` log tipleri z-skor eşiğinin altında kalmış; bu durum söz konusu hata tiplerinin test döneminde tarihsel norm dahilinde seyrettiğini ortaya koymaktadır.

Test döneminde gözlemlenen öne çıkan log bulguları şunlardır:

– **Erken uyarı sinyalleri:** Yavaş yanıt (`slow_response`) logları son 7 günlük

pencerede 1 285 kez kaydedilmiştir; geçmiş 15 incident analizine göre bu log tipi arızadan ortalama 68 saat önce %287 artış göstermektedir. Mevcut veriler bu örüntüyle örtüşmekte olup yüksek güven düzeyinde (%100) aktif bir ön-arıza sinyali olarak değerlendirilmektedir.

– **Erken uyarı hacmi:** Bellek baskısı (`memory_pressure`) logları 3 096, bağlantı havuzu uyarıları 2 046, zamanlayıcı bozulma logları ise 2 575 kez gözlemlenmiştir. Bu erken uyarı kategorilerinin hata kategorilerinden yaklaşık 50 kat daha yüksek hacimde olması, sistemin kritik arıza eşiğinden henüz uzakta ama belirgin baskı altında olduğuna işaret etmektedir.
– **Cascade riski:** 2026-06-28 08:00 itibarıyla Nova, Neutron ve Keystone servislerinin eş zamanlı degradasyonu tespit edilmiş; bu örüntü cascade risk kanalı tarafından 1 saatlik bir çakışma penceresiyle işaretlenmiştir.
– **Z-skor anomalileri:** Kota aşımı loglarının z-skoru 4,5'e çıkmış (normal değerin 0,8 katı artış); disk I/O hatası $z = 3{,}6$, ağ hatası $z = 2{,}8$, DB bağlantı hatası ise $z = 2{,}6$ olarak ölçülmüştür. Tüm bu değerler $\sigma > 2{,}5$ eşiğini aşarak anomali olarak sınıflandırılmıştır.

4.5. Öneri Motoru ve LLM Çıktıları

Kural tabanlı motor ve LLM katmanı birlikte 9 öneri üretmiştir: 2 KRİTİK ve 7 UYARI düzeyinde. Kapasite durum özeti şöyledir: vCPU %79,6 (eşik %90,0, tahmini aşım tarihi: 2026-09-12, yaklaşık 74 gün), Bellek %85,5 (eşik %88,0, tahmini aşım tarihi: 2026-08-15, yaklaşık 46 gün), Disk %80,0 (kararlı trend, aşım >180 gün).

Öneri üretim kanalları ve üretilen uyarı dağılımı Table 4.12'de verilmektedir.

Tablo 4.12. Kanal bazında öneri dağılımı — test kümesi son gözlemi (2026-06-30)

Kanal	Kategori	Sayı	En Yüksek Önem
Kapasite	UYARI	2	vCPU %79,6 — eşik 74 gün
Log anomali	KRİTİK/UYARI	4	Kota Aşımı $z = 4{,}5$
Ön-arıza örüntü	UYARI	1	Yavaş Yanıt +287% / 68 s önce
Cascade riski	KRİTİK	1	3 servis eş zamanlı (2026-06-28)
Dönemsel risk	UYARI	1	Yaz Stajı 2026 aktif

LLM katmanında zenginleştirilmiş istem Claude Sonnet (`claude-sonnet-4-6`) modeline iletilmektedir. İstem; kapasite tahmin durumunu, SHAP özellik sıralamasını,

log anomali özetini, ön-arıza örüntülerini ve cascade risk değerlendirmesini yapılandırılmış metin olarak bir arada sunmaktadır. Model bu bağlamı bütünsel olarak değerlendirerek servis bazında önceliklendirilmiş operasyonel öneriler üretmektedir.

Figure 4.6'te gösterilen yanıt, Anthropic API (`claude-sonnet-4-6`) tarafından 2026-06-30 tarihli test kümesi girdisiyle üretilmiştir.

Bu yanıt, CloudMon'un farklı analiz katmanlarını (kapasite tahmini, SHAP açıklaması, log anomali tespiti, cascade risk) birbirine bağlayan bütünsel bir operasyonel değerlendirme sunmaktadır. Kural tabanlı motorun tespit ettiği dokuz uyarı (2 KRİTİK, 7 UYARI), LLM tarafından öncelikli aksiyon sırasına dönüştürülmekte; her öneri hem tahmin hem açıklanabilirlik hem de log kanıtıyla gerekçelendirilmektedir. Bu yapı, CloudMon'un bir izleme aracı olmanın ötesine geçerek açıklanabilir ve eyleme dönüştürülebilir öneriler üreten bir operasyonel zekâ sistemi olduğunu göstermektedir.

4.6. İleriye Dönük Kapasite Projeksiyonları

Test döneminin son gözlem noktası olan 2026-06-30 itibarıyla CloudMon, mevcut büyüme trendleri ve tahmin modelleri kullanılarak 3–6 aylık ileriye dönük kapasite projeksiyonu üretmektedir.

4.6.1. Kapasite Dolum Tarihleri

Test kümesi sonu itibarıyla her kaynağın mevcut kullanım durumu ve lineer trend projeksiyon sonuçları Table 4.13'de verilmektedir.

Tablo 4.13. Kapasite dolum tarihi projeksiyonu (2026-06-30 baz alınarak)

Kaynak	**Mevcut (%)**	**Eşik (%)**	**Trend/Gün**	**Tahmini Dolum**
vCPU	79,6	90,0	+0,275	2026-09-12 ($\approx$74 gün)
Bellek	85,5	88,0	+0,151	2026-08-15 ($\approx$46 gün)
Disk	80,0	85,0	+0,031	$>$2027-01-01 ($>$180 gün)

Bu projeksiyonların yorumlanmasında önemli bir uyarı gerekmektedir: lineer trend varsayımı, büyüme hızının önümüzdeki aylarda değişmeyeceğini kabul etmektedir. Staj sezonu (Temmuz–Eylül) veya büyük bir proje lansmanı gibi iş yükü artışları bu tarihleri öne çekebilir. Nitekim tahmin motorunun ürettiği 72 saatlik projeksiyonlar (Table 4.3) vCPU için halihazırda 0,7728 R^2 ile güçlü bir öngörü sunmaktadır; 24 saatlik projeksiyonlar ise 0,9577 R^2 ile yüksek kesinlikte kapasite dolum tarihini

[Anthropic Claude Sonnet - claude-sonnet-4-6 çıktısı]

BULUT ALTYAPI OPERASYONEL DEĞERLENDİRME RAPORU
Tarih: 2026-06-30 | Sağlayıcı: Anthropic claude-sonnet-4-6

YÖNETİCİ ÖZETİ

Altyapı, kısa vadede müdahale gerektiren iki kritik sinyal üretmektedir. Bellek eşiğinin yaklaşık 46 gün içinde (%85,5 → %88,0) aşılması beklenmektedir; bu süre, kapasite planlaması için gerçekçi ancak sıkışık bir pencere sunmaktadır. Daha acil olan ise 2026-06-28 tarihinde Nova, Neutron ve Keystone servislerinde eş zamanlı gözlemlenen degradasyon: bu örüntü tarihsel olarak tam arızadan 12-36 saat önce ortaya çıkmaktadır.

1. KRİTİK - BELLEK KAPASİTESİ (Eşik: ≈46 gün)

Mevcut kullanım %85,5 olup 30 günlük medyan artış hızı +0,151%/gün'dür. Bu hızda eşim tarihi 2026-08-15 olarak öngörülmektedir.

SHAP analizi, tahminin birincil sürücüsünün vm_count_rmean_24h (aktif VM sayısının 24 saatlik hareketli ortalaması) olduğunu göstermektedir; ikincil katkı total_errors_rsum_72h'den (72 saatlik hata toplamı) gelmektedir. Bu, bellek baskısının VM büyümesiyle birlikte servis hatalarının da artmasıyla hızlandığına işaret etmektedir.

Önerilen aksiyonlar:
(1) Son 7 günde bellek tüketimi en yüksek olan ilk 10 VM'yi belirleyin; aşırı tahsis yapanlar için Nova memory_mb limitlerini gözden geçirin.
(2) Nova memory_mb_used değerini Keystone proje kotalarıyla karşılaştırın; kota aşımı log z-skoru 4,5 ile son derece yüksektir ve birden fazla projenin mevcut kotasını zorladığını göstermektedir.
(3) Büyük bellekli VM'leri daha az yoğun compute node'lara live-migrate edin; bu hem anlık baskıyı azaltır hem de eşim tarihini öteleyebilir.

2. KRİTİK - CASCADE RİSKİ (2026-06-28, 3 servis)

Nova, Neutron ve Keystone'un 08:00-09:00 UTC penceresinde eş zamanlı degradasyonu tespit edilmiştir. Bu örüntü, tek servis arızasından farklı olarak kaynak çekişmesine (resource contention) veya ortak bir altyapı sorununa (ağ ya da depolama katmanı) işaret etmektedir.

Önerilen aksiyonlar:
(1) 2026-06-28 08:00 itibarıyla Nova, Neutron ve Keystone log'larını çapraz inceleyin; ortak bir hata mesajı veya bağlantı başarısızlığı örüntüsü arayın.
(2) Bu zaman penceresinde gerçekleşen VM operasyonlarını (launch, delete, resize) belirleyin; yoğun bir iş yükü ani compute ve ağ baskısına yol açmış olabilir.
(3) Tekrarını önlemek için Nova zamanlayıcısına kaynak başına eş zamanlı işlem sınırı (concurrent build limit) tanımlamayı değerlendirin.

3. UYARI - ÖN-ARIZA SİNYALİ (Yavaş Yanıt, +287%)

slow_response log sayısı son 7 günde 1,285 adet olup geçmiş 15 incident analizi bu log tipinin arızadan ortalama 68 saat önce belirgin artış gösterdiğini ortaya koymaktadır. Bu pencere hâlâ açık durumdadır.

Önerilen aksiyonlar:
(1) Keystone token doğrulama yanıt sürelerini izleyin; yavaş yanıt loglarının %60'ı Keystone'dan kaynaklanmaktadır.

desteklemektedir.

4.6.2. Kritik Senaryo Analizi

En İyi Senaryo: Mevcut büyüme hızı korunur; ek VM tahsisi yapılmaz. Bu durumda Bellek eşimi Ağustos 2026 ortasında, vCPU eşimi Eylül 2026 başında aşılır. Operatörün önerilen aksiyonları (VM yeniden dengeleme, bellek optimizasyonu) uygulaması dolum tarihlerini 2–3 ay öteleme potansiyeli taşımaktadır.

En Kötü Senaryo: Yaz stajı döneminde ek 50–70 VM başlatılır. Bu durumda vCPU ve Bellek büyüme hızları sırasıyla %0,4 ve %0,25'e çıkabilir; dolum tarihleri yaklaşık 30 gün öne gelebilir. Log tabanlı erken uyarı sisteminin bu artışı 68 saat öncesinde `slow_response` log artışıyla sinyalize edeceği beklenmektedir.

Müdahale Etkisi: Bellek kullanımının %85,5 düzeyinde sabitlenmesi (büyüme durduğunu varsayarsak) eşim tarihi belirsizleşir ve alarm geçersiz hâle gelir. CloudMon bu senaryoyu müdahalenin başarılı olduğu biçiminde yorumlar ve operatöre "Bellek büyüme trendi yavaşladı: öneri başarıyla uygulandı" mesajını üretir.

4.6.3. Model Tahmin Aralığı Değerlendirmesi

Noktasal tahmin ötesinde güven aralığı (confidence interval) bilgisi operasyonel kararlar için kritik önem taşımaktadır. CloudMon mevcut sürümünde noktasal tahmin üretmektedir; bu durum sınırlılıklar arasında değerlendirilmektedir (section 5.3).

Bununla birlikte, test kümesindeki RMSE değerlerinden yaklaşık bir güven aralığı oluşturulabilmektedir. vCPU 24 saatlik tahmin için $\text{RMSE} = 1{,}29$ yüzde puan olduğundan, $\pm 2 \cdot \text{RMSE}$ olarak hesaplanan yaklaşık %95 güven aralığı $\pm 2{,}6$ yüzde puan genişliğindedir. Bu aralık, 74 günlük dolum tarihi tahmininin gerçekte 65–83 gün aralığında gerçekleşebileceğini göstermektedir; operasyonel karar almada bu belirsizlik marjı dikkate alınmalıdır.

4.7. Log Risk Skoru ve Servis Sağlık Analizi

4.7.1. Log Risk Skoru Hesaplama Yöntemi

CloudMon log işleme pipeline'ının 4. aşamasında her OpenStack servisi için bir *log risk skoru* hesaplanmaktadır. Bu skor, servisin mevcut log aktivitesini tarihsel normla kıyaslayan, 0–1 aralığında normalize edilmiş bir sağlık göstergesidir.

Risk skoru iki bileşenden oluşmaktadır:

$$r_{\text{log}} = 0{,}4 \cdot s_{\text{uyarı}} + 0{,}6 \cdot s_{\text{hata}} \tag{4.1}$$

Burada $s_{\text{uyarı}}$ ve s_{hata}, ilgili kategorideki log sayısının 99. yüzdelik dilime normalize edilmiş değerleridir:

$$s_k = \min\left(1, \frac{c_k}{p_{99}(c_k)}\right), \quad k \in \{\text{uyarı, hata}\} \tag{4.2}$$

Burada c_k son bir saatteki k kategorisi log sayısı, $p_{99}(c_k)$ ise eğitim kümesindeki aynı kategorinin 99. yüzdelik dilimidir. Normalizasyonun üst sınırı $\min(\cdot, 1)$ ile 1'e sabitlenmekte; böylece 99. yüzdelik dilimi aşan değerler aşırı cezalandırılmaktan korunmaktadır.

$w_{\text{uyarı}} = 0{,}4$ ve $w_{\text{hata}} = 0{,}6$ ağırlık değerleri, hata loglarının erken uyarı loglarına kıyasla daha anlık bir sorun işareti taşıdığını yansıtmaktadır. Bu asimetrik ağırlıklandırma, erken uyarı fazındaki yüksek hacimli logların risk skorunu orantısız biçimde artırmasını engellerken, az sayıda hata logunun dahi risk skorunu belirgin biçimde yükseltmesini sağlamaktadır.

4.7.2. Servis Bazında Log Risk Skoru Sonuçları

Test döneminin son gözlem noktası (2026-06-30) itibarıyla dört OpenStack servisi için hesaplanan log risk skorları Table 4.14'de verilmektedir.

Tablo 4.14. Servis bazında log risk skoru — son gözlem noktası (2026-06-30 23:00 UTC)

Servis	$s_{\text{uyarı}}$	s_{hata}	r_{log}	**Durum**
Nova	0,78	0,71	0,740	KRİTİK
Keystone	0,82	0,65	0,718	KRİTİK
Neutron	0,45	0,38	0,408	UYARI
Cinder	0,31	0,49	0,418	UYARI

Nova ve Keystone'un log risk skoru $r_{\text{log}} > 0{,}7$ eşiğini aşarak KRİTİK durumda sınıflandırılmıştır. Bu bulgular cascade risk tespiti ile tutarlıdır: 2026-06-28 tarihinde Nova, Neutron ve Keystone'un eş zamanlı degradasyon sergilediği dönemde her üç servisin log risk skoru tarihsel zirvesine ulaşmıştır.

Cinder'ın uyarı bölgesinde kalması ise Disk kullanımının (%80,0) yavaş büyüme trendi ile uyumludur; depolama katmanı işlem ve ağ katmanına kıyasla daha az baskı altındadır.

4.7.3. Haftalık Log Risk Skoru Trendleri

Table 4.15'de test döneminin son dört haftasına ait haftalık ortalama log risk skorları verilmektedir. Bu tablo, sistemin hangi haftadan itibaren belirgin biçimde degradasyon başladığını göstermektedir.

Tablo 4.15. Son dört hafta — Nova haftalık ortalama log risk skoru

Hafta	$s_{\text{uyarı}}$	s_{hata}	$r_{\log}$	**Durum**
02–08 Haz 2026	0,41	0,29	0,338	Normal
09–15 Haz 2026	0,54	0,43	0,474	Dikkat
16–22 Haz 2026	0,66	0,58	0,612	UYARI
23–30 Haz 2026	0,78	0,71	0,740	KRİTİK

Bu tablo, Nova'nın log risk skorunun dört hafta içinde Normal seviyeden KRİTİK seviyeye kademeli olarak yükseldiğini göstermektedir. Bu kademeli artış, erken uyarı sisteminin önemini somutlaştırmaktadır: iki hafta önceki UYARI sinyali yakalanıp aksiyon alınsaydı, son haftanın KRİTİK durumundan kaçınılabilirdi. Kısa vadeli proaktif yaklaşımın üretim ortamındaki değeri bu tablo üzerinden açıkça izlenebilmektedir.

4.7.4. Log Risk Skoru ile Kapasite Tahmini Korelasyonu

Log risk skorunun kapasite tahmin modeline katkısını nicel olarak değerlendirmek amacıyla iki ayrı model karşılaştırılmıştır: (i) yalnızca metrik özellikleri kullanan *temel model* ve (ii) log özelliklerini de içeren *hibrit model* (CloudMon'un gerçek modeli).

vCPU 24 saatlik tahmin üzerinde gerçekleştirilen bu ablasyon deneyinin sonuçları Table 4.16'de verilmektedir.

Tablo 4.16. Log özellik katkısı — vCPU 24 s Doğrusal Regresyon ablasyon deneyi

Model	**Özellik Uzayı**	$\mathbf{R^2}$	**RMSE**	**MAE**	**MAPE**
Temel Model	Yalnızca Metrik (148 özellik)	0,9391	1,551	1,106	1,337
Hibrit Model	Metrik + Log (272 özellik)	0,9577	1,293	0,905	1,099
Artış		**+0,0186**	**−16,6%**	**−18,1%**	**−17,8%**

Log özelliklerinin eklenmesiyle R^2 0,9391'den 0,9577'ye yükselmiş; RMSE ise 1,551'den 1,293'e düşmüştür (%16,6 iyileşme). Bu bulgu, log tabanlı özelliklerin kapasite tahmine istatistiksel olarak anlamlı katkı yaptığını doğrulamaktadır. SHAP

analizinin 272 özellikli hibrit uzayda log özelliklerini ilk 10 arasına yerleştirmesi bu katkının nicel temeliyle uyumludur.

5. SONUÇLAR VE ÖNERİLER

Bu bölümde CloudMon sisteminin deneysel bulgularından çıkarılan sonuçlar özetlenmekte, çalışmanın özgün katkıları değerlendirilmekte ve çalışmanın sınırlılıkları ile gelecek araştırma önerileri tartışılmaktadır.

5.1. Temel Bulgular

Bu çalışma; kapasite tahmini, açıklanabilirlik analizi ve log tabanlı erken uyarı olmak üzere üç ana araştırma ekseninde somut bulgular üretmiştir.

5.1.1. Kapasite Tahmin Modeli

42 model (7 algoritma $\times$ 3 kaynak $\times$ 2 ufuk) değerlendirmesinin en belirgin bulgusu, Doğrusal Regresyon'un (LR) ağaç tabanlı tüm algoritmaları geride bırakmasıdır. 24 saatlik ufukta LR, vCPU için $R^2 = 0{,}9577$, Bellek için $R^2 = 0{,}7945$ ve Disk için $R^2 = 0{,}6984$ değerlerine ulaşmıştır. En yakın rakibi olan Gradyan Artırmalı Ağaçlar, vCPU 24 s senaryosunda yalnızca $R^2 = 0{,}1079$ üretmiştir; bu fark, OpenStack zaman serilerinin test döneminde güçlü monoton trendler barındırdığını ve LR'nin bu trendi gecikme ve hareketli ortalama özellikleri üzerinden doğrudan öğrendiğini göstermektedir.

72 saatlik ufukta sonuçlar kaynak bazında ayrışmaktadır. vCPU'da LR, $R^2 = 0{,}7728$ ile etkin tahmin gücünü korumuştur. Bellek ve Disk'te ise MLP en iyi performer konumuna geçmiş; bununla birlikte R^2 değerleri sırasıyla 0,3456 ve 0,2212'ye gerilemiştir. Ağaç tabanlı modellerin büyük çoğunluğu 72 saatlik ufuklarda negatif R^2 üretmiş, yani ortalama tahminden daha kötü performans göstermiştir. Bu bulgu, söz konusu modellerin 272 özellikli yüksek boyutlu uzayda eğitim kümesine aşırı uyduğunu ve zaman serisi genellemesinde yetersiz kaldığını ortaya koymaktadır.

5.1.2. SHAP Açıklanabilirlik Bulguları

SHAP analizi, log tabanlı özelliklerin salt metrik özelliklerinden anlamlı biçimde farklılaştığını ve kapasite tahminine bağımsız katkı yaptığını nicel olarak göstermiştir. vCPU 24 s modelinin ilk 10 özelliği arasında dört log özelliği yer almaktadır: `resource_exhausted_count_rsum_72h` (5. sıra, $|\phi| = 2\,150$), `total_errors_rsum_72h` (6. sıra, $|\phi| = 1\,800$), `scheduler_degradation_count_rsum_72h` (9. sıra, $|\phi| = 1\,050$) ve

`timeout_count_rsum_72h` (10. sıra, $|\phi| = 1\,028$). Disk 24 s modelinde ise `total_errors_rsum_24h` birinci sıraya taşınmış; log özellikleri metrik özelliklerini bile geride bırakmıştır. Bu bulgular, log verilerinin kapasite tahmininde salt gürültü değil, anlamlı bir sinyal kaynağı olduğunu kanıtlamakta ve hibrit özellik uzayının kurucu varsayımını doğrulamaktadır.

5.1.3. Log Analizi ve Erken Uyarı

Dört aşamalı log işleme pipeline'ı (trend tespiti, z-skor anomali tespiti, ön-arıza örüntü eşleştirme, cascade risk tespiti) test dönemi (Nisan–Haziran 2026) üzerinde anlamlı sinyaller üretmiştir. *Slow_response* loglarının geçmiş 15 incident analizine göre arızadan ortalama 68 saat önce %287 oranında artış gösterdiği bulunmuş ve mevcut test dönemi verisi bu örüntüyle örtüşmüştür. Kota aşımı loglarının z-skoru 4,5'e çıkmış; disk I/O hatası ($z = 3{,}6$), ağ hatası ($z = 2{,}8$) ve veritabanı bağlantı hatası ($z = 2{,}6$) da anormallik eşiğini ($\sigma > 2{,}5$) aşmıştır. 2026-06-28 tarihinde Nova, Neutron ve Keystone servislerinin eş zamanlı degradasyonu cascade risk kanalı tarafından tespit edilmiştir. Bu bulgular, log tabanlı erken uyarı mekanizmasının metrik eşik alarmlarına kıyasla üç güne yakın önceden sinyal üretme potansiyeline sahip olduğunu göstermektedir.

5.1.4. Öneri Motoru ve LLM Entegrasyonu

Kural tabanlı motor ve LLM katmanı (Claude Sonnet + GPT-4o) birlikte 9 öneri üretmiştir: 2 KRİTİK ve 7 UYARI. LLM'e iletilen zenginleştirilmiş bağlam; kapasite durumunu, log anomali özetini, SHAP özellik sıralamasını ve cascade risk skorunu kapsamaktadır. Üretilen öneriler, tahmin modelinin sayısal çıktısını (tahmini eşik tarihi), SHAP açıklamasını (en etkili özellik) ve log analizini (erken uyarı korelasyonu) somut operasyonel aksiyonlarla birleştirmektedir. Bu yapı, CloudMon'un reaktif bir izleme aracı olmanın ötesine geçerek açıklanabilir ve eyleme dönüştürülebilir öneriler üreten bir operasyonel zekâ sistemi olduğunu göstermektedir.

5.2. Tezin Özgün Katkıları

Bu çalışma, kapsamlı deneysel değerlendirme çerçevesinde aşağıdaki dört özgün katkıyı sunmaktadır:

1. **Log–metrik korelasyonuna dayalı kapasite tahmini:** Metrik ve log verilerinin ortak bir özellik uzayında birleştirilmesi, her iki veri kaynağının da kapasite

tahminine anlamlı katkı yaptığını göstermiştir. SHAP analizi, log tabanlı özelliklerin yalnızca metrik özelliklerini değil, ağaç tabanlı modellerin gördüğü her iki veri tipini de geride bırakabildiğini nicel olarak ortaya koymuştur. Hibrit özellik uzayı, yalnızca metrik tabanlı yaklaşımlara kıyasla SHAP ilk 10'unda %40 log özellik payıyla (vCPU 24 s) üstün açıklanabilirlik sunmaktadır.

2. **Dört aşamalı log işleme pipeline'ı:** Ham log sayımlarından ön-arıza örüntü eşleştirmesine ve cascade risk tespitine uzanan sistematik analiz hattı, tek bir aşamalı log sayımı yaklaşımlarına kıyasla daha zengin ve erken sinyaller üretmektedir. Ön-arıza örüntüsünün 68 saatlik öncü uyarı özelliği, operasyonel müdahale için pratik bir zaman penceresi sağlamaktadır.

3. **Açıklanabilir kapasite tahmin sistemi:** Her tahmin için hesaplanan SHAP değerleri; hangi metriğin ya da log tipinin kararı yönlendirdiğini operatöre aktarmaktadır. Bu yaklaşım, kara kutu tahmin modellerini yorumlanabilir aksiyon önerilerine dönüştürerek bulut operatörlerinin karara güvenmesini ve gereksiz kota artışı kararlarını daha bilinçli değerlendirmesini sağlamaktadır.

4. **Zenginleştirilmiş bağlamla LLM destekli öneri motoru:** Kapasite durumu, log anomali sinyalleri, SHAP özellik önem sıralaması ve cascade riski bir araya getirilerek yapılandırılmış bağlam oluşturulmuş; bu bağlam Claude Sonnet ve GPT-4o modellerine iletilmiştir. Üretilen öneriler, sayısal tahmin çıktısı ile yorumsal açıklamayı birleştiren servis bazında önceliklendirilmiş aksiyonlar içermekte; böylece operatörün ayrı sistemlere bakma zorunluluğunu ortadan kaldırmaktadır.

5.3. Sınırlılıklar

Bu çalışmanın değerlendirilmesinde aşağıdaki sınırlılıklar göz önünde bulundurulmalıdır:

1. **Eğitim kümesi büyüklüğü ve tek küme:** Modeller tek bir OpenStack kümesinin yaklaşık 9 aylık verisine (Temmuz 2025–Mart 2026) dayalı olarak eğitilmiştir. Bu durum, ağaç tabanlı modellerin zaman serisi genellemesinde başarısız olmasının kısmi nedeni olabilir; daha uzun eğitim veya farklı kümelerden elde edilen veriler ağaç modellerini güçlendirebilir. Ayrıca bulgular, yalnızca bu kümenin iş yükü

örüntüsü için geçerli olup farklı ölçek veya kullanım biçimlerine sahip OpenStack kümelerine doğrudan genellenemeyebilir.

2. **72 saatlik Disk tahmin gücünün sınırlı olması:** Disk 72 s senaryosunda yalnızca MLP pozitif R^2 (0,2212) üretmiş; diğer tüm modeller rassal tahminden daha kötü performans sergilemiştir. Disk kullanımının uzun vadede sergilediği düzensiz ve veri bağımlı örüntüsü, mevcut özellik kümesiyle yeterince yakalanamamaktadır. Bu tahmin ufku için ek özellik mühendisliği veya daha gelişmiş zaman serisi modelleri gerekmektedir.

3. **LLM çıktılarının nesnel değerlendirmesi:** Öneri motorunun LLM katmanı, üretilen önerilerin kalitesini nesnel ölçütlerle değerlendirmek için bir insan değerlendirmesi (human evaluation) ya da karşılaştırma taban çizgisi (baseline) kullanılmamıştır. Mevcut değerlendirme, üretilen aksiyonların içerik kontrolüne dayanmakta olup operasyonel uygulamada etkinliklerini doğrulayan kontrollü bir deney yapılamamıştır.

4. **Gerçek zamanlı pipeline yokluğu:** CloudMon, bu çalışma kapsamında toplu (batch) veri işleme ile test edilmiştir. Canlı OpenStack ortamında akış verisi işleme (streaming), model güncelleme gecikmesi ve düşük gecikimli öneri üretimi gibi operasyonel zorluklar deneysel ortamda ele alınmamıştır.

5.4. Gelecek Çalışma Önerileri

Bu çalışmanın bulguları ve sınırlılıkları ışığında aşağıdaki araştırma yönleri önerilmektedir:

1. **Daha uzun ve çok kümeli veri ile model genellemesi:** Ağaç tabanlı modellerin genelleme yetersizliği, birden fazla OpenStack kümesinden toplanan ve birkaç yıllık zaman aralığını kapsayan verilerle yeniden değerlendirilebilir. Transfer öğrenme yaklaşımları, bir kümede eğitilen modelin diğer kümelere uyarlanmasını sağlayarak küme-özgü eğitim maliyetini azaltabilir.

2. **Artımlı ve çevrimiçi öğrenme:** Bulut iş yükleri zamanla değiştiğinden, modellerin yeni gelen verilerle sürekli güncellenmesini sağlayan artımlı öğrenme

(incremental learning) ve kavram kayması (concept drift) tespiti mekanizmaları sisteme entegre edilmelidir. Bu yaklaşım, modellerin uzun vadeli operasyonel geçerliliğini koruyacaktır.

3. **Gerçek zamanlı akış mimarisi:** Mevcut toplu işleme pipeline'ı, Apache Kafka veya benzer bir akış platformu üzerine yeniden tasarlanarak düşük gecikmeli uyarı üretimi sağlanabilir. Gerçek zamanlı özellik hesaplama, özellikle cascade riski gibi zaman-kritik uyarıların pratikte değer üretmesini mümkün kılacaktır.

4. **LLM çıktılarının kontrollü değerlendirmesi:** Öneri motorunun etkinliği, bulut operatörlerinin katılımıyla yürütülecek bir kullanıcı çalışmasıyla ölçülebilir. Bu çalışma; üretilen önerilerin doğruluğunu, uygulanabilirliğini ve operatör güvenini nicel olarak değerlendirme olanağı sunacaktır. Ayrıca farklı LLM modelleri (açık kaynak ile kapalı kaynak) karşılaştırmalı olarak test edilebilir.

5. **Disk 72 saatlik tahmin için gelişmiş yöntemler:** Disk kullanımının uzun vadeli örüntüsünü daha iyi yakalamak amacıyla ayrıştırma tabanlı modeller (STL, Prophet) veya LSTM gibi dizi tabanlı derin öğrenme mimarileri araştırılabilir. Ayrıca I/O olaylarına dayalı olay güdümlü (event-driven) özellikler, bu senaryodaki tahmin boşluğunu kapatabilir.

6. **Diğer bulut platformlarına genişleme:** CloudMon mimarisinin AWS, Azure veya Kubernetes kümelerine uyarlanması, platform bağımsız bir AIOps çerçevesi geliştirme ve farklı altyapı örüntülerinde bulguların tekrarlanabilirliğini test etme açısından değerli bir araştırma yönü oluşturmaktadır.

5.5. Genel Değerlendirme

Bu tez, OpenStack tabanlı özel bulut altyapılarında proaktif kapasite yönetimini desteklemeye yönelik uçtan uca bir AIOps sistemi olan CloudMon'u tanıtmış ve deneysel olarak değerlendirmiştir. Hibrit özellik mühendisliği, açıklanabilir makine öğrenmesi ve LLM tabanlı öneri üretimini entegre eden bu yaklaşım; mevcut literatürdeki izole çalışmaların ötesine geçerek birden fazla analiz katmanını tek bir operasyonel zekâ platformunda bir araya getirmektedir.

Deneysel bulgular, Doğrusal Regresyon'un 24 saatlik ufuklarda ağaç tabanlı modellere kıyasla belirgin biçimde üstün olduğunu; log özelliklerinin SHAP analizinde güçlü bir sinyal kaynağı oluşturduğunu ve dört aşamalı log pipeline'ının metrik eşik alarmlarına üç güne yakın zaman önünde uyarı üretme kapasitesine sahip olduğunu göstermiştir. Bu bulgular bir arada değerlendirildiğinde, CloudMon'un bulut operasyonlarında önleyici müdahaleyi destekleyen pratik ve yorumlanabilir bir araç olma potansiyeli taşıdığı sonucuna ulaşılmaktadır.

KAYNAKLAR

Anthropic (2024). The Claude 3 Model Family: Opus, Sonnet, Haiku*, Anthropic*,

Beyer, B., Jones, C., Petoff, J., Murphy, N. R. (2016). *Site Reliability Engineering: How Google Runs Production Systems*. Sebastopol, CA: O'Reilly Media.

Breiman, L. (2001). Random Forests. *Machine Learning*, *45* (1), 5–32. DOI: https://doi.org/10.1023/A:1010933404324

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., Amodei, D. (2020). Language Models are Few-Shot Learners. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33, pp. 1877–1901.

Calheiros, R. N., Masoumi, E., Ranjan, R., Buyya, R. (2015). Workload Prediction Using ARIMA Model and Its Impact on Cloud Applications' QoS. *IEEE Transactions on Cloud Computing*, *3* (4), 449–458. DOI: https://doi.org/10.1109/TCC.2014.2350475

Chandola, V., Banerjee, A., Kumar, V. (2009). Anomaly Detection: A Survey. *ACM Computing Surveys*, *41* (3), 1–58. DOI: https://doi.org/10.1145/1541880.1541882

Chen, T., Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 785–794. DOI: 10.1145/2939672.2939785.

Dang, Y., Lin, Q., Huang, P. (2019). AIOps: Real-World Challenges and Research Innovations. In: *Proceedings of the 41st International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, pp. 4–5. DOI: 10.1109/ICSE-SEIP.2019.00009.

Du, M., Li, F., Zheng, G., Srikumar, V. (2017). DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. In: *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pp. 1285–1298. DOI: 10.1145/3133956.3134015.

Fluentd Authors (2024). *Fluentd: Unified Logging Layer*, https://www.fluentd.org (Ziyaret Tarihi:).

Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, *29* (5), 1189–1232. DOI: https://doi.org/10.1214/aos/1013203451

He, P., Zhu, J., Zheng, Z., Lyu, M. R. (2016). An Evaluation Study on Log Parsing Algorithms for System Log Analysis. In: *Proceedings of the 46th Annual IEEE/IFIP International Conference on Dependable Systems and Networks (DSN)*, pp. 654–661. DOI: 10.1109/DSN.2016.66.

He, S., Zhu, J., He, P., Lyu, M. R. (2021). A Survey on Automated Log Analysis for Reliability Engineering. *ACM Computing Surveys*, *54* (6), 130:1–130:37. DOI: https://doi.org/10.1145/3460345

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T. Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 3146–3154.

Landauer, M., Onder, S., Skopik, F., Wurzenberger, M. (2023). Deep Learning for Anomaly Detection in Log Data: A Survey. *Machine Learning with Applications*, *12* DOI: https://doi.org/10.1016/j.mlwa.2023.100470

Lim, B., Arik, S., Loeff, N., Pfister, T. (2021). Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting. *International Journal of Forecasting*, *37* (4), 1748–1764. DOI: https://doi.org/10.1016/j.ijforecast.2021.03.012

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., Lee, S. I. (2020). From Local Explanations to Global Understanding with Explainable AI for Trees. *Nature Machine Intelligence*, *2* (1), 56–67. DOI: https://doi.org/10.1038/s42256-019-0138-9

Lundberg, S. M., Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30, pp. 4765–4774.

Makedonas, A., Kalloniatis, C., Gritzalis, S. (2022). An Efficient Workload Prediction Model for Cloud Data Centers Based on Machine Learning. *Future Internet*, *14* (4). DOI: https://doi.org/10.3390/fi14040108

Meng, W., Liu, Y., Zhu, Y., Zhang, S., Pei, D., Liu, Y., Chen, Y., Zhang, R., Tao, S., Sun, P., Zhou, R. (2019). LogAnomaly: Unsupervised Detection of Sequential and

Quantitative Anomalies in Unstructured Logs, 4739–4745. DOI: https://doi.org/10.24963/ijcai.2019/658

Notaro, P., Cardoso, J., Gerndt, M. (2021). A Survey of AIOps Methods for Failure Management. *ACM Transactions on Intelligent Systems and Technology*, *12* (6), 1–45. DOI: https://doi.org/10.1145/3479909

OpenAI (2023). GPT-4 Technical Report*, OpenAI*,

OpenSearch Project (2024). *OpenSearch: Open Source Search and Analytics Suite*, https://opensearch.org (Ziyaret Tarihi:).

OpenStack Foundation (2024). *OpenStack: Open Source Cloud Computing Software*, https://www.openstack.org (Ziyaret Tarihi:).

Pang, G., Shen, C., Cao, L., Hengel, A. van den (2021). Deep Learning for Anomaly Detection: A Review. *ACM Computing Surveys*, *54* (2). DOI: https://doi.org/10.1145/3439950

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., Gulin, A. (2018). CatBoost: Unbiased Boosting with Categorical Features. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 31.

Prometheus Authors (2024). *Prometheus: From Metrics to Insight*, https://prometheus.io (Ziyaret Tarihi:).

Thanos Authors (2024). *Thanos: Highly Available Prometheus Setup with Long Term Storage*, https://thanos.io (Ziyaret Tarihi:).

Xu, W., Huang, L., Fox, A., Patterson, D., Jordan, M. (2009). Detecting Large-Scale System Problems by Mining Console Logs, 117–132. DOI: https://doi.org/10.1145/1629575.1629587

EKLER

Ek-A

Ek A: Log Tipi Tanımları ve Kaynak Eşleşmeleri

Table A.1.'de CloudMon'un izlediği 15 log tipinin tam tanımları, kaynak servisleri ve ön-arıza analizi sonuçları verilmektedir.

Tablo A.6.1. CloudMon log tipi kataloğu — tam tanımlar ve kaynak servisler

Log Tipi	Kaynak Servis	Tetiklenme Koşulu
Hata Logları (8 tip)		
`timeout_count`	Nova, Neutron, Cinder	API isteği yapılandırılmış süreyi (varsayılan 60 s) aşar
`db_connection_count`	Nova, Keystone, Cinder	Veritabanı bağlantısı kurulamaz veya bağlantı havuzu tükenir
`resource_exhausted_count`	Nova	vCPU veya bellek kotası aşıldığında instance başlatılamaz
`quota_exceeded_count`	Keystone, Nova	Proje bazındaki kaynak kotası aşılır
`auth_failure_count`	Keystone	Token doğrulama veya kullanıcı kimlik doğrulama başarısız olur
`network_error_count`	Neutron	Sanal ağ yönlendirme veya güvenlik grubu uygulamasında hata oluşur
`scheduler_error_count`	Nova (scheduler)	Hiçbir compute node mevcut isteği karşılayamaz
`io_error_count`	Cinder, Nova	Blok depolama biriminde okuma/yazma hatası oluşur
Erken Uyarı Logları (7 tip)		
`slow_response_count`	Nova-API, Keystone	API yanıt süresi normal değerin 3 katını aşar (uyarı seviyesi)
`memory_pressure_count`	Nova-compute	Compute node belleği %80 dolarken soft limit uyarısı üretilir
`connection_pool_warn_count`	Nova, Neutron, Cinder	DB bağlantı havuzu doluluk oranı %85'i aşar
`scheduler_degradation_count`	Nova (scheduler)	Zamanlayıcı karar süresi beklenenden %50 daha uzun sürer
`quota_pressure_count`	Keystone	Proje kotasının %90'ı kullanıldığında baskı uyarısı üretilir
`disk_io_degradation_count`	Cinder	Disk I/O gecikmesi normal değerin 2 katına çıkar
`cascade_indicator_count`	Tüm servisler	Birden fazla servis aynı anda degradasyon yaşar

Ek B: Tam Model Performans Tabloları

Table A.2.'de 42 modelin tüm dört metrik üzerindeki tam sonuçları verilmektedir. Her tablo ayrı bir (kaynak, ufuk) senaryosuna karşılık gelmektedir.

Ek C: SHAP Özellik Önem Tabloları — Bellek ve Disk Modelleri

Tablo A.6.2. Tam model karşılaştırma — vCPU 24 s (tekrar, tam metrik)

Model	R^2	RMSE	MAE	MAPE
Lin. Regresyon	0,9577	1,293	0,905	1,099
Grad. Artırmalı	0,1079	5,938	4,304	5,017
LightGBM	0,0906	5,995	4,291	4,992
MLP	0,0544	6,113	4,328	5,234
Rast. Orman	0,0456	6,142	4,496	5,249
XGBoost	0,0355	6,174	4,482	5,225
CatBoost	−1,386	9,710	7,852	9,297

Tablo A.6.3. Tam model karşılaştırma — vCPU 72 s

Model	R^2	RMSE	MAE	MAPE
Lin. Regresyon	0,7728	2,951	1,865	2,222
MLP	0,2946	5,199	3,780	4,644
Rast. Orman	−0,571	7,758	6,128	7,219
Grad. Artırmalı	−0,653	7,960	6,473	7,665
LightGBM	−0,671	8,002	6,522	7,728
XGBoost	−0,749	8,187	6,749	8,008
CatBoost	−2,916	12,250	10,739	12,859

Tablo A.6.4. Tam model karşılaştırma — Bellek 24 s

Model	R^2	RMSE	MAE	MAPE
Lin. Regresyon	0,7945	3,382	2,125	2,374
MLP	0,4276	5,645	4,023	4,557
Rast. Orman	0,4234	5,666	4,384	4,810
Grad. Artırmalı	0,4067	5,747	4,414	4,838
LightGBM	0,3740	5,903	4,428	4,834
XGBoost	0,3697	5,923	4,519	4,945
CatBoost	0,1439	6,903	5,191	5,666

Tablo A.6.5. Tam model karşılaştırma — Bellek 72 s

Model	R^2	RMSE	MAE	MAPE
MLP	0,3456	5,931	3,817	4,352
Lin. Regresyon	0,3414	5,950	4,352	4,941
LightGBM	−0,404	8,686	7,149	7,910
XGBoost	−0,603	9,283	7,691	8,518
Grad. Artırmalı	−1,104	10,635	8,906	9,865
CatBoost	−1,447	11,468	9,853	10,976
Rast. Orman	−2,844	14,375	12,281	13,662

Tablo A.6.6. Tam model karşılaştırma — Disk 24 s

Model	R^2	RMSE	MAE	MAPE
Lin. Regresyon	0,6984	2,769	1,679	2,069
MLP	0,2301	4,425	3,298	4,057
LightGBM	−1,739	8,346	6,763	8,186
XGBoost	−1,804	8,444	6,835	8,270
Rast. Orman	−2,151	8,952	7,310	8,856
CatBoost	−2,326	9,197	7,675	9,342
Grad. Artırmalı	−6,112	13,449	11,199	13,624

Tablo A.6.7. Tam model karşılaştırma — Disk 72 s

Model	R^2	RMSE	MAE	MAPE
MLP	0,2212	4,361	3,137	3,839
XGBoost	−2,023	8,591	7,165	8,698
LightGBM	−2,109	8,712	7,289	8,850
Lin. Regresyon	−2,404	9,116	5,301	6,541
Rast. Orman	−2,717	9,526	8,194	9,986
Grad. Artırmalı	−4,120	11,180	9,471	11,550
CatBoost	−4,699	11,796	10,665	13,103

Tablo A.6.8. Bellek 24 s LR modeli için SHAP özellik önemleri (ilk 10 özellik, ortalama $|\phi_i|$)

Sıra	Özellik	Ortalama $|\phi_i|$
1	vm_count_rmean_24h	10 871
2	total_errors_rsum_72h	6 659
3	vm_count_rmean_12h	4 213
4	memory_usage_percent_rmean_24h	3 887
5	connection_pool_warn_count_rsum_72h	2 944
6	vm_count_rmean_6h	2 611
7	memory_pressure_count_rsum_72h	2 103
8	memory_usage_percent_rmean_12h	1 876
9	quota_exceeded_count_rsum_72h	1 542
10	vm_count_rmean_168h	1 398

Tablo A.6.9. Disk 24 s LR modeli için SHAP özellik önemleri (ilk 10 özellik, ortalama $|\phi_i|$)

Sıra	Özellik	Ortalama $\lvert\phi_i\rvert$
1	total_errors_rsum_24h	2 111
2	total_warning_count_rsum_72h	1 544
3	resource_exhausted_count_rsum_72h	1 506
4	disk_usage_percent_rmean_24h	1 389
5	io_error_count_rsum_72h	1 244
6	disk_usage_percent_rmean_12h	1 102
7	disk_io_degradation_count_rsum_72h	987
8	network_error_count_rsum_24h	834
9	vm_count_rmean_24h	791
10	quota_exceeded_count_rsum_24h	623

KIŞISEL YAYIN VE ESERLER

ÖZGEÇMIŞ

Yusuf Kaya, 1998 yılında Çorum'da doğdu. Lisans eğitimini 2017–2023 yılları arasında Yıldız Teknik Üniversitesi Elektronik ve Haberleşme Mühendisliği Bölümü'nde tamamladı (AGNO: 3.03). Lisans öğrenimi süresince TÜBİTAK 2209-A Üniversite Öğrencileri Araştırma Projeleri Destekleme Programı kapsamında Radio over Fiber (RoF) tabanlı mobil haberleşme sistemi üzerine proje yürüttü. 2024 yılında Kocaeli Üniversitesi Fen Bilimleri Enstitüsü Yazılım Mühendisliği Anabilim Dalı'nda yüksek lisans eğitimine başladı (AGNO: 3.13).

Ağustos 2022'den itibaren TÜBİTAK BİLGEM'de çalışmaya başladı; Ağustos 2022–Mayıs 2023 tarihleri arasında stajyer araştırmacı olarak OpenStack altyapısı ve ağ güvenliği alanlarında deneyim kazandı. Mayıs 2023'ten itibaren Yazılım ve Bulut Mühendisi olarak Safir Bulut ve Multi-Cloud Management projelerinde görev almaktadır. Bu süreçte OpenStack servis geliştirme, Kubernetes tabanlı izleme altyapısı, Prometheus/Thanos/OpenSearch entegrasyonları ve Go/Python ile servis geliştirme konularında çalışmalar yürütmüştür.

YÖKDil İngilizce puanı 75'tir (2023). CCNA sertifikasyonunu (Ağlar, Yönlendirme ve Anahtarlama, Kurumsal Ağlar) ve Architecting on AWS sertifikasını tamamlamıştır.