KOCAELİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

BİLGİSAYAR MÜHENDİSLİĞİ
ANABİLİM DALI

YÜKSEK LİSANS TEZİ

DERİN ÖĞRENME İLE SINIFTAN BAĞIMSIZ NESNE TESPİTİ: BELİRGİNLİK ODAKLI GELECEK UYGULAMALARA YÖNELİK BİR YAKLAŞIMIN GELİŞTİRİLMESİ

ŞEYMA USTA

KOCAELİ 2025

KOCAELİ ÜNİVERSİTESİ

FEN BİLİMLERİ ENSTİTÜSÜ

BİLGİSAYAR MÜHENDİSLİĞİ

ANABİLİM DALI

YÜKSEK LİSANS TEZİ

DERİN ÖĞRENME İLE SINIFTAN BAĞIMSIZ NESNE TESPİTİ: BELİRGİNLİK ODAKLI GELECEK UYGULAMALARA YÖNELİK BİR YAKLAŞIMIN GELİŞTİRİLMESİ

ŞEYMA USTA

Doç. Dr. Orhan AKBULUT		
Danışman,	**Kocaeli Üniv.**	**.....**
Doç. Dr. Alev MUTLU		
Jüri Üyesi,	**Kocaeli Üniv.**	**.....**
Dr. Öğr. Üyesi Fulya AKDENİZ		
Jüri Üyesi,	**Kocaeli Sağlık ve Teknoloji Üniv.**	**.....**

Tezin Savunulduğu Tarih: 14.11.2025

ETİK BEYAN VE ARAŞTIRMA FONU DESTEĞİ

Kocaeli Üniversitesi Fen Bilimleri Enstitüsü tez yazım kurallarına uygun olarak hazırladığım bu tez/proje çalışmasında,

- Bu tezin/projenin bana ait, özgün bir çalışma olduğunu,
- Çalışmamın hazırlık, veri toplama, analiz ve bilgilerin sunumu olmak üzere tüm aşamasında bilimsel etik ilke ve kurallara uygun davrandığımı,
- Bu çalışma kapsamında elde edilen tüm veri ve bilgiler için kaynak gösterdiğimi ve bu kaynaklara kaynakçada yer verdiğimi,
- Bu çalışmamın Kocaeli Üniversitesi'nin abone olduğu intihal yazılım programı kullanılarak Fen Bilimleri Enstitüsü'nün belirlemiş ölçütlere uygun olduğunu,
- Kullanılan verilerde herhangi bir tahrifat yapmadığımı,
- Tezin/projenin herhangi bir bölümünü bu üniversite veya başka bir üniversitede başka bir tez/proje çalışması olarak sunmadığımı,

beyan ederim.

☐ Bu tez/proje çalışmasının herhangi bir aşaması hiçbir kurum/kuruluş tarafından maddi/alt yapı desteği ile desteklenmemiştir.

☑ Bu tez/proje çalışması kapsamında üretilen veri ve bilgiler Kocaeli Üniversitesi Bilimsel Araştırma Projeleri Koordinasyon Birimi tarafından 4196 no'lu proje kapsamında maddi/alt yapı desteği alınarak gerçekleştirilmiştir.

Herhangi bir zamanda, çalışmamla ilgili yaptığım bu beyana aykırı bir durumun saptanması durumunda, ortaya çıkacak tüm ahlaki ve hukuki sonuçları kabul ettiğimi bildiririm.

.....

Şeyma USTA

YAYIMLAMA VE FİKRİ MÜLKİYET HAKLARI

Fen Bilimleri Enstitüsü tarafından onaylanan lisansüstü tezimin/projemin tamamını veya herhangi bir kısmını, basılı ve elektronik formatta arşivleme ve aşağıda belirtilen koşullarla kullanıma açma izninin Kocaeli Üniversitesi'ne verdiğimi beyan ederim. Bu izinle Üniversiteye verilen kullanım hakları dışındaki tüm fikri mülkiyet haklarım bende kalacak, tezimin/projemin tamamının ya da bir bölümünün gelecekteki çalışmalarda (makale, kitap, lisans ve patent vb.) kullanımı bana ait olacaktır.
Tezin/projenin kendi özgün çalışmam olduğunu, başkalarının haklarını ihlal etmediğimi ve tezimin/projenin tek yetkili sahibi olduğumu beyan ve taahhüt ederim. Tezimde yer alan telif hakkı bulunan ve sahiplerinden yazılı izin alınarak kullanılması zorunlu metinlerin yazılı izin alarak kullandığımı ve istenildiğinde suretlerini Üniversiteye teslim etmeyi taahhüt ederim.
Yükseköğretim kurulu tarafından yayınlanan ***"Lisansüstü Tezlerin Elektronik Ortamda Toplanması, Düzenlenmesi ve Erişime Açılmasına İlişkin Yönerge"*** kapsamında tezim aşağıda belirtilen koşullar haricinde YÖK Ulusal Tez Merkezi/ Kocaeli Üniversitesi Kütüphaneleri Açık Erişim Sisteminde erişime açılır.

☐ Enstitü yönetim kurulu kararı ile tezimin/projemin erişime açılması mezuniyet tarihinden itibaren 2 yıl ertelenmiştir.
☐ Enstitü yönetim kurulu gerekçeli kararı ile tezimin/projemin erişime açılması mezuniyet tarihinden itibaren 6 ay ertelenmiştir.
☑ Tezim/projem ile ilgili gizlilik kararı verilmemiştir.

.....

Şeyma USTA

ÖNSÖZ VE TEŞEKKÜR

Görsel dünyada insanların ilk olarak dikkatini çeken nesneler, genellikle sahneyi anlamlı hale getiren belirgin nesnelerdir. İnsan görsel sistemi, bir sahneye bakıldığında öncelikle bu dikkat çekici bölgeleri algılar. Bilgisayarla görü alanında da bu dikkat çekici bölgelerdeki doğal seçicilik, otomatik sistemlerin nesne algılama ve sınıflandırma süreçlerine yol gösterici olmuştur. Tez çalışmasında, derin öğrenme tabanlı nesne tespiti yaklaşımlarına, belirgin nesnelerin tespiti ve sınıftan bağımsız nesne algılama kavramları üzerinden yeni bir bakış sunmayı amaçlamaktadır. Özellikle veri etiketleme sürecinin hızlandırılmasına yönelik olarak, görüntülerdeki tüm nesnelerin belirgin nesne olarak değerlendirilmesi fikriyle başlatılan bu araştırma, gelecekte yalnızca dikkat çekici nesneleri ön plana çıkaracak modellere doğru ilerlemeyi hedeflemektedir. Bu çalışmada, veri etiketleme süreçlerinde nesne tespiti ile belirginliğe dayalı nesne tespiti arasındaki ilişkiyi keşfetmek amacıyla, bu alanda gerçekleştirilen güncel çalışmalar incelenmiştir. Çalışma, sınıfa dayalı veri etiketleme ihtiyacını azaltmak amacıyla, yalnızca sınıftan bağımsız nesne tespitine odaklanan bir ön etiketleme yaklaşımı önermekte; böylece hem etiketleme sürecini hızlandırmakta hem de daha önce görülmemiş sınıfların tespitine olanak tanımaktadır. Bu kapsamda, derin öğrenme tabanlı nesne tespitinde farklı mimari yaklaşımları temsil eden YOLOv8, YOLOv11 ve Faster R-CNN modelleri kullanılmıştır. YOLOv8 ve YOLOv11, gerçek zamanlı nesne tespitine odaklanan tek aşamalı dedektör mimarileridir. Bu modeller, yüksek işlem hızı ve verimliliği sağlarken, farklı varyantları (örneğin nano, medium, large, xl gibi) arasında parametre sayısı ve doğruluk açısından dengeli bir performans aralığı sunmaktadır. Buna karşılık, Faster R-CNN, iki aşamalı bir mimari yapıya sahiptir; ilk aşamada olası nesne bölgelerini üretmekte, ikinci aşamada ise bu bölgeleri sınıflandırarak daha yüksek konumsal doğruluk elde etmektedir. Deneysel süreçte bu üç model ailesi, COCO 2017 veri kümesinin 80 sınıfı kullanılarak farklı yapılandırmalarda eğitilmiş ve tüm nesne kategorileri tek bir sınıfta birleştirilerek sınıftan bağımsız bir eğitim stratejisi uygulanmıştır. Mevcut çalışmada, görüntülerde yer alan tüm nesneler belirgin nesne olarak kabul edilmiş ve model bu varsayım temelinde eğitilmiştir. Bu yaklaşım, nesne varlığını herhangi bir sınıfsal ayrım yapmadan genel bir tek nesne kategorisi altında değerlendirmeyi hedeflemektedir. Bununla birlikte, gelecekteki çalışmalarda bu stratejinin daha seçici bir yapıya dönüştürülmesi planlanmaktadır. Özellikle, yalnızca görselde dikkat çekici ve öne çıkan belirgin nesnelerin seçilerek tek bir sınıf altında inceleneceği, böylece modelin yalnızca nesne varlığını değil, belirginlik düzeyi yüksek nesneleri tespit etme yeteneğinin de değerlendirileceği bir yapılandırma hedeflenmektedir. Bu doğrultuda, ilerleyen aşamalarda nesne tespiti süreci, belirgin nesne, arka plan ayrımını daha derinlemesine analiz eden bir yapıya dönüştürülerek geliştirilecektir. Sonuç olarak, bu çalışmada nesne tespiti süreci temel bileşen olarak ele alınmış, ancak belirginliğe dayalı nesne tespiti yöntemlerinin de ön etiketleme aşamasında dikkat çekici bölgeleri belirleyerek sürece hız ve doğruluk kazandırabileceği görülmüştür. Dolayısıyla belirginlik tabanlı yaklaşımlar, doğrudan ana bileşen olarak değil, destekleyici ve tamamlayıcı bir unsur olarak değerlendirilmekte; ilerleyen çalışmalarda nesne tespiti modellerine entegre edilerek anotasyon maliyetini azaltabilecek ve zayıf gözetimli senaryolarda yardımcı bir rol üstlenebilecek potansiyele sahip olduğu öngörülmektedir.

Tez çalışmamızı destekleyen Kocaeli Bilimsel Araştırma Projeleri Koordinasyon Birimi'ne teşekkür ederiz.

Tez çalışmamızda bilgilerini ve desteğini benden esirgemeyen kıymetli danışman hocam Doç. Dr. Orhan AKBULUT'a teşekkür ederim.

Yaptığımız çalışmanın her aşamasında destek aldığım çalışma arkadaşlarım Eren GÜNEŞ ve Ülkü İrem DENİZ'e teşekkürü borç bilirim. Benimle her zaman gurur duyan, yanımda olan ve tez çalışmamda bana destek olan ablam Ahsen USTA'ya ve aileme çok teşekkür ederim.

Kasım - 2025 Şeyma USTA

İÇİNDEKİLER

ETİK BEYAN VE ARAŞTIRMA FONU DESTEĞİ i
YAYIMLAMA VE FİKRİ MÜLKİYET HAKLARI ii
ÖNSÖZ VE TEŞEKKÜR iii
İÇİNDEKİLER v
ŞEKİLLER DİZİNİ vi
TABLOLAR DİZİNİ vii
SİMGELER VE KISALTMALAR DİZİNİ viii
ÖZET x
ABSTRACT xii
1. GİRİŞ 1
1.1. Nesne Tespiti 2
1.2. Belirgin Nesne Tespiti 3
2. LİTERATÜR ÇALIŞMASI 6
2.1. Nesne Tespiti 6
2.2. Belirgin Nesne Tespiti 9
2.3. Veri Etiketleme 10
2.4. Hızlı Veri Etiketleme 12
3. TEZ KAPSAMINDA KULLANILAN YÖNTEMLER 14
3.1. YOLOv8 Mimarisi 14
3.2. YOLOv11 Mimarisi 17
3.3. Faster-RCNN Mimarisi 19
3.4. Omurga (Backbone) Mimarisi 27
3.4.1. RESNET50 MİMARİSİ (Residual Network) 27
3.4.2. Özellik Piramit Ağı (Feature Pyramid Network) 28
4. BİLGİSAYAR GÖRÜ ALANINDA VERİ ETİKETLEME 30
4.1. Veri Etiketleme 30
4.2. Hızlı Veri Etiketleme 31
5. ÖNERİLEN METEDOLOJİ 32
5.1. Sınıfa Bağımlı Derin Öğrenme Temelli Nesne Tespiti İle Veri Etiketleme 33
5.2. Sınıftan Bağımsız Derin Öğrenme Temelli Nesne Tespiti İle Veri Etiketleme 33
6. VERİ KÜMESİ VE MODEL YAPILANDIRMA PARAMETRELERİ 35
6.1. Veri Kümesi 35
6.2. COCO Veri Kümesindeki Sınıf Dağılımı 36
7. DENEYSEL SONUÇLAR 39
7.1. YOLOv8 Mimarisinin Varyasyon Karşılaştırılması 40
7.2. YOLOv11 Mimarisinin Varyasyon Karşılaştırılması 44
7.3. Faster-RCNN Mimarisinin Karşılaştırılması 49
8. SONUÇ VE ÖNERİLER 53
KAYNAKLAR 56
KİŞİSEL YAYIN VE ESERLER 60
ÖZGEÇMİŞ 61

ŞEKİLLER DİZİNİ

Şekil 2.1. YOLOv10m modeli test videosu ekran görüntüsü 6
Şekil 2.2. SSD300-VGG16 modeli test videosu ekran görüntüsü 6
Şekil 2.3. EfficientDet-D2 modeli test videosu ekran görüntüsü 7
Şekil 3.1. YOLO sürümlerinin yıllara göre gelişim çizelgesi..... 14
Şekil 3.2. Faster R-CNN'de özellik haritası çıkarımı..... 22
Şekil 3.3. Faster R-CNN'de bölge teklif ağının oluşturulması..... 24
Şekil 3.4. Faster R-CNN'de nesne sınıflandırılması ve kutu iyileştirme..... 26
Şekil 3.5. Özellik Piramit Ağı (Lin ve diğ., 2017). 29
Şekil 6.1. COCO 2017 veri setinden alınan örnek görseller..... 35
Şekil 6.2. COCO 2017 Veri Kümesinde Sınıf Bazında Örnek Dağılım (N>10.000)..... 36
Şekil 6.3. COCO 2017 Veri Kümesinde Sınıf Bazında Örnek Dağılım (N<5.500)..... 37
Şekil 6.4. COCO 2017 Veri Kümesinde Sınıf Bazında Örnek Dağılım (10.000>N>5.500)..... 37
Şekil 7.1. Görülmemiş nesneler üzerinde varsayılan ve sınıf-bağımsız YoloV8 modellerinin görsel karşılaştırması (a) Varsayılan model, (b) Önerilen yöntem. 42
Şekil 7.2. Görülmemiş nesneler üzerinde YOLOv8n (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.) 43
Şekil 7.3. Görülmemiş nesneler üzerinde YoloV8m (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)..... 44
Şekil 7.4. Görülmemiş nesneler üzerinde YoloV8x (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)..... 44
Şekil 7.5. Görülmemiş nesneler üzerinde varsayılan ve sınıf-bağımsız YoloV11 modellerinin görsel karşılaştırması (a) Varsayılan model, (b) Önerilen yöntem. 47
Şekil 7.6. Görülmemiş nesneler üzerinde YoloV11n (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.) 48
Şekil 7.7. Görülmemiş nesneler üzerinde YoloV11m (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.) 48
Şekil 7.8. Görülmemiş nesneler üzerinde YoloV11x (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.) 49
Şekil 7.9. Görülmemiş nesneler üzerinde Faster-RCNN (ÖY) mimarisinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.) 51

TABLOLAR DİZİNİ

Tablo 3.1. YOLO sürümlerinin yıllara göre yapı, omurga ve ortalama başarı (AP) değerleri karşılaştırması. 16
Tablo 3.2. COCO (80 sınıf) veri kümesiyle eğitilmiş YOLOv8 farklı varyant sonuçları. 16
Tablo 3.3. COCO veri kümesi ile eğitilmiş YOLOv11 farklı varyant sonuçları. 18
Tablo 6.1. COCO Veri Kümesi Üzerindeki Yapılandırma Parametreleri 38
Tablo 7.1. Sınıftan Bağımsız Nesne Tespitinde YOLOv8 Varyantlarının Performans Karşılaştırması 41
Tablo 7.2. Sınıftan bağımsız nesne tespitinde YOLOv11 varyantlarının performans karşılaştırması. 46
Tablo 7.3. Sınıftan bağımsız nesne tespitinde Faster-RCNN performans karşılaştırması. 50

SİMGELER VE KISALTMALAR DİZİNİ

Σ	:	Toplam İşareti
μ	:	Ortalama Değer
σ	:	Standart Sapma
N	:	Veri Sayısı
AP_i	:	i. Sınıfa Ait Ortalama Doğruluk Değeri
IoU	:	Intersection over Union (Kesişim Birlik Oranı)

Kısaltmalar

AI	:	Artificial Intelligence (Yapay Zeka)
AP	:	Average Precision (Ortalama Doğruluk)
AR	:	Average Recall (Ortalama Geri Çağırma)
BBox	:	Bounding Box (Sınırlayıcı Kutu)
CNN	:	Convolutional Neural Network (Evrişimsel Sinir Ağı)
COCO	:	Common Objects in Context (Ortamda Yaygın Nesneler Veri Kümesi
COCO-LT	:	Long-Tailed COCO Dataset (Uzun Kuyruklu COCO Veri Kümesi)
ConvNeXt	:	Improved Convolutional Network Architecture (Geliştirilmiş Konvolüsyonel Ağ)
CSP	:	Cross Stage Partial Derivatives (Kısmi Aşama Bağlantılı Türevler)
CV	:	Computer Vision (Bilgisayarla Görme)
Darknet	:	Feature Extractor in YOLO Architecture (YOLO Mimarisinde Kullanılan Özellik Çıkarıcı Ağ)
DAD	:	Driver Anomaly Detection (Sürücü Anomali Tespiti)
DL	:	Deep Learning (Derin Öğrenme)
EfficientDet	:	Efficient Object Detection Network (Verimli Nesne Algılama Ağı)
EfficientNet	:	Efficient Neural Network (Verimli Sinirsel Ağ)
EfficientRep	:	Efficient Representation Network (Verimli Temsiller Öğrenme Ağı)
Fast R-CNN	:	Fast Region-Based Convolutional Neural Network (Hızlandırılmış Bölge Tabanlı Evrişimsel Sinir Ağı)
Faster R-CNN	:	Faster Region-Based Convolutional Neural Network (Geliştirilmiş Bölge Tabanlı Evrişimsel Sinir Ağı)
FixMatch	:	Consistency and Pseudo-Labeling Based Semi-Supervised Learning (Tutarlılık ve Sahte Etiketleme Yöntemi)
FPN	:	Feature Pyramid Network (Özellik Piramidi Ağı)
FPS	:	Frames Per Second (Saniye Başına Kare)
FCOS	:	Fully Convolutional One-Stage Object Detector (Tam Konvolüsyonel Tek Aşamalı Nesne Algılayıcı)
GPU	:	Graphics Processing Unit (Grafik İşlem Birimi)
GT	:	Ground Truth (Gerçek Etiket)
HC	:	Hierarchical Correction (Hiyerarşik Düzeltme)
IoU	:	Intersection over Union (Kesişim Üzerinden Birleşim)
IRA	:	Interactive Recurrent Annotation (Etkileşimli Yinelenen Etiketleme)
mAP	:	Mean Average Precision (Ortalama Ortalama Doğruluk)
MAE-NAS	:	Masked Autoencoder - Neural Architecture Search (Maskelenmiş

		Otomatik Kodlayıcı - Sinirsel Mimari Arama)
MIM	:	Masked Image Modeling (Maskeli Görüntü Modellemesi)
MixMatch	:	Semi-Supervised Learning with Mixed Labels (Karışık Etiketli Öğrenme Yöntemi)
MS-COCO	:	Microsoft Common Objects in Context Dataset (Microsoft Ortak Nesneler Bağlamında Veri Kümesi)
NAS	:	Neural Architecture Search (Sinirsel Mimari Arama)
NMS	:	Non-Maximum Suppression (Maksimum Olmayan Bastırma)
ÖY	:	Öğrenme Yöntemi
PyTorch	:	Python Deep Learning Framework (Python Derin Öğrenme Çerçevesi)
PaddlePaddle	:	Parallel Distributed Deep Learning Framework (Paralel Dağıtık Derin Öğrenme Çerçevesi)
PyQt5	:	Python Qt5 GUI Framework (Python Qt5 Grafik Arayüz Çerçevesi)
R-CNN	:	Region-based Convolutional Neural Network (Bölge Tabanlı Evrişimsel Sinir Ağı)
ReMixMatch	:	Advanced Semi-Supervised Learning (Gelişmiş Yarı Denetimli Öğrenme Yöntemi)
RepConvN	:	Re-parameterized Convolutional Network (Yeniden Parametreleştirilmiş Evrişimsel Ağ)
ResNet	:	Residual Network (Artık Ağ)
ResNet-vd	:	Variant Deep Residual Network (Derin Artık Ağ Varyantı)
RPN	:	Region Proposal Network (Bölge Öneri Ağı)
ROI	:	Region of Interest (İlgi Bölgesi)
R-ViT	:	Residual Vision Transformer (Artık Görsel Dönüştürücü)
SIU	:	Similarity in Union (Birleşim Benzerliği)
SSL	:	Semi-Supervised Learning (Yarı Denetimli Öğrenme)
SSD	:	Single Shot MultiBox Detector (Tek Atışlı Çok Kutu Tespit Edici)
SSDLite	:	Lightweight SSD Version (Hafifletilmiş SSD Sürümü)
ViT	:	Vision Transformer (Görsel Dönüştürücü)
VIA	:	VGG Image Annotator (VGG Görsel Etiketleme Aracı)
VOC-LT	:	Visual Object Classes - Long Tail (Uzun Kuyruklu Görsel Nesne Sınıfları)
YOLO	:	You Only Look Once (Bir Kez Bak ve Tanı)
YOLO-NAS	:	You Only Look Once - Neural Architecture Search (YOLO - Sinirsel Mimari Arama Tabanlı Model)
YOLOv8	:	You Only Look Once Version 8 (YOLO Modelinin Sekizinci Sürümü)

DERİN ÖĞRENME İLE SINIFTAN BAĞIMSIZ NESNE TESPİTİ: BELİRGİNLİK ODAKLI GELECEK UYGULAMALARA YÖNELİK BİR YAKLAŞIMIN GELİŞTİRİLMESİ

ÖZET

İnsan görsel sistemi, bir sahneye bakıldığında öncelikle dikkat çekici ve öne çıkan bölgeleri algılar. Bu doğal eğilim, bilgisayarla görme alanındaki çalışmalara da ilham vermiş ve belirgin nesne tespiti kavramını ortaya çıkarmıştır. Belirgin nesne tespiti, görüntüdeki en dikkat çekici nesneleri veya bölgeleri otomatik olarak tanımlamayı amaçlayarak görsel bilginin yorumlanmasında önemli bir temel oluşturur. Günümüzde, bu yaklaşım yalnızca nesne tanıma süreçlerinde değil, aynı zamanda veri etiketleme ve hızlı anotasyon çalışmalarında da verimlilik kazandıran bir ön adım olarak değerlendirilmektedir.

Görsel veri, günümüz yapay zeka uygulamalarının temel yapı taşlarından biri haline gelmiş ve özellikle bilgisayarla görme alanında önemli bir rol üstlenmiştir. Derin öğrenme tekniklerinin bu alandaki yükselişi, büyük ölçüde yüksek kaliteli, etiketlenmiş veri kümelerinin var olmasına bağlıdır. Ancak, veri etiketleme; ölçeklenebilirlik, zaman yönetimi ve insan gücü gibi açılardan oldukça zorlu bir süreçtir. Bu durum, etiketleme süreçlerinde verimlilik odaklı yaklaşımlara zemin oluşturmuştur.

Klasik olan veri etiketleme yöntemleri genel olarak her nesneye ait bir sınıf etiketi belirlenmesiyken, bu yöntem birçok uygulama için maliyeti yüksek ve zaman alıcıdır. Özellikle etiketleme aşamasında sınıf bilgisine ihtiyaç duyulmadığı ya da sınıfların dinamik olarak veya sonradan belirlendiği senaryolarda, sınıftan bağımsız veri etiketleme yöntemleri daha pratik bir yaklaşım sunmaktadır. Bu yaklaşımlar, yalnızca nesnelerin görüntü içindeki konumlarını tespit edip sınıf ataması öncesindeki süreci hızlandırmayı hedefler. Nesne tespiti sürecinin önemli olduğu bu çalışmada, belirginliğe dayalı nesne tespiti yöntemlerinin de ön etiketleme sürecinde dikkat çekici bölgeleri belirleyerek potansiyel olarak hız ve doğruluk kazandırabileceği görülmüştür. Belirginliğe dayalı nesne tespiti, gelecek çalışmalarda nesne tespiti modellerine entegre edilerek anotasyon maliyetini daha da azaltabilecek ve zorlu senaryolarda destekleyici bir yol üstlenebilecektir.

Bu çalışmada farklı mimari modeller ele alınmıştır. İlk modelde, 80 sınıflı COCO 2017 veri kümesi üzerinde önceden eğitilmiş YOLOv8 modellini kullanarak sınıf bilgisine bakmadan nesne tespiti gerçekleştirilmiştir. İkinci modelde aynı varyasyonları kullanarak ve YOLOv11 modeli kullanılarak, tüm nesne kategorilerinin tek bir sınıf altında birleştirildiği sınıf bilgisinden bağımsız bir yapılandırmayla eğitilmiştir. Bu yapılandırma, nesne örneklerini sınıf bilgisi gerektirmeden tespit etmeyi mümkün kılar. Üçüncü modelde ise Faster-RCNN modelini de kullanarak tüm nesne kategorilerinin tek bir sınıf altında birleştirildiği sınıf bilgisinden bağımsız bir yapılandırmayla ilerlenmiş ve bu yaklaşımların sonuçları birbirleriyle kıyaslanmıştır. Önerilen yöntemler, yalnızca görüntülerdeki nesnelerin konumlarına odaklanarak daha hızlı anotasyon yapılmasına imkan tanımaktadır. Her yaklaşım da, görüntü başına çok sayıda nesne örneği içeren senaryolarda daha hızlı anotasyonu kolaylaştırma potansiyeline sahiptir. Sınıf

bilgisinden bağımsız yapılandırmamız, farklı nesne tespiti senaryolarında güçlü ve genellenebilir bir performans sergilemiş, anotasyon süreçlerini hızlandırma potansiyelini ortaya koymuştur. Bu kapsamda, çalışma, belirgin nesne tespiti yaklaşımının veri anotasyon süreçlerinde kullanılabilirliğini ortaya koyarak gelecekteki hızlı etiketleme araştırmalarına katkı sunmaktadır. Bu yönüyle çalışma, belirgin nesne tespiti kavramının hızlı veri anotasyonu ve sınıftan bağımsız nesne algılama süreçlerine entegre edilmesi açısından yenilikçi bir yaklaşım sunmaktadır.

Anahtar Kelimeler: Anotasyon, Etiketleme, Nesne Tespiti, Sınıftan Bağımsız.

CLASS-AGNOSTIC OBJECT DETECTION WITH DEEP LEARNING FOR FUTURE SALIENCY-BASED APPLICATIONS

ABSTRACT

The human visual system, when viewing a scene, first perceives regions that are salient and prominent. This natural tendency has inspired studies in computer vision and led to the emergence of the concept of salient object detection. Salient object detection aims to automatically identify the most attention-grabbing objects or regions in an image, forming an important foundation for interpreting visual information. Today, this approach is considered not only within object recognition pipelines but also as a preparatory step that improves efficiency in data labeling and rapid annotation workflows.

Visual data has become one of the fundamental building blocks of contemporary artificial intelligence applications and plays a particularly important role in the field of computer vision. The rise of deep learning in this area largely depends on the availability of high-quality, labeled datasets. However, data annotation is a highly challenging process in terms of scalability, time management, and human effort. This has paved the way for efficiency-oriented approaches in annotation workflows.

Traditional data labeling methods typically assign a class label to each object instance, which is costly and time-consuming for many applications. Especially in scenarios where class information is not required at the labeling stage, or where classes are determined dynamically or retrospectively, class-agnostic labeling methods offer a more practical approach. These methods aim to accelerate the pre-classification phase by detecting only the locations of objects within the image. In this study, where the object detection process is central, saliency-based object detection methods were also observed to identify attention-worthy regions during pre-annotation, potentially improving both speed and accuracy. In future work, saliency-based detection can be integrated into object detection models to further reduce annotation costs and serve as supportive guidance in challenging scenarios.

This study examines different architectural models. In the first model, object detection was performed without considering class information by using a YOLOv8 model pre-trained on the COCO 2017 dataset with 80 classes. In the second model, using the same variations and the YOLOv11 model, training was conducted in a class-agnostic configuration in which all object categories are merged under a single class. This configuration enables the detection of object instances without requiring class labels. In the third model, a Faster-R CNN-based approach was adopted with the same single-class configuration, and the results of these approaches were compared. The proposed methods focus solely on the locations of objects in images, enabling faster annotation. Each approach has the potential to facilitate quicker annotation in scenarios containing many object instances per image. Our class-agnostic configuration demonstrated strong and generalizable performance across different object detection scenarios, revealing its potential to accelerate annotation processes. In this regard, the study demonstrates the usability of the saliency-based detection paradigm within data annotation workflows and

contributes to future research on rapid labeling. Thus, it offers an innovative perspective on integrating the concept of saliency into fast data annotation and class-agnostic object perception.

Keywords: Annotation, Data-Labeling, Object Detection, Class-Agnostic.

1. GİRİŞ

Son yıllarda yapay zeka alanında yapılan çalışmalar oldukça yoğunlaşmıştır. Veri odaklı problemlerde özellikle derin öğrenme modelleri etkin çözümler sunmuştur. Derin öğrenme, çok katmanlı sinir ağları aracılığıyla veri kümelerinden özellikler çıkarma, karmaşık kalıpları ayırt etme ve çeşitli veri türlerine (görsel, işitsel, metinsel) uyum sağlama yeteneğine sahip bir öğrenme paradigmasını temsil eder. Özellikle görsel veri analizi alanında, doğruluk ve genelleme açısından gösterilen başarı, geleneksel yöntemlerle elde edilemeyen sonuçlar, derin öğrenme modellerinin önemini ortaya çıkarmıştır.

Derin öğrenme modellerinin bilgisayarla görme alanında ulaştığı yüksek doğruluk oranları, büyük ölçüde yüksek kaliteli ve etiketlenmiş görüntü verilerinin kullanılmasına dayanmaktadır (Northcutt ve diğ., 2021; Wang ve diğ., 2022). Görüntü sınıflandırma, nesne tespiti ve segmentasyon gibi görevlerde başarılı sonuçlar elde edebilmek için, giriş görüntülerinin anlamlı çıktılarla ilişkilendirilmesi gerekmektedir. Bu durum, denetimli öğrenme yöntemlerinin doğası gereği, her görüntüye ait bir doğru cevap bulunmasını zorunlu kılmaktadır. Ancak bu doğrulama süreci, özellikle çok nesneli veya karmaşık sahneler içeren görüntülerde, hatta piksel düzeyinde hassasiyet gerektiren segmentasyon görevlerinde oldukça zorlu hale gelmektedir.

Bu süreçte, öğrenme tabanlı yaklaşımlar yalnızca denetimli modellerle sınırlı kalmamış; yarı denetimli, kendi kendini denetleyen ve pekiştirmeli öğrenme yöntemleriyle daha esnek hale gelmiştir. Bu yeni öğrenme paradigmaları, etiketli veriye olan bağımlılığı azaltarak öğrenme sürecini daha verimli ve ölçeklenebilir hale getirmiştir. Özellikle bilgisayarla görme alanında bu yaklaşımlar görüntü sınıflandırma, nesne tespiti, belirgin nesne analizi ve veri etiketleme gibi görevlerde önemli ilerlemeler sağlamıştır.

Medikal görüntüleme, uydu gözlemleri, tarımsal analizler ve otonom sürüş sistemleri gibi alanlarda binlerce hatta milyonlarca görüntünün manuel olarak etiketlenmesi, yoğun insan emeği gerektiren, zaman alıcı ve maliyetli bir süreçtir. Bu zorluklar, veri etiketleme sürecini daha verimli ve ölçeklenebilir hale getirmek amacıyla otomatik veya yarı otomatik hızlı etiketleme yöntemlerinin geliştirilmesini gerekli kılmıştır. Bu yaklaşımlar sayesinde etiketleme sürecindeki insan müdahalesi azaltılmakta, etiketleme hızında kayda değer artışlar sağlanmakta ve büyük ölçekli veri kümelerinin oluşturulması

kolaylaşmaktadır.

1.1. Nesne Tespiti

Nesne tespiti, bilgisayarla görme alanında derin öğrenme tabanlı sistemlerin temel bileşenlerinden biridir ve görüntüdeki nesnelerin hem varlığını hem de konumlarını belirlemeye odaklanır. Günümüzde nesne tespiti, bilgisayarla görme alanının en temel problemlerinden biri olarak kabul edilmekte ve güvenlik, otonom araçlar, üretim, sağlık gibi pek çok farklı alanda kullanılmaktadır. Derin öğrenme tabanlı modellerin gelişimiyle birlikte, nesne tespiti sistemleri artık daha hızlı, daha doğru ve daha karmaşık sahneleri analiz edebilecek düzeye ulaşmıştır. Literatürde, gerçek zamanlı nesne tespiti alanında YOLO ailesi ve Faster R-CNN mimarilerine dayanan çok sayıda çalışma bulunmaktadır. YOLOv8 ve YOLOv11, önceki sürümlerine kıyasla hem model doğruluğu hem de işlem hızı açısından önemli gelişmeler sunmaktadır; nesne tespiti, segmentasyon ve sınıflandırma görevlerinde yüksek performans göstermektedir (Abdullah ve diğ., 2024; Jocher ve Team, 2025; Ultralytics, 2025). Ultralytics tarafından geliştirilen bu model ailesi, nano, small, medium, large ve xlarge dahil olmak üzere bir dizi varyantı kapsar (Jocher ve Team, 2025; Ultralytics, 2025). Bu varyantlar; hesaplama karmaşıklığı, parametre sayısı, bellek kullanımı ve doğruluk performansı açısından farklılık göstermektedir. Böylece kullanıcılar, sınırlı donanım kaynaklarına sahip sistemlerde hafif modelleri (örneğin, YOLOv8-nano) tercih ederken, yüksek doğruluk gerektiren ve güçlü GPU kaynaklarına sahip ortamlarda daha büyük modelleri (örneğin, YOLOv11-xlarge) kullanabilmektedirler. Model ailesinin bu ölçeklenebilir ve modüler yapısı, hem gerçek zamanlı hem de hassasiyet odaklı nesne tespiti görevleri için geniş bir uygulama yelpazesi sunmaktadır.

Faster R-CNN, özellikle küçük nesnelerin tespitinde öne çıkan iki aşamalı bir dedektör mimarisidir. Modelin ilk aşaması, görüntüde nesnelerin bulunma olasılığının yüksek olduğu bölgeleri belirleyen bir bölge öneri ağı içermektedir. İkinci aşamada ise bu bölgeler sınıflandırılarak her nesnenin ait olduğu sınıf tahmin edilir ve sınırlayıcı kutular konum açısından daha doğru hale getirilmektedir.

1.2. Belirgin Nesne Tespiti

Görsel verilerin anlamlandırılması ve yorumlanması, bilgisayarla görme alanının temel hedeflerinden biridir. Bu süreçte, insan görme sisteminden ilham alan modellerin geliştirilmesi, sahnedeki nesnelerin dikkat çekiciliğini veya belirginliğini anlamayı önemli bir araştırma konusu haline getirmiştir. Belirginlik kavramı, bir görüntüde insan dikkatini en çok çeken veya çevreden görsel olarak ayrışan nesne ya da bölgeleri tanımlamaktadır (Borji ve diğ., 2015; Itti ve diğ., 1998). Bu kavram, görsel dikkat modelleri, ön etiketleme sistemleri ve nesne tespiti uygulamalarında önemli bir rol oynamaktadır. Belirginliğe dayalı yöntemler, özellikle görüntüdeki dikkat çekici alanların tespitiyle, öğrenme sürecinde öncelikli bölgeleri belirleyerek veri etiketleme işlemini hızlandırma potansiyeline sahiptir (Jain ve diğ., 2019; Zhou ve diğ., 2020).

Literatürde belirgin nesne tespiti üzerine geliştirilen yöntemler, genellikle alt düzey ve üst düzey yaklaşımlar olarak sınıflandırılmaktadır. Alt düzey yaklaşımlar, insan görsel sistemindeki dikkat mekanizmasını taklit ederek düşük seviye görsel özellikler üzerinden belirgin bölgeleri çıkarır. Örneğin, Leal ve arkadaşları (Leal ve diğ., 2019), sözlük öğrenme ve seyrek kodlama tabanlı bir yöntemle, görüntüdeki nadir desenlerin belirgin alanları temsil ettiğini göstermiştir. Çalışmada her yama için seyrek kodlama uygulanmış, ardından atomların sıklığı analiz edilerek bir belirginlik haritası oluşturulmuştur. Bu yöntem, özellikle gri tonlu görüntülerde klasik yaklaşımlardan daha yüksek doğruluk elde etmeyi sağlamıştır .

Bunun yanında, Zhao ve diğ. tarafından önerilen artık yapılı CNN tabanlı belirginlik modeli, geleneksel ağ yapılarındaki bilgi kaybını azaltmak için artık bağlantılar ve çok ölçekli filtreler kullanmıştır. Bu yaklaşım, daha derin katmanlarda ayrıntı kaybını önleyerek belirgin bölgelerin daha doğru şekilde yakalanmasını sağlamıştır. Benzer biçimde, Wang ve diğ. U-Net tabanlı bir mimariyle hem konum hem de kenar duyarlılığını koruyan bir belirginlik haritalama tekniği geliştirilmiştir. Bu model, karmaşık sahnelerdeki nesnelerin sınırlarını hassas biçimde çıkarabilmiş ve geleneksel CNN mimarilerine kıyasla daha iyi segmentasyon sonuçları elde etmiştir. Ayrıca, Liu ve diğ., süper piksel tabanlı belirginlik tespiti yaklaşımıyla, görüntü bölütlerini yapay sinir ağları üzerinden analiz ederek dikkat çekici bölgeleri daha kompakt biçimde temsil etmeyi önermektedir (Chen ve Lin, 2020; Liu ve diğ., 2022; Wang ve diğ., 2021).

Belirginliğe dayalı yöntemlerin bu çeşitliliği, özellikle görüntüdeki dikkat çekici alanların tespiti ile öğrenme sürecinde öncelikli bölgeleri belirleyerek veri etiketleme işlemini hızlandırma potansiyeline sahiptir (Jain ve diğ., 2019; Zhou ve diğ., 2020). Bu çalışmada, farklı YOLOv8 ve YOLOv11 varyantlarının anotasyon sürecine potansiyel katkısı iki deneysel düzenek üzerinden değerlendirilmiştir. İlk düzende, COCO 2017 veri kümesi üzerinde sınıf bilgisine duyarlı olarak önceden eğitilmiş modeller kullanılarak nesne tespiti gerçekleştirilmiştir. İkinci düzende ise, sınıf bilgisinden bağımsız bir yapılandırma benimsenmiş; yalnızca nesne konumlarının tespitine odaklanılmış ve bu yapılandırmada farklı YOLOv8, YOLOv11 varyantları ile Faster R-CNN modeli yeniden eğitilmiştir. Her iki yaklaşım da, anotasyon sürecini desteklemek amacıyla nesne konumlarını bulma yetenekleri açısından karşılaştırılmıştır.

Bu çalışmada, bildiriden farklı olarak Faster R-CNN modeli ile YOLOv8 ve YOLOv11 üzerinde yapılan deneyler tekrarlanmış ve elde edilen sonuçlar karşılaştırmalı olarak incelenmiştir. Mevcut çalışma, fotoğraflarda yer alan tüm nesneleri belirgin nesne olarak kabul etmekte ve model eğitimini bu varsayım üzerine kurmaktadır. Böylece tüm nesneler, sınıfsal ayrım yapılmaksızın tek bir genel nesne sınıfı altında değerlendirilmektedir.

Bununla birlikte, gelecek çalışmalarda bu yaklaşımın daha seçici bir yapıya dönüştürülmesi planlanmaktadır. Özellikle, yalnızca görselde dikkat çekici ve öne çıkan belirgin nesnelerin seçilerek tek bir sınıf altında incelenmesi, modelin yalnızca nesne varlığını değil, aynı zamanda belirginlik düzeyi yüksek nesneleri ayırt etme kapasitesini de değerlendirmeyi mümkün kılacaktır. Böylece gelecek aşamalarda, nesne tespiti süreci belirgin nesne, arka plan ayrımına dayalı iki sınıflı bir yapı hâline getirilecek ve bu yapılandırma, ön etiketleme süreçlerinde daha doğru, hızlı ve etkili sonuçlar elde edilmesine katkı sağlayacaktır.

Bu tez çalışmasının özgün katkısı, belirginlik temelli yaklaşımları veri etiketleme süreçleriyle ilişkilendirerek otomatik ön etiketleme sürecine yeni bir bakış açısı kazandırmasıdır. Çalışma, derin öğrenme temelli nesne tespit modellerinin (YOLOv8, YOLOv11 ve Faster R-CNN) sınıftan bağımsız biçimde eğitilmesiyle hem görülmemiş sınıfların tespitine olanak sağlamış hem de etiketleme sürecinde model tabanlı hızlandırma potansiyelini ortaya koymuştur. Ayrıca, belirginlik temelli nesne tespiti

kavramı ilk kez bu kapsamda ön etiketleme süreciyle ilişkilendirilmiştir. Böylece, gelecekteki çalışmalarda belirgin nesnelerin seçilerek daha etkili ve ölçeklenebilir bir etiketleme süreci elde edilmesine yönelik bir temel oluşturulmuştur. Bu yönüyle çalışma, hem veri anotasyon süreçlerini hızlandırmaya hem de zayıf gözetimli öğrenme yöntemlerinin gelecekteki entegrasyonuna katkı sağlayacak yeni bir araştırma ekseni sunmaktadır.

2. LİTERATÜR ÇALIŞMASI

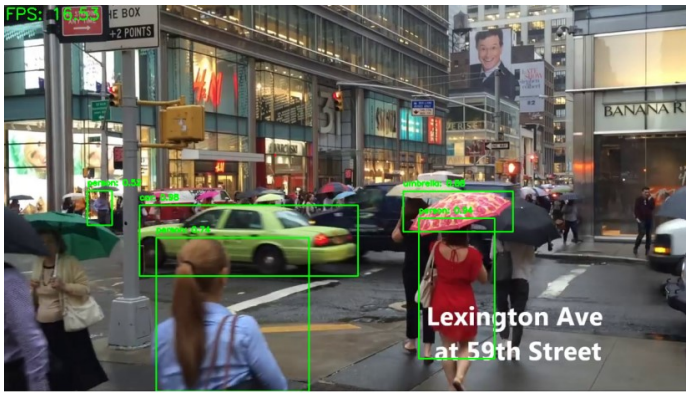
Bu bölümde nesne tespiti, belirgin nesne tespiti ve veri etiketleme alanında yapılan çalışmalar incelenmiştir.

2.1. Nesne Tespiti

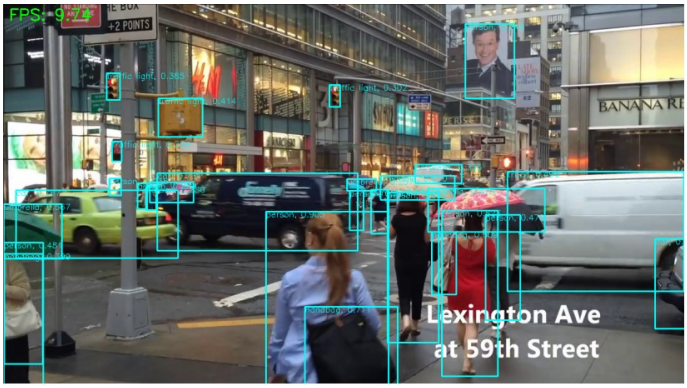
Elifnur Yılmaz ve arkadaşının yürüttüğü çalışmada (Yılmaz ve diğ., 2023), gerçek zamanlı nesne tespiti alanında üç farklı derin öğrenme tabanlı algoritma olan YOLO, SSD ve EfficientDet ile karşılaştırılmıştır. Araştırmada, modellerin tespit doğruluğu, işlem süresi ve donanım gereksinimleri açısından performansları değerlendirilmiş; bu amaçla çeşitli veri setleri üzerinde deneyler yapılmıştır. Elde edilen sonuçlar, YOLO ailesinin özellikle gerçek zamanlı uygulamalarda yüksek hız avantajı sunduğunu, SSD'nin hız-doğruluk dengesi açısından tatmin edici olduğunu, EfficientDet'in ise daha düşük işlem süresine kıyasla yüksek doğruluk oranları sağlayabildiğini ortaya koymuştur.



Şekil 2.1. YOLOv10m modeli test videosu ekran görüntüsü



Şekil 2.2. SSD300-VGG16 modeli test videosu ekran görüntüsü



Şekil 2.3. EfficientDet-D2 modeli test videosu ekran görüntüsü

Çalışmanın genel sonucuna göre, model seçimi uygulama amacına göre yapılmalıdır; yüksek hız gerektiren sistemlerde YOLO tercih edilebilecekken, doğruluğun kritik olduğu senaryolarda EfficientDet öne çıkmaktadır. Çalışmanın sonuçlarına ait örnek görüntüler Şekil 2.1, 2.2, 2.3'de gösterilmiştir.

Piyush Kumar ve arkadaşı (Kumar ve Sharma, 2024), çalışmalarında nesne tespiti alanındaki güncel gelişmeleri ele alarak YOLOv8 algoritmasını ve COCO veri kümesi üzerindeki performansını derinlemesine incelemişlerdir. Araştırmada, YOLOv8'in mimari yapısı, eğitim süreci ve önceki YOLO sürümlerine göre getirdiği iyileştirmeler detaylı olarak açıklanmıştır. COCO veri kümesi üzerinde yapılan deneylerde modelin mAP, hız ve küçük nesne tespiti konularındaki başarısı değerlendirilmiştir. Sonuçlar, YOLOv8'in hem yüksek doğruluk hem de düşük gecikme süresi ile gerçek zamanlı uygulamalara uygun olduğunu göstermiştir. Çalışma ayrıca YOLOv8'in, mobil ve gömülü sistemlerde çalıştırılabilirliği açısından da avantajlı olduğunu; bunun, modelin optimize edilmiş mimarisi ve verimli eğitim stratejilerinden kaynaklandığını vurgulanmıştır.

Sridhar Munjam'ın (Munjam ve Kasturi, 2024) tarafından uydu görüntülerinde gemilerin yüksek doğrulukla tanınmasını sağlamak amacıyla yapılan çalışmada, nesne tespiti alanında kullanılan güncel yöntemler, derin öğrenmeye dayalı yaklaşımlar üzerinden ele alınmıştır. Faster R-CNN, iki aşamalı yapısı sayesinde yüksek doğruluk elde etmesine rağmen, hesaplama maliyeti ve hız açısından bazı kısıtlar taşımaktadır. Buna karşın, YOLO ailesinin yeni sürümleri, tek aşamalı yapısı sayesinde gerçek zamanlı nesne tespiti için daha uygun bir çözüm sunmaktadır. Çalışmada, YOLOv8 ve Faster R-CNN'in birleştirilmesiyle yeni bir derin öğrenme sistemi geliştirilmesi amaçlanmıştır.

Ayrıca, hız ve doğruluk dengesinin otonom araçlar, akıllı güvenlik sistemleri ve endüstriyel otomasyon gibi alanlarda önemli bir rol oynadığı vurgulanmaktadır. Sonuç olarak, Faster R-CNN doğruluk açısından güçlü bir yöntem olarak kalırken, YOLOv8 gibi modern tek aşamalı modellerin pratik uygulamalarda giderek daha fazla tercih edildiği belirtilmiştir. Bu birleşik YOLOv8 + Faster R-CNN modeli, %98,2 doğruluk, %100 geri çağırma (recall), %87,0 kesinlik (precision) ve %84,95 ortalama birleşme oranı (IoU) değerlerinde bir performansa ulaşmıştır.

Faster R-CNN'in doğruluğunu artırmak amacıyla bölge öneri ağı kullanımının faydaları (Steketee, 2024) tarafından ele alınmıştır. Ayrıca, transformer yapılarının Faster R-CNN'e entegre edilmesiyle sağlanabilecek avantajlar kullanılarak daha yüksek doğruluğa sahip bir nesne tespit modeli geliştirilmesi hedeflenmiştir. Faster R-CNN'in, bölge öneri ağı sayesinde yüksek doğruluk sunduğu, ancak hız açısından sınırlı kaldığı belirtilmiştir. Tek aşamalı model olarak YOLO ailesi, hız ve gerçek zamanlı uygulamalarda öne çıkarken, doğruluk açısından iki aşamalı yöntemlerle rekabet etmektedir. Transformer modellerinin Faster R-CNN'e entegre edildiği R-ViT, güncel nesne tespit yöntemleriyle karşılaştırılmıştır. Bu karşılaştırmada, kaydırılmış pencereler transformeri (Swin Transformer) ve Özellik piramidi ağı (FPN) birleşimi, ResNet-50 tabanlı varyanta göre daha yüksek performans sağlamıştır. Yöntem, özellikle küçük nesnelerin tespitinde ve çok sayıda nesne içeren görüntülerde başarılı sonuçlar vermiştir. Ancak, ortalama doğruluk açısından mevcut en gelişmiş yöntemlerin gerisinde kalmıştır. Transformer tabanlı özellik çıkarıcılar içinde en iyi sonucu veren model, Faster R-CNN olup 0.47 mAP değerine ulaşmıştır.

Jose Gabriel Rodriguez'in yaptığı çalışma (Rodriguez, 2023), Faster R-CNN ve FPN ile geliştirilmiş Faster R-CNN olmak üzere iki nesne tespit sisteminin evrişimsel sinir ağları tabanlı uygulamalarını göstermiştir. COCO ve PASCAL VOC veri kümeleri kullanılarak üç deney gerçekleştirilmiş; elde edilen sonuçlar mAP metriği üzerinden orijinal yöntemlerle karşılaştırılmıştır. Sonuç olarak, en doğru çalışan modelin tespitine dair örnekler sunulmuştur. FPN tabanlı dedektör, COCO test kümesinde %38,1 mAP@[.5, .95] ve %61,1 mAP@0.5 değerlerine ulaştığı görülmüştür.

Mask R-CNN tabanlı atık tespiti için yapılan çalışmada (Chang ve Wang, 2022), R-CNN algoritmalarının özellikleri tanıtılmakta ve incelenmektedir. Mask R-CNN, piksel

düzeyinde yüksek doğrulukla çok sayıda nesneyi karmaşık kategoriler altında sınıflandırıp konumlandırabilmekte ve bu çalışmada yapılmak istenen görev için uygun bir model sunulmuştur. Eğitimi için, VGG Image Annotator (VIA) aracı kullanılarak COCO formatında 5175 farklı nesne içeren bir veri kümesi oluşturulmuştur. Bu veri kümesi, ReLearn şirketi tarafından sağlanan 2451 farklı atık kutusu görüntüsünden elde edilmiştir. Son veri kümesi, %80 eğitim ve %20 doğrulama olacak şekilde ayrılmıştır. Modeli değerlendirmek için şu göstergeler kullanılmıştır: Kesinlik-Geri Çağırma, tüm kategorilerin Ortalama AP değeri, mAP, toplam kayıp ve dal kaybı. Karşılaştırmalar sonucunda, 28x28 boyutundaki maskeye sahip ağın en iyi performansı gösterdiği sonucuna varılmıştır. Bu modelin mAP değeri %82,85'e ulaşmış ve cam kategorisinde ortalama doğruluk %86,71 olarak kaydedilmiştir.

Ahmed Haj Hassine ve Kevin Hamed'in yaptığı çalışma (Haj Hassine ve Hamed, 2025), COCO 2017 veri kümesi kullanılarak YOLOv11'in beş farklı konfigürasyonu (Nano, Small, Medium, Large, Extra-Large) nesne boyutuna göre karşılaştırılmıştır. Sonuçlar, nesne boyutunun tespiti üzerinde belirleyici bir etkiye sahip olduğunu göstermiştir. Büyük nesnelerde doğruluk oranı %92,8 mAP50'ye kadar çıkarken, nano ölçekli nesnelerde bu oran %2,5 seviyelerine kadar düşmektedir. Orta ölçekli YOLOm modeli, doğruluk, eğitim süresi ve işlem hızını dengeleyen en verimli yapı olarak öne çıkmıştır. Mimari gelişmelere rağmen, elde edilen bulgular, çok küçük nesnelerin tespitinde doğuştan gelen sınırlamaların devam ettiğini ortaya koymuştur. Bu durum, daha ileri araştırmalara olan ihtiyacı vurgulamaktadır. Ayrıca, çalışma sürdürülebilir kalkınma açısından sonuçların önemini tartışmakta ve daha yüksek çözünürlüklü veri setleri ile alana özgü optimizasyonların gelecekte küçük nesne tespiti yeteneklerini artırmak için kullanılabileceğini önermiştir.

2.2. Belirgin Nesne Tespiti

Büyük ölçüde etiketli veri gerektiren geleneksel nesne tespiti yaklaşımlarının ötesine geçilerek, yarı denetimli ve kendi kendini denetleyen öğrenme stratejilerinin gerçek dünyadaki nesne tespiti görevlerinde nasıl kullanılabileceği incelenmiştir. Araştırmacılar, özellikle küçük nesnelerin yer aldığı karmaşık ortamlarda, sınırlı etiketli veriyle yüksek performans elde edebilmek için örnek ayrımı ve maskeli görüntü modellemesi (MIM) gibi stratejiler üzerinde yoğunlaşmışlardır. Uygulamada, farklı kodlayıcı mimariler (Evrişimsel Sinir Ağı – CNN ve Görsel Dönüştürücü – ViT) üzerinde yapılan

karşılaştırmalı deneyler, öz denetimli ön eğitim sürecinin seçiminin; omurga ağ yapısı, veri türü ve nesne boyutu gibi faktörlerle doğrudan ilişkili olduğunu göstermiştir. Bu kapsamda gerçekleştirilen çalışma (Ciocarlan ve diğ., 2024), etiketleme maliyetlerini düşürmenin yanı sıra, özellikle küçük nesne tespiti senaryolarında model verimliliğini anlamlı ölçüde artırabileceğini ortaya koymuştur.

Geleneksel nesne tespit modellerinin eğitildiği sabit sınıf setleriyle sınırlı kaldığı düşüncesinden yola çıkan bu çalışma (Li ve diğ., 2024), açık dünya nesne tespiti kavramını kapsamlı biçimde ele almıştır. Bilinen sınıfların dışında kalan yeni veya etiketlenmemiş nesnelerin tespit edilmesi ve öğrenilmesi üzerine yapılan sistematik analizde; karşılaştırma veri kümeleri, değerlendirme metrikleri ve mevcut yöntemlerin güçlü ve zayıf yönleri ayrıntılı olarak tartışılmıştır. Çalışma bulguları, gerçek hayat senaryolarında gerektiği şekilde değişebilen ve genişleyebilen tespit sistemlerinin hala pek çok teknik ve veri temelli zorlukla karşılaştığını vurgulamıştır.

2.3. Veri Etiketleme

Xinyu Yang tarafından yapılan çalışmada (Nunes, 2025), yarı denetimli öğrenmenin diğer alanlardaki başarısından yola çıkarak, etiketli veri eksikliğinin bulunduğu hayvan analizi alanında yararlı olabileceği savunulmuştur. Mevcut yarı denetimli tespit modelleri, etiketli ve etiketsiz veriyi birlikte kullanırken öğrenme çökmesi sorunu yaşayabilmektedir. Bu sorunu çözmek için tezde politika yönlendirmeli bir yarı denetimli model önerilmiştir. Modeldeki müfredat öğrenme politikaları, öğrenme sürecini kendini güçlendiren bir döngüye yönlendirir ve modelin genel başarımını artırır. Yapılan deneyler, PanAfrica ve Bee veri setlerinde önerilen yöntemlerin, mevcut en iyi yarı denetimli tespit yöntemlerinden daha iyi performans gösterdiğini kanıtlamıştır. Ayrıca, düşük veri senaryolarında MS-COCO ve PASCAL VOC 2007 veri setlerinde de en iyi sonuçlara ulaşılmıştır.

Marco Pedersoli ve arkadaşlarının yaptığı çalışmada (Meethal, 2023), modern derin tespit modellerinin eğitiminde etiketleme sorununu hafifletmek için zayıf denetimli, kendi kendine denetimli, yarı denetimli, alan uyarlamalı ve az örnekli öğrenme gibi çeşitli yönelimler incelenmiştir. Çalışmalarının üçüncü bölümü, mevcut yarı denetimli tespit sistemlerinin yüksek çözünürlüklü hava görüntüleri için uyarlanması üzerinedir. Dronlar ve uydular aracılığıyla elde edilen bu görüntüler, gözetim ve izleme

uygulamalarında bol miktarda bulunmakta ancak etiket eksikliği nedeniyle genellikle eğitimde kullanılmamıştır. Yüksek çözünürlüklü görüntülerdeki küçük nesneler, mevcut yöntemlerde etkili bir şekilde sahte etiketlenemediğinden yarı denetimli eğitim performansı düşmektedir. Bu problemi çözmek için tezde yakınlaştırma yaklaşımına dayalı yoğunluk kırpma yöntemi önerilmiştir. Bu yöntem, küçük nesnelerin yoğun olarak bulunduğu bölgeleri tespit eder, bu bölgeleri kırparak yeniden ölçeklendirir ve dedektör içinde işler. Böylece, daha fazla sahte etiket üretimi sağlanarak küçük nesnelerin tespit başarımı artırılmıştır. Sonuçlar, önerilen yöntemle yarı denetimli hava görüntüsü nesne tespitinde belirgin bir performans artışı elde edildiğini göstermiştir.

Alexandre Ferreira Nunes tarafından yapılan çalışmada (Nunes, 2025), MixMatch, ReMixMatch ve FixMatch gibi görüntü sınıflandırma için geliştirilmiş başarılı SSL algoritmalarının nesne tespiti görevlerine uyarlanabilirliği incelenmiştir. Bu uyarlama sürecinin bir aşaması olarak, Tam konvolüsyonel tek aşamalı nesne algılayıcı (FCOS) modeline Kayıp Maskesi mekanizması eklenmiştir. Bu yenilik, modelin etiketsiz görüntülerdeki belirli bölgeleri eğitim sırasında göz ardı etmesini sağlayarak etiket gürültüsü üzerindeki kontrolü artırmıştır. Yapılan deneysel çalışmalarda YOLOv8, mAP değeri ve saniye başına kare (FPS) performansında önceki sürümler olan YOLOv5 ve YOLOv7'ye göre daha üstün sonuçlar elde etmiştir. Ayrıca model, farklı boyutlardaki (n, s, m, l, x) varyantları sayesinde donanım kısıtlamalarına ve uygulama ihtiyaçlarına göre esnek bir yapı sağlamaktadır. COCO 2017 veri kümesi üzerinde yapılan testlerde, YOLOv8'in küçük nesneleri tanımada daha başarılı olduğu, ancak bazı karmaşık sahnelerde Faster R-CNN gibi iki aşamalı yöntemlerin daha yüksek doğruluk sunduğu gözlemlenmiştir.

Jiayao Chen tarafından ortaya konulan çalışmada (Zhao ve diğ., 2023a), Sınıf farkındalıklı öğrenme yaklaşımı, hem sınıflar arası dengesizliği hem de aynı sınıf içindeki pozitif-negatif örnek dengesizliğini ele almak için bir model geliştirmiştir. Model, sınıf farkındalıklı gömme adı verilen bir yapı kullanarak her sınıf için ayrı özellik temsilleri öğrenmekte ve dağılım dengeli kayıp fonksiyonu ile azınlık sınıflarına daha yüksek ağırlık vererek eğitim sürecini dengeli hale getirmiştir. Ayrıca, veri artırma teknikleriyle küçük sınıflara ait örneklerin çeşitliliği artırılmış ve modelin genelleme kabiliyeti geliştirilmiştir. Deneysel sonuçlar, önerilen yöntemin VOC-LT ve COCO-LT veri setlerinde mevcut yöntemlere göre daha yüksek mAP değerleri elde ettiğini

göstermektedir. Özellikle kuyruk sınıflarda %3,66'ya varan performans artışı sağlanmıştır.

Sajna Salimon tarafından yapılan çalışmada (Salimon, 2023), sınıflandırma ve tespit görevlerini yapılandırılmış, modüler bir derin öğrenme mimarisi içinde birleştiren hibrit bir yaklaşım sunulmuştur. Bir CNN ağı, elma ve üzüm yapraklarını ayırt etmek için, YOLOv11 ise hastalıklı bölgelerin hızlı ve doğru bir şekilde yerini belirlemek ve tespit edilen bölgelerdeki hastalık türlerini ince ayrıntılarıyla sınıflandırmak için kullanılmıştır. Model, doğal koşullarda çekilmiş on farklı herkese açık veri kümesi üzerinde eğitilmiş ve test edilmiştir. Bu veri setleri, farklı ışık, açı ve arka plan koşullarına sahip üzüm ve elma yaprağı görüntülerini içermektedir. YOLOv11 tabanlı tespit aşamasında, Test mAP@0.5 = 0.990 ve yüksek kesinlik (precision) ile duyarlılık (recall) değerleri elde edilmiştir. Buna karşın, son aşamadaki EfficientNet-V2s sınıflandırma modeli yalnızca %49.2 test doğruluğu elde etmiştir. Sistemin modüler yapısı, hastalık bölgelerinin etkili bir şekilde izole edilmesini sağlamış ve YOLOv8 + CNN ile YOLOv5 + ResNet gibi temel modellerden daha iyi performans göstermiştir.

2.4. Hızlı Veri Etiketleme

Durga Divya Reddy (Reddy ve N., 2024), yaptığı çalışmada akıllı etiketleme ve anonimleştirme aracı adında bir yazılım tanıtmıştır. Bu yazılım, PyQt5 kullanılarak geliştirilmiş ve kullanıcıya kolay bir arayüz sunmaktadır. Sistem içinde YOLO algoritması ile otomatik etiketleme, Mask R-CNN tabanlı segmentasyon ve anonimleştirme, yani yüz veya plaka bulanıklaştırma gibi özellikler bir araya getirilmiştir. Akıllı anotasyon özelliği sayesinde kullanıcılar, görüntüleri ya da videoları hem manuel hem de otomatik şekilde etiketleyebilmektedir. Böylece nesne tespiti ve tanıma için gerekli veri kümeleri çok daha kolay hazırlanabilmektedir. Bu özellik, özellikle zaman kazandırmasıyla dikkat çekmiştir. Makalede, aracın görüntülerdeki nesneleri otomatik olarak tanıyıp etiketleme yeteneğine vurgu yapılmıştır. Önceki sistemlerde, bazı web tabanlı yarı otomatik araçlarda etiketleme süreci hızlanmış olsa da, hala insan müdahalesine çok fazla ihtiyaç duyulduğu belirtilmiştir. Akıllı etiketleme ve anonimleştirme aracı, bu eksiklikleri gidermek için otomatik ve yarı otomatik etiketleme modlarını birleştiren hibrit bir yapı önermiştir. Sistem büyük otonom sürüş veri setlerinde test edilmiştir. Otomatik etiketleme aşamasında kullanılan YOLOv3 modeliyle yaklaşık %80 doğruluk oranı elde edilmiştir.

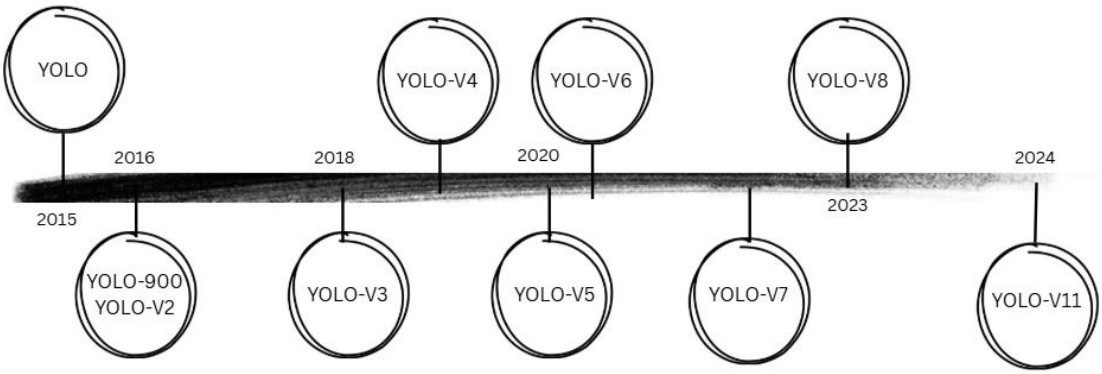
Le ve arkadaşları (Kim ve diğ., 2023) yaptıkları çalışmada etkileşimli kendinden etiketleme adında bir sistem geliştirmiştir. Bu sistem, video verilerinde nesne etiketleme sürecinde insan emeğini azaltmak ve süreci daha verimli hale getirmek için tasarlanmıştır. Yani kısaca, sistem kendi kendine öğrenebilen bir yapıya sahiptir. Etkileşimli kendinden etiketleme iki kısımdan oluşmaktadır: otomatik yinelenen etiketleme ve etkileşimli yinelenen etiketleme. Otomatik yinelenen etiketleme kısmında, önceden eğitilmiş bir model etiketlenmemiş videoları tekrar tekrar izleyip kendi performansını geliştirmiştir. Bu süreçte model, "sahte" yani otomatik olarak üretilmiş etiket kutuları oluşturur. Sonrasında, Etiketleme asistanı adlı modül bu kutuları zamansal olarak kontrol eder ve daha güvenilir etiketler haline getirir. Etkileşimli yinelenen etiketleme sürecinde ise kullanıcı devreye girer. Modelin yanlış yaptığı yerler, insan tarafından düzeltilir ve bu düzeltmeler, modelin kendini yeniden eğitmesi için kullanılır. Ayrıca, hiyerarşik düzeltme adında bir modül, benzer kareleri analiz ederek düzeltme işlemini hızlandırır; yani kullanıcı her kareye tek tek müdahale etmek zorunda kalmaz. Deneylerde, sistemin CityScapes ve DAD veri setlerinde hem doğruluk hem de hız açısından oldukça başarılı olduğu görülmüştür. Etkileşimli kendinden etiketleme, manuel etiketlemeye göre yaklaşık dokuz kat daha hızlı çalışmıştır. Ayrıca, insan müdahalesi oranı da %66,7'den %35,9'a düşmüştür. Ek olarak, önerilen birleşim benzerliği (SIU) metriği, klasik IoU ve AP metriklerine göre daha kapsamlı bir değerlendirme sağlamıştır. Sonuç olarak, çalışma, insan etkileşimiyle otomatik süreçlerin birleştiği bu tür sistemlerin gelecekte video tabanlı nesne tespiti ve otonom sistemlerde veri üretimini çok kolaylaştıracağını göstermiştir.

3. TEZ KAPSAMINDA KULLANILAN YÖNTEMLER

Tez kapsamında kullanılan yöntemler sırasıyla YOLOv8, YOLOv11 ve Faster-RCNN şeklindedir.

3.1. YOLOv8 Mimarisi

Bilgisayarla görü alanında nesne tespitinin zorunlu görevi paradigmatik bir evrim geçirmiştir. Bu metamorfoz, 2016 yılında YOLO çerçevesinin çığır açan tanıtımıyla başlatılmıştır. YOLO'nun öncü metodolojisi, gerçek zamanlı işleme kısıtlamalarına bağlı kalırken sınırlayıcı kutuları ve sınıf olasılıklarını aynı anda tahmin eden, böylece geleneksel iki aşamalı nesne algılama çerçevelerinden ayrılan uyumlu bir mimari ortaya koymuştur. YOLO çerçevesinin önemi sadece tekil mimari paradigmasında değil, aynı zamanda evrimsel ilerlemelerinde de yatmaktadır. Şekil 3.1'de gösterildiği gibi, ilk yinelemesi YOLOV1 ile başlayan ve mevcut YOLOV8 ile devam eden her sürüm, YOLO'ya çeşitli endüstriyel uygulamalarda benzersiz çeviklik ve uyarlanabilirlik kazandıran öncü mimari yeniliklerin bir sentezini ortaya koymuştur.



Şekil 3.1. YOLO sürümlerinin yıllara göre gelişim çizelgesi

YOLO'nun felsefi temelleri, hassasiyet ve işleme hızı arasındaki doğal bir denge ile vurgulanır ve bu da onu hem bilimsel araştırmalar hem de profesyonel endüstri uygulamaları için etkili bir çözüm haline getirir. YOLOV8 (You Only Look Once - versiyon 8), nesne algılama, görüntü sınıflandırma ve görüntü segmentasyonu dahil, ancak bunlarla sınırlı olmamak üzere bir dizi bilgisayar görme uygulaması için özel olarak tasarlanmış, derin öğrenme metodolojilerine dayanan sofistike bir yapay zeka çerçevesini temsil eder. Bu model, 2023 yılında Ultralytics ekibi tarafından resmi olarak

tanıtıldı ve YOLO serisindeki en çağdaş ve gelişmiş yinelemelerden biri olarak durmaktadır. Birincil amacı bir görüntü veya video akışındaki nesneleri gerçek zamanlı olarak tespit etmek ve konumlandırmaktır. Nesnelerin etrafına sınırlayıcı kutu çizmek, hangi sınıf kategorisine ait olduğunu belirtmektir. YOLOV8 çapasız (anchor-free) yapısı, daha iyi kayıp fonksiyonları ve yüksek hız-doğruluk arasında optimum denge ile öne çıkıyor. Bu model, hem bilimsel araştırmalarda hem de endüstriyel uygulamalarda nesne algılama, sınıflandırma ve segmentasyon görevleri için en çok tercih edilen çerçevelerden biri olarak ortaya çıkmıştır (Jocher ve Team, 2025; Ultralytics, 2025).

Tablo 3.1'de Ultralytics'ten alınan bilgilerle düzenlenmiş 2015–2023 yılları arasında YOLO ailesinin evrimini; çapa (anchor) stratejisi, yazılım çatısı ve omurga (backbone) tercihleriyle birlikte raporlanan AP (%) değerleri üzerinden özetlemektedir. İlk dönem çalışmalar Darknet üzerinde ve çoğunlukla çapa tabanlı iken (YOLOv2–v5), 2021'den itibaren çapasız yaklaşımlara (YOLOX, YOLOv8) belirgin bir geçiş gözlenmektedir; bu eğilim etiket ön varsayımlarını sadeleştirip başlık tasarımını basitleştirerek pratik kurulumları hızlandırmaktadır. Çatı düzeyinde Darknet $\rightarrow$ PyTorch/PaddlePaddle göçü, sistemin olgunlaşmasına ve mühendislik araçlarının zenginleşmesine işaret eder. Omurga tarafında Darknet53/CSPDarknet çizgisinden ResNet-vd, EfficientRep, RepConvN ve NAS türevli (MAE-NAS, YOLO-NAS) yapılara doğru bir çeşitlenme vardır; odak giderek hesaplama verimliliği ve genelleme dengesine kaymıştır. Performans açısından tabloda bildirilen sonuçlar, YOLOv7 (56.8 AP) ve Scaled-YOLOv4 (56.0 AP) gibi olgun çapa tabanlı sürümlerin halen güçlü olduğunu; buna karşılık YOLOv8'in (53.9 AP) çapasızsiz tasarımla hız ve doğruluk açısından rekabetçi kaldığını göstermektedir. Bu tablo, modele özgü tasarım kararlarının çapa stratejisi, (omurga ve çerçeve) tespit doğruluğu kadar eğitilebilirlik ve dağıtım maliyeti üzerinde de belirleyici olduğunu ortaya koymaktadır. AP değerlerinin deneysel protokollere (veri kümesi seçimi, çözünürlük ve eğitim metodolojileri gibi) bağlı varyasyona tabi olması dikkat çekicidir; bu nedenle, mutlak karşılaştırmalar yapılırken bu bağlamsal tutarsızlıklar dikkate alınmalıdır.

Tablo 3.1. YOLO sürümlerinin yıllara göre yapı, omurga ve ortalama başarı (AP) değerleri karşılaştırması.

Versiyon	Tarih	Çapa	Yazılım Çerçevesi	Özellik Çıkarıcı	AP(%)
YOLO	2015	NO	Darknet	Darknet24	63.4
YOLOv2	2016	YES	Darknet	Darknet24	63.4
YOLOv3	2018	YES	Darknet	Darknet53	36.2
YOLOv4	2020	YES	Darknet	CSPDarknet53	43.5
YOLOv5	2020	YES	Pytorch	Modified CSP v7	55.8
PP-YOLO	2020	YES	PaddlePaddle	ResNet50-vd	45.9
Scaled-YOLOv4	2021	YES	Pytorch	CSPDarknet	56.0
PP-YOLOv2	2021	YES	PaddlePaddle	ResNet101-vd	50.3
YOLOR	2021	YES	Pytorch	CSPDarknet	55.4
YOLOX	2021	NO	Pytorch	Modified CSP v5	51.2
PP-YOLOE	2022	NO	PaddlePaddle	CSPRepResNet	54.7
YOLOv6	2022	NO	Pytorch	EfficientRep	52.5
YOLOv7	2022	NO	Pytorch	RepConvN	56.8
DAMO-YOLO	2022	NO	Pytorch	MAE-NAS	50.0
YOLOv8	2023	NO	Pytorch	YOLOv8	53.9

Tablo 3.2'de Ultralytics'ten alınan COCO veri kümesi ile eğitilmiş YoloV8 mimarisi, çeşitli boyutlarda sunulmaktadır. Nano (n), küçük (s), orta (m), büyük (l) ve Xlarge (x). Bu çeşitlilik, kullanıcıların donanım imkanlarına ve uygulamanın ihtiyaç duyduğu doğruluk ile işleme hızı arasındaki gerekli dengeye uygun olarak en uygun varyantı seçme yetkisi verir. Her bir varyantın temel farkı, kapsadığı parametrelerin miktarında ve buna karşılık gelen hesaplama yükünde yatmaktadır.

Tablo 3.2. COCO (80 sınıf) veri kümesiyle eğitilmiş YOLOv8 farklı varyant sonuçları.

Model	Boyut (pixel)	mAP@0.5:0.95	Hız (CPU ONNX) (ms)	Hız (A100 TensorRT) (ms)	Değerler (M)
YOLOv8n	640	37.3	80.4	0.99	3.2
YOLOv8s	640	44.9	128.4	1.20	11.2
YOLOv8m	640	50.2	234.7	1.83	25.9
YOLOv8l	640	52.9	375.2	2.39	43.7
YOLOv8x	640	53.9	479.1	3.53	68.2

YOLOv8n (Nano): En küçük ve hızlı varyantı temsil eder. Sınırlı parametre sayısı nedeniyle, gömülü sistemler, IoT cihazları ve mobil uygulamalar dahil olmak üzere sınırlı donanım yeteneklerine sahip ortamlarda tercih edilmektedir. Gerçek zamanlı performansın çok önemli olduğu senaryolarda, doğruluk kaybı göze alınarak kullanılabilir.

YOLOv8s (Small): Nano'ya kıyasla daha yüksek doğruluk sağlar, ancak hala hız oranını korur. Bu teknoloji, kalite güvence süreçlerinde veya endüstriyel sınıf kameraların kullanıldığı gözetim mekanizmaları gibi orta seviye donanımlarda yaygın olarak kullanılmaktadır. Hız ve doğruluk arasında dengeli bir çözüm sunmaktadır.

YOLOv8m (Medium): Bu varyant, genel amaçlı uygulamalar için en uygun seçim olarak kabul edilebilir. Parametre boyutu orta seviyededir ve hem doğruluk hem de hız açısından övgüye değer sonuçlar verir. Bilimsel araştırmalar ve çeşitli alanlarda prototipleme için sıklıkla tercih edilmektedir.

YOLOv8l (Large): Parametre sayısındaki artış sayesinde doğruluk oranıda artar. Bununla birlikte, bu varyant yüksek hesaplama maliyeti gerektirir. Kesin bir tespit oranının çok önemli olduğu tıbbi görüntüleme veya otonom araç sistemlerinde karşılaşılan kapsamlı veri setlerinde uygulama için özellikle uygundur.

YOLOv8x (Xlarge): En büyük varyanttır ve optimum doğruluk performansını elde etmeyi amaçlamaktadır. Hem eğitim hem de çıkarım süreçlerinin uzun süresine rağmen, sağlam GPU altyapılarında uygulandığında üstün sonuçlar verir. Bu varyant özellikle araştırma laboratuvarlarında, büyük teknoloji işletmelerinde ve yüksek hassasiyet gerektiren yapay zeka uygulamalarında tercih edilmektedir.

3.2. YOLOv11 Mimarisi

YOLOv11, bilgisayarlı görü ve nesne tespiti alanında önceki sürümlerine kıyasla önemli yapısal ve işlemsel iyileştirmeler sunan bir model mimarisidir. Model, daha yüksek doğruluk ve zorlu sahnelerde daha hassas tespitler gerçekleştirebilmek amacıyla geliştirilmiş bir omurga ve boyun mimarisi kullanarak özellik çıkarımı kapasitesini önemli ölçüde artırmıştır. Bu sayede, hem küçük hem de karmaşık nesnelerin daha başarılı bir şekilde tespit edilmesine olanak sağlamıştır. YOLOv11, mimari alanda yapılan optimizasyonlar ve yeniden tasarlanan eğitim işlem hatları sayesinde yalnızca doğruluk açısından değil, aynı zamanda hesaplama verimliliği ve hız açısından da önceki modellere göre daha iyi bir performans sergilemektedir. Özellikle, modelin farklı varyantları arasında yer alan YOLOv11m, YOLOv8m sürümüne kıyasla yaklaşık %22 oranında daha az parametre kullanmasına rağmen COCO 2017 veri kümesinde daha yüksek mAP değeri elde etmektedir. Bu durum, YOLOv11'in mimari optimizasyonlar

sayesinde doğruluktan ödün vermeden hafifletilmiş ve verimli bir model haline geldiğini göstermektedir. Ayrıca, YOLOv11 ortamlar arası uyarlanabilirlik açısından da esneklik sunar; uç cihazlardan bulut tabanlı sistemlere, NVIDIA GPU'ları destekleyen yüksek performanslı altyapılara kadar geniş bir yelpazede kolayca dağıtılabilir. Bu yönüyle hem araştırma hem de endüstriyel uygulamalarda maksimum erişilebilirliği sağlar. Bununla birlikte, YOLOv11 yalnızca klasik nesne algılama görevleriyle sınırlı değildir. Model, örnek bölümleme, görüntü sınıflandırma, poz tahmini ve yönlendirilmiş nesne algılama gibi çok çeşitli bilgisayarlı görü görevlerinde etkili bir şekilde kullanılabilecek şekilde tasarlanmıştır. Böylece YOLOv11, hem performans hem de çok yönlülük açısından modern derin öğrenme tabanlı nesne tespit sistemleri arasında yeni bir standart oluşturmaktadır.

Tablo 3.3'de Ultralytics'ten alınan COCO veri kümesi ile eğitilmiş YoloV11 mimarisinin çeşitli boyutlarını göstermektedir.

Tablo 3.3. COCO veri kümesi ile eğitilmiş YOLOv11 farklı varyant sonuçları.

Model	**Boyut (pixel)**	**mAP@0.5:0.95**	**Hız (CPU ONNX) (ms)**	**Hız (A100 TensorRT) (ms)**	**Değerler (M)**
YoloV11n	640	39.5	56.1 ± 0.8	1.5 ± 0.0	2.6
YoloV11s	640	47.0	90.0 ± 1.2	2.5 ± 0.0	9.4
YoloV11m	640	51.5	183.2 ± 2.0	4.7 ± 0.1	20.1
YoloV11l	640	53.4	238.6 ± 1.4	6.2 ± 0.1	25.3
YoloV11x	640	54.7	462.8 ± 6.7	11.3 ± 0.2	56.9

YOLOv11n (Nano): YOLOv11 ailesinin en küçük ve en hızlı sürümüdür. Parametre sayısının az olması sayesinde düşük bellek kullanımıyla çalışabilir ve bu yönüyle gömülü sistemler, mobil cihazlar veya IoT tabanlı uygulamalarda tercih edilmektedir. Gerçek zamanlı işlem gerektiren uygulamalarda, doğruluk oranında bir miktar düşüş olmasına rağmen yüksek hız avantajı sağlamaktadır. Özellikle işlem kapasitesinin sınırlı olduğu sistemlerde, enerji verimliliği ve düşük gecikme süreleri nedeniyle etkili bir seçenek olarak öne çıkmaktadır.

YOLOv11s (Small): Small varyantı, Nano sürümüne göre daha fazla parametreye sahiptir ve bu da doğruluk oranında belirgin bir artış sağlamaktadır. Hız açısından hâlâ verimli olan bu model, orta ölçekli projeler için uygun bir çözüm sunar. Genellikle endüstriyel kalite kontrol sistemlerinde, üretim hatlarında veya gerçek zamanlı gözetim

uygulamalarında kullanılır. Hız ve doğruluk arasında dengeli bir performans sunması, onu çok yönlü bir model haline getirmektedir.

YOLOv11m (Medium): YOLOv11 ailesinin orta seviye varyantı olan Medium modeli, hem hız hem de doğruluk açısından optimum dengeyi sağlayan genel amaçlı bir seçenektir. Bu model, araştırma ve prototipleme çalışmalarında sıkça tercih edilmektedir. COCO 2017 veri kümesi üzerinde yapılan deneylerde, YOLOv11m modelinin, YOLOv8m'e kıyasla %22 daha az parametre kullanmasına rağmen daha yüksek mAP değerine ulaştığı görülmüştür. Bu sonuç, modelin hem hesaplama açısından verimli hem de yüksek doğruluk sağlayan bir yapı sunduğunu göstermektedir.

YOLOv11l (Large): Large varyantı, daha yüksek parametre sayısı sayesinde doğruluk oranını artırırken işlem süresi açısından daha fazla kaynak kullanır. Bu sürüm, büyük ve karmaşık veri setleriyle çalışılan projelerde güçlü bir performans sergilemektedir. Özellikle tıbbi görüntüleme, otonom araç sistemleri, güvenlik gözetimi ve uzaktan algılama gibi doğruluğun ön planda olduğu alanlarda tercih edilmektedir. YOLOv11l modeli, küçük nesnelerin tespitinde geliştirilmiş başarımıyla öne çıkar ve genellikle yüksek donanım gücü gerektiren sistemlerde kullanılır.

YOLOv11x (Xlarge): YOLOv11 ailesinin en büyük ve en yüksek doğruluğa sahip varyantıdır. Derin ağ yapısı ve geniş parametre sayısı sayesinde, karmaşık sahnelerde dahi yüksek doğruluk oranlarına ulaşabilmektedir. Eğitim ve çıkarım süreçleri uzun sürse de, güçlü GPU altyapılarıyla desteklendiğinde üstün performans elde edilir. YOLOv11x genellikle araştırma laboratuvarları, ileri seviye endüstriyel uygulamalar ve yüksek doğruluk gerektiren yapay zeka projelerinde kullanılır. Gerçek zamanlı işlem önceliği olmayan, ancak kesin tespit gerektiren senaryolarda en uygun model olarak değerlendirilir.

3.3. Faster-RCNN Mimarisi

Faster R-CNN (Bölge Tabanlı Evrişimli Sinir Ağı), 2015 yılında Ren ve meslektaşları tarafından geliştirilen derin öğrenme tabanlı bir nesne algılama tekniğidir. Önceki sürümleri olan R-CNN ve Fast R-CNN tarafından sunulan bölge önerisi ve sınıflandırma süreçlerini hızlandırmak için tasarlanmıştır. En dikkat çekici yeniliği, dışsal yöntemlerle yapılan bölge önerisini ortadan kaldırarak, bunun yerine ağa entegre edilmiş bir bölge

öneri ağı kullanmasıdır.

Faster R-CNN, tek aşamalı metodolojiler (YOLO, SSD) kadar yüksek hızlı olmasa da, iki aşamalı mimarisi sayesinde yüksek doğruluk seviyelerine ulaşır. İşleme süresi, kullanılan donanımın özelliklerine ve verilerin çözünürlüğüne bağlı olmasının yanı sıra:

- Ortalama olarak, COCO ve Pascal VOC gibi standart veri kümelerine sahip bir grafik işleme birimi (GPU) kullanıldığında, yaklaşık 5–7 FPS'de çalışmaktadır.
- İşlem süresini belirleyen en önemli aşama, bölge teklifi ağının önerdiği bölgeler üzerinden yapılan konvolüsyonel özellik çıkarımı ve sınıflandırmadır.
- Hesaplama gideri, derin evrişimli mimarilerin (örneğin, ResNet, VGG vb.) uygulanmasıyla artmaktadır. Yüksek performanslı GPUlar' bu tür senaryolarda tercih edilmektedir.

Sonuç olarak, Faster R-CNN gerçek zamanlı uygulamalar için çoğu zaman yavaş kalırken, yüksek performans gerektiren projelerde tercih edilmektedir.

Faster R-CNN mimarisinin ilk aşamasını oluşturan bölge öneri ağı, giriş görüntüsü içindeki olası nesne bölgelerini tespit etmek için kullanılır. Bu işlem sırasında, görüntü ResNet veya VGG16 gibi bir omurga mimarisi aracılığıyla işlenir ve bu mimariden türetilen özellik haritası üzerinde çeşitli işlemler gerçekleştirilir. Daha sonra, özellik haritasındaki her konumda farklı boyutlarda ve en boy oranlarında stratejik olarak konumlandırılan sınırlayıcı kutular oluşturulur. Bu kutular, görsel sahne içindeki potansiyel nesne konumlarını belirtir.

Bölge öneri ağı, oluşturulan her bağlantı kutusunu inceleyerek nesnelerin varlığını tespit eder. Bu sınıflandırma sırasında, önemli derecede örtüşme sergileyen kutular (IoU) pozitif olarak belirlenirken, minimum veya var olmayan örtüşmeye sahip olanlar negatif olarak sınıflandırılır. Ayrıca, RPN yalnızca bir nesnenin varlığını tanımlamakla kalmaz, aynı zamanda kutuların uzamsal konumunu optimize etmek için gerekli ofsetleri tahmin ederek daha hassas bir hizalama sunar.

Bu noktada, eğitim süreci iki temel kayıp fonksiyonu tarafından yönlendirilir. Sınıflandırma kaybı, bir çapanın bir nesneyi mi yoksa bir arka planı mı temsil ettiğinin kesin olarak ayırt edilmesini kolaylaştırır. Tersine regresyon kaybı, bağlantı kutularının gerçek nesnelerle daha doğru bir şekilde hizalanması için gerekli konum ayarlamalarını

elde eder. Sonuç olarak, RPN en olası ve optimize edilmiş bölge önerilerini sonraki aşamalara iletir.

Bölge öneri ağı tarafından oluşturulan bölge önerileri, sonraki aşamada daha fazla özgüllükle incelenir. Bu sınırlayıcı kutuların boyutlarının değişkenlik gösterdiği göz önüne alındığında, sinir ağının operasyonel etkinliğini kolaylaştırmak için bunların sabit boyutlara dönüştürülmesi gerekmektedir. Bu işlev için kullanılan ilgi bölgesi havuzlama olarak bilinen teknik, önerilen her bölgeyi daha küçük segmentlere ayırarak havuzlamayı yürütür ve böylece tüm bölgeleri boyut olarak tek tip hale getirir.

Daha sonra, bu sabit boyutlu bölgeler küçük bir alt ağa iletilir. Burada ağ, her bir bölgeyi analiz ederek hangi sınıfa ait olduğunu (örneğin; kedi, insan vb.) tahmin eder. Bu sınıflandırma prosedürü boyunca, sınıflandırmaların doğru tanımlanmasını garanti etmek için çapraz entropi kaybı kullanılır. Ayrıca, önerilen bölgelerin nesnelerle daha doğru bir şekilde hizalanmasını sağlamak için sınırlayıcı kutuların yeniden konumlandırılmasında bir iyileştirme yapılır. Bu iyileştirme, sınırlayıcı kutuların gerçek nesnelerle uyumluluğunu kolaylaştıran regresyon kaybının uygulanmasıyla gerçekleştirilir.

Şekil 3.3'de de görüldüğü üzere birinci aşamada potansiyel bölge önerisi yapılır. Şeklin detaylı adımlarla açıklamasına aşağıda yer verilmiştir.

Görsel: Şekil 3.3a'da sisteme giriş olarak verilen orijinal görüntü alınır. Görüntü, modelin işleyebileceği sabit boyutlara dönüştürülür ve ön işleme (normalize etme, yeniden boyutlandırma vb.) uygulanır. Bu görüntü, sonraki adımlarda özellik çıkarımı için temel girdiyi oluşturur.

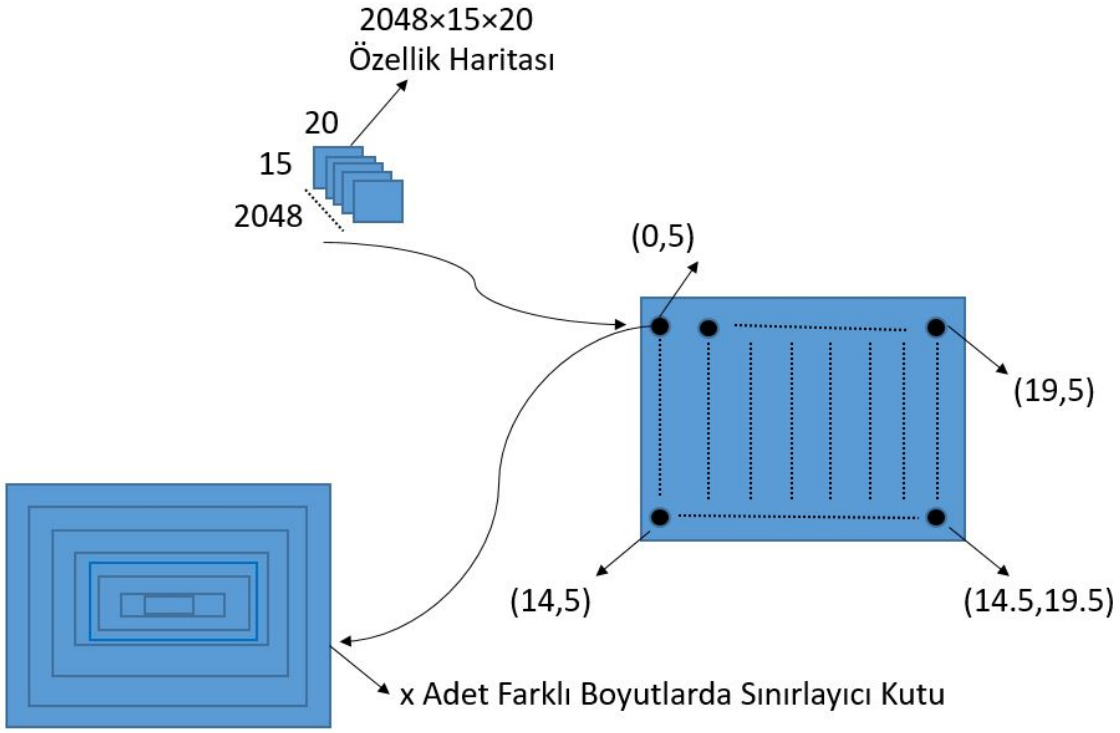
ResNet50: Şekil 3.3b aşamasında, giriş görüntüsü ResNet50 tabanlı bir evrişimli sinir ağı üzerinden geçirilir. ResNet50'nin görevi, görüntüdeki düşük seviyeli (kenarlar, dokular) ve yüksek seviyeli (şekil, nesne yapısı) özellikleri çıkarmaktır. Böylece görüntüdeki anlamlı örüntüler, bir özellik haritasına dönüştürülür.

Özellik Haritası (Feature Map): ResNet50'den çıkan son katman, artık doğrudan pikseller değil, her bir hücresinin belirli bir görüntü bölgesinin özelliklerini temsil ettiği bir özellik haritasıdır. Şekil 3.3c'de oluşturulan bu harita, görüntüdeki nesnelerin nerede olabileceğine dair zengin uzamsal bilgi taşır. Şekil 3.2'de, faster R-CNN mimarisinde özellik haritasının nasıl oluşturulduğu ve bölge öneri sürecinde nasıl kullanıldığı

gösterilmektedir. Girdi görüntüsü, ağın derin katmanlarından geçirilerek farklı çözünürlüklerde temsil edilen çok boyutlu bir özellik haritasına dönüştürülmektedir. Bu harita, Şekil 3.2'de verilen örnekte 2048 × 15 × 20 boyutlarında olup, görüntüdeki uzamsal ve anlamsal bilgiyi özetlemektedir.

Elde edilen özellik haritası üzerinde, ağ belirli konumlarda sabit oran ve ölçeklerde çeşitli sınırlayıcı kutular üretmektedir. Bu kutular, farklı boyutlardaki nesnelerin konumlarını yakalamak amacıyla tanımlanmaktadır. Her bir anchor kutusu, (0, 5) – (19, 5) ve (14, 5) – (14.5, 19.5) gibi koordinat aralıklarında konumlanarak olası nesne bölgelerini tarar. Bu aşamada ağ, hangi bölgelerin nesne içerdiğini tahmin eder ve gereksiz bölgeleri eleyerek işlem yapar.

Şeklin sol kısmında gösterilen iç içe dikdörtgen yapılar, farklı ölçeklerdeki sınırlayıcı kutularının görüntü üzerindeki dağılımını temsil etmektedir. Bu işlem sonucunda ağ, hem küçük hem de büyük nesneleri tespit edebilecek şekilde eğitilmektedir. Kısacası, Faster R-CNN'deki özellik haritası, derin katmanlardan çıkarılan çok düzeyli görsel bilgiyi toplayarak, nesne tespiti için aday bölgelerin belirlenmesini sağlayan temel bileşendir.



Şekil 3.2. Faster R-CNN'de özellik haritası çıkarımı.

Referans Kutuları (Anchor Boxes): Özellik haritasının her hücresinde çeşitli boyut ve oranlarda referans kutuları oluşturulmaktadır. Şekil 3.3d'de örnek gösterimi mevcuttur. Her referans kutusu, görüntüde bir nesnenin bulunabileceği olası bir konumdur. Bu kutular, modelin farklı şekil ve boyutlardaki nesneleri yakalayabilmesini sağlamaktadır.

Çapa (Anchor): Şekil 3.3e adımında bir çapa örneği gösterilmiştir. Referans kutularının bir kısmı, gerçek etiketli nesnelerle yüksek örtüşme oranına sahipse, pozitif çapa olarak işaretlenir. Bu kutular, modelin hangi bölgelerde nesne olduğunu öğrendiği örneklerdir. Diğer düşük örtüşmeli kutular negatif olarak kabul edilir ve arka plan olarak değerlendirilir.

1x1 Kernel: Şekil 3.3f'de özellik haritası üzerinde 1×1 boyutunda konvolüsyon çekirdekleri uygulanmaktadır. Bu çekirdekler, her çapa için iki temel çıktı üretir; bunlar nesne varlığı olasılığı ve sınırlayıcı kutu ofsetleridir. Nesne varlığı olasılığı, kutuda nesne olup olmadığını belirleyen olasılık skorlarıdır (örneğin [0.1, 0.2, ..., 0.9, 0.5]). Sınırlayıcı kutu ofsetleri, çapa kutusunun konum düzeltmeleridir. Bu küçük konvolüsyon işlemi sayesinde faster R-CNN hem sınıflandırma hem de kutu regresyonu görevini aynı anda öğrenebilir.

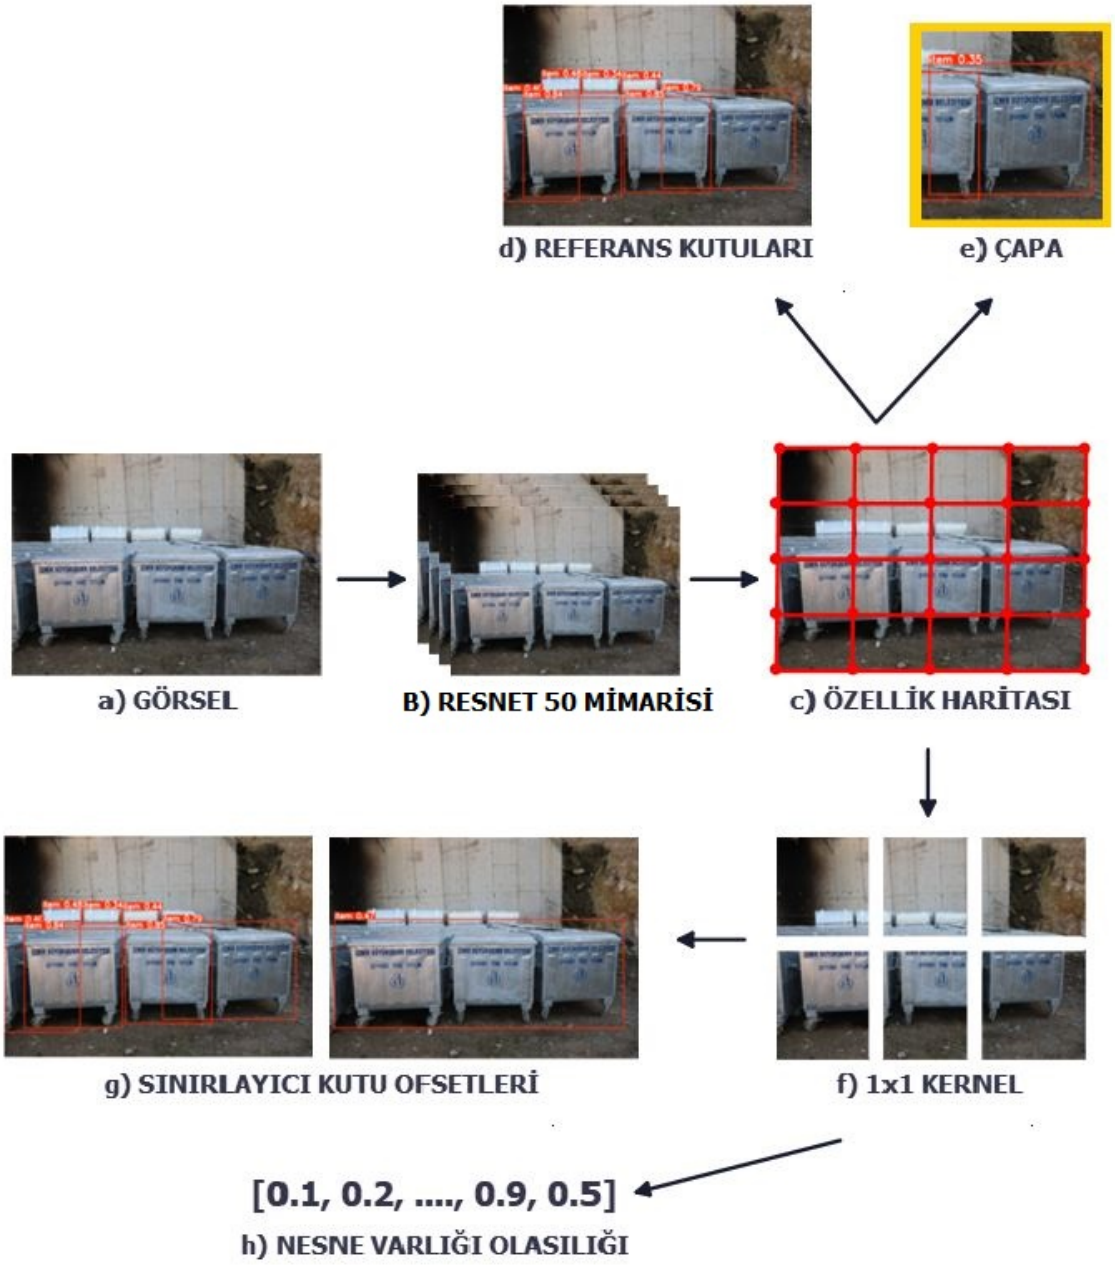
Sınırlayıcı Kutu Ofsetleri: RPN ve ROI, referans kutuları kullanarak tahmin edilen kutuların koordinatlarını daha doğru hale getirmeye çalışır. Her çapa kutu için küçük ofset (sapma) değerleri tahmin edilmektedir ($\Delta x, \Delta y, \Delta w, \Delta h$). Bu ofset'ler, çapa kutularının konumlarını düzeltir ve gerçek nesnenin çevresine daha iyi hizalanmış kutular üretir. Şekil 3.3g'de gösterilmektedir.

Nesne Varlığı Olasılığı: Şekil 3.3h'dan anlaşılacağı üzere, son aşamada her kutu için tahmin edilen skorlar değerlendirilir. Yüksek olasılıklı kutular (örneğin > 0.5) pozitif tespit olarak seçilmektedir. Ardından NMS (Non-Maximum Suppression) algoritması uygulanarak çakışan kutular elenir ve en yüksek skora sahip tespit korunur. Böylece model, yalnızca en güvenilir ve doğru nesne tahminlerini çıktı olarak verir.

Sınıf Puanları: Sınıflandırma ağının çıktısı (Şekil 3.4f), her bölge için tahmin edilen kategori olasılıklarını temsil etmektedir. Örneğin, bir bölge için [0.1, 0.7, 0.2] şeklinde skorlar olabilir; burada en yüksek skor, nesnenin hangi sınıfta olduğunu göstermektedir.

Tam Entropi: Sınıflandırma sonuçlarının doğruluğu, tam entropi kayıp fonksiyonu

(Şekil 3.4g) ile değerlendirilir. Bu kayıp, tahmin edilen sınıf dağılımı ile gerçek etiketler arasındaki farkı ölçer. Modelin doğru sınıfa yüksek olasılık ataması amaçlanmaktadır.



Şekil 3.3. Faster R-CNN'de bölge teklif ağının oluşturulması.

Sonuç: Son aşamada Şekil 3.4'deki L2 kaybı (W2) ve tam entropi kaybı (W1) birlikte toplanır. Bu iki kayıp, farklı ağırlıklar (W1, W2) altında birleştirilerek toplam kayıp fonksiyonu oluşturulur. Bu aşama, çok görevli öğrenme (multi-task learning) ilkeleri üzerine kuruludur. Ağ, aynı anda hem nesne kategorilerini tahmin eder hem de sınırlayıcı kutuların yerelleştirilmesini iyileştirir. Bu uyumlu metodoloji, Faster

R-CNN'nin üstün doğruluk elde etmesini sağlamada çok önemlidir.

Şekil 3.4'de yer alan ikinci aşamada, önerilen bölgelerin nesne sınıfını tahmin etmek için kullanılır ve sınırlayıcı kutu, nesneyle daha iyi eşleşecek şekilde iyileştirilir.

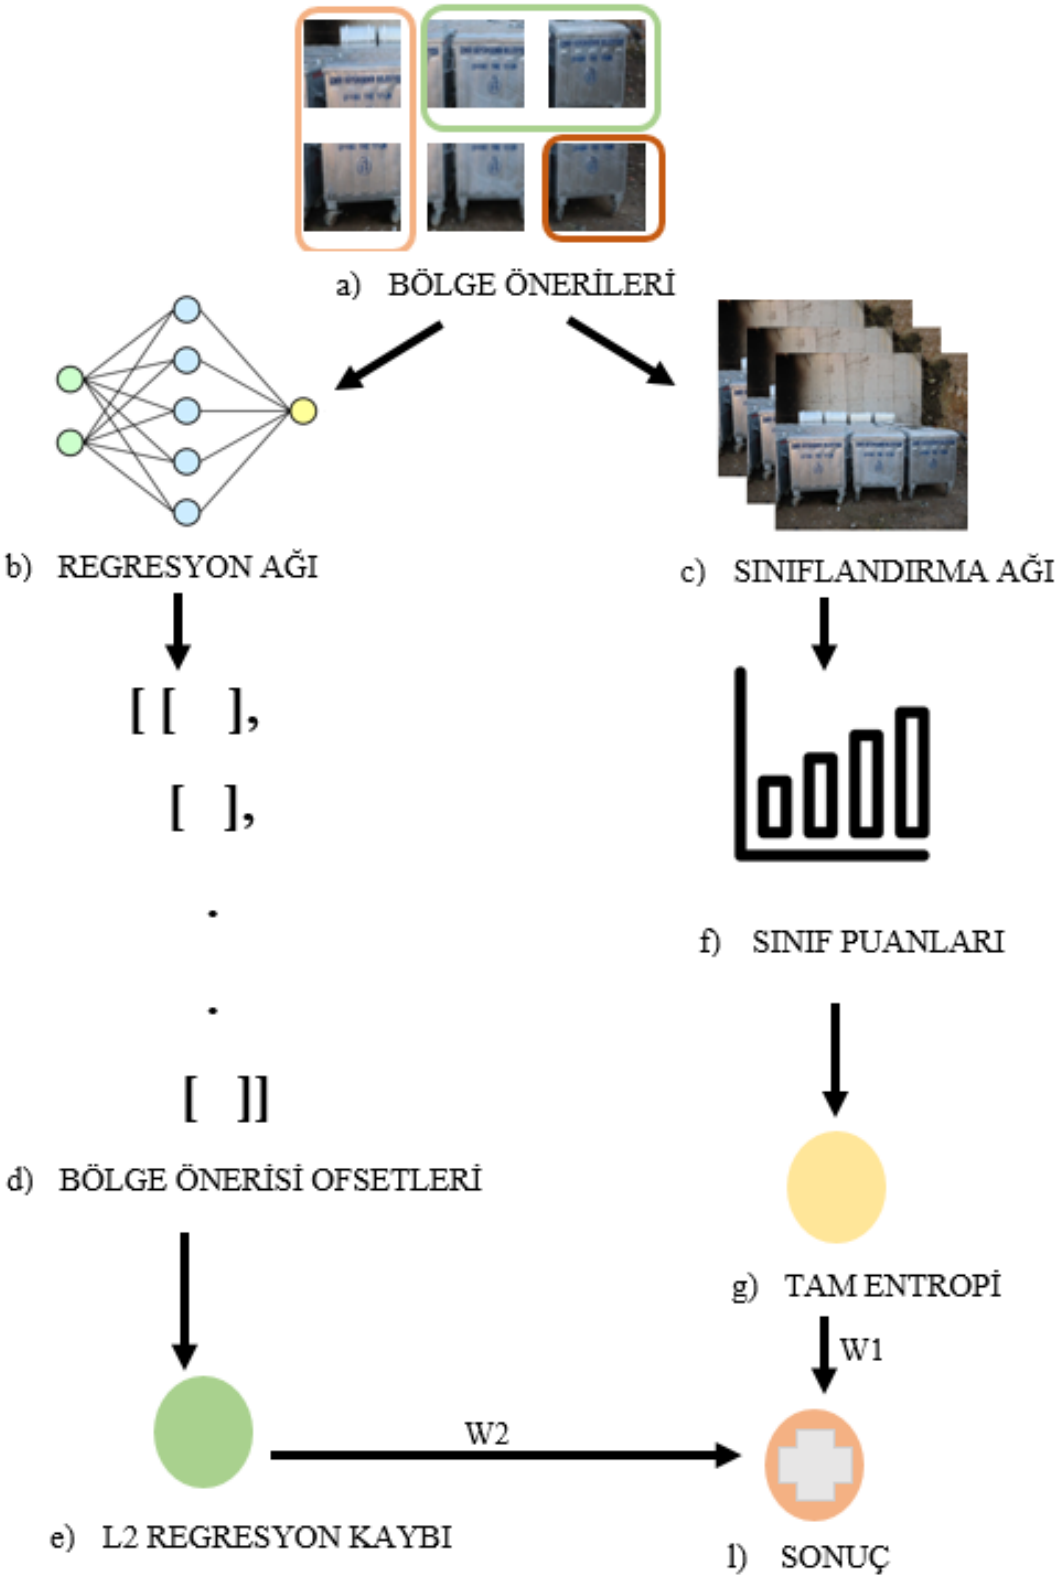
Bölge Önerileri: Şekil 3.4a'da, bölge önerileri tarafından üretilen ve nesne içerme olasılığı yüksek olan dikdörtgen bölgeler seçilmiştir. Bu önerilen bölgeler, önceki özellik haritasından çıkarılmış ve potansiyel nesne bölgelerini temsil eden aday kutulardır. Model bu bölgeler üzerinde hem sınıflandırma hem de konum güncellemesi yapacaktır.

Regresyon Ağı: Şekil 3.4b'de seçilen her bölge regresyon ağına aktarılır. Bu ağ, çapa veya öneri kutularının konumunu (x, y, genişlik, yükseklik) daha doğru hale getirmek için konum düzeltmeleri üretir. Yani, her bölge önerisi için model, gerçek nesne kutusuna yaklaşacak şekilde bir dönüşüm öğrenir.

Sınıflandırma Ağı: Aynı bölge önerileri, paralel bir yoldan Şekil 3.4c'deki sınıflandırma ağına gönderilir. Bu ağ, her önerilen bölgenin hangi sınıfa ait olduğunu (örneğin insan, araç, kutu vb.) veya arka plan olup olmadığını tahmin eder. Böylece model yalnızca nesnenin nerede olduğunu değil, ne olduğunu da belirler.

Bölge Önerisi Ofsetleri: Regresyon ağından çıkan sonuç, Şekil 3.4d'deki her önerilen kutunun konumundaki ofset değerlerini içermektedir. Bu değerler, öneri kutularının koordinatlarını daha hassas hale getirir. Bu sayede, modelin tespit ettiği kutular gerçek nesnelerin çevresine daha iyi hizalanır.

L2 Regresyon Kaybı: Şekil 3.4'deki regresyon ağı tarafından tahmin edilen koordinatlarla gerçek koordinatlar arasındaki fark, L2 kaybı (Ortalama Kare Hatası) fonksiyonu ile ölçülmektedir. Bu kayıp fonksiyonu, modelin konum tahmin hatasını minimize etmesini sağlamaktadır.



Şekil 3.4. Faster R-CNN'de nesne sınıflandırılması ve kutu iyileştirme.

3.4. Omurga (Backbone) Mimarisi

Omurga mimarisi, özellikle bilgisayarla görme alanında derin öğrenme mimarisinin önemli bir unsurunu oluşturur. Birincil özellik çıkarma ağı olarak hizmet eder. Temel işlevi, bir görüntü ile örneklenen işlenmemiş giriş verilerini almayı ve onu nesne algılama, görüntü segmentasyonu veya sınıflandırma gibi çeşitli alt görevlerde kullanılabilecek bir dizi yükseltilmiş öznitelik veya özellik haritalarına dönüştürmeyi içerir. Omurga, bir görüntü içinde bulunan kenarlar, dokular, şekiller ve nesneler dahil olmak üzere temel kalıpları algılama ve anlama yeteneğini kazanan sinir ağının ayrılmaz bir bileşeni olarak kavramsallaştırılabilir.

Omurga, tipik olarak ImageNet gibi kapsamlı bir görüntü sınıfıdır. Belirli bir transfer öğrenimi kategorisini temsil eden bu başlatma prosedürü, ağı geniş bir dizi temel görsel niteliği tanımlama yeteneğiyle donatmaktadır. Yeni bir görev için uyarlanmış bir modelin geliştirilmesinde, uygulayıcılar eğitim sürecini sıfırdan başlatmak yerine sıklıkla bu önceden eğitilmiş omurgayı tercih ederler. Bu metodoloji, eğitim süresini ve gerekli etiketli veri miktarını önemli ölçüde azaltır ve aynı zamanda modelin genel performansını artırır.

Omurgadan türetilen özellikler daha sonra mimarinin boynu ve başına iletilir; bu da ek işlemeyle sonuçlanır ve nihai çıktıyı oluşturur. Uygun bir boyun seçimi, genellikle gerçek zamanlı operasyonel etkinliğin elde edilmesi için gerekli olan doğruluk, model boyutsallığı ve çıkarımdaki gecikme arasında bir denge gerektirir.

Omurga yapısal tasarımı yıllar boyunca önemli bir evrim geçirmiştir ve birbirini izleyen her mimari yenilik, hem verimlilikte hem de performansta iyileştirmeler sağlamıştır. Birçok etkili omurga yapılarından biri olan ResNet-50'yi kendi çalışmamızda kullandık.

3.4.1. RESNET50 MİMARİSİ (Residual Network)

ResNet, derin evrişimli sinir ağlarında katman sayısının artmasıyla birlikte ortaya çıkan bozulma problemini çözmek üzere tasarlanmış, artık öğrenme fikrine dayalı bir mimaridir. ResNet-50, derin öğrenme tabanlı görsel tanıma sistemlerinde sıklıkla kullanılan, 50 katmandan oluşan bir artık öğrenme mimarisidir. Bu yapı, derin ağlarda katman sayısının artmasıyla ortaya çıkan bozulma ve gradyan sönümlenmesi problemlerini ortadan kaldırmak amacıyla geliştirilmiştir.

Modelin temelinde, her biri birkaç evrişim, normalizasyon ve aktivasyon işleminden oluşan artık bloklar yer alır. Her blokta giriş tensörü x, belirli işlemlerden geçirilerek F(x) fonksiyonuna dönüştürülür ve ardından atlama bağlantısı adı verilen kısa bir yol üzerinden doğrudan çıkışa eklenir. Böylece, katman çıkışı Denklem 3.1'deki gibi ifade edilir.

$$y = F(x) + x \tag{3.1}$$

Bu yapı sayesinde model, doğrudan çıktı değerini değil, yalnızca giriş ile çıktı arasındaki farkı, yani artık kısmı öğrenir. Böylece öğrenme süreci hem daha kararlı hale gelir hem de ağın derinliği arttığında bile performans kaybı yaşanmaz.

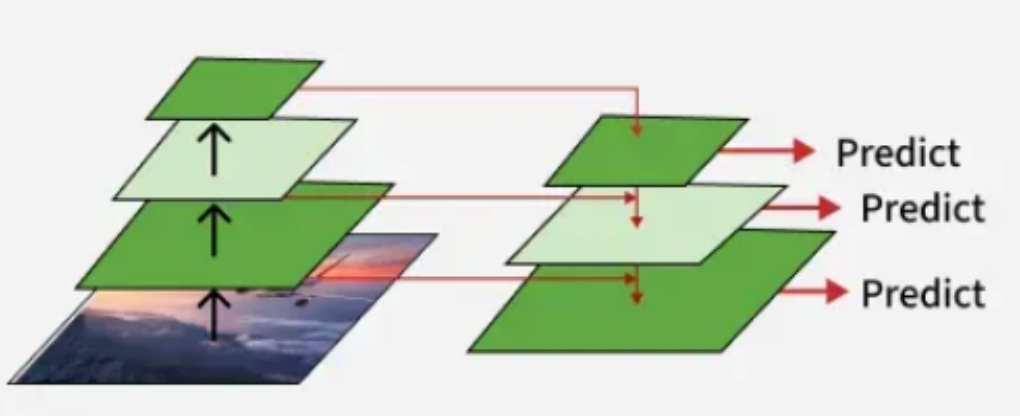
Bu tezde ResNet-50'nin tercih edilmesinin başlıca nedeni, doğruluk ile hesaplama verimliliği arasında sağladığı optimum dengedir. Daha derin mimariler (ResNet-101, ResNet-152) daha yüksek ayırt etme gücü sunsa da, eğitim süresi ve bellek gereksinimleri oldukça fazladır. ResNet-50 ise orta ölçekli veri kümelerinde yüksek performans gösterirken, aynı zamanda hızlı eğitilebilmesiyle öne çıkar.

Ayrıca, önceden eğitilmiş ResNet-50 modellerinin kolayca transfer edilebilmesi, sınırlı veriyle çalışan projelerde önemli bir avantaj sağlar. Bu durum, özellikle yarı otomatik veri etiketleme süreçlerinde modelin ön-etiketleme yaparak insan müdahalesini azaltmasına olanak tanır.

3.4.2. Özellik Piramit Ağı (Feature Pyramid Network)

Özellik piramidi ağı, evrişimli omurgalarla birlikte (ResNet gibi), çeşitli çözünürlük katmanlarında çok ölçekli ve anlamsal olarak zenginleştirilmiş temsillerin oluşturulmasını kolaylaştıran birleştirme mimarisini temsil eder.

Şekil 3.5'de özellik piramidi ağı bağlantı yapısı gösterilmektedir. Geleneksel görüntü piramidi metodolojisiyle ilişkili hesaplama karmaşıklıklarına katlanmak yerine, özellik piramit ağı yatay bağlantıların eşlik ettiği yukarıdan aşağıya bir yol uygular. Üst katmanlardaki (düşük çözünürlüklü, semantik bakımdan güçlü) özellikler, bir üst örnekleme işlemiyle alt katmanlardaki (yüksek çözünürlüklü, ayrıntı bakımından zengin) özelliklerle birleştirilir. Ardından, 1×1 evrişimlerle kanal uyumu sağlanır ve 3×3 evrişimlerle birleşim pürüzsüzleştirilir.



Şekil 3.5. Özellik Piramit Ağı (Lin ve diğ., 2017).

Sonuç olarak, P_2 ila P_5 (ve gerekirse P_6 ila P_7) gibi ölçeklenmiş özellik haritaları elde edilir. Her seviye, alıcı alanı o ölçekteki nesnelere uygun olacak biçimde tespit başlığına beslenir. Bu mekanizma, Faster/Mask R-CNN ve RetinaNet dahil olmak üzere hem iki aşamalı hem de tek aşamalı dedektörlerde "tak ve çalıştır" bir bileşen olarak yaygın biçimde kullanılmaktadır. Özellikle küçük nesneler için hassasiyeti artırırken, genel hesaplama maliyetinin yönetilebilir kalmasını sağlar (Lin ve diğ., 2017).

Bu tez kapsamında, özellik piramit ağlarının önemi; konumsal ve kategorik tahminlerle ilgili çapraz ölçekli tutarlı ipuçlarının sağlanmasına, dolayısıyla etiketleme kalitesi üzerindeki dolaylı etkisine dayanmaktadır. Yüksek çözünürlüklerde anlamsal olarak zenginleştirilmiş haritalar, kompakt ve yoğun sahnelerde sınırlayıcı kutu ve maske oluşturmanın hassasiyetini artırır. Böylece, ön etiketleme veya yarı otomatik açıklama süreçleriyle ilişkili insan düzeltme yükünü hafifletme kapasitesine sahiptir.

4. BİLGİSAYAR GÖRÜ ALANINDA VERİ ETİKETLEME

Bu bölümde veri etiketleme ve hızlı veri etiketlemeden bahsedilmektedir.

4.1. Veri Etiketleme

Veri etiketleme, bilgisayarlı görü alanında makine öğrenmesi ve derin öğrenme modellerinin eğitilebilmesi için görsel veriler (görüntüler veya videolar) üzerinde bilgi işaretleme sürecidir. Bu süreçte her bir görüntüye, modele öğretilecek şekilde belirli nesnelerin sınıfı, konumu ve şekli gibi bilgiler eklenir. Etiketleme işlemi, görsel veriye anlam kazandırarak modelin denetimli öğrenme çerçevesinde doğru çıktılar üretmesini sağlar.

Bilgisayarla görme alanında, sınırlayıcı kutu, çokgen, nokta, elips, küboid, iskelet ve anlamsal segmentasyon gibi çeşitli anotasyon türleri yaygın olarak kullanılmaktadır. Bu anotasyon türlerinin her biri, belirli görev ve doğruluk gereksinimlerini karşılamak üzere tasarlanmıştır. Sınırlayıcı kutu anotasyonu, bir nesnenin konumunu göstermek amacıyla onu dikdörtgen bir kutu içine almayı içerir. Basitliği ve verimliliği nedeniyle genellikle nesne tespiti görevlerinde tercih edilir. Çokgen anotasyonu, nesnenin çevresine çoklu noktalar yerleştirilerek daha hassas bir dış hat çizilmesini sağlar. Nokta anotasyonu, yüz hatları gibi nesneler üzerindeki belirli kilit noktaların işaretlenmesini içerir. Elips anotasyonu, oval şekilli nesneleri yaklaşık olarak tanımlamak için eliptik bir form kullanır. Küboid anotasyon, nesneleri derinlik, yükseklik ve genişlik bilgilerini içerecek şekilde 3D sınırlayıcı kutularla çevreler. İskelet anotasyonu, eklemleri temsil etmek için poz tahmini görevlerinde kullanılır. Anlamsal segmentasyon ise piksel düzeyinde anotasyon yapılarak nesnelerin her bir pikselinin etiketlenmesini sağlar.

Farklı görevlerde yaygın olarak kullanılmalarına rağmen, bu anotasyon yöntemlerinin bazı zorlukları bulunmaktadır. Özellikle büyük ölçekli veri kümeleriyle çalışırken, manuel anotasyon genellikle emek yoğun ve zaman alıcı bir süreçtir. Çokgen veya küboid anotasyonu gibi bazı yöntemler, çok sayıda noktanın hassas bir şekilde konumlandırılmasını gerektirir. Ayrıca, piksel düzeyindeki anotasyonlar önemli ölçüde zaman ve çaba gerektirir. Bu zorluklar, daha hızlı ve daha verimli anotasyon süreçlerinin önemini açıkça ortaya koymaktadır.

4.2. Hızlı Veri Etiketleme

Hızlı veri anotasyonu, görsel verileri mümkün olan en kısa sürede ve minimum insan çabasıyla etiketleyerek bilgisayarla görme modellerinin eğitim sürecini hızlandırmayı amaçlar. Derin öğrenme için hızlı anotasyon oldukça önemlidir çünkü modellerin etkili bir şekilde çalışabilmesi için büyük ve doğru etiketlenmiş veri kümelerine ihtiyaç vardır. Anotasyon sürecini hızlandırmak amacıyla yarı denetimli etiketleme, aktif öğrenme stratejileri ve kullanıcı dostu arayüzlere sahip anotasyon araçları gibi çeşitli yöntemler geliştirilmiştir. Bu yaklaşımlar kaliteyi düşürmeden daha hızlı anotasyon yapılmasına olanak tanır ve özellikle zaman kısıtlaması olan durumlarda oldukça faydalıdır.

5. ÖNERİLEN METEDOLOJİ

Bu bölümde, görsel veri açıklama sürecinde belirgin nesne tespitine dayalı sınıftan bağımsız nesne tespiti yapılmasını sağlayan derin öğrenme tabanlı bir yöntem önerilmektedir. Çalışmanın temel amacı, geleneksel olarak sınıf etiketlerine bağımlı şekilde çalışan belirgin nesne tespiti modellerinin sınırlı genelleme kabiliyetlerini aşmak ve modelin önceden tanımlanmamış nesneleri de açıklayabilmesini sağlamaktır. Bu kapsamda, önerilen metodoloji iki farklı sınıftan bağımsız yaklaşım üzerine inşa edilmiştir. Bu yaklaşımla ilerlemenin temel nedeni sadece nesne tespiti yapmamaktır.

İlk yapı, bölge tabanlı bir yöntem olan Faster R-CNN mimarisine dayanmaktadır. Bu modelde, sınıf tahmin katmanı kaldırılarak yalnızca bölge öneri ağı ve konum bilgisi üzerinden genel nesne tespiti yapılmıştır. İkinci yapı ise, tek aşamalı bir tespit mimarisi olan YOLOv8 ve YOLOv11 modellerinin farklı varyantları kullanılarak sınıftan bağımsız biçimde yeniden yapılandırılmasıyla elde edilmiştir. Bu modelde sınıf etiketleri yerine nesnenin geometrik ve yapısal özellikleri dikkate alınarak konum tabanlı açıklama üretilmiştir.

Bu iki yaklaşımın uygulanmasında modeller, COCO veri kümesi üzerinde önceden eğitilmiş ağırlıklarla başlatılmıştır. Her iki yaklaşım, görsel içeriğin anlamlandırılmasında insan yorumuna benzer bir çıkarım süreci oluşturmayı hedeflemektedir. Eğitim sürecinde COCO (80 sınıf) veri kümesi kullanılmış, ancak sınıf etiketleri eğitim sırasında devre dışı bırakılarak modelin yalnızca nesne bölgelerini öğrenmesi sağlanmıştır. Modeller Google Colab ortamında, A100 GPU üzerinde 100 epoch boyunca eğitilmiştir.

Elde edilen sonuçlar, önerilen sınıftan bağımsız yapıların hem bilinen hem de daha önce görülmemiş nesnelerde başarılı tespit ve açıklama üretebildiğini göstermektedir. Ayrıca, bu yaklaşımlar literatürde yaygın olarak kullanılan sınıfa bağımlı YOLOv8, YOLOv11 ve Faster R-CNN modelleri ile karşılaştırılmış; açıklayıcılık, hız ve genelleme performansı açısından anlamlı farklar ortaya koymuştur.

Sonuç olarak, önerilen metodoloji derin öğrenme tabanlı nesne tespiti alanında, önceden tanımlı sınıf etiketlerine bağlı kalmadan görsel anlamlandırma yapılabileceğini göstermekte ve bu yönüyle geleneksel sınıfa bağlı yaklaşımlara alternatif bir çözüm

sunmaktadır.

5.1. Sınıfa Bağımlı Derin Öğrenme Temelli Nesne Tespiti İle Veri Etiketleme

Bu sistemler, görüntü içerisindeki nesnelerin hem sınıflandırma hem de konumlandırma işlemlerini eş zamanlı olarak gerçekleştiren çok katmanlı yapay sinir ağı modelleridir. Günümüzde bu amaçla en sık kullanılan mimariler arasında YOLO, Faster R-CNN ve SSD yer almaktadır. Bu modeller, farklı işlem hızları ve doğruluk düzeyleriyle gerçek zamanlı nesne tespiti alanında önemli başarılar elde etmiştir. Özellikle YOLO serisi, tek aşamalı tespit yaklaşımıyla yüksek hız sağlamaktadır. Faster R-CNN mimarisi, iki aşamalı bölge öneri mekanizması sayesinde daha yüksek doğruluk oranlarına ulaşmaktadır.

Bu çalışmada, sınıfa bağlı nesne tespiti kapsamında önceden eğitilmiş Faster R-CNN, YOLOv8 ve YOLOv11 modellerinin performansları ayrıntılı biçimde değerlendirilmiştir. Her üç model de sahne içerisindeki nesneleri tanımlama ve konumlandırma kabiliyetleri açısından karşılaştırılmıştır. Değerlendirme sürecinde, modellerin COCO veri kümesi üzerindeki başarımı ölçülmüş, ardından daha önce görülmemiş bir özel veri kümesi üzerinde test edilerek genelleme yetenekleri analiz edilmiştir. Böylece, üç mimarinin bilinen sınıflarda ve yeni nesne türlerinde gösterdiği tespit başarısı mAP ölçütleriyle karşılaştırılmıştır.

Elde edilen bulgular, bu modellerin yalnızca sınıf temelli nesne tanıma görevlerinde değil, aynı zamanda görsel açıklama sürecini doğrudan destekleyebilecek şekilde kullanılabileceğini göstermektedir. Özellikle Faster R-CNN'in bölge bazlı yapısı, açıklama üretiminde konum duyarlılığını artırırken; YOLOv8'in yüksek hızda çıkarım yapabilme yeteneği, gerçek zamanlı açıklama sistemleri için avantaj sağlamaktadır. Bu nedenle, her iki mimari de açıklama odaklı yapay zeka sistemlerinde tamamlayıcı roller üstlenebilecek potansiyele sahiptir.

5.2. Sınıftan Bağımsız Derin Öğrenme Temelli Nesne Tespiti İle Veri Etiketleme

Sınıftan bağımsız nesne tespiti, görüntü içerisindeki nesnelerin konumlarının belirlenmesine odaklanan ve bu nesnelerin hangi kategoriye ait olduğunu dikkate almayan bir yaklaşımdır. Bu yöntem, görsel sahnede yer alan her nesneyi genel bir nesne varlığı olarak değerlendirir ve sınıf etiketlerinden bağımsız biçimde konum tahmini yapar. Böylece, sınıf bilgisinin gerekli olmadığı veya mevcut etiketlerin yetersiz olduğu

durumlarda bile etkili bir tespit gerçekleştirilebilir. Özellikle etiketlenmemiş veya yeni oluşturulan veri kümeleriyle çalışırken, bu yaklaşım ön açıklama üretim sürecini büyük ölçüde hızlandırmakta ve veri etiketleme maliyetini azaltmaktadır.

Bu çalışmada, sınıftan bağımsız tespit uygulaması için COCO veri kümesi üzerinde önceden eğitilmiş YOLOv8, YOLOv11 ve Faster-RCNN modelleri temel alınmıştır. Orijinal COCO yapılandırması 80 farklı nesne kategorisinden oluşmasına rağmen, bu çalışmada tüm sınıf bilgileri devre dışı bırakılmıştır. Model, tespit ettiği tüm nesneleri tek ve genel bir sınıfa aitmiş gibi değerlendirmekte; böylece yalnızca nesnelerin sınırlayıcı kutularını konum bilgisi olarak çıktı vermektedir. Bu sayede model, belirli bir sınıf etiketine bağlı kalmaksızın sahne içindeki nesne bölgelerini belirleyebilmektedir.

Bu strateji, açıklama sürecini basitleştirerek veri etiketleme yükünü önemli ölçüde azaltır ve insan müdahalesine daha az ihtiyaç duyan bir ön açıklama altyapısı oluşturur. Tespit edilen konum bilgileri, daha sonraki aşamalarda insan denetimiyle veya yarı otomatik sistemler aracılığıyla doğru sınıf etiketleriyle eşleştirilebilir. Bu yaklaşım, özellikle büyük ölçekli veri kümeleri, daha önce görülmemiş nesne türleri veya hızlı prototipleme gerektiren uygulamalarda zaman tasarrufu sağlaması bakımından oldukça avantajlıdır. Ayrıca, bu yöntemin kullanılması, gelecekteki sınıflandırma modelleri için daha esnek ve genellenebilir bir ön işleme aşaması oluşturur.

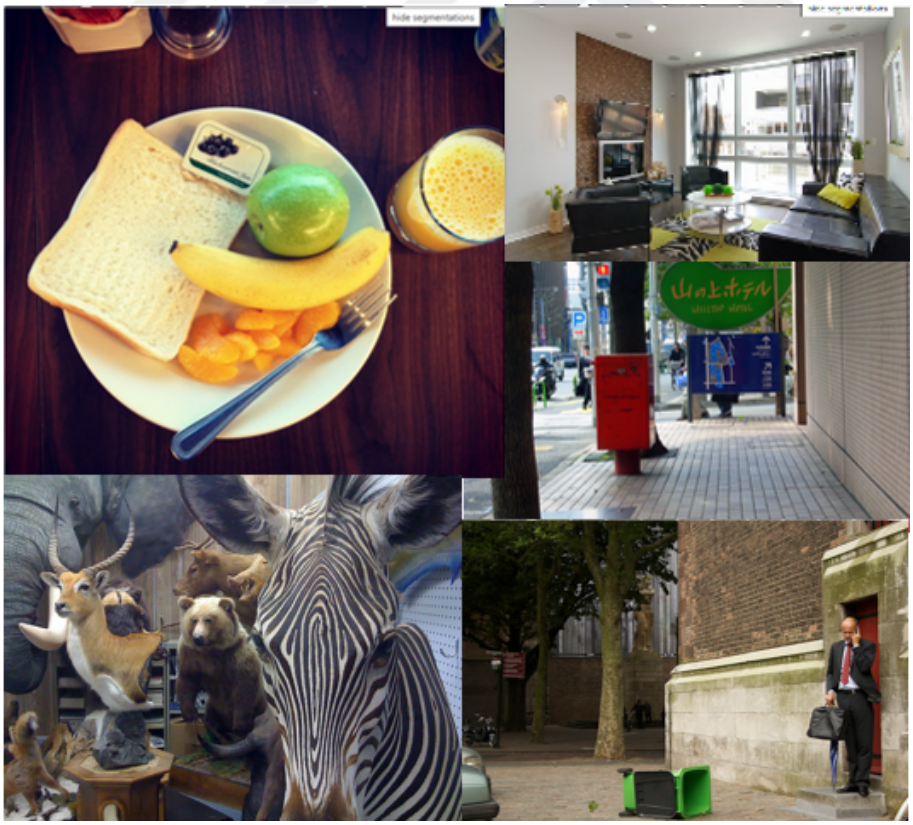
6. VERİ KÜMESİ VE MODEL YAPILANDIRMA PARAMETRELERİ

Bu bölümde veri kümesi ve model yapılandırma maddelerinden detaylı bir şekilde bahsedilmiştir.

6.1. Veri Kümesi

Bu çalışmada, hızlı görüntü açıklama yöntemlerini değerlendirmek amacıyla yaygın olarak kullanılan COCO 2017 veri kümesi kullanılmıştır. COCO, çeşitli nesne tespiti ve segmentasyon görevlerinde derin öğrenme modellerinin eğitimi ve test edilmesi için tasarlanmış, yüksek çözünürlüklü görüntülerden oluşan kapsamlı bir koleksiyondur. 2017 sürümü; 118.287 eğitim görüntüsü, 5.000 doğrulama görüntüsü ve 40.670 test görüntüsünden oluşmaktadır.

Doğal ve karmaşık sahneleri içermesi nedeniyle COCO, hızlı açıklama sistemlerinin gerçek dünya koşullarındaki uygulanabilirliğini değerlendirmek için ideal bir ortam sağlamaktadır. COCO veri kümesine ait örnek resimler Şekil 6.1'de verilmiştir.



Şekil 6.1. COCO 2017 veri setinden alınan örnek görseller.

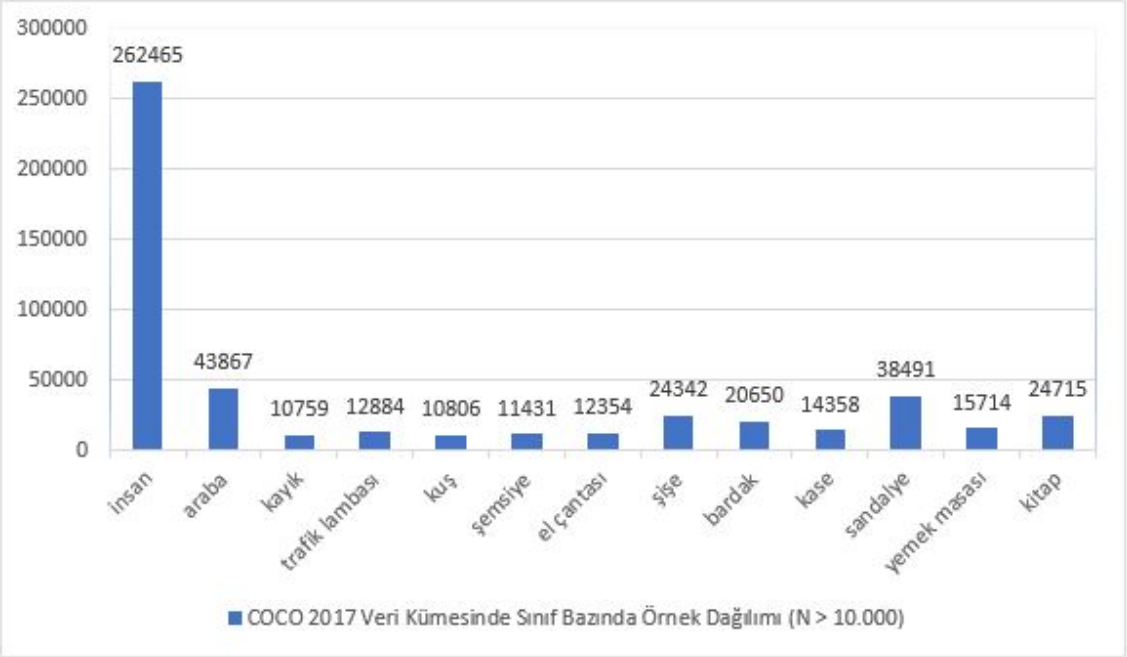
6.2. COCO Veri Kümesindeki Sınıf Dağılımı

COCO veri kümesi, toplam 80 farklı nesne kategorisini içermekle birlikte, bu sınıflar veri kümesi genelinde eşit olarak dağılmamıştır. Bazı kategoriler (örneğin insan, araba, sandalye) binlerce örnekle temsil edilirken, bazı nadir sınıflar (örneğin saç kurutma makinesi, tost makinesi) oldukça az sayıda örneğe sahiptir.

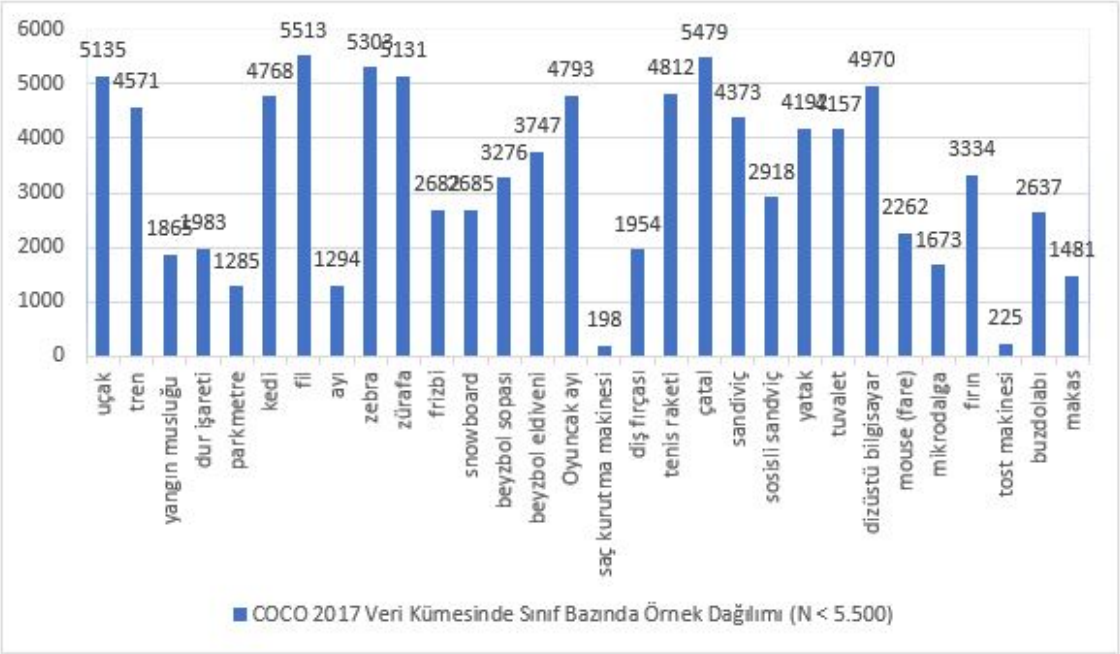
Şekil 6.2, Şekil 6.3 ve Şekil 6.4'te sınıflar arasındaki dağılım dengesizliği daha anlaşılabilir bir yapıda gösterilmiştir. Bu dengesiz sınıf dağılımı, modellerin eğitim sürecinde belirli sınıflara aşırı uyum göstermesine veya nadir sınıfların düşük tespit doğruluğuna neden olabilmektedir.

Bu nedenle, çalışmada kullanılan sınıftan bağımsız tespit yaklaşımı, bu dengesizliği ortadan kaldırarak nesnelerin yalnızca konumlarına odaklanmakta ve modelin genelleme kabiliyetini artırmaktadır.

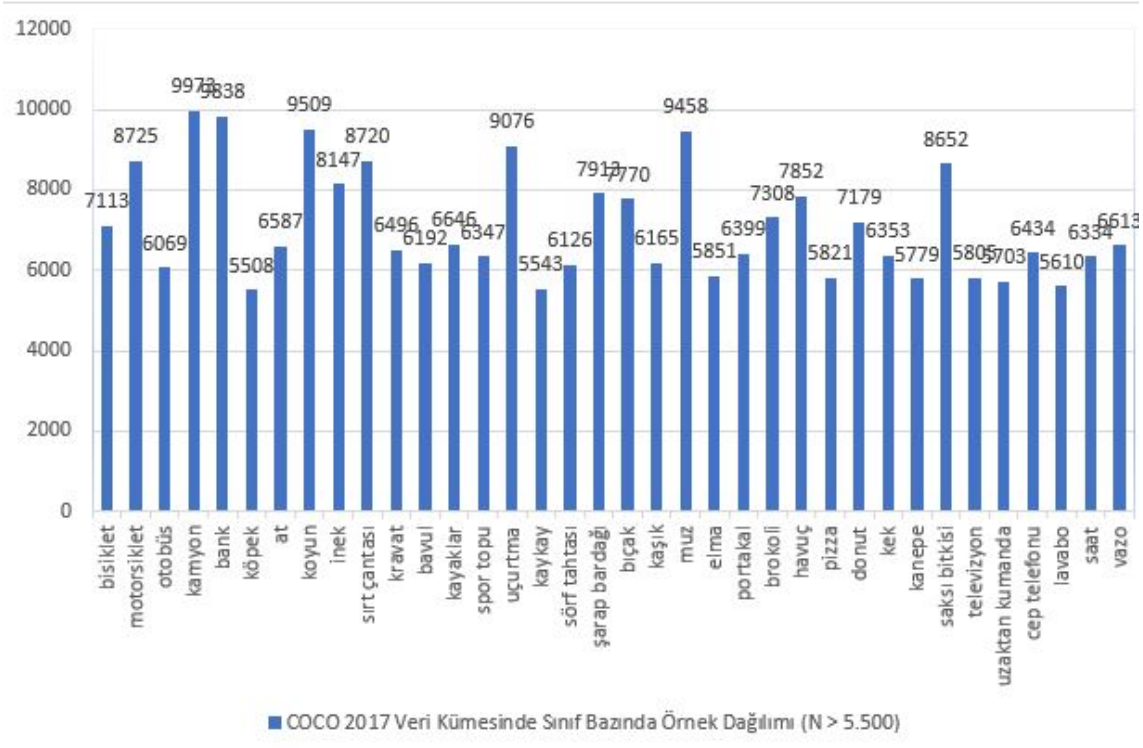
COCO veri kümesine ek olarak, bazı halka açık örnek görüntüler de kullanılmıştır. Bu görüntüler, COCO'daki 80 sınıf içerisinde yer almayan nesne türlerini içerecek şekilde seçilmiştir. Bu sayede, sistemin yeni veya daha önce görülmemiş nesne türleri üzerindeki performansı da değerlendirilebilmiştir.



Şekil 6.2. COCO 2017 Veri Kümesinde Sınıf Bazında Örnek Dağılım (N>10.000).



Şekil 6.3. COCO 2017 Veri Kümesinde Sınıf Bazında Örnek Dağılım (N<5.500).



Şekil 6.4. COCO 2017 Veri Kümesinde Sınıf Bazında Örnek Dağılım (10.000>N>5.500).

Tablo 6.1, COCO veri kümesi üzerinde uygulanan eğitim yapılandırmasını

özetlemektedir. Model, her biri orantıyı koruyarak 640 piksele yeniden boyutlandırılan giriş görüntüleri ile, 8 ve 16 olmak üzere iki farklı yığın boyutunda ve toplamda 100 epoch boyunca eğitilmiştir.

Tablo 6.1. COCO Veri Kümesi Üzerindeki Yapılandırma Parametreleri

Parametre	**Değerler**
Epoch Sayısı	100
Yığın Boyutu	8, 16
Resim Boyutu	640

7. DENEYSEL SONUÇLAR

Sınıftan bağımsız nesne tespiti gerçekleştirmek amacıyla Faster-RCNN, YOLOv8 ve YOLOv11 mimarilerinin üç varyantı (nano, medium ve xlarge) eğitilmiştir. Bu çalışmada diğer varyantlar dikkate alınmamıştır. Tüm modeller, COCO veri kümesi üzerinde önceden eğitilmiş (pre-trained) ağırlıklar ile başlatılmış ve böylece temel görsel özelliklerin korunması sağlanmıştır. Önceden eğitilmiş başlangıç, sınıftan bağımsız yeniden eğitim sürecinin daha hızlı ve kararlı bir şekilde ilerlemesine katkı sağlamıştır.

Modeller, nesnelerin sınıf bilgisinden bağımsız olarak yalnızca varlığını öğrenmesi amacıyla, COCO veri kümesindeki sınıf etiketleri kaldırılarak eğitilmiştir. Eğitim sürecinde görsel veri üzerindeki tüm nesneler belirgin nesne olarak kabul edilmiştir. Belirgin olan nesnelere bir, belirgin olmayan nesnelere ise arka plan değeri atanmıştır. Böylece model, sınıf ayrımı yapmadan yalnızca nesnenin varlığını tahmin etmeye odaklanmıştır.

Eğitim sürecinde transfer öğrenme yaklaşımı benimsenmiş ve modeller, önceden eğitilmiş ağırlıklar üzerinden optimize edilmiştir. Nesne tespiti modellerinin performansını nicel olarak değerlendirmek için yaygın olarak kullanılan metrik mAP değeridir. Bu metrik, modelin tahmin doğruluğunu sayısal olarak ölçer ve Denklem 7.1'de tanımlanmıştır.

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^{N} \text{AP}_i \tag{7.1}$$

Burada, N sınıf sayısını ve APi ise i. sınıf için ortalama doğruluğu temsil etmektedir. Bu çalışmada yalnızca tek bir sınıf kullanıldığından, mAP değeri bu tek sınıfa ait AP değeriyle eşdeğerdir. Dolayısıyla, değerlendirme doğrudan hedef nesneye yönelik tespit performansını yansıtmaktadır. AP, belirli bir sınıf için hassasiyet–duyarlılık (Precision–Recall) eğrisi oluşturularak ve bu eğrinin altında kalan alan hesaplanarak elde edilmektedir. AP hesaplanırken, bir tahminin doğru sayılabilmesi için tahmin kutusu ile gerçek kutu arasındaki IoUnun belirli bir eşiği geçmesi gerekmektedir.

Denklem 7.2'de görüldüğü üzere, IoU denklemini Denklem 2'de görmekteyiz. $mAP@0.5$, $IoU \geq 0.5$ değerine sahip olursa tespit doğru kabul edilir. Yani bir nesne tespit tahmini, gerçek kutuyla %50'den fazla örtüşmeye sahip demektir. Bu tespit bu sebepten dolayı doğru tespit olarak adlandırılmaktadır. Ama $IoU \geq 0.75$ olur ise ölçüm

daha sıkı bir şekilde gerçekleştirilmiştir. *mAP*@0.5:0.95 ifadesinin anlamı ise 0.5'ten 0.95'e kadar 0.05 aralıklarla hesaplanmaktadır.

$$IoU = \frac{Gerçek\ ve\ Tahmin\ Kutularının\ Kesişimi}{Birleşimi} \tag{7.2}$$

Her bir eşiğe göre AP ölçülür ve bu değerlerin ortalaması alınır. Bu nedenle, *mAP*@0.5:0.95 değeri daha katı ve güvenilir bir performans göstergesidir. Bu çalışmada karşılaştırma yaparken *mAP*@0.5:0.95 değeri dikkate alındı.

7.1. YOLOv8 Mimarisinin Varyasyon Karşılaştırılması

Sınıf-bağımsız nesne tespiti için YOLOv8 varyantlarının performans karşılaştırması Tablo 7.1'de verilmiştir. Tablo 7.1, Önerilen Yöntem (ÖY) altında eğitilen üç farklı YOLOv8 varyantının (Nano, Medium ve XLarge) değerlendirme sonuçlarını göstermektedir. Modeller, mAP@0.5:0.95 skorları açısından karşılaştırılmıştır. Her varyant için, hem varsayılan önceden eğitilmiş (pretrained) YOLOv8 modeli hem de sınıf-bağımsız kurulum kullanılarak yeniden eğitilen modelin sonuçları sunulmuştur. "Default YOLOv8" olarak etiketlenen satırlar, YOLOv8 tarafından resmi olarak sağlanan ve sınıf bilinçli şekilde eğitilmiş, herhangi bir yeniden eğitme işlemi yapılmadan kullanılan modelleri temsil etmektedir. "YOLOv8 (ÖY)" olarak etiketlenen satırlar, önerilen yöntemiyle yeniden eğitilen modelleri ifade etmektedir. Bu yapılandırmada, COCO veri kümesindeki tüm sınıf etiketleri kaldırılmış ve modeller yalnızca nesne varlığını, kategori ayrımı olmaksızın tespit etmek üzere eğitilmiştir.

Her bir YOLOv8 varyantı, önerilen yöntem kurulumunda iki farklı yığın boyutu (8 ve 16) ile eğitilmiştir. mAP@0.5:0.95 açısından, Tablo 7.1'deki sonuçlar, açıklama odaklı uygulamalar için çeşitli önemli çıkarımlar sunmaktadır. Özellikle, YOLOv8 modelleri arasında en küçük ve en hızlı olan Nano varyantı, önerilen sınıf-bağımsız kurulumla yeniden eğitildiğinde belirgin bir iyileşme göstermektedir. mAP değeri, varsayılan modeldeki 0.373'ten 0.410'a yükselmiştir; bu da hafif modellerin dahi hedeflenmiş yeniden eğitim stratejilerinden önemli ölçüde fayda sağlayabileceğini göstermektedir. Bu durum, hızlı ve düşük kaynak gerektiren uygulamaların dahi hızlı açıklama görevleri için güvenilir destek sunabileceğini ortaya koymaktadır.

Model karmaşıklığı Nano'dan Medium ve XLarge'a doğru arttıkça, mAP değerlerinde

istikrarlı bir artış gözlenmekte ve önerilen yöntem altında XLarge model için bu değer 0.540'a kadar ulaşmaktadır. Bu eğilim beklenmektedir, zira daha büyük modeller genellikle daha karmaşık desenleri öğrenme kapasitesine sahiptir. Doğruluğun hızdan daha kritik olduğu açıklama sistemlerinde, bu yüksek kapasiteli modeller özellikle kalabalık veya karmaşık sahnelerde daha güvenilir tespit performansı sunabilir.

Sınıf-bağımsız tespit modelleri, model tahminlerinin insan açıklayıcılara rehberlik ettiği ve insan geri bildirimiyle aşamalı olarak iyileştiği yarı denetimli açıklama sistemlerine entegre edilebilir. Okuyucular, veri açıklama sürecini geliştirmek amacıyla sınıf-bağımsız öğrenme stratejilerini, örneğin örnek segmentasyonu veya poz tahmini gibi daha karmaşık görevlere uyarlamayı keşfedebilirler.

Tablo 7.1. Sınıftan Bağımsız Nesne Tespitinde YOLOv8 Varyantlarının Performans Karşılaştırması

Model	**Sürüm**	**Yığın Boyutu**	**mAP@0.5:0.95**	**Eğitim Süresi (saat)**
Varsayılan YoloV8	Nano	16	0,373	NA
YoloV8 (ÖY)	Nano	16	0,400	17 h
YoloV8 (ÖY)	Nano	8	0,410	21 h
Varsayılan YoloV8	Medium	16	0,502	NA
YoloV8 (ÖY)	Medium	16	0,520	25 h
YoloV8 (ÖY)	Medium	8	0,520	37 h
Varsayılan YoloV8	XLarge	16	0,539	NA
YoloV8 (ÖY)	XLarge	16	0,540	100 h
YoloV8 (ÖY)	XLarge	8	0,541	110 h

Varsayılan YOLOv8 ve sınıftan bağımsız YOLOv8 modellerinin yeni (daha önce görülmemiş) nesneler üzerindeki görsel karşılaştırması Şekil 7.1'de sunulmuştur. Şekil 7.1, daha önce kullanılmamış bir veri kümesinden elde edilen niteliksel çıkarım sonuçlarını, yığın boyutu 8 olan üç farklı YOLOv8 model varyantı (Nano, Medium ve XLarge) için göstermektedir. Her bir satır, model karmaşıklığını yansıtmaktadır ve üstten alta doğru hafif yapıdan ağır yapıya bir ilerleme söz konusudur. İlk sütun, standart COCO kategorileriyle eğitilmiş sınıf-bilinçli (class-aware) varsayılan modellerin tespit

sonuçlarını gösterirken, sağ sütun ise önerilen sınıftan bağımsız modellerin çıktılarından oluşmaktadır.

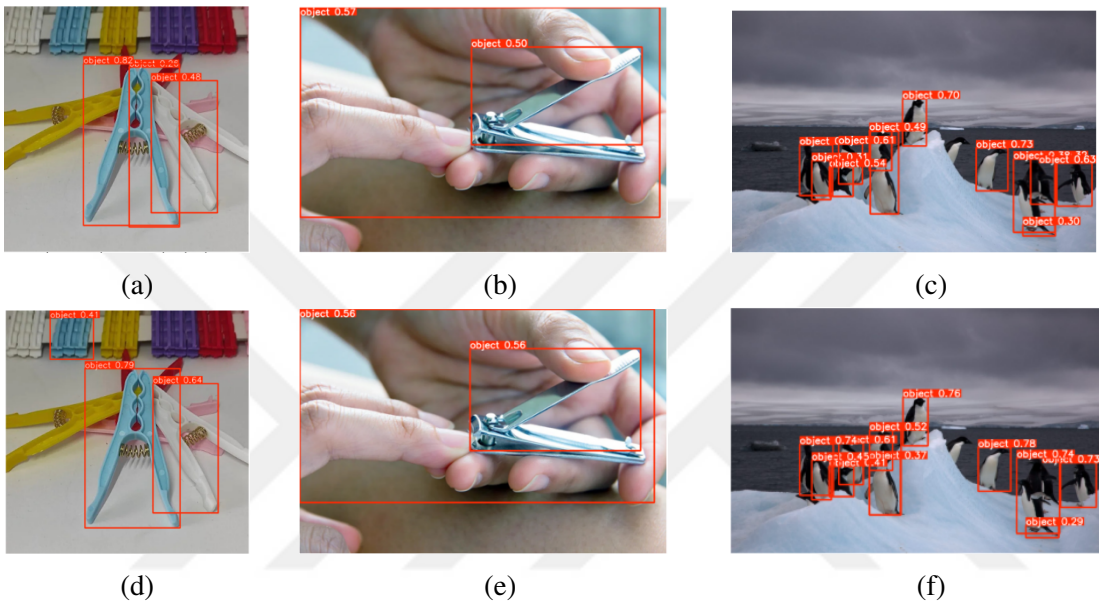


Şekil 7.1. Görülmemiş nesneler üzerinde varsayılan ve sınıf-bağımsız YoloV8 modellerinin görsel karşılaştırması (a) Varsayılan model, (b) Önerilen yöntem.

Görüldüğü üzere, sınıf-bağımsız modeller aynı görüntü üzerinde genel olarak daha kapsamlı ve tutarlı tespitler gerçekleştirmektedir; özellikle de orijinal COCO sınıf listesinde yer almayan nesneler için bu fark belirginleşmektedir. Örneğin, varsayılan modeller çoğu zaman bazı nesne sınırlarını atlayabilir veya göz ardı edebilirken, önerilen yöntem varyantları belirli bir sınıfa ait olup olmamasına bakmaksızın daha fazla nesne örneğini doğru şekilde tespit etmeyi başarmaktadır. Bu sonuçlar, sınıftan bağımsız eğitimin modelin genel nesne bölgelerini algılama yeteneğini geliştirdiğini ve böylece kullanıcı tanımlı veya alışılmamış nesnelerin açıklanmasında daha etkili hale geldiğini göstermektedir.

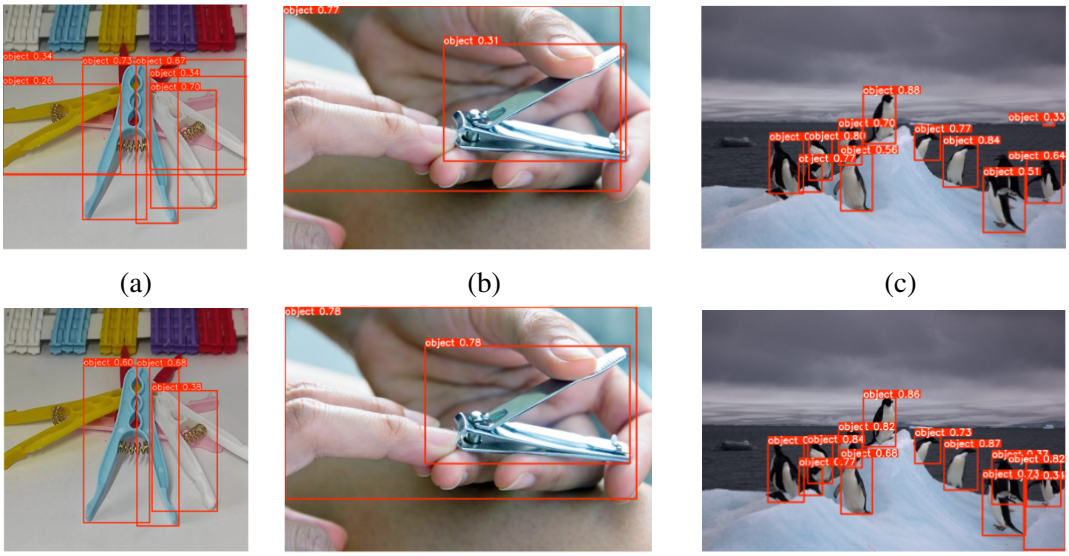
Sınıftan bağımsız YOLOv8 modelleri olan Nano, Medium ve XLarge'ın, yeni (daha önce görülmemiş) nesneler üzerindeki çıkarım sonuçları sırasıyla Şekil 7.2, 7.3 ve 7.4'te gösterilmiştir. Görsel sonuçlar, iki farklı yığın boyutu (8 ve 16) altında elde

edilmiştir. Şekil 7.2'de, her iki yığın boyutu ayarında da, eğitim kümesinde yer almayan nesne kategorilerine ait çok sayıda örnek başarıyla tespit edilmiştir. Bu durum, sınıf-bağımsız yaklaşımın genelleme yeteneğini desteklemektedir. Ayrıca, üçüncü sütunda yer alan görselde, yığın boyutu 16 ile eğitilmiş modelin daha fazla sayıda nesne tespit ettiği ve üst üste gelen nesneleri birbirinden daha iyi ayırt edebildiği gözlemlenmektedir.



Şekil 7.2. Görülmemiş nesneler üzerinde YOLOv8n (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)

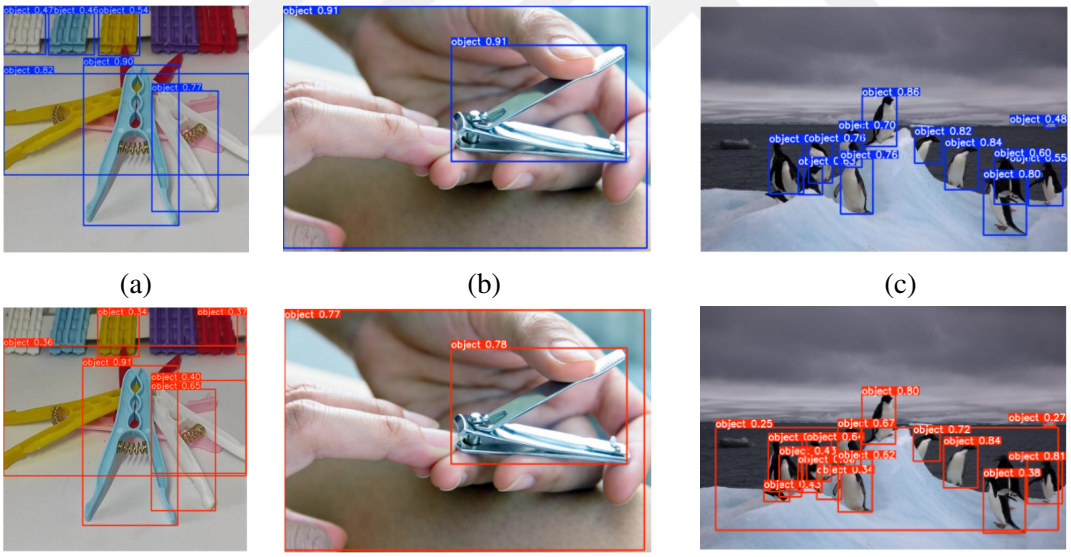
Yığın boyutu 8 ve 16 ile eğitilen Medium model varyantları, Nano modeline kıyasla daha kararlı ve doğru nesne sınırları sağlamaktadır. Nesneler daha hassas bir şekilde çevrelenmiş olup, tahmin edilen sınırlayıcı kutuların sayısı daha optimize görünmektedir. Şekil 7.4'te sunulan görsel sonuçlara göre, XLarge model genel olarak tüm varyantlar arasında en yüksek nesne tespit performansını göstermektedir. Bu model, karmaşık sahnelerdeki örtüşme ve kalabalıklara rağmen, tüm görüntülerde son derece hassas ve tutarlı sınırlayıcı kutular üretmektedir. Nano ve Medium modellere kıyasla, XLarge model daha fazla nesne örneğini daha iyi konumlandırarak tespit etmektedir.



(a) (b) (c)

(d) (e) (f)

Şekil 7.3. Görülmemiş nesneler üzerinde YoloV8m (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)



(a) (b) (c)

(d) (e) (f)

Şekil 7.4. Görülmemiş nesneler üzerinde YoloV8x (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)

7.2. YOLOv11 Mimarisinin Varyasyon Karşılaştırılması

Sınıftan bağımsız nesne tespiti kapsamında kullanılan YOLOv11 varyantlarının performans karşılaştırması Tablo 7.2'de verilmiştir. Bu tablo, önerilen yöntem ile

yeniden eğitilen üç farklı YOLOv11 modelinin (Nano, Medium ve XLarge) mAP@0.5:0.95 değerleri üzerinden değerlendirilmesini içermektedir. Her bir varyant için, hem varsayılan önceden eğitilmiş YOLOv11 modellerinin hem de sınıftan bağımsız yeniden eğitilen sürümlerinin sonuçları karşılaştırmalı olarak sunulmuştur. Varsayılan modeller, sınıf etiketleriyle eğitilmiş resmi sürümleri temsil ederken; önerilen yöntem yapılandırmasında tüm sınıf bilgileri kaldırılmış, modeller yalnızca nesnelerin konumlarını tespit edecek şekilde optimize edilmiştir.

Tablodaki sonuçlar incelendiğinde, her üç varyantta da sınıftan bağımsız yeniden eğitim sonrasında mAP değerlerinde hafif ancak tutarlı bir artış gözlemlenmektedir. En küçük model olan YOLOv11-Nano, varsayılan durumda 0.395 olan mAP değerini önerilen yöntem yapılandırmasıyla 0.415 seviyesine taşımıştır. Bu artış, küçük boyutlu modellerin bile uygun bir yeniden eğitim stratejisiyle belirgin iyileşme gösterebildiğini ortaya koymaktadır. Model kapasitesi arttıkça elde edilen kazanımlar da daha belirgin hale gelmektedir. Medium varyantı, varsayılan modeldeki 0.515'lik başarıyı 0.529'a yükseltmiş; XLarge modelinde ise bu değer 0.547'den 0.553 seviyesine ulaşmıştır. Bu durum, daha büyük modellerin karmaşık sahnelerdeki desenleri öğrenme ve genelleme kapasitesinin daha yüksek olduğunu göstermektedir.

Eğitim süresi açısından bakıldığında, model boyutu büyüdükçe hem işlem süresinde hem de doğruluk oranında paralel bir artış görülmektedir. Nano modelin yaklaşık 20-33 saat arasında tamamlanan eğitimi, XLarge modelde 70 saatten fazla sürmektedir. Bu sonuçlar, yüksek doğruluk gerektiren görevlerde XLarge modelinin daha avantajlı, ancak hız ve kaynak verimliliği öncelikli durumlarda Nano varyantının daha uygun bir seçenek olduğunu göstermektedir.

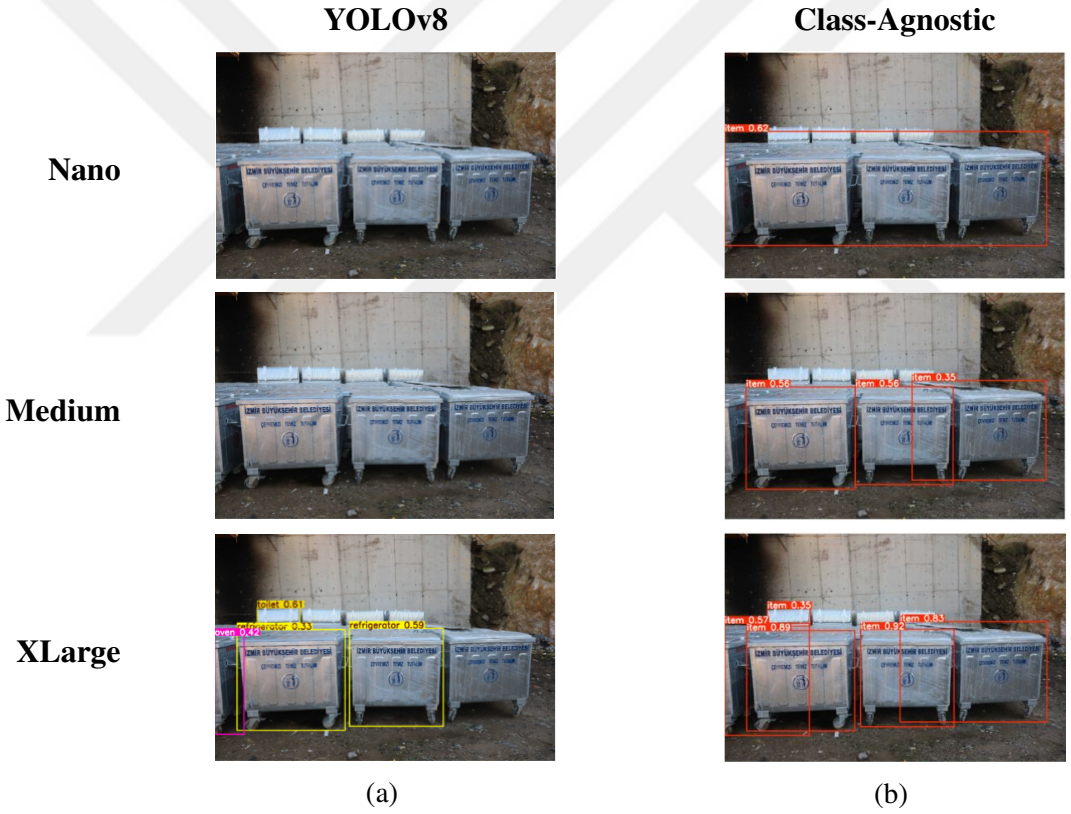
Genel olarak, YOLOv11 modelleriyle yapılan bu deneyler, sınıftan bağımsız eğitim stratejisinin nesne konumlandırma başarımını olumsuz etkilemediğini; aksine, modelin genelleme kabiliyetini artırdığını ortaya koymaktadır. Bu bulgular, önerilen yöntemin açıklama tabanlı uygulamalarda insan müdahalesi gereksinimini azaltarak yarı denetimli sistemlerin etkinliğini artırma potansiyeline sahip olduğunu göstermektedir.

Tablo 7.2. Sınıftan bağımsız nesne tespitinde YOLOv11 varyantlarının performans karşılaştırması.

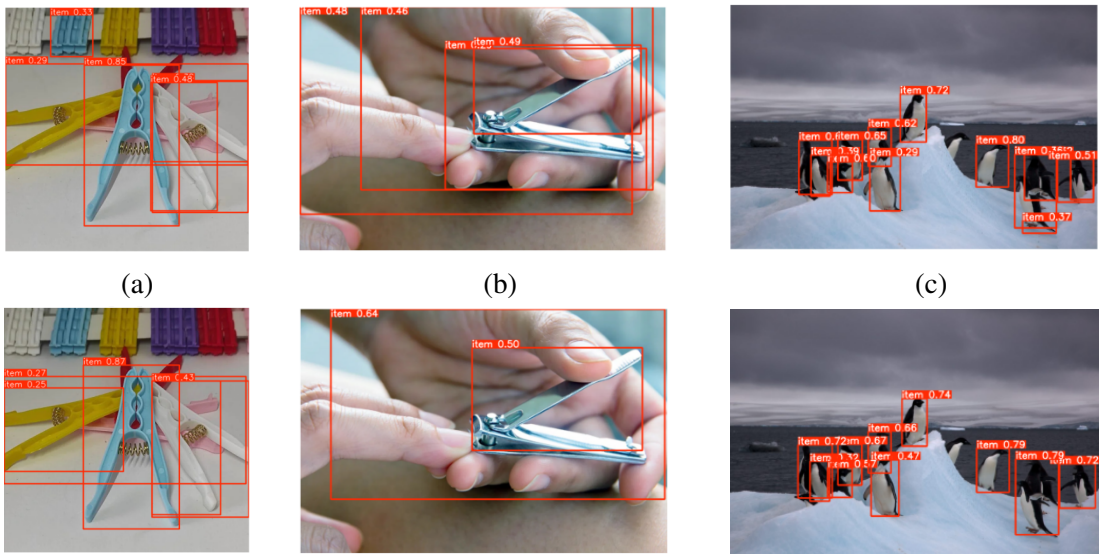
Model	Varyant	Yığın Boyutu	mAP@0.5:0.95	Eğitim Süresi (saat)
Varsayılan YOLOv11	Nano	16	0,395	Belirtilmemiş
YOLOv11 (ÖY)	Nano	16	0,415	20 h
YOLOv11 (ÖY)	Nano	8	0,411	33 h
Varsayılan YOLOv11	Medium	16	0,515	Belirtilmemiş
YOLOv11 (ÖY)	Medium	16	0,529	35 h
YOLOv11 (ÖY)	Medium	8	0,527	45 h
Varsayılan YOLOv11	XLarge	16	0,547	Belirtilmemiş
YOLOv11 (ÖY)	XLarge	16	0,553	77 h
YOLOv11 (ÖY)	XLarge	8	0,552	69 h

Varsayılan YOLOv11 ve sınıftan bağımsız olarak yeniden eğitilmiş YOLOv11 modellerinin yeni (daha önce görülmemiş) nesneler üzerindeki görsel karşılaştırması Şekil 7.5'te sunulmuştur. Şekil, daha önce eğitim sürecinde kullanılmamış bir veri kümesi üzerinde elde edilen niteliksel sonuçları göstermekte olup, yığın boyutu 8 ve üç farklı YOLOv11 varyantını (Nano, Medium ve XLarge) içermektedir. Her bir satır modelin karmaşıklığını temsil etmekte, üstten alta doğru daha yüksek parametre sayısına ve öğrenme kapasitesine sahip mimarilere geçişi yansıtmaktadır. İlk sütun, COCO sınıf etiketleriyle eğitilmiş sınıf bilinçli varsayılan modellerin tespit sonuçlarını; sağ sütun ise önerilen sınıftan bağımsız modellerin çıktılarından elde edilen tespitleri göstermektedir. Görseller incelendiğinde, sınıftan bağımsız YOLOv11 modellerinin, varsayılan modellere kıyasla daha kapsamlı ve sahneyle daha uyumlu tespitler gerçekleştirdiği görülmektedir. Özellikle, COCO veri kümesinde bulunmayan nesne türleri söz konusu olduğunda bu fark daha belirgin hale gelmektedir. Varsayılan modeller, belirli sınıf etiketlerine bağımlı olarak çalıştıklarından, eğitimde yer almayan nesneleri sıklıkla göz ardı etmektedir. Buna karşın, önerilen yöntem yapılandırmasıyla eğitilen YOLOv11 varyantları, nesnenin türüne bakmaksızın görüntüdeki belirgin bölgeleri başarıyla yakalamakta ve sınırlayıcı kutularla ifade etmektedir. Bu durum, sınıftan bağımsız

eğitimin modelin genel nesne algılama kabiliyetini güçlendirdiğini ve yeni nesnelerin tespiti için daha esnek bir yapı sunduğunu göstermektedir. Ayrıca, sınıftan bağımsız YOLOv11 modellerinin Nano, Medium ve XLarge varyantlarına ait çıkarım sonuçları sırasıyla Şekil 7.6, 7.7 ve 7.8'de verilmiştir. Bu görseller, iki farklı yığın boyutu (8 ve 16) ayarında elde edilmiştir. Özellikle Şekil 7.8'de, her iki yığın boyutu değeriyle eğitilen modellerin, eğitim verisinde yer almayan nesne kategorilerine ait çok sayıda nesneyi doğru şekilde tespit ettiği gözlemlenmektedir. Bu bulgu, sınıftan bağımsız yaklaşımın genelleme kabiliyetini artırdığı ve modelin sınıf farkı gözetmeden yeni nesneleri tanımlayabildiğini doğrulamaktadır. Ayrıca, daha yüksek yığın boyutuyla (16) eğitilen modellerin, özellikle kalabalık sahnelerdeki üst üste gelen nesneleri daha iyi ayırt ettiği ve tespit yoğunluğunu artırdığı da dikkat çekmektedir.



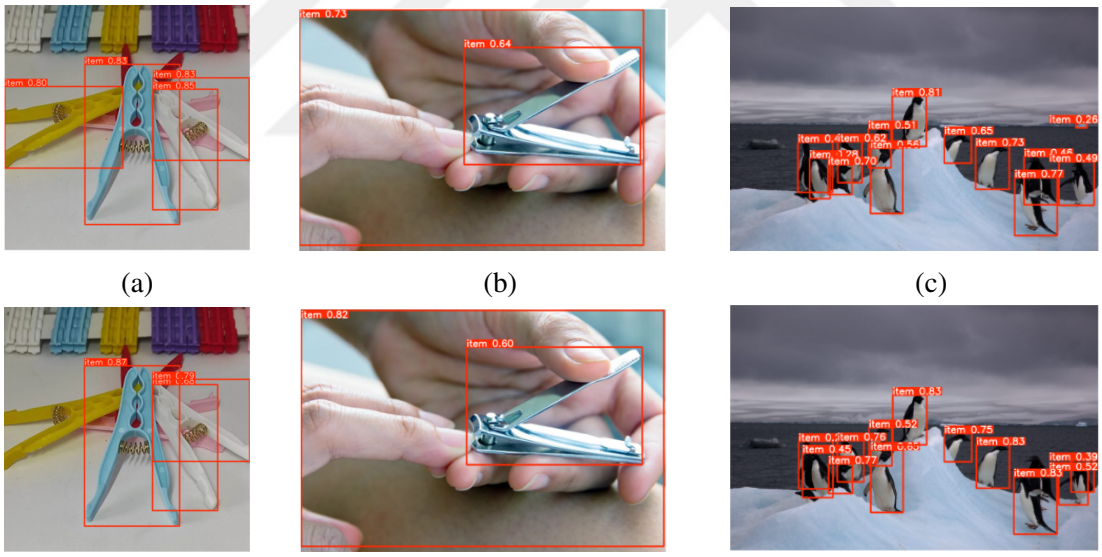
Şekil 7.5. Görülmemiş nesneler üzerinde varsayılan ve sınıf-bağımsız YoloV11 modellerinin görsel karşılaştırması (a) Varsayılan model, (b) Önerilen yöntem.



(a) (b) (c)

(d) (e) (f)

Şekil 7.6. Görülmemiş nesneler üzerinde YoloV11n (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)



(a) (b) (c)

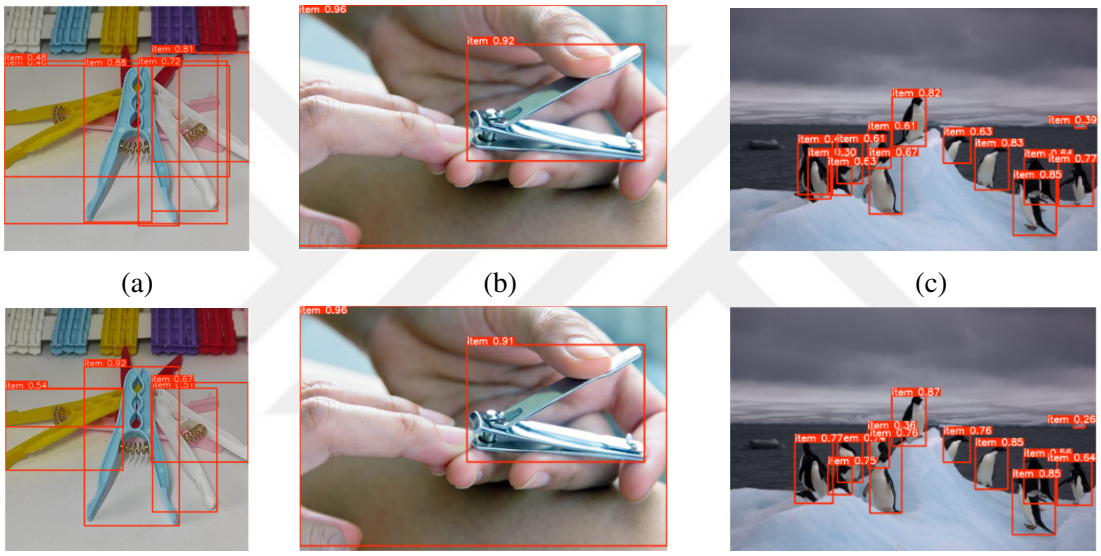
(d) (e) (f)

Şekil 7.7. Görülmemiş nesneler üzerinde YoloV11m (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)

Yığın boyutu 8 ve 16 ile eğitilen YOLOv11-Medium varyantları, Nano modele kıyasla daha kararlı nesne tespiti davranışı sergilemektedir. Elde edilen sonuçlara göre, Medium modelin tahmin ettiği sınırlayıcı kutular daha dengeli dağılmış olup, gereksiz veya

yinelenen tespitler minimize edilmiştir. Bu modeller, nesne sınırlarını daha net biçimde belirleyerek sahne içindeki konumlandırmayı iyileştirmektedir.

Şekil 7.8'de gösterilen niteliksel sonuçlara göre, YOLOv11-XLarge varyantı tüm modeller arasında en yüksek tespit performansını göstermektedir. Bu model, karmaşık sahne yapılarında, örtüşen veya birbirine yakın nesneleri ayırt etmede üstün bir hassasiyet sergilemektedir. Ayrıca, yoğun nesne içeren ortamlarda dahi sınırlayıcı kutuların oldukça tutarlı ve doğru biçimde yerleştirildiği gözlemlenmiştir. Nano ve Medium modellere kıyasla, XLarge modelin hem tespit edilen nesne sayısı hem de lokalizasyon doğruluğu açısından daha üstün olduğu görülmektedir.



(a) (b) (c)

(d) (e) (f)

Şekil 7.8. Görülmemiş nesneler üzerinde YoloV11x (ÖY) modelinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)

Bu bulgular, YOLOv11 mimarisinin derin katman yapısının ve iyileştirilmiş özellik haritası aktarım mekanizmasının, sınıftan bağımsız tespit görevlerinde genel performansa olumlu katkı sağladığını göstermektedir. Özellikle yüksek çözünürlüklü sahnelerde, XLarge modelin sunduğu bu kararlılık, açıklama sürecinde insan müdahalesine duyulan ihtiyacı azaltabilecek düzeydedir.

7.3. Faster-RCNN Mimarisinin Karşılaştırılması

Tablo 7.3'te görüldüğü üzere, Faster-RCNN modellerinin sınıftan bağımsız yapılandırmada elde ettiği sonuçlar, önceden eğitilmiş Torchvision ve AutoGluon

modelleriyle kıyaslandığında oldukça tatmin edici düzeydedir. Torchvision tarafından yayımlanan Faster-RCNN-ResNet50-FPN-V2 modeli, COCO 2017 doğrulama kümesinde $mAP@0.5:0.95 = 0.467$ değeriyle referans bir doğruluk oranına ulaşmıştır. AutoGluon ortamında elde edilen varsayılan Faster-RCNN modeli ise $mAP@0.5:0.95 = 0.385$ sonucuyla daha düşük bir performans sergilemiştir.

Bu tez kapsamında yeniden eğitilen modellerde, özellikle yığın boyutu değerinin artırılmasıyla doğruluk oranlarında gözle görülür bir artış sağlanmıştır. Yığın boyutu değeri 8 olan konfigürasyonda ortalama doğruluk 0.406, yığın boyutu değeri 16 olan konfigürasyonda ise 0.447 olarak hesaplanmıştır. Bu sonuç, modelin sınıftan bağımsız biçimde eğitilmesine rağmen, önceden eğitilmiş modellere yakın doğruluk seviyelerine ulaşabildiğini göstermektedir. Ayrıca, modelin 160–165 saatlik eğitim süresi içerisinde, daha karmaşık ve çok nesneli sahnelerde bile yüksek konum doğruluğunu koruyabildiği gözlenmiştir.

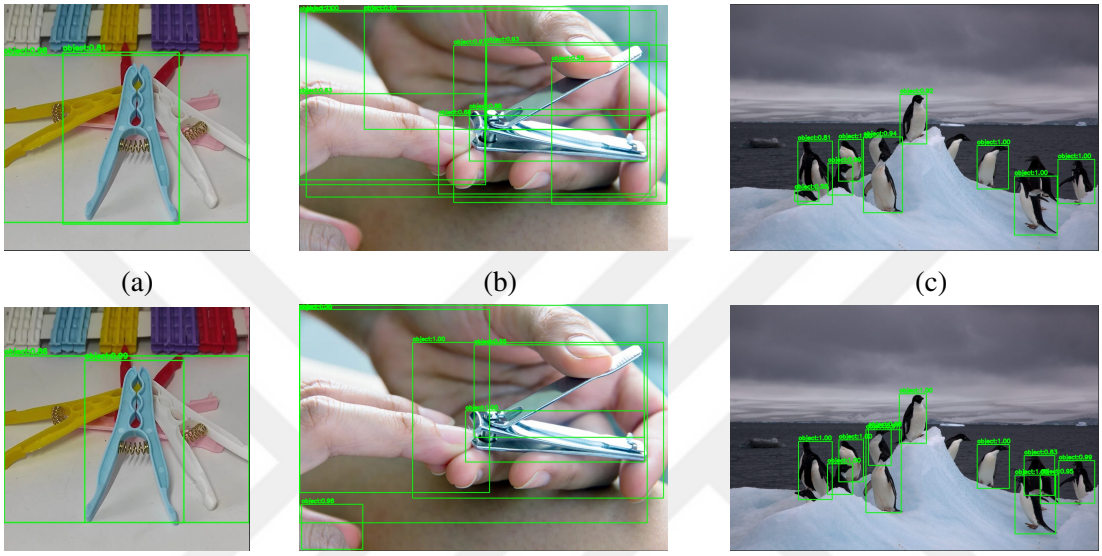
Faster-RCNN'in yüksek hesaplama maliyetine rağmen başarımını sürdürmesi, mimarinin güçlü bölge öneri ağı yapısından kaynaklanmaktadır. Bu özellik, modelin özellikle yoğun nesne içeren sahnelerde tespit sınırlarını doğru bir şekilde belirlemesini sağlamıştır. Sonuç olarak, bu çalışma kapsamında geliştirilen Faster-RCNN konfigürasyonlarının, sınıftan bağımsız öğrenme senaryolarında hız, doğruluk ve verimlilik açısından dengeli bir performans sunduğu ve referans modellere kıyasla rekabetçi sonuçlar elde ettiği söylenebilir.

Tablo 7.3. Sınıftan bağımsız nesne tespitinde Faster-RCNN performans karşılaştırması.

Model	**Yığın Boyutu**	**mAP@0.5:0.95**	**Eğitim Süresi (saat)**
Varsayılan Torchvision Faster-RCNN	Belirtilmemiş	0,467	Belirtilmemiş
Varsayılan AutoGluon Faster-RCNN	1	0,385	Belirtilmemiş
Faster-RCNN (ÖY)	8	0,406	165 h
Faster-RCNN (ÖY)	16	0,447	160 h

Performans farkının temel nedeni, modelin 80 sınıf yerine tek bir sınıfta eğitilmesi ve bu sayede veri çeşitliliğinin azalmasıdır. Ayrıca küçük yığın boyutlarında görülen gradyan

kararsızlığı ve daha yüksek optimizasyon gürültüsü, mAP değerlerinde azalmaya yol açmıştır. Buna karşın yığın boyutunun 16'ya çıkarılması, öğrenme sürecinin stabilitesini artırmış ve modelin referans değere daha fazla yaklaşmasını sağlamıştır. Önerilen Faster-RCNN modeli, Şekil 7.9'da görüleceği üzere yığın boyutu 8 de oluşan karmaşıklık yığın boyutu 16 da görülmemektedir. Bu da daha önce bahsedildiği gibi stabilitenin arttığını göstermektedir.



(a) (b) (c)

(d) (e) (f)

Şekil 7.9. Görülmemiş nesneler üzerinde Faster-RCNN (ÖY) mimarisinin çıkarım sonuçları. (Yığın Boyutu; a, b, c = 8 / d, e, f = 16 şeklindedir.)

Önerilen Faster-RCNN modelinin bu çalışma kapsamında elde edilen performansı, sınıftan bağımsız konfigürasyonun gerçek sınıf farkındalığı olmadan dahi nesne konumlarını başarılı biçimde tespit edebildiğini göstermektedir. Bu bulgu, hızlı ön etiketleme sistemleri için önemli bir potansiyel sunmakta; gelecekte sınıf bilgisiyle birleştirilen hibrit yaklaşımların doğruluk açısından daha rekabetçi hale gelebileceğini ortaya koymaktadır. Gelecek çalışmalarda, Faster-RCNN modelinin belirgin nesne ve arka plan ayrımı yapılmış veriler üzerinde yeniden eğitilmesi planlanmaktadır. Böylece, yalnızca dikkat çekici nesnelerin tespit edilmesi hedeflenerek modelin ön etiketleme performansı daha yüksek doğruluk ve hızla optimize edilebilecektir. Görüldüğü üzere, sınıf bağımsız modeller, aynı görüntü üzerinde genel olarak daha kapsamlı ve tutarlı tespitlerde bulunmaktadır. Özellikle orijinal COCO sınıf listesinde yer almayan nesneler için bu fark belirginleşmektedir. Örneğin, varsayılan modeller çoğu zaman bazı nesne sınırlarını atlayabilir veya göz ardı edebilirken, önerilen yöntem varyantları belirli bir

sınıfa ait olup olmamasına bakmaksızın daha fazla nesne örneğini doğru şekilde tespit etmeyi başarmaktadır. Bu sonuçlar, sınıftan bağımsız eğitimin modelin genel nesne bölgelerini algılama yeteneğini geliştirdiğini ve böylece kullanıcı tanımlı veya alışılmamış nesnelerin açıklanmasında daha etkili hale geldiğini göstermektedir.

8. SONUÇ VE ÖNERİLER

Bu tez çalışmasında, görsel veri etiketleme süreçlerinde açıklama hızını ve verimliliğini artırmak amacıyla belirginlik temelli sınıftan bağımsız nesne tespiti yaklaşımı önerilmiş ve değerlendirilmiştir. Bu araştırma çabasında, YOLOv8, YOLOv11 ve Faster R-CNN olmak üzere üç farklı derin öğrenme mimarisi, hem sınıfa bağlı hem de sınıftan bağımsız konfigürasyonlara karşı sistematik olarak değerlendirilmiştir.

Elde edilen sonuçlar, sınıftan bağımsız öğrenme stratejisinin modellerin genelleme kabiliyetini artırdığını ve daha önce görülmemiş nesneleri dahi başarılı bir şekilde tespit edebildiğini göstermiştir. Özellikle YOLOv8 ve YOLOv11 mimarileri, tek aşamalı ve çapasız yapılarına bağlı olarak, sınıf bilgisinden bağımsız biçimde nesne bölgelerini tanımlamada yüksek performans sergilemiştir. Bu mimarilerde, COCO veri kümesindeki sınıf etiketleri kaldırıldığında bile tespit başarımı istikrarlı kalmış ve belirli varyantlarda mAP değerlerinde artış gözlemlenmiştir.

YOLOv11 ailesi, daha derin katman yapısı ve gelişmiş mekanizması sayesinde, özellikle karmaşık sahnelerde ve örtüşen nesnelerde daha kararlı sınırlayıcı kutular üretmiştir. Model karmaşıklığı arttıkça (Nano $\rightarrow$ Medium $\rightarrow$ XLarge), tespit doğruluğunda düzenli bir artış gözlenmiş ve XLarge varyantı tüm modeller arasında en yüksek mAP değerini (0.553) elde etmiştir. Buna karşılık, daha hafif olan Nano modelinin bile sınıftan bağımsız olarak yeniden eğitildiğinde anlamlı bir performans artışı göstermesi, yöntemin düşük kaynak gerektiren açıklama sistemlerinde uygulanabilir olduğunu göstermektedir.

Faster-RCNN modeli, sınıftan bağımsız yapılandırmada yeniden eğitilmiş ve farklı yığın boyutlarında performans değerlendirmeleri yapılmıştır. Elde edilen sonuçlar, modelin yüksek doğruluk potansiyelini sınıf bilgisinden bağımsız senaryolarda dahi koruyabildiğini göstermektedir. Özellikle karmaşık ve çok nesneli sahnelerde Faster-RCNN'in bölge öneri ağı sayesinde nesne konumlarını doğru biçimde belirleme eğilimi dikkat çekmiştir.

Bununla birlikte, tek bir genel nesne sınıfı altında gerçekleştirilen eğitim süreci, modelin genel genelleme kabiliyetini sınırlandırmış ve mAP değerlerinde hafif bir düşüşe neden olmuştur. Ancak yığın boyutunun artırılmasıyla birlikte öğrenme sürecinde kararlılık sağlanmış ve model, doğruluk açısından referans değerlere yaklaşmıştır. Bu durum,

Faster-RCNN'in özellikle konum hassasiyetinin kritik olduğu uygulamalarda (örneğin, medikal görüntüleme, endüstriyel denetim veya uydu gözlemleri) güvenilir bir seçenek olduğunu ortaya koymaktadır.

Bu çalışmada elde edilen bulgular, modern tek aşamalı modellerin özellikle YOLOv8 ve YOLOv11 ailesinin sınıftan bağımsız senaryolarda dahi yüksek genelleme başarımı gösterdiğini ortaya koymuştur. YOLO tabanlı modellerin hem daha güncel mimari bileşenlere sahip olması hem de sınıf bilgisinden bağımsız olarak bölge önerilerini güvenilir şekilde üretebilmesi, Faster R-CNN'e kıyasla daha kararlı ve yüksek doğruluklu sonuçlar sunmasını sağlamıştır. Bununla birlikte, Faster R-CNN'in iki aşamalı yapısı bazı karmaşık sahnelerde daha tutarlı konum tahminleri üretme potansiyeli taşısa da, genel eğilim modern YOLO sürümlerinin hem doğruluk hem de hız bakımından daha avantajlı olduğunu göstermektedir. Bu nedenle, otomatik ve yarı otomatik veri etiketleme gibi hızın kritik olduğu uygulamalarda YOLO ailesi daha uygun bir seçenek olarak öne çıkarken; konum hassasiyetinin öncelikli olduğu özel senaryolarda Faster R-CNN hala değerlendirilebilir bir alternatif olmaya devam etmektedir.

Genel olarak, YOLO mimarileri hız ve genelleme açısından gerçek zamanlı açıklama sistemleri için daha uygun bulunurken; Faster R-CNN, yüksek doğruluk ve konum hassasiyeti gerektiren uygulamalarda tercih edilebilecek bir alternatif sunmaktadır. Bu sonuçlar, belirginlik tabanlı sınıftan bağımsız yaklaşımın farklı model mimarilerine uyarlanabileceğini ve veri etiketleme süreçlerinde esnek bir biçimde kullanılabileceğini ortaya koymaktadır.

Bu tez kapsamında geliştirilen yaklaşım, özellikle etiketlenmemiş büyük veri kümelerinde ön açıklama adımını hızlandırmak için etkili bir araç olarak değerlendirilebilir. Model çıktıları, insan açıklayıcıların müdahalesiyle kolayca doğrulanabilir veya iyileştirilebilir. Böylece insan makine iş birliğine dayalı yarı denetimli açıklama süreçlerinin etkinliği artırılabilir.

Gelecek çalışmalarda, tüm nesneleri belirgin olarak değerlendiren mevcut yaklaşımdan farklı olarak, yalnızca görüntüye ilk bakıldığında insan algısında ön plana çıkan ve dikkat çeken nesnelerin tespit edilmesi hedeflenmektedir. Bu sayede sistem, insan görsel dikkat mekanizmasını taklit ederek yalnızca gerçekten belirgin nesneleri tanımlayacak ve veri

etiketleme sürecinde daha anlamlı açıklama çıktıları üretecektir.

Bu tez kapsamında geliştirilen sınıftan bağımsız belirgin nesne tespiti yaklaşımı, görsel veri etiketleme süreçlerinde insan müdahalesini azaltarak açıklama hızını artırabilecek ve aynı zamanda yeni ve tanımlanmamış nesnelerin tespitinde etkinlik sağlayabilecek bir yöntem olarak öne çıkmaktadır. Elde edilen sonuçlar, bu yöntemin hem YOLO tabanlı mimarilerde genelleme başarımını hem de Faster R-CNN gibi bölge tabanlı sistemlerde konum doğruluğunu desteklediğini göstermektedir. Dolayısıyla, önerilen strateji, gelecekte otomatik veri etiketleme, nesne keşfi ve yarı denetimli öğrenme alanlarında yenilikçi bir paradigma olarak değerlendirilebilir.

KAYNAKLAR

Abdullah, M. A. M., Rahman, M. H., Islam, S. M. S. (2024). YOLO11 to Its Genesis: A Decadal and Comprehensive Review of the You Only Look Once (YOLO) Series. *arXiv preprint*.

Ahmed, M., Hashmi, K. A., Pagani, A., Liwicki, M., Stricker, D., Afzal, M. Z. (2021). Survey and Performance Analysis of Deep Learning-Based Object Detection in Challenging Environments. *Sensors*, *21*(15), 1–22.

Bochkovskiy, A., Wang, C. Y., Liao, H. Y. M. (2020). YOLOv4: Optimal Speed and Accuracy of Object Detection. *arXiv preprint*.

Boesch, G. (2023). PyTorch vs TensorFlow: A Head-to-Head Comparison for Object Detection Models. *AI Journal*, *5*(3), 98–107.

Borji, A., Cheng, M.-M., Jiang, H., Li, J. (2015). Salient Object Detection: A Survey. *Computer Vision and Image Understanding*, *130*, 80–109.

Chang, Y., Wang, H. (2022). Waste Detection and Classification Using Mask R-CNN: An Approach to Intelligent Waste Management. *Journal of Environmental Informatics Letters*, *7*(1), 23–32.

Chen, K., Liu, S. (2023). Balanced Feature Learning in Object Detection. *Pattern Recognition Letters*, *165*, 112–120.

Chen, Y., Lin, C. (2020). Image Saliency Detection by Residual and Inception-like CNNs. *IEEE Access*, *8*, 124315–124327.

Ciocarlan, A., Lefebvre, S., Le Hégarat-Mascle, S., Woiselle, A. (2024). Self-Supervised Learning for Real-World Object Detection: A Survey. *arXiv preprint*.

Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., Fei-Fei, L. (2009). ImageNet: A Large-Scale Hierarchical Image Database, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., Zisserman, A. (2010). The PASCAL Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision (IJCV)*, *88*(2), 303–338.

Güler, Ü. (2022). Image Annotation and Object Detection Using TensorFlow and Faster R-CNN. *Turkish Journal of Computer Vision*, *3*(2), 86–97.

Haj Hassine, A., Hamed, K. (2025). A Comparative Analysis of YOLOv11 Models: Impact of Object Size on Detection Performance. B.Sc. Thesis, KTH Royal Institute of Technology, Stockholm, Sweden.

He, K., Zhang, X., Ren, S., Sun, J. (2016). Deep Residual Learning for Image Recognition, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Itti, L., Koch, C., Niebur, E. (1998). A Model of Saliency-Based Visual Attention for Rapid Scene Analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *20*(11), 1254–1259.

Jain, A., Sharma, R., Gupta, V. (2019). Efficient Annotating with Object Detection Models. *arXiv preprint*.

Jocher, G., Team, U. (2025). *YOLOv8 Documentation*. https://docs.ultralytics.com,

Kim, H., Han, J.-H., Kim, M., Kang, J. (2023). Toward Interactive Self-Annotation for Video Object Bounding Box: Recurrent Self-Learning and Hierarchical Annotation-Based Framework. *IEEE Access*, *11*, 123456–123470.

Kumar, P., Sharma, R. (2024). YOLOv8 Nesne Tespit Algoritmasının COCO Veri Kümesi Üzerindeki Performansının Değerlendirilmesi: Hız, Doğruluk ve Uygulama Etkinliği. *Uluslararası Makine Öğrenmesi Uygulamaları Dergisi*, *14*(2), 78–90.

Leal, A., Duarte, R., Figueiredo, M. A. T. (2019). Simple Method for Detecting Visual Saliencies Based on Dictionary Learning and Sparse Coding. *Pattern Recognition Letters*, *128*, 180–188.

Li, Y., Wang, Y., Wang, W., Lin, D., Li, B., Yap, K.-H. (2024). Open World Object Detection: A Survey. *arXiv preprint*.

Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., Belongie, S. (2017). Feature Pyramid Networks for Object Detection, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Zitnick, C. L. (2014). Microsoft COCO: Common Objects in Context, *European Conference on Computer Vision (ECCV)*.

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A., Ciompi, F., Ghafoorian, M., Sánchez, C. I. (2017). A Survey on Deep Learning in Medical Image Analysis. *Medical Image Analysis*, *42*, 60–88.

Liu, Q., Zhao, H., Huang, P. (2022). Advanced Superpixel-Based Features and Machine Learning Based Saliency Detection. *Expert Systems with Applications*, *194*, 116535.

Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C. Y., Berg, A. C. (2016). SSD: Single Shot MultiBox Detector, 21–37.

Liu, Z., Zhang, Y., Chen, Y., Zhang, X. (2020). Deep Learning-Based Image Classification Techniques for the COCO Dataset. *IEEE Access*, *8*, 108230–108245.

Meethal, A. P. (2023). Learning to Localize Objects with Limited Supervision. Ph.D. Thesis, École de Technologie Supérieure, Université du Québec, Montreal, Canada.

Munjam, S., Kasturi, B. S. P. K. (2024). Improved Ship Detection in Satellite Images using Faster R-CNN and YOLOv8. Master's Thesis, Blekinge Institute of Technology, Karlskrona, Sweden.

Northcutt, C. G., Jiang, L., Chuang, I. L. (2021). Confident Learning: Estimating Uncertainty in Dataset Labels. *Journal of Artificial Intelligence Research (JAIR)*, *70*, 1373–1411.

Nunes, A. F. (2025). From Classification to Detection: Adapting Semi-Supervised Frameworks to Object Detection. M.Sc. Thesis, University of Porto, Faculty of Engineering, Portugal.

Raj, K. (2017). Inception and Residual CNN Architectures for Visual Object Recognition. *Int. J. Comput. Vis. Appl. 12*(4), 233–240.

Reddy, D. D., N., V. H. (2024). Smart Annotation and Anonymizer, *15th International Conference on Computing, Communication and Networking Technologies (ICCCNT)*, IIT Mandi, India.

Redmon, J., Divvala, S., Girshick, R., Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Ren, S., He, K., Girshick, R., Sun, J. (2015). Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks, *Advances in Neural Information Processing Systems (NeurIPS)*.

Rodriguez, J. G. (2023). Improving Object Detection with Faster R-CNN and Feature Pyramid Networks. *Journal of Computer Vision and Image Understanding*, *215*, 103–122.

Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Fei-Fei, L. (2015). ImageNet Large Scale Visual Recognition Challenge. *International Journal of Computer Vision (IJCV)*, *115*(3), 211–252.

Salimon, S. (2023). A Modular Deep Learning Framework Combining YOLOv11 and EfficientNet for Plant Disease Detection. *International Journal of Intelligent Systems and Applications in Engineering*, *11*(4), 355–366.

Settles, B. (2009). Active Learning Literature Survey*, University of Wisconsin-Madison*, Computer Sciences Technical Report 1648,

Singh, B., Verma, M. (2023). Comparative Analysis of YOLOv8 and Faster R-CNN for Real-Time Object Detection. *Journal of Computer Vision Research*, *11*(2), 55–63.

Steketee, T. (2024). Bölge Öneri Doğruluğunu Artırmak İçin Faster R-CNN ve Transformer Mimarilerinin Entegrasyonu. *Zeki Sistemler ve Bilgisayarla Görme Dergisi*, *9*(4), 210–224.

Ultralytics. (2025). *YOLOv8 Benchmarks on COCO Dataset*. https://github.com/ultralytics/ultralytics,

Voulodimos, A., Doulamis, N., Doulamis, A., Protopapadakis, E. (2018). Deep Learning for Computer Vision: A Brief Review. *Computers*, *8*(2), 1–16.

Wang, E. K., Damasevicius, R., Maskeliunas, R. (2022). A Survey on Image Data Annotation for Computer Vision Applications. *Journal of Imaging*, *8*(6), 1–26. DOI: https://doi.org/10.3390/jimaging8060155

Wang, Z., Li, J., Zhang, T. (2021). Salient Region Detection in Images Based on U-Net and Deep Learning. *Neural Computing and Applications*, *33*(12), 6785–6798.

Wu, Z., Shen, C., Van Den Hengel, A. (2015). Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification, *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*.

Yılmaz, E., Kaya, O., Demir, F. (2023). Gerçek Zamanlı Nesne Tespitinde YOLO, SSD ve EfficientDet Algoritmalarının Karşılaştırmalı Performans Analizi. *Yapay Zeka ve Bilgisayarla Görme Dergisi*, *10*(3), 145–158.

Zafar, M. A. (2022). Comparative Evaluation of Deep Learning Object Detectors for Real-Time Applications. *Journal of Artificial Intelligence and Data Science*, *8*(1), 45–60.

Zhao, W., Chen, Y., Zhang, L. (2023a). Class-Aware Learning for Imbalanced Multi-Label Classification. *IEEE Transactions on Neural Networks and Learning Systems*, *34*(9), 12345–12358.

Zhao, Z., Liu, X., Wang, J. (2023b). A Comprehensive Review of YOLO: From YOLOv1 to YOLO-v8 and Beyond. *arXiv preprint*.

Zhou, Y., Zhang, Y., Wang, X., Tang, Y. (2020). Semi-Automatic Annotation for Object Detection in Aerial Images. *Remote Sensing*, *12*(20), 1–14.

KİŞİSEL YAYIN VE ESERLER

Usta, Ş., Güneş, E., Deniz, Ü. İ., Yıldız, U., Küçük, K. ve Akbulut, O. (2025). Smart Data Annotation: Accelerating Data Labeling Processes through Deep Learning. *10. Uluslararası Bilgisayar Bilimleri ve Mühendisliği Konferansı (UBMK)*, İstanbul Teknik Üniversitesi, İstanbul, 17-18-19 Eylül 2025.

ÖZGEÇMİŞ

İlk ve orta öğrenimini Kılıçarslan İlköğretim Okulu, lise öğrenimini Tevfik Seno Arda Anadolu Lisesi'nde tamamlamıştır. 2015 yılında başladığı Atatürk Üniversitesi Mühendislik Fakültesi Elektrik Elektronik Mühendisliği Bölümü'nden 2020 yılında mezun oldu. 2022 yılında Kocaeli Üniversitesi Fen Bilimleri Enstitüsü Bilgisayar Mühendisliği Ana Bilim Dalı'nda Yüksek Lisans Programına başladı. 2025 yılında mezun olma durumundadır. 2021'den itibaren özel bir şirkette Otomasyon Yazılım Mühendisi olarak görev almaktadır.